

# **Entwicklung eines ML-Modells zur Qualitätsbewertung von Punktschweißverbindungen**

Xiaochuan Lu

**Diplomarbeit**

# **Entwicklung eines ML-Modells zur Qualitätsbewertung von Punktschweißverbindungen**

**Xiaochuan Lu**

Geboren am: 1. November 1994 in Shandong

Studiengang: Allgemeiner und konstruktiver Maschinenbau

Matrikelnummer: 4724130

## **Diplomarbeit**

zur Erlangung des akademischen Grades

## **Diplom-Ingenieur (Dipl.-Ing.)**

Betreuer

**Dipl.-Ing. Christian Mathiszik**

**Dipl.-Ing. Johannes Koal**

**Dipl.-Ing. Tomas Teren**

Betreuer Hochschullehrer

**Prof. Dr.-Ing. habil. U. Füssel**

Eingereicht am: 16. Februar 2021

# **Selbstständigkeitserklärung**

Hiermit versichere ich, dass ich die vorliegende Arbeit mit dem Titel *Entwicklung eines ML-Modells zur Qualitätsbewertung von Punktschweißverbindungen* selbstständig und ohne unzulässige Hilfe Dritter verfasst habe. Es wurden keine anderen als die in der Arbeit angegebenen Hilfsmittel und Quellen benutzt. Die wörtlichen und sinngemäß übernommenen Zitate habe ich als solche kenntlich gemacht. Es waren keine weiteren Personen an der geistigen Herstellung der vorliegenden Arbeit beteiligt. Mir ist bekannt, dass die Nichteinhaltung dieser Erklärung zum nachträglichen Entzug des Hochschulabschlusses führen kann.

Dresden, 16. Februar 2021

Xiaochuan Lu

# **Zusammenfassung**

In dieser Diplomarbeit wurden maschinelles Lernen zur Bewertung der Qualität bei Widerstandspunktschweißen (WPS) vorgestellt. Wie allgemein bekannt ist, dass das WPS sich in sehr kurzer Zeit mit einem Zusammenwirken der Schweißstrom und Elektrodenkraft erledigen lässt. Deswegen sind Bewertung und Überwachung der Qualität durch Überwachung der dynamischen Prozesse und gleichzeitig Durchführung einer Regelung für Parameter schwer zu schaffen. Aufgrund der umfangreichen verfügbaren Prozessgrößen und deren zeitlicher Verlauf während des Schweißprozesses lässt sich die Anwendung des maschinellen Lernens ermöglichen. Zu diesem Zweck wurden Messungen des Schweißstroms, der Schweißspannung, der Elektrodenkraft, der Elektrodenwegmessung während des Schweißens durchgeführt und aus diesen Prozessparametern abgeleitete Features wurden ebenfalls zur Qualitätsbewertung verwendet. Bei Verknüpfung der Eingänge (Features) und Ausgänge (Zustände) waren nicht alle Korrelation zwischen Eingänge und Ausgänge im Prinzip linearkorrelierend. Deshalb wurden die nichtlinearen Modelle (neuronale Netzwerke, Stützvektormaschine, Lernende Vektorquantisierung, baumbasierte Methode) anstatt den linearen Modellen im Gebrauch gemacht. Zur Untersuchung der Einfluss der Schweißparameter auf der Schweißpunktqualität wurden die Experimente in zwei Richtungen unterteilt. Die einen war bei nicht konstanter Elektrodenbedingung, die anderen war bei nicht konstantem Schweißstrom. Diese Ergebnisse deuten darauf hin, dass das maschinelle Lernen einer der gültigsten Methoden waren, eine Online-Qualitätsüberwachung für WPS durchzuführen.

# **Abstract**

In this thesis, machine learning was presented to evaluate the quality in resistance spot welding (RSW). As it is well known that RSW can be done in a very short time with an interaction of welding current and electrode force. Therefore, evaluation and monitoring of quality by monitoring dynamic processes and at the same time performing control for parameters are difficult to achieve. Due to the extensive available process variables and their time course during the welding process, the application of machine learning can be made possible. For this purpose, measurements of the welding current, the welding voltage, the electrode force, the electrode movement during welding were performed and features derived from these process parameters were also used for quality assessment. When relating the inputs (features) and outputs (targets), not all correlation between inputs and outputs were in principle linear correlating. Therefore, the nonlinear models (neural networks, support vector machine, learning vector quantization, tree-based method) were made in use instead of the linear models. To study the influence of welding parameters on spot weld quality, the experiments were divided into two directions. One was at non-constant electrode condition, the other was at non-constant welding current. These results indicate that machine learning was one of the most suitable methods to perform online quality monitoring for resistance spot welding.

# Inhaltsverzeichnis

<b>Zusammenfassung</b>	<b>IV</b>
<b>Abstract</b>	<b>V</b>
<b>Abbildungsverzeichnis</b>	<b>XIV</b>
<b>Tabellenverzeichnis</b>	<b>XVI</b>
<b>Algorithmenverzeichnis</b>	<b>XVII</b>
<b>Abkürzungsverzeichnis</b>	<b>XVIII</b>
<b>Symbolverzeichnis</b>	<b>XXIII</b>
<b>1 Einleitung und Motivation</b>	<b>1</b>
<b>2 Stand der Technik und Forschung</b>	<b>3</b>
2.1 Widerstandspunktschweißen . . . . .	3
2.2 Qualitätsprüfung von Punktschweißungen . . . . .	5
2.2.1 Zerstörende Prüfung . . . . .	6
2.2.2 Zerstörungsfreie Prüfung . . . . .	7
2.3 ML-Anwendung im Widerstandpunktschweißen . . . . .	9
<b>3 Versuchsdurchführung</b>	<b>11</b>
3.1 Versuchswerkstoffe . . . . .	11
3.2 Verwendete Anlagentechnik . . . . .	13
3.2.1 Versuchsstand . . . . .	13
3.2.2 Messmethoden . . . . .	14

3.2.3 Chromatisch konfokale Mikroskopie zur Oberflächentopographiemessung . . . . .	16
3.2.4 Metallographische Untersuchungen von Schweißverbindungen . . . . .	17
3.2.5 Torsionsprüfung . . . . .	18
3.3 Durchgeführte Messungen . . . . .	20
3.3.1 Elektrodenverschleißuntersuchung . . . . .	20
3.3.2 Verschiedene Stromstärken . . . . .	21
3.3.2.1 Stufenuntersuchung . . . . .	21
3.3.2.2 Spritzeruntersuchung . . . . .	23
<b>4 Versuchsergebnisse</b>	<b>25</b>
4.1 Elektrodenverschleißuntersuchung . . . . .	25
4.1.1 Punktdurchmesser . . . . .	25
4.1.2 Elektrodenopographie . . . . .	26
4.1.3 Metallographische Darstellung vom Querschliff der Punkte . . . . .	26
4.2 Verschiedene Stromstärken . . . . .	29
4.2.1 Stufenuntersuchung . . . . .	29
4.2.1.1 Punktdurchmesser und Brucharten . . . . .	29
4.2.1.2 Metallographische Darstellung vom Querschliff der Punkte	31
4.2.1.3 Torsionsprüfung . . . . .	31
4.2.2 Spritzeruntersuchung . . . . .	32
<b>5 Definitionen und Eigenschaften eines Algorithmus</b>	<b>34</b>
5.1 Algorithmen Design . . . . .	34
5.2 Vorverarbeitung . . . . .	37
5.2.1 Vorverarbeitung für Strom- und Spannungssignal . . . . .	38
5.2.2 Vorverarbeitung für Kraft- und Elektrodenhubsignal . . . . .	41
5.3 Einspeichern . . . . .	46
<b>6 Bestimmung der Qualitätspараметer</b>	<b>47</b>
6.1 Qualitätsparameter bei Elektrodenverschleißuntersuchung . . . . .	47
6.1.1 Aus der Schweißspannung und dem Schweißstrom gewonnene Parameter . . . . .	48
6.1.2 Aus der Kraft und dem Elektrodenhub gewonnene Parameter . . . . .	53
6.2 Qualitätsparameter bei verschiedenen Stromstärken . . . . .	57
6.2.1 Spritzer Diagnose . . . . .	57
6.3 Zusammenfassung der Qualitätsparameter . . . . .	59

<b>7 Experimentelle Testdaten</b>	<b>61</b>
7.1 Experimentelle Testdaten für Elektrodenverschleißuntersuchung . . . . .	62
7.1.1 Versuchsvorbereitung und Berechnung . . . . .	62
7.1.2 Versuchsplanung . . . . .	65
7.1.3 Experimentdurchführung und Ergebnisanalyse . . . . .	67
7.2 Experimentelle Testdaten für Stufenuntersuchung der verschiedenen Stromstärken . . . . .	71
7.2.1 Versuchsplanning . . . . .	72
7.2.2 Experimentdurchführung und Analyse der Ergebnisse . . . . .	73
<b>8 Modell des maschinellen Lernens</b>	<b>75</b>
8.1 Frühere Forschungen . . . . .	75
8.2 Modellierung neuronaler Netze für Elektrodenverschleißuntersuchung . . .	79
8.2.1 Unüberwachtes Pre-Training und Fine-Tuning . . . . .	82
8.2.1.1 Greedy Layerwise . . . . .	83
8.2.1.2 Tying Weights . . . . .	85
8.2.1.3 Ergebnisse . . . . .	86
8.3 ML-Modells für verschiedenen Stromstärken . . . . .	89
8.3.1 Klassifizierung der Schweißqualität bei Stufenuntersuchung . . . . .	89
8.3.1.1 Klassifizierung durch LVQ-Algorithmus . . . . .	90
8.3.1.2 Klassifizierung durch Baum-Algorithmus . . . . .	94
8.3.1.3 Klassifizierung durch SVM-Algorithmus . . . . .	95
8.3.1.4 Zusammenfassung . . . . .	97
8.3.2 Klassifizierung der Spritzeruntersuchung . . . . .	98
8.3.2.1 Spritzeruntersuchung bei MDK1 . . . . .	98
8.3.2.2 Spritzeruntersuchung bei MDK2 . . . . .	102
<b>9 Zusammenfassung und Ausblick</b>	<b>108</b>
<b>Literaturverzeichnis</b>	<b>111</b>
<b>A Graphischer Anhang</b>	<b>118</b>
A.1 Verschleiß- und Prüfblech . . . . .	118
A.2 Qualitätsparameter . . . . .	119
A.2.1 Qualitätsparameter bei Elektrodenverschleißuntersuchung . . . . .	119
A.2.2 Qualitätsparameter bei verschiedenen Stromstärken . . . . .	121
A.3 Klasse-Diagramm . . . . .	125
A.4 Random Forest . . . . .	128

A.5 Gewichtsmatrix . . . . .	129
A.5.1 Greedy Layerwise . . . . .	129
A.5.2 Tying Weights . . . . .	129
<b>B Tabellarischer Anhang</b>	<b>131</b>
<b>C Programmcodes</b>	<b>135</b>

# Abbildungsverzeichnis

2.1	Prozessschritte beim WPS . . . . .	4
2.2	Schematische Darstellung einer einschnittige Punktschweißverbindung . . . . .	4
2.3	Wärmebilanz beim Punktschweißen . . . . .	5
2.4	Widerstände und Temperaturverteilung beim WPS . . . . .	5
2.5	typische zerstörende Prüfverfahren . . . . .	6
2.6	Brucharten und ihre Vermessung beim WPS . . . . .	7
2.7	Drei Arten von Schweißverbindungen mit unterschiedlichen Versagensarten . . . . .	8
2.8	Funktionsprinzip nach der Impuls-Echo-Methode . . . . .	8
2.9	Vergleich zwischen zerstörungsfreier Remanenzmessung und zerstörend geprüftem Schweißpunkt . . . . .	9
2.10	Einstellbereich von Schweißstrom und Schweißzeit beim WPS . . . . .	9
2.11	Schematische Darstellung des WPS-Qualitätsbewertungssystems . . . . .	10
3.1	Versuchsstand zum WPS der Professur für Fügetechnik und Montage an der Technischen Universität Dresden . . . . .	14
3.2	Elektrodenkappenfräser . . . . .	15
3.3	TDMS-Dateistruktur . . . . .	16
3.4	Konfokales Messprinzip mit mechanischem Tiefescan . . . . .	17
3.5	Konfokales Messprinzip mit chromatischen Tiefescan . . . . .	17
3.6	Links: das konfokal chromatische Messsystem bei der Oberflächentopographiemessung einer Elektrodenkappe; Rechts: Elektrodenkontaktfläche einer CuCr1Zr-Elektrode . . . . .	18
3.7	Messgrößen am Querschliff . . . . .	19
3.8	Torsionsprüfung . . . . .	19
3.9	Tatsächliche Signale von Schweißstrom und Elektrodenkraft bei MDK1 .	22
3.10	Tatsächliche Signale von Schweißstrom und Elektrodenkraft bei MDK2 .	23

---

3.11 Links: Versuchsablauf des Stufenversuchs von MDK1; Rechts: Versuchsablauf des Stufenversuchs von MDK 2 . . . . .	24
4.1 Schweißpunktdurchmesser der Elektrodenverschleißuntersuchung . . . . .	25
4.2 Die gemessenen Linsendurchmesser und Elektrodeneindrucksdurchmesser	28
4.3 Die gemessenen Elektrodeneindrucktiefen . . . . .	29
4.4 Die Brucharten und Punktdurchmesser nach verschiedenen Stromstärken	30
4.5 Die klassifizierte Schweißqualität nach verschiedenen Stromstärken . . .	30
4.6 Torsionsmoment-Torsionswinkel-Diagramm für verschiedene Stromstärken	32
4.7 Die nach Beobachtung und Einschätzung gelabelten Bleche bei der Spritzeruntersuchung . . . . .	33
5.1 Die Struktur Top-down-Design zur Verarbeitung der Daten aus dem Datensatz . . . . .	35
5.2 Vorgehen bei ML-Verfahren . . . . .	36
5.3 Schematische Darstellung des Überblicks auf die Algorithmen . . . . .	36
5.4 Einzelne Technical Data Management Streaming (TDMS)-Datei Struktur eines Schweißpunkts . . . . .	37
5.5 links: Das rohe und effektive Stromsignal; Rechts: Das rohe und effektive Spannungssignal . . . . .	39
5.6 Analyse der optimierte Fensterbreite für einzelnes Stromsignal . . . . .	39
5.7 Ein Überblick der optimierte Fensterbreite . . . . .	40
5.8 Ein Arbeitsablauf der Algorithmen für Vorverarbeitung des Stromsignals	41
5.9 links: Das rohe und gefilterte Kraftsignal; Rechts: Das rohe und gefilterte Wegmessung . . . . .	42
5.10 Funktionsweise des Kalman-Filters . . . . .	44
5.11 Suche des optimierten Q Parameters . . . . .	45
5.12 Struktur vom neuen aufgebauten Datenbasis . . . . .	46
6.1 Links: ermittelter dynamischer Widerstand; Rechts: ermittelte Prozessleistung . . . . .	48
6.2 Skalierte dynamische Widerstände der ganzen Schweißpunkte . . . . .	49
6.3 ermittelte Leistungskurven für verschiedene Schweißqualitäten . . . . .	50
6.4 Gesamte Wärmemenge für alle Schweißpunkte bei MDK1 und Stufe 5 . .	51
6.5 Intensitätsdiagramm der partiellen Wärmemenge und Korrelationskoeffizient zwischen dem Punktdurchmesser und den den partiellen Wärmemenge bei MDK1 . . . . .	51

6.6	Vergleich der tatsächliche und theoretische Wärmemengenkurve . . . . .	52
6.7	Erwärmungsgeschwindigkeiten mit der Schweißpunktnummer . . . . .	53
6.8	obere Wegmessungen und Längenänderungen der Elektroden . . . . .	54
6.9	Veränderung der Elektrodenarbeitsfläche (Links) und Elektrodendruck (Rechts)	55
6.10	Veränderung der Elektrodeneindrucktiefen und die Extraktion der Features	56
6.11	Intensitätsdiagramm der Elektrodenkräfte . . . . .	56
6.12	starker Spritzer während des Schweißprozesses . . . . .	58
6.13	dynamische Widerstände der Schweißpunkte in dem Stromstufenversuch .	58
6.14	Signalverhalten beim Spritzer . . . . .	58
6.15	Elektrodenkräfte der Schweißpunkte in dem Stromstufenversuch . . . .	59
6.16	Elektrodenkräfte für verschiedene Schweißqualität . . . . .	59
7.1	konfokal-chromatische Oberflächenmessung beim P0400 . . . . .	62
7.2	Elektrodenarbeitsfläche und Längenänderung . . . . .	63
7.3	Theoretische Flächenwachstumsrate . . . . .	63
7.4	Elektodenlängenänderung und Auswirkungskoeffizient der Schnittgenauigkeit mit der Schweißpunktnummer . . . . .	65
7.5	Tausendstel Auswirkung der Bearbeitung für Elektrodenarbeitsflächen .	65
7.6	Flussdiagramm zu experimentellen Testdaten für Elektrodenverschleißuntersuchung . . . . .	66
7.7	1: Elektrodenfräsen; 2: gefräste und nicht gefräste Elektrodenkappe; 3: Schneiden durch Werkzeugmaschine; 4: Schweißen des einzelnen Blechs; 5: konfokal-chromatische Oberflächenmessung; 6: Torsionsprüfung . . . .	67
7.8	konfokale GUI und Parameter . . . . .	68
7.9	Ausgangszustände der Elektrodenkappen . . . . .	68
7.10	Der erste Schweißpunkt jeder Schweißstufe . . . . .	69
7.11	konfokal-chromatischen Oberflächemessungen der Elektrodenkappen . .	70
7.12	Nach konfokalen Messungen ermittelte Längenänderungen und entsprechende absolute Anteile der Arbeitsflächenänderungen von Elektrodenkap- pen . . . . .	70
7.13	Schweißpunktdurchmesser der Testbleche . . . . .	71
7.14	Ergebnisse der Torsionsprüfung für die Testdaten der Elektrodenverschlei- ßuntersuchung . . . . .	72
7.15	Flussdiagramm zu experimentellen Testdaten für verschiedene Stromstufen	73
7.16	Meißelprüfung für Testdaten mit verschiedenen Stromstärken . . . . .	74
7.17	Schweißen für Testdaten mit verschiedenen Stromstärken . . . . .	74

7.18 Schweißpunktdurchmesser und Schweißpunktqualität für Testdaten mit verschiedenen Stromstärken . . . . .	74
8.1 Die topologischen Strukturen des neuronalen BP-Netzwerks . . . . .	76
8.2 Architektur des neuronalen Netzwerks der lernenden Vektorquantisierung (LVQ) . . . . .	76
8.3 Positionseinfluss auf die Punktdurchmesser . . . . .	80
8.4 Labelverbreitung mit verschiedenen Klassifizierungskriterien . . . . .	82
8.5 Flussdiagramm mit der Vorgehensweise zur Validierung des Modells . . . . .	82
8.6 Layerwises unüberwachtes Pre-Training und überwachtes Fine-Tuning Strategie . . . . .	84
8.7 Tying-Weights unüberwachtes Pre-Training und überwachtes Fine-Tuning . . . . .	86
8.8 Performance von Autoencoder . . . . .	88
8.9 Performance des Fine-Tunings . . . . .	89
8.10 Erklärte Varianz als Funktion der Anzahl der Dimensionen . . . . .	90
8.11 Architektur des neuronalen Netzwerks der lernenden Vektorquantisierung (LVQ) . . . . .	91
8.12 Konfusionsmatrix auf Testdaten durch LVQ bei verschiedenen Stromstärken	93
8.13 LVQ Klassifizierung nach PCA . . . . .	94
8.14 Entscheidungsbaum Klassifizierung nach PCA . . . . .	95
8.15 Random-Forest-Klassifikator . . . . .	96
8.16 Entscheidungsbäume vom optimalen Random-Forest-Klassifikator . . . . .	96
8.17 SVM Klassifizierung nach PCA . . . . .	97
8.18 Herausfinden der Kriterien zur Klassifizierung der Spritzerstärke . . . . .	98
8.19 Erklärte Varianz als Funktion der Anzahl der Dimensionen für Spritzeruntersuchung . . . . .	99
8.20 Optimale Anzahl der Cluster . . . . .	99
8.21 Auswählen der Anzahl der Cluster mit Silhouette-Analyse bei KMeans-Clustering bei MDK1 . . . . .	100
8.22 Schlüsselfeature zum Clustering bei MDK1 . . . . .	101
8.23 Signalverläufe von jedem Cluster bei MDK1 . . . . .	101
8.24 Kriterien zur Klassifizierung der Spritzerstärke für MDK1 . . . . .	103
8.25 Vergleich der Abweichung und Silhouettenkoeffizienten zwischen signifikanten und Features und PCA . . . . .	104
8.26 Clusterschwerpunkt bei MDK2 . . . . .	104
8.27 Auswählen der Anzahl der Clusters mit Silhouette-Analyse bei KMeans-Clustering bei MDK2 . . . . .	104

8.28 Schlüsselfeature zum Clustering bei MDK2 . . . . .	105
8.29 Signalverläufe von jedem Cluster bei MDK2 . . . . .	106
8.30 Kriterien zur Klassifizierung der Spritzerstärke für MDK2 . . . . .	107
 A.1 Schematische Darstellung der Verschleiß- und Prüfbleche . . . . .	118
A.2 Von Wegmessung extrahierte Features . . . . .	119
A.3 Von Wärmemenge extrahierte Features . . . . .	119
A.4 Von Leistungskurve extrahierte Features . . . . .	120
A.5 Von Elektrodenkraft extrahierte Features . . . . .	120
A.6 Von dynamischem Widerstand extrahierte Features . . . . .	121
A.7 Intensitätsdiagramm der partiellen Wärmemenge und Korrelationskoeffizient zwischen dem Punkt durchmesser und den partiellen Wärmemenge bei MDK2 . . . . .	121
A.8 Von Wegmessung extrahierte Features . . . . .	122
A.9 Von Wärmemenge extrahierte Features . . . . .	122
A.10 Von Leistungskurve extrahierte Features . . . . .	123
A.11 Von Elektrodenkraft extrahierte Features . . . . .	123
A.12 Von dynamischem Widerstand extrahierte Features . . . . .	124
A.13 Klasse-Diagramm für effektive Werte und Extraktion der Features . . . . .	125
A.14 Klasse-Diagramm für Lesen der Daten . . . . .	126
A.15 Klasse-Diagramm für Einspeichern . . . . .	127
A.16 Entscheidungsbäume vom optimalen Random-Forest-Klassifikator . . . . .	128
A.17 Anpassung der Gewichte nach Fine-Tuning . . . . .	129
A.18 Anpassung der Gewichte nach Fine-Tuning . . . . .	130

# Tabellenverzeichnis

3.1	Materialdickenkombinationen . . . . .	12
3.2	Chemische Zusammensetzung von Blechen . . . . .	12
3.3	Mechanische Eigenschaften von Blechen . . . . .	12
3.4	Geometrie und Material der Elektrodenkappen . . . . .	13
3.5	Chemische Zusammensetzung von Elektrodenkappen . . . . .	13
3.6	Mechanische Eigenschaften von Elektrodenkappen . . . . .	13
3.7	Messgrößen und Gerätetechnik zur Datenerfassung für die Zerspan- und Schweißversuche . . . . .	15
3.8	Versuchsmatrix MDK1 . . . . .	20
3.9	Eigenschaften der Verschleiß- und Prüfbleche für die Elektrodenverschleißuntersuchung . . . . .	20
3.10	Schweißbedingungen für MDK1 . . . . .	21
3.11	Versuchsmatrix für MDK 2 . . . . .	22
3.12	Schweißbedingungen für MDK2 . . . . .	23
3.13	Schweißbedingungen für Spritzeruntersuchung . . . . .	24
4.1	Elektrodenoberflächen der Anode . . . . .	27
4.2	Elektrodenoberflächen der Kathode . . . . .	28
4.3	Querschliffe der Punkte bei MDK2 . . . . .	31
4.4	Bedeutungen der Label auf den Blechoberflächen . . . . .	33
6.1	zusammengefasste extrahierte Features . . . . .	60
7.1	Die zu schneidende Länge für Elektrodenkappen nach den gefitteten Kurven	67
8.1	Zusammenfassung von einigen früheren Forschungen auf der Grundlage künstlicher Intelligenz . . . . .	78

8.2	Parameter von gestapelten Autoencodern und Fine-Tuning . . . . .	85
8.3	Parameter von Tying-Weights-Autoencoder und Fine-Tuning . . . . .	86
8.4	Fine-Tuning Ergebnisse der Greedy-Layerwise-Methode . . . . .	87
8.5	Fine-Tuning Ergebnisse der Tying-Weights-Methode . . . . .	89
8.6	Unterschiedliche ML-Modelle zur Klassifizierung der Schweißpunktqualität	97
B.1	Querschliffe der Punkte bei MDK1 . . . . .	131
B.2	Ermittelte Elektrodenarbeitsflächen und Elektrodenlängenänderungen mittels konfokal-chromatischer Oberflächenmessung . . . . .	132
B.3	Verwendete Features für ML-Modell bei MDK1 . . . . .	133
B.4	Features zur Klassifikation der Schweißqualität . . . . .	133
B.5	Features zur Klassifikation der Spritzerstärke . . . . .	134

# **Algorithmenverzeichnis**

5.1	ID-Suche . . . . .	41
5.2	Suche der Tal-ID und Peak-ID . . . . .	42
5.3	Effektivwert mit EGM . . . . .	43
5.4	Kalman-Filter . . . . .	45
8.1	Verbreitung des Labels . . . . .	83

# **Abkürzungsverzeichnis**

BP	Back-Propagation
DNN	tiefe neuronale Netzwerke
DT	Entscheidungsbaum
DW	dynamischer Widerstand
EGM	Einseitiger gleitender Mittelwert
KNN	künstliche neuronale Netzwerke
LVQ	Lernende Vektorquantisierung
MDK	Materialdickenkombinationen
ML	maschinelles Lernen
MSE	Mittelwert des quadratischen Fehlers
PCA	Hauptkomponentenanalyse
RF	Random-Forst-Klassifikator
RSW	resistance spot welding
SNR	Signal-Rausch-Verhältnis
SVC	C-Stützvektor-Klassifikation
SVM	Stützvektormaschine
TDMS	Technical Data Management Streaming
WPS	Widerstandspunktschweißen

# Symbolverzeichnis

Formelzeichen	Einheit	Bezeichnung
$a$	mm	extrahierter Abstand von konfokaler Messung
$A_{80}$	%	Bruchdehnung
$A_{ab}$	mm <sup>2</sup>	Elektrodenarbeitsfläche
$B_r$	mT	Remanenzflussdichte
$d_1$	mm	Schweißpunkt durchmesser quer zum Prüfblech
$d_2$	mm	Schweißpunkt durchmesser längs zum Prüfblech
$d_n$	mm	Linsendurchmesser
$d_{w,min}$	mm	Mindestpunkt durchmesser
$d_{w,soll}$	mm	Soll-Durchmesser
$d_w$	mm	Punktdurchmesser
$d_{el}$	mm	Elektrodeneindruck durchmesser unten
$\Delta e_{max}$	mm	maximale Wegänderung

---

<b>Formelzeichen</b>	<b>Einheit</b>	<b>Bezeichnung</b>
$d_{eu}$	mm	Elektrodeneindruckdurchmesser oben
$\Delta I$	kA	Schweißstromschritt/Stromänderung beim Spritzer
$\Delta L_E$	mm	Elektrodenlängenänderung
$d_m$	mm	gemittelter Durchmesser der Elektrodenarbeitsfläche
$d_n$	mm	Linsendurchmesser
$\Delta P$	kW	Leistungsdifferenz zwischen dem Peak- und Wendepunkt
$\dot{Q}$	kJ/s	Erwärmungsgeschwindigkeit
$\Delta S$	mm	Wegdifferenz
$\Delta t$	ms	Zeitdifferenz zwischen dem Peak- und Wendepunkt
$d_x$	mm	Durchmesser in x-Achse
$dy$	-/mm	Abweichung/Durchmesser in y-Achse
$e_l$	mm	Elektrodeneindrucktiefe unten
$e_{pe}$	mm	Eindrucktiefe beim Prozessende
$e_{se}$	mm	Eindrucktiefe beim Schweißende
$e_u$	mm	Elektrodeneindrucktiefe oben
$F_0$	kN	Elektrodenkraft am Beginn der Schweißzeit
$F_E$	kN	Elektrodenkraft

---

---

<b>Formelzeichen</b>	<b>Einheit</b>	<b>Bezeichnung</b>
$F_s$	kN	Scherzugkraft
$F_{max}$	kN	maximale Elektrodenkraft
$F_{min}$	kN	minimale Elektrodenkraft beim bestimmten Zeitbereich
$H$	–	Entropie (Informationstheorie)
$H_E$	mm	Elektrodenhub
$I_S$	A	Schweißstrom
$I_{eff}$	kA	Effektivwert des Stromsignals
$I_{eff,V,i}$	kA	Effektivwert des Stromsignals beim Vergleichspunkt
$k$	–/mm	Kosten/Auswirkungskoeffizient der Schnittgenauigkeit
$K_k$	–	Kalman-Gain von $\mathbf{x}_k$
$L$	mm	Restgesamtblechdicke
$M_T$	Nm	Torsionsmoment
$P$	–	Fehlerkovarianz
$P_l$	mm	Linseneindringtiefe unten
$P_u$	mm	Linseneindringtiefe oben
$p_{ab}$	N/mm <sup>2</sup>	Elektodendruck
$P_k$	–	Fehlerkovarianz von $\mathbf{x}_k$

---

---

<b>Formelzeichen</b>	<b>Einheit</b>	<b>Bezeichnung</b>
$P_{max}$	kW	Peakwert von Leistung
$P_v$	kW/s	Gradient zwischen dem Peak- und Wendepunkt
$Q$	J/–	Wärmemenge/Prozessrauschkovarianz
$Q_{ges}$	kJ	gesamte Wärmemenge
$Q_{sig}$	J	signifikante partielle Wärmemenge
$R$	–/mΩ	Messrauschkovarianz/dynamisch widerstand
$R_{-10}$	mΩ	gemittelter dynamischer Widerstand von letzten 10%
$R_{10}$	mΩ	gemittelter dynamischer Widerstand von erstem 10%
$R_{1,\dots,n}$	Ω	elektrische Einzelwiderstände
$R_e$	N/mm <sup>2</sup>	Streckgrenze
$R_g$	Ω	Gesamtwiderstand
$R_m$	N/mm <sup>2</sup>	Zugfestigkeit
$R_{p0,2}$	Mpa	0,2%-Dehngrenze
$\rho$	mΩ · mm <sup>2</sup> /mm	spezifischer elektrischer Widerstand
$S_1$	kN/s	Elektrodenkraftanstiegsgradient
$S_2$	kN/s	Elektrodenkraftabstiegsgradient
$S_{k0}$	mm	Wegmessungsumme bei Vorhaltzeit

---

---

<b>Formelzeichen</b>	<b>Einheit</b>	<b>Bezeichnung</b>
$S_{ke}$	mm	Wegmessungsumme beim Prozessende
$S_{min}$	mm	minimale Wegmessungsumme
$S_{se}$	mm	Wegmessungsumme beim Schweißende
$t$	mm	Blechdicke
$t_D$	ms	Druckzeit
$t_N$	ms	Nachhaltzeit
$t_S$	s	Schweißzeit
$t_V$	ms	Vorhaltzeit
$U_{eff}$	V	Effektivwert des Spannungssignals
$\varphi_T$	°	Torsionswinkel
$W$	Ws	elektrische Arbeit

---

# 1 Einleitung und Motivation

Das WPS ist ein Fügeverfahren in der Blechverarbeitung, das sich nach wie vor großer Beliebtheit in dünnblechverarbeitenden Kraft- und Schienenfahrzeugbau, im Metallbau und in der Gerätetechnik erfreut. Gegenüber den anderen Schweißverfahren sind die Vorteile gute Energieeffizienz, geringer Bauteilverzug durch die Schweißwärme, hohe Produktivität, gute Automatisierbarkeit und erfolgt ohne den Einsatz von Zusatzwerkstoffen. Angesichts der Unsicherheit der Qualität der einzelnen Schweißpunkte ist es in der Industrie üblich, eine erhebliche Anzahl der Schweißpunkte hinzuzufügen, um Vertrauen in die strukturelle Integrität der Schweißbaugruppen zu gewinnen. In den letzten Jahren hat der weltweit Wettbewerb um verbesserte Produktivität und reduzierte nicht wertschöpfende Aktivität wie die Automobilhersteller gezwungen, diese redundanten Punktschweißung zu beseitigen. Um die Anzahl der Punktschweißung zu minimieren und dennoch wesentliche Eigenschaften wie Festigkeit zu erfüllen, muss die Schweißpunktqualität erreichen werden.

Deswegen ist es notwendig, die Methode zur Qualitätsbewertung zu entwickeln. Die Schweißprozessparameter spielen große Rolle für Qualitätsbewertung, aber die Probleme der Schweißprozessanalyse liegen in hohen Prozessdynamik. Das WPS wird kurzzeitig (z. B.  $600\text{ ms}$ ) durchgeführt, sodass für die Reaktion der Steuerung während des Schweißprozesses nur einige Hundertstelsekunden in Verfügung stehen. Ausschließlich der geringe Zeit zur Analyse stellt man sich darüber hinaus dem Problem des komplexen physikalischen Prozesses (mechanisch und thermoelektrisch physikalisches Feld) sowie der Ausrüstungs- und Materialabhängigkeit. Aus diesem Grund ist es schwierig, den ganzen Schweißprozess mathematisch zu modellieren oder ein System zur universellen Überwachung der Schweißpunktqualität auszuarbeiten.

Algorithmen für maschinelles Lernen (ML) haben sich in den letzten Jahren rasant entwickelt und sind in der industriellen Produktion weit verbreitet, besonders für Qualitätsüberwachung und Parameteroptimierung. Diese von den gefilterten und entrauschten Signale,

die durch Sensoren gemessen werden, extrahierten Features werden als Eingangsparameter mittels verschiedener ML-Modelle geeignete Ergebnisse für die Prozessüberwachung liefern.

Hauptziel der Diplomarbeit ist unter Hilfe der ML-Modelle zur Qualitätsbewertung beim WPS. Ausgehend vom aktuellen Stand der Technik sollten geeignete ML-Modelle entwickelt, getestet und validiert werden. Die ganzen Trainingsdaten werden in zwei Gruppen aufgeteilt. Die Daten aus der einen untersuchte die Auswirkung der Elektrodenbedingungen auf die Schweißpunktqualität. Die Besonderheit dafür ist, dass wegen den Tausende von Schweißpunkten aber kleiner davon Gelabelten das unüberwachte ML-Modell benutzt wurden. Die Daten aus der anderen untersuchte die Auswirkung des Schweißstromes auf die Schweißpunktqualität. Anschließend können die trainierten ML-Modelle an neuen Schweißpunkten überprüft werden, die genauso in oben genannten zwei Gruppen für verschiedene experimentelle Zwecke aufgeteilt.

## 2 Stand der Technik und Forschung

### 2.1 Widerstandspunktschweißen

Das WPS gehört zu den Press-Verbindungsschweißverfahren und wird dort den Widerstandspunktschweißprozessen zugeordnet [34]. Das erfolgt durch wassergekühlte Elektroden, die mit einer definierten Kraft auf die Bleche gepresst und von einem Schweißstrom durchflossen werden. Üblicherweise wird der Schweißstrom als  $50\text{ Hz}$  Wechselstrom oder über einen Mittelfrequenz-Inverter als Gleichstrom in das System eingebracht. Abbildung 2.1 zeigt die Prozessschritte bei einem WPS. Während der Vorhaltzeit  $t_V$  werden die Elektroden auf die Blechoberfläche bewegt, die Kraft baut sich über die Kraftanstiegszeit bis einstellte konstante Kraft  $F_E$  auf. Anschließend kommt es zur Schweißzeit  $t_S$ . Der Schweißstrom wird schnell auf  $I_S$  erreicht und bei der Anwendung einer Konstantstromregelung konstant gehalten, während an der Kontaktstelle zwischen beiden Blechen eine schmelzflüssige Zone entsteht und eine Schweißlinse erzeugt werden. In der Nachhaltzeit  $t_N$  bleiben die Elektroden geschlossen und kühlten Schweißlinse unter Druck ab. Die Abbildung 2.2 zeigt eine schematische Darstellung der Gestalt einer Punktschweißverbindung.

Aus der physikalischen Sicht gesehen ist, dass die Wärme unmittelbar an der Schweißstelle zwischen den Fügepartnern erzeugt wird (Kontaktwiderstand zwischen den Fügepartnern bei Überlappstößen). Die zwischen zwei Elektroden durch den Schweißstrom erzeugt Wärmemenge  $Q$  ist nach dem jouleschen Gesetz der zwischen den Elektroden umgesetzten elektrischen Arbeit  $W$  etwertig. Die elektrische Arbeit von  $1\text{ Ws}$  entspricht einer Wärmemenge von  $1\text{ J}$ . Die beim WPS erzeugte Wärmemenge ist somit:

$$Q = I_s^2 \cdot R_g \cdot t_s \quad (2.1)$$

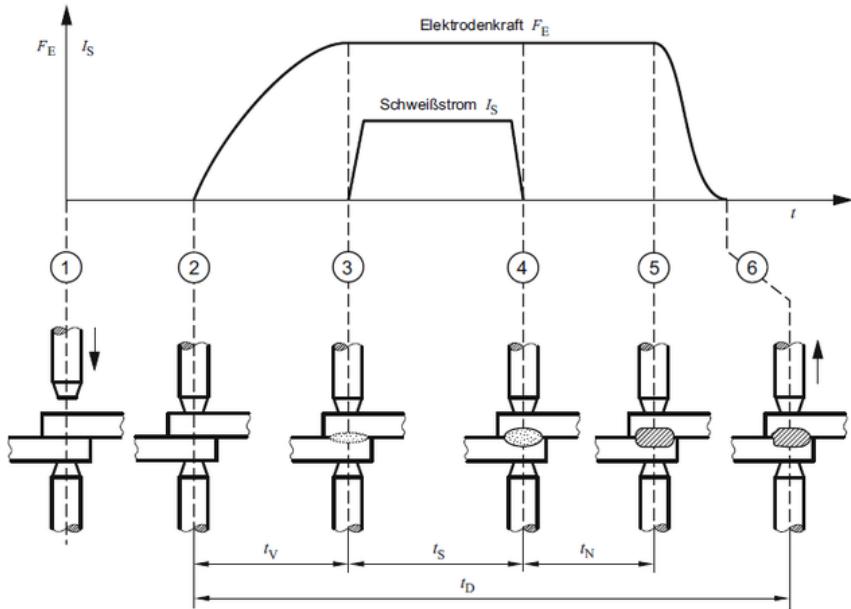


Abbildung 2.1: Prozessschritte beim WPS [33]

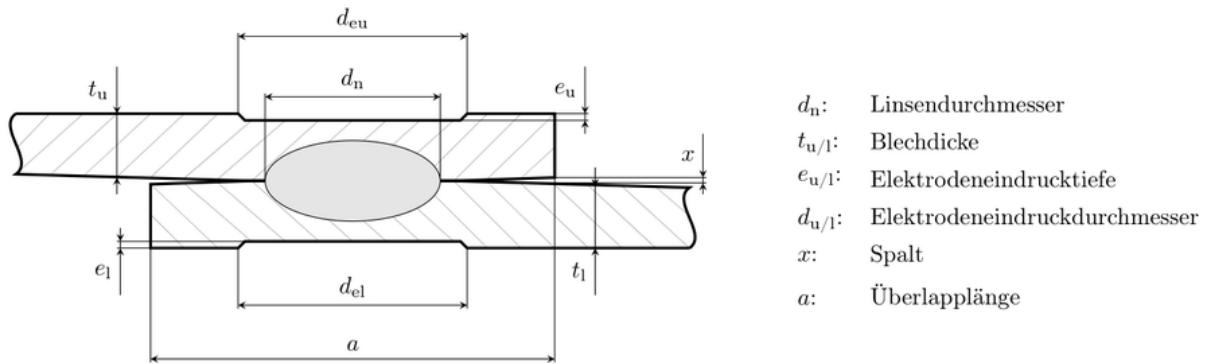


Abbildung 2.2: schematische Darstellung einer einschnittige Punktschweißverbindung [31]

Ist die Wärmeeinbringung hoch genug, bildet sich eine Schweißlinse aus. Die Wärmebilanz (Abbildung 2.3) zeigt jedoch, dass dafür nur die wirksame Wärmemenge genutzt wird. Die Verlustwärme ist unter anderem abhängig von der Schweißzeit, der Wärmeleitfähigkeit, der Blechdicke, der Geometrie und Kühlung der Elektroden sowie der Nachpresszeit. Der Gesamtwiderstand (Abbildung 2.4) setzt sich aus den Kontaktwiderständen an beiden Blechen und Kontaktstellen der Elektrode-Bleche und ihren Stoffwiderständen zusammen, aber teilt sich unterschiedliche Größe auf unterschiedlichen Zonen auf. Die Kontaktwiderstände haben den größten Einfluss auf die Wärmeeinbringen. Dabei ist  $R_4$  der größte Widerstand, sodass dort die meiste Wärme eingebracht wird und die Bildung der Schweißlinse erfolgt.

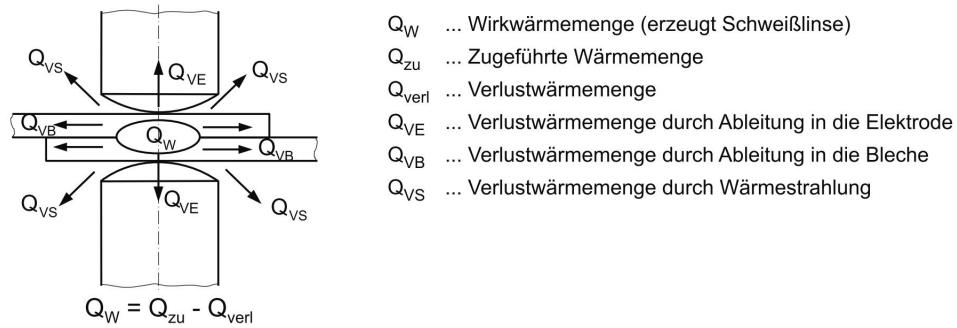


Abbildung 2.3: Wärmebilanz beim Punktschweißen [33]

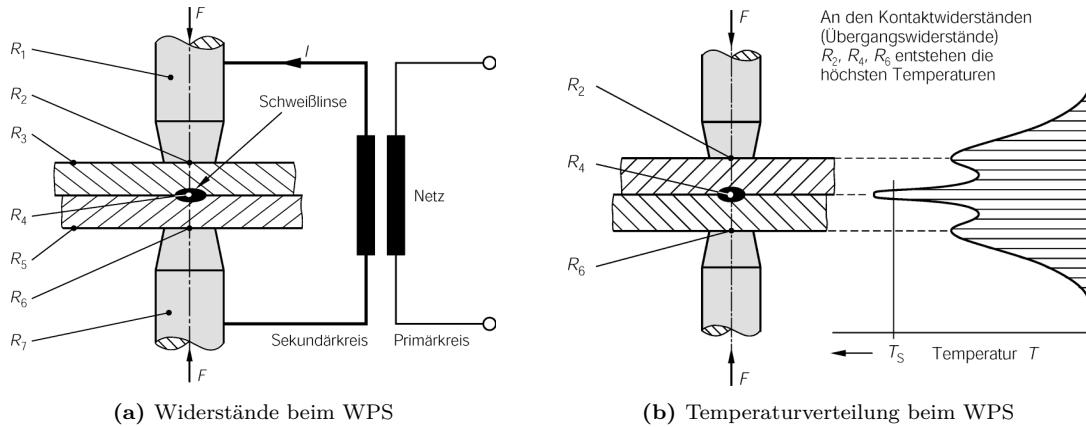


Abbildung 2.4: Widerstände und Temperaturverteilung beim WPS [20]

## 2.2 Qualitätsprüfung von Punktschweißungen

Die Schweißpunktqualität bezieht sich auf die Qualität von Schweißverbindungen, die mit dem WPS hergestellt wurden. Die durch WPS miteinander verbundene Bleche sollten erwartete Lebensdauer und Festigkeit erfüllen. Um eine erwartete Qualität zu erreichen, sollen die Anforderungen an Konstruktion, Werkstoffe, Fertigung und Personal als Zielgröße behandelt werden [16]. Einige wesentliche Merkmale zur Qualitätsbewertung sind z. B. Punktdurchmesser  $d_w$ , Linsendurchmesser  $d_n$ , Linseneindringtiefe  $P_u$ ,  $P_l$ , Scherzugkraft  $F_s$ . Um die Qualität von Schweißverbindung zu bestimmen, kann man die Prüfverfahren in zerstörender Prüfung (Abbildung 2.5) und zerstörungsfreier Prüfung unterteilen.

### 2.2.1 Zerstörende Prüfung

Bei den zerstörenden Prüfverfahren unterscheidet man für Punkt-, Buckel- und Rollennahtschweißverbindungen zwischen Werkstatt- und Laborprüfverfahren [17]. Schäl-, Abroll- und Meißelversuch sind die einfachsten Werkstattprüfverfahren zum Beurteilen der Eigenschaften von Punktschweißverbindungen. Ein andere typische zerstörende Prüfung ist Torsionsversuch. Das Ziel dieser Torsionsprüfung besteht in der Bestimmung des Schweißpunktdurchmessers und der Bruchart an gebrochenen Proben und in der Bewertung des Einflusses der verschiedenen Stahlwerkstoffe, der Schweißparameter und anderer Faktoren auf die Verformungsfähigkeit einer Widerstandspunktschweißverbindung [13]. Die Scherzugfestigkeit wird vielfach als Kennwert für die erreichten Festigkeitseigenschaften von Punktschweißverbindungen verwendet, deswegen werden der Scherzugversuch im Allgemeinen für Laborverfahren verwendet.

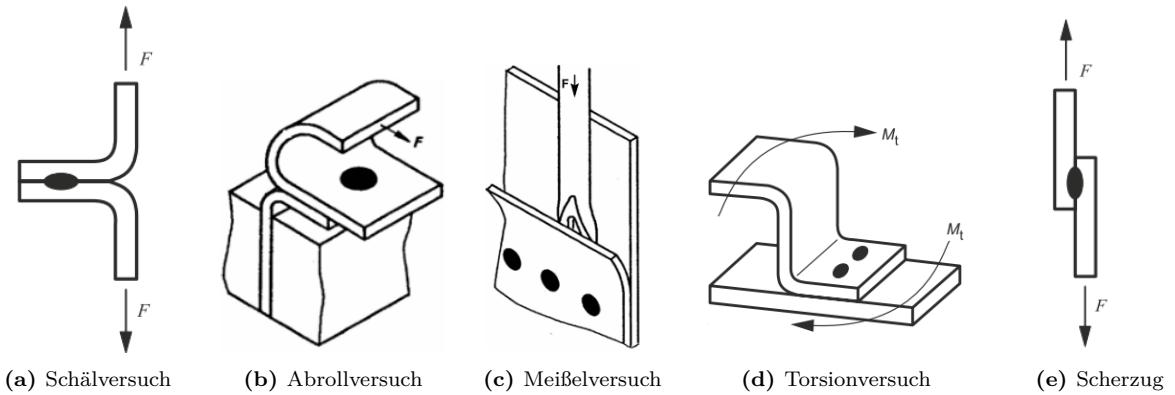
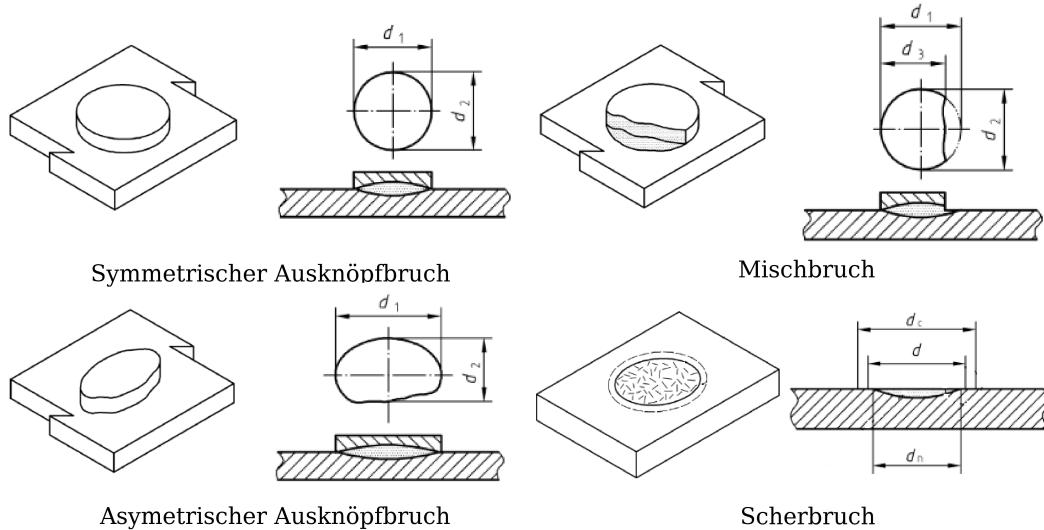


Abbildung 2.5: typische zerstörende Prüfverfahren [17, 34]

Zur Qualitätsbewertung nach der zerstörenden Prüfung sind die Brucharten und die Größe des Punktdurchmessers hilfreich. Die Abbildung 2.6 hat die Messungen des Punktdurchmessers für unterschiedliche Brucharten dargestellt. Grundsätzlich unterscheidet man zunächst drei Brucharten, den Ausknöpfbruch, den Scherbruch und den Mischbruch [17]. Im Vergleich zur guten Schweißpunktqualität, die wegen hoher Festigkeit von Verbindung häufig den Ausknöpfbruch oder Mischbruch in zerstörenden Prüfung anzeigt, zeigt die schlechte Qualität vom Punktschweißen infolge weniger zugeführten Energie häufig den Scherbruch in der zerstörenden Prüfung an. Darüber hinaus ist der Spritzer jedoch ein negatives Phänomen, das die Schweißpunktqualität in irgendeiner Weise ernsthaft beeinträchtigen kann. Das auftritt, wenn die dem Schweißbereich zugeführte Energie zu viel aufgegeben wird. Infolgedessen kommt es zum Ausbruch des geschmolzenen Materials. Der Spritzer ist aufgrund der geringeren Festigkeit und des schlechten Aussehens sowie

des hohen Elektrodenverschleißes zu vermeiden [38].



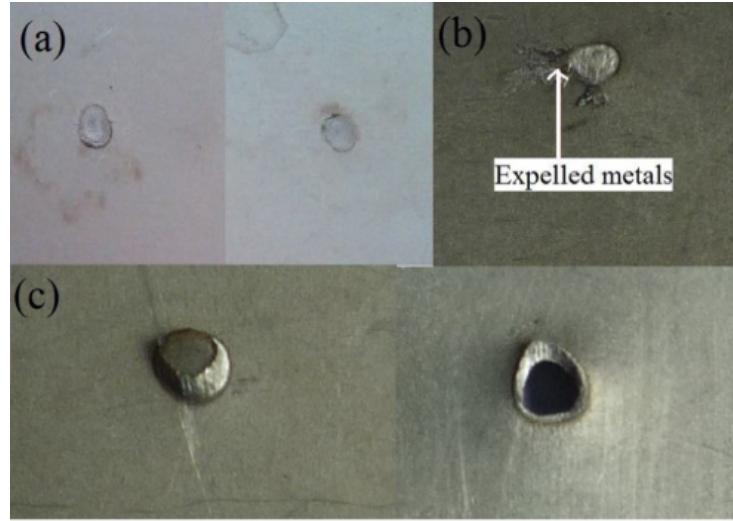
**Abbildung 2.6:** Brucharten und ihre Vermessung beim WPS nach [11]

Die Abbildung 2.7 zeigt drei typische Arten von Schweißverbindungen nach Durchführung des Scherzugtests für 0,4 mm dicke Titanlegierung TC2 [49]. Die Probe in Abbildung 2.7 a zeigt den Scherbruch, was anzeigt, dass es sich um eine zu kleine Schweißlinse handelt. Die Probe in Abbildung 2.7 c zeigt den Ausknöpfbruch. Offenbar ist die Versage in der Schweißzone. Unter der Auswirkung von Wärme eine groß genügende Schweißlinse aufgebaut wurde, was bedeutet, dass die Schweißverbindung eine gute Dehnbarkeit aufweist hat. Die ausgestoßenen geschmolzenen Metalle werden in Abbildung 2.7 b an dem Blech beobachtet.

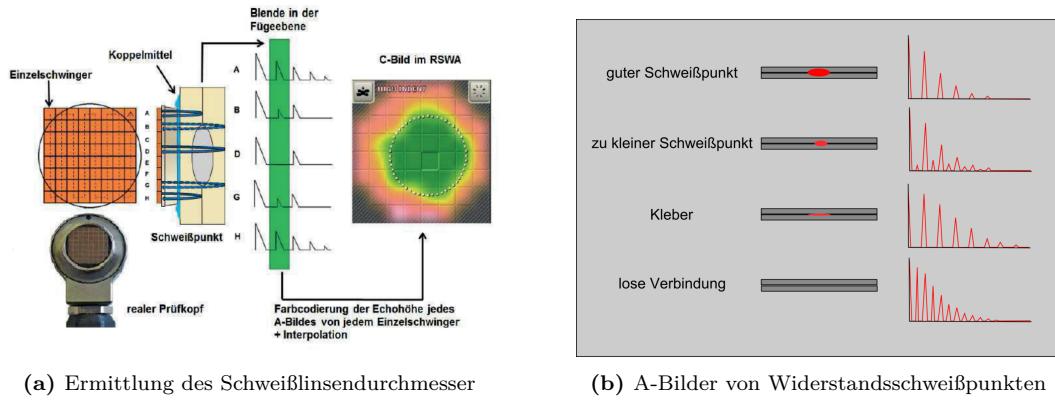
## 2.2.2 Zerstörungsfreie Prüfung

Die Ultraschallprüfung (Abbildung 2.8) [30, 43] ist ein akustisches Verfahren zum Auffinden von Materialfehlern mittels Ultraschall. Nach dem Impuls-Echo-Verfahren sendet der Prüfkopf einen kurzen Schallimpuls in das Material. Die Schallwelle breitet sich in der Probe aus und wird entweder an einer Fehlstelle oder an einer Probenrückwand bzw. Grenzfläche reflektiert. Das Echo wird vom selben Prüfkopf empfangen, von dem das Signal gesendet wurde. Dabei wird die Schweißlinsendurchmesser ermittelt und die Schweißpunktqualität aus der Form dieser Echofolge abgeleitet.

Es gibt daneben weitere Möglichkeiten zur zerstörungsfreien Prüfung, z. B. magnetisches



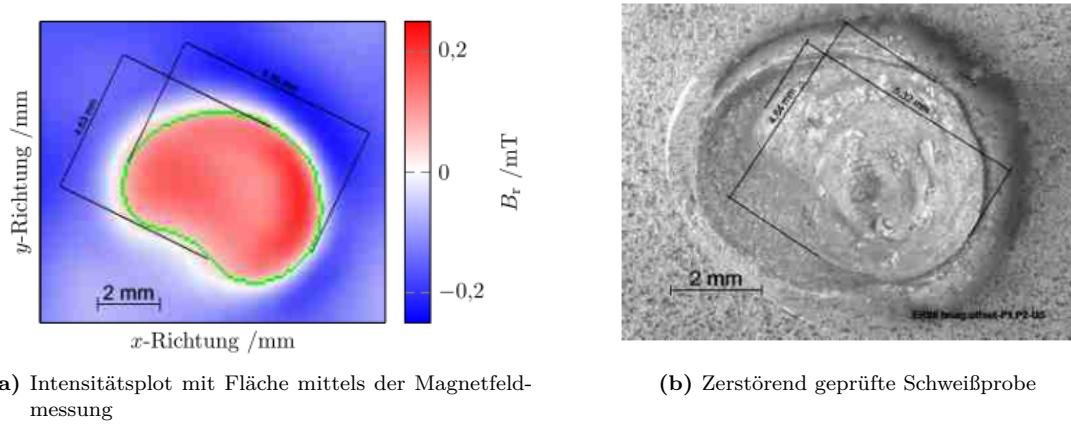
**Abbildung 2.7:** Drei Arten von Schweißverbindungen mit unterschiedlichen Versagensarten: (a) schlechte Schweißverbindung, (b) Spritzer, (c) gute Schweißverbindung [49]



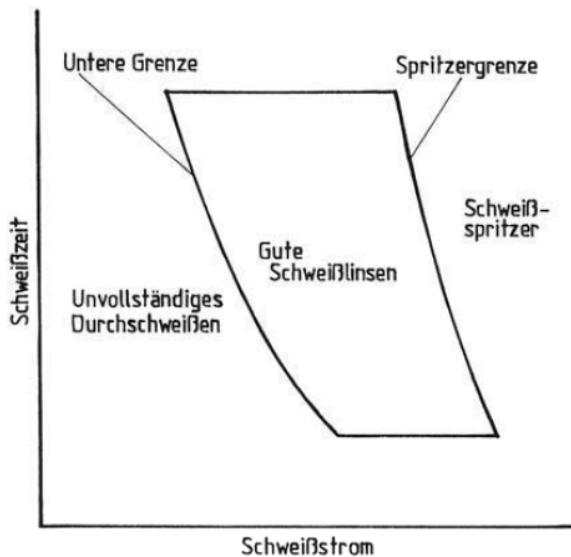
**Abbildung 2.8:** Funktionsprinzip nach der Impuls-Echo-Methode [18, 44]

Prüfverfahren (Abbildung 2.9) [32], das durch Analyse der Remanenzflussdichte  $B_r$ , die mittels Magnetfeldsensoren gemessen wird, den Linsendurchmesser ermittelt kann.

Parameterüberwachung bzw. -analyse, die beispielsweise durch Analyse der Features der Schweißstrom, Elektrodenkraft und Schweißzeit, die zahlreiche Autoren als Approximationen einen Raum mit drei Achsen anführen, eine unscharfe Aussage der Qualität realisieren. Für die häufigsten Schweißarbeiten stehen die Abbildung 2.10 mit empfohlenen Schweißparametern in zwei Parametern zur Verfügung, die auf empirischen Erfahrungswerten basieren, aber bei einer genaueren Analyse auch ein Raum mit mehreren zehn Parametern möglich wäre.



**Abbildung 2.9:** Vergleich zwischen zerstörungsfreier Remanenzmessung und zerstörend geprüftem Schweißpunkt [32]

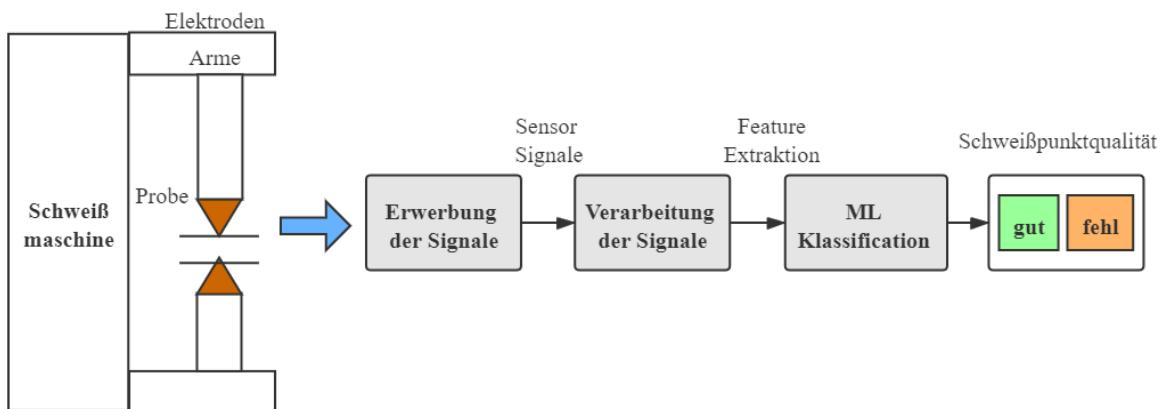


**Abbildung 2.10:** Einstellbereich von Schweißstrom und Schweißzeit beim WPS [34]

## 2.3 ML-Anwendung im Widerstandpunktschweißen

Eine Vielzahl verfügbarer zerstörender Prüfverfahren ist nützlich, um die Festigkeit der Schweißverbindung festzustellen, und kann wertvolle Informationen über die Schweißpunktqualität und die Angemessenheit des ausgewählten Parameter liefern. Solche herkömmlichen Verfahren können jedoch nur die Qualität spezifischer Punktproben sicherstellen und weisen Einschränkungen im weit verbreiteten Fließbandsystem auf. Darüber hinaus machen die Produktverschwendungen und die Arbeitskosten, die bei der Durchführung von solchen Tests anfallen, diesen Ansatz andererseits unattraktiv. Zwar wurden mehrere

zerstörungsfreie Prüfverfahren untersucht, bei denen die Qualität der Schweißpunkte mit Ultraschallwellen oder magnetisches Feld untersucht wurden. Die Anwendung der zerstörungsfreien Prüfung bei der Online-Qualitätsprüfung verursacht jedoch viele Probleme hinsichtlich Kosten und Ausstattung. Diese Anforderung hat zu einer aktiven Forschung nach einem Qualitätsbewertungssystem (Abbildung 2.11) für WPS geführt, das die zerstörungsfreie Prüfung wirksam ergänzen kann. Mit der Entwicklung der Algorithmen von ML hat schon immer mehr zur Qualitätsbewertung oder Parameteroptimierung in vielen Produktionsbereichen einschließlich WPS angewendet. Bei diesen Forschungen [1, 3, 4, 19, 22, 28, 30, 38, 49] können neuronales Netz, Lernende Vektorquantisierung (LVQ) und baumbasierte Methoden der Anforderung vom Qualitätsbewertungssystems gut anpassen. Im Vergleich zu den zerstörenden und zerstörungsfreien Prüfmethoden bieten diese Ansätze eine wirtschaftlichere und flexiblere Fähigkeit, insbesondere in Kombination mit effizienten Modellierungstechniken.



**Abbildung 2.11:** Schematische Darstellung des WPS-Qualitätsbewertungssystems

Jedoch hat die Analyse der Daten aus Sensoren gezeigt, dass es schwierig ist, repräsentative Merkmale aller Prozessparameter aus begrenzten Informationen zu extrahieren. Das bedeutet, dass die Messungen das Prozessverhalten unter den verschiedenen Bedingungen widerspiegeln müssen, und die gemessenen Variablen müssen eine Unterscheidung zwischen bestimmten Zuständen des Prozesses ermöglichen.

# **3 Versuchsdurchführung**

Die Schweißverfahren wurden sorgfältig ausgewählt, so dass das in der Praxis angewendet werden konnte und leicht zu überprüfen und zu verstehen war. Hierbei wurden die Bleche unterschiedlicher Materialien und Dicken verwendet. Außerdem wurden die ganzen Schweißparameter und Elektrodenzustand unter der Überwachung verändert. Der Zweck war Untersuchung der Einfluss der Elektrodenzustände und des Schweißstroms auf die Schweißpunktqualität. Die Analyse des vom Elektrodenverschleiß ausgehenden Einflusses wurden Tausende Schweißungen durchgeführt. Die Analyse des vom veränderten Schweißstrom ausgehenden Einflusses wurden den Elektrodenverschleiß aufgrund der wenigen durchgeführten Schweißungen nicht berücksichtigt. Alle der verwendeten Messdaten und der programmierten Prozessüberwachungssystems wurden unter der Hilfe von Sensoren und Labviewprogramme in Versuchsstand zum WPS der Professur für Fügetechnik und Montage an der Technischen Universität Dresden erfolgt. Die meisten experimentellen Daten stammen aus diesem Schlussbericht [31].

## **3.1 Versuchswerkstoffe**

Bei den Versuchen wurden folgende Bleche verwendet (Tabelle 3.1):

- Für Materialdickenkombinationen (MDK) 1 wurden das verzinkte Stahlblech HX340LAD+Z100 nach DIN EN 10346, Dicke  $t = 2,0\text{ mm}$  verwendet;
- Für MDK2 wurden das verzinkte Stahlblech HX340LAD+Z100, aber Dicke  $t = 3,0\text{ mm}$  und das elektrolytisch verzinkte Stahlblech DC04+ZE75/75 nach DIN EN 10152, Dicke  $t = 0,65\text{ mm}$  verwendet.

Die chemische Zusammensetzung der verwendeten Blechen kann von der Tabelle 3.2 ent-

**Tabelle 3.1:** Materialdickenkombinationen

<b>Bezeichnung der MDK</b>	<b>Oberes Blech</b>	<b>Unteres Blech</b>
MDK1	HX340LAD+Z100 $t = 2,0 \text{ mm}$	HX340LAD+Z100 $t = 2,0 \text{ mm}$
MDK2	DC04+ZE75/75 $t = 0,65 \text{ mm}$	HX340LAD+Z100 $t = 3,0 \text{ mm}$

nommen werden.

**Tabelle 3.2:** Chemische Zusammensetzung von Blechen

<b>Bezeichnung</b>			<b>Chemische Zusammensetzung</b>								
Name	Werkstoff-Nr.	Überzug	C max	P max	S max	Mn max	Ti max	Si max	Al max	Nb max	
HX340LAD	1.0933	Z	0,12	0,03	0,025	1,4	0,15	0,5	0,015	0,1	
DC04	1.0338	ZE	0,08	0,03	0,03	0,4	-	-	-	-	

In Tabelle 3.3 sind die entsprechenden physikalischen Eigenschaften zur Verfügung.

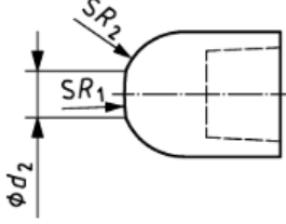
**Tabelle 3.3:** Mechanische Eigenschaften von Blechen

<b>Bezeichnung</b>			<b>Mechanische Eigenschaften</b>		
Name	Werkstoff-Nr.	Überzug	$R_e$ max	$R_m$ [N/mm <sup>2</sup> ]	$A_{80}$ min
HX340LAD	1.0933	Z	420	410 - 510	21
DC04	1.0338	ZE	220	270 - 350	37

Für MDK1 und MDK2 wurden die selben Elektrodenkappen nach DIN EN ISO 5821 in Gebrauch gemacht. Die Informationen der Geometrie und Material von Elektrodenkappen wurden in Tabelle 3.4 gezeigt. In Tabelle 3.5 und Tabelle 3.6 sind die chemische Zusammensetzung nach DIN EN 13388 und physikalische Eigenschaften nach DIN EN 12163 zu benutzen.

**Tabelle 3.4:** Geometrie und Material der Elektrodenkappen

Type	Material	Zustand	Geometrie [mm]		
			$d_2$	$R_1$	$R_2$
F1	CuCr1Zr	startgefräst	6	40	8

**Tabelle 3.5:** Chemische Zusammensetzung von Elektrodenkappen

Bezeichnung		Chemische Zusammensetzung				
Name	Werkstoff-Nr.	Cr [%] max	Zr [%] max	Fe [%] max	Si [%] max	Cu [%] max
CuCr1Zr	2.1293	1,20	0,30	0,08	0,10	Rest

**Tabelle 3.6:** Mechanische Eigenschaften von Elektrodenkappen

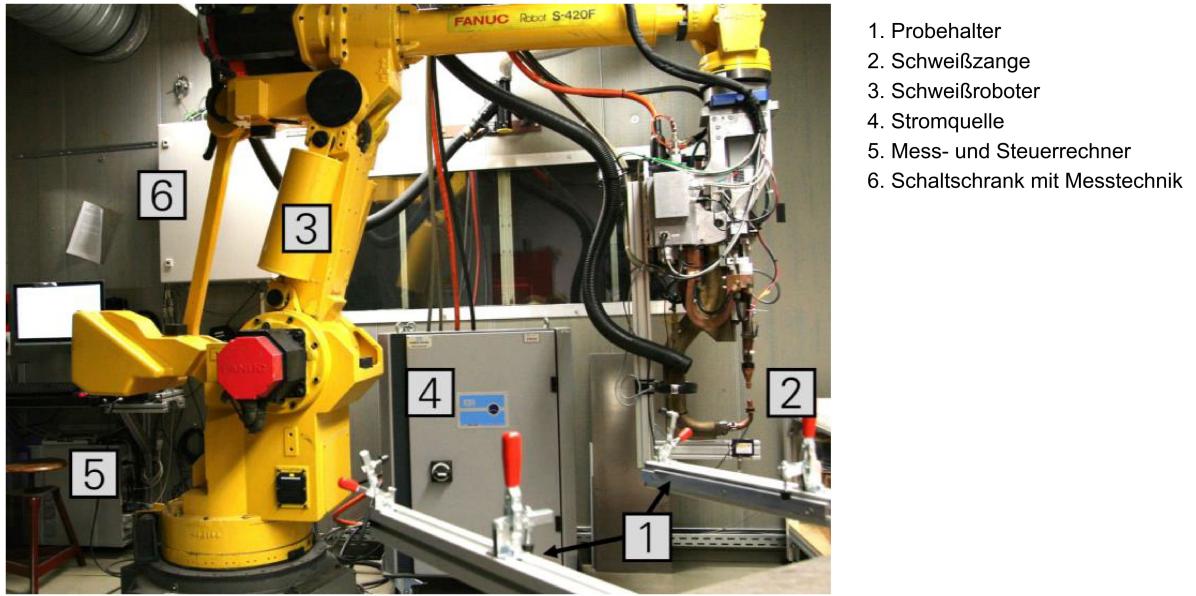
Bezeichnung		Mechanische Eigenschaften		
Name	Werkstoff-Nr.	$R_{p0,2}$ [N/mm <sup>2</sup> ] min	$R_m$ [N/mm <sup>2</sup> ] min	$A_{80}$ [%] min
CuCr1Zr	2.1293	420	470	8

## 3.2 Verwendete Anlagentechnik

### 3.2.1 Versuchsstand

Für Untersuchung der Einfluss des Elektrodenverschleißes und der Einfluss des Schweißstroms auf Schweißpunktqualität wurden der Versuchsstand an der Technischen Universität Dresden, Institut für Fertigungstechnik, Professur für Fügetechnik und Montage eingesetzt (Abbildung 3.1). Die Kenndaten des Versuchstands sind in [31] zusammengefasst.

Vor der Durchführung von WPS wurden die Elektrodenkappen gefräst. Einerseits hat



**Abbildung 3.1:** Versuchsstand zum WPS der Professur für Fügetechnik und Montage an der Technischen Universität Dresden [31]

die Elektrodenkappe nach dem Fräsen die Lebensdauer, die Schweißpunktzahl und die Qualität des Schweißens erheblich verbessert, andererseits kann die Elektrode nach dem Fräsen die Arbeitsdurchmesser der Elektrodenkappe in den erforderlichen Zustand erreichen. Die Kenndaten des eingesetzten Elektrodenkappenfräser der Firma Bräuer Systemtechnik GmbH (Abbildung 3.2) sind in [31] zusammengefasst. Außerdem beeinflussen sowohl die Elektrodenkraft als auch die Schnittgeschwindigkeit die Schnittergebnisse, die Versuchsmatrix und Ergebnisse der Untersuchung lassen sich in [31] erfassen.

### 3.2.2 Messmethoden

Im Bezug auf die Erfassung von Schweißparameter während des Schweißens und Zerspannens kam eine Menge Sensoren zur Anwendung. In einem Schweißen wurden die folgenden Messgrößen gemessen, einige davon um das Schweißprozess und andere davon um den Elektrodenfräsen geht. Jede Messgröße hatte mit einer Messfrequenz von  $1e^5 \text{ Hz}$  einen Kanal besetzt. Die Vorrichtung G0S-1034-4 der Goldammer GmbH zur Datenerfassung waren an die folgenden Sensoren (Tabelle 3.7) angeschlossen.

Die gemessenen Signale wurden bereits im Computer im Format .tdms gespeichert. Das Technical Data Management-Dateiformat (TDM) ist eine durch NI entwickelte Lösung anstatt der traditionellen Ansätze für Speichern der Messdaten. Nicht nur die Messdaten

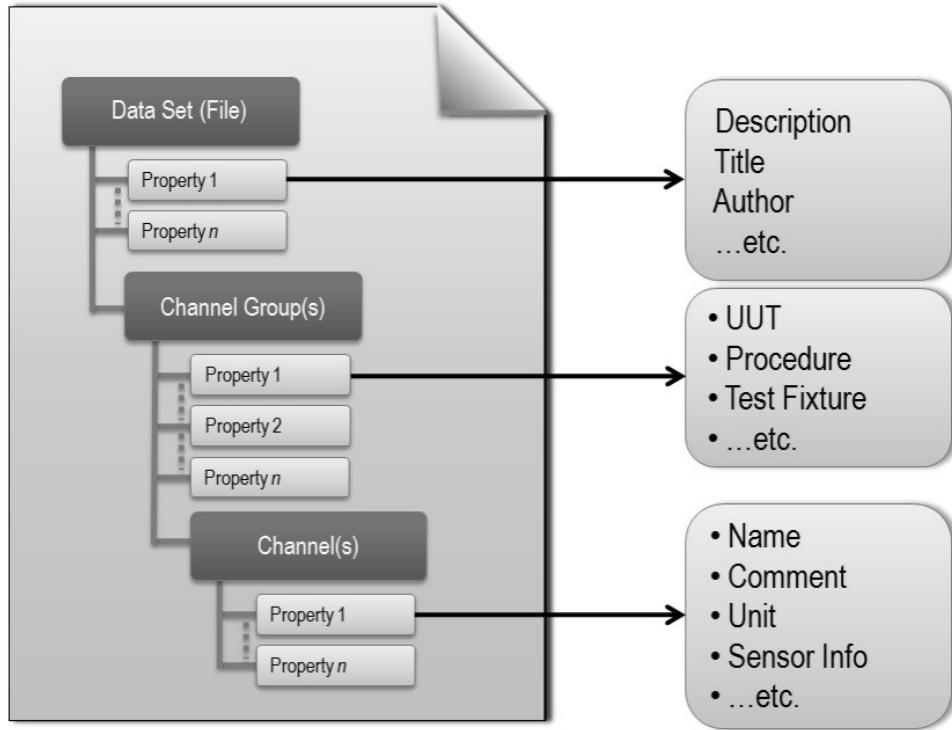


**Abbildung 3.2:** Elektrodenkappenfräser

**Tabelle 3.7:** Messgrößen und Gerätetechnik zur Datenerfassung für die Zerspan- und Schweißversuche

Messgrößen	Sensor	Versuchstyp
Drehzahl	Hall-Sensor A1324 Allegro Systems	Zerspannversuche
Schweißspannung	Prozesssensor P 100 K, HKS Prozesstechnik GmbH	Schweißversuche
Elektrodenkraft	Ladungsverstärker ICAM Type 5073, Kistler Instrumente AG	Zerspanversuche Schweißversuche
Schweißstrom	Prozesssensor P 100 K, HKS Prozesstechnik GmbH	Schweißversuche
Wegmessung Anode/Kathode	Wegmessensensoren OADM 20U2460/S14C, Baumer Electric AG	Zerspanversuche Schweißversuche

auch die beschreibende Zusatzinformationen werden gespeichert. Die wichtigste Eigenschaft des internen Formats der TDMS-Dateistruktur ist seine hierarchische Organisation. Das TDMS-Datenformat ist anhand dreier Hierarchieebenen strukturiert (Abbildung 3.3): Datei, Gruppe und Kanal. Aufgrund dieser Kanalgruppierung kann man entscheiden, wie man die Daten verständlicher organisieren. Diese hierarchische organisierte Dateistruktur lässt die Datensätze schnell extrahieren.

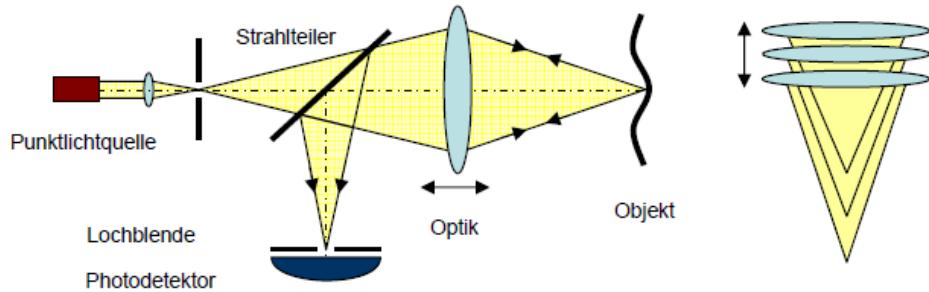


**Abbildung 3.3:** Jede TDMS-Datei umfasst Zusatzeigenschaften zu den Datei-, Gruppen- und Kanalebenen [36]

### 3.2.3 Chromatisch konfokale Mikroskopie zur Oberflächentopographiemessung

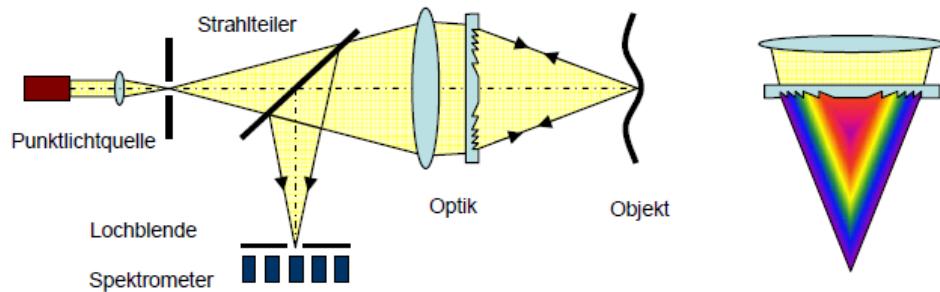
Zur Vermessung von technische Oberfläche hat sich die konfokale Messtechnik als ein zuverlässiges Verfahren erwiesen. In der Vergangenheit wurden konfokale Abstandssensoren meistens als Punktsensoren implementiert. Zu diesem Zweck wird eine Punktlichtquelle und eine zu vermessende Oberfläche abgebildet. Der Fokusfleck auf der Oberfläche wird zurück reflektiert und durch eine Lochblende auf einen Detektor abgebildet. Wenn sich die Oberfläche in der Fokusebenen befindet (Abbildung 3.4), handelt es sich bei der Punktlichtquelle um scharfe Bilder auf dem Detektor, was bedeutet, dass auf dem Detektor eine hohe Intensität gemessen wird. Befindet sich die Fläche außerhalb des Fokus, ist die Abbildung der Lichtquelle sowohl auf der Oberfläche als auch auf dem Detektor unscharf und die detektierte Intensität ist geringer. Eine Abstandsmessung mit einem konfokalen Sensor erfolgt deswegen über einen Tiefenscan [29].

Einen speziellen Anwendungsfall der konfokalen Mikroskopie stellt die Verwendung eines konfokal-chromatischen Sensors dar. Das Messprinzip des chromatisch konfokalen Mikro-



**Abbildung 3.4:** Konfokales Messprinzip mit mechanischem Tiefenscan [29]

skopie basiert auf einer Kodierung des Objektabstandes durch die Wellenlängen, d. h. der Abstand wird im Messbereich chromatisch kodiert. Den Messaufbau eines konfokalen chromatischen Systems zeigt Abbildung 3.5. Die sich im Fokus befindliche Wellenlänge wird von der Oberfläche reflektiert, durch den Strahltieler abgelenkt und trifft hinter einer Lochblende auf ein Spektrometer. Durch die Blende gelangt fast ausschließlich Licht aus dem fokussierten Wellenlängenbereich auf den Detektor. Aus dem spektralen Intensitätsmaximum des reflektierten Signals lässt sich dann über eine Kalibrierung die Distanz zur Oberfläche ermitteln [29].

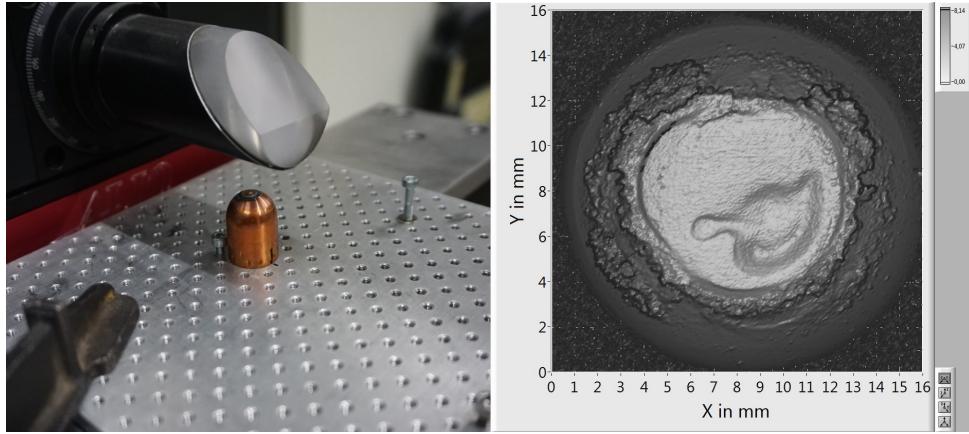


**Abbildung 3.5:** Konfokales Messprinzip mit chromatischen Tiefenscan [29]

Die Erfassung der Oberflächentopographien der Elektrodenkappen erfolgte mit dem chromatisch-konfokalen Präzisionsgerät CHRocodile E der Firma Precitec (Abbildung 3.6). Der verwendete Messkopf trägt die Bezeichnung „PVPortable Alio“ mit Seriennummer 0460-B.0000/03-03.

### 3.2.4 Metallographische Untersuchungen von Schweißverbindungen

Die Prüfbleche wurden mit dem Bühler Isomet 4000 Präzisionsnasstrennanlage so getrennt, dass die Schnittebene 0,5 mm von der Mitte des Elektrodeneindrucks lag, anschlie-



**Abbildung 3.6:** Links: das konfokal chromatische Messsystem bei der Oberflächentopographiemessung einer Elektrodenkappe; Rechts: Elektrodenkontaktefläche einer CuCr1Zr-Elektrode

ßend wurden die Proben eingebettet, geschliffen, poliert und mit der 5% Nital-Lösung geätzt [31]. Die lichtmikroskopischen Aufnahmen erfolgten mit den Lichtmikroskopen Leica MZ APO, Wild und Carl Zeiss Smartzoom, damit die wichtigen Kenngrößen der Schweißverbindungen, die in der Abbildung 3.7 markiert ist, mit der AxioVision 4.8.2.0 Software ausgemessen wurden.

### 3.2.5 Torsionsprüfung

Zwei Bleche werden durch einen Schweißpunkt verbunden. Das obere Blech wird mit einer beweglichen Aufnahme gegen das in einer Vorrichtung fest eingespannte untere Blech gleichmäßig verdreht (Abbildung 3.8 a). Danach können die Punktdurchmesser und die Brucharten sicher bestimmt werden. Für Laborversuche wurden das Torsionsmoment  $M_T$  und die Torsionswinkel  $\varphi_T$  während der Beanspruchung auf einem geeigneten Registriergerät aufgezeichnet. Die Abbildung 3.8 b zeigt die durch Sensor erfassten Messgrößen beim Torsionsversuch am Torsionsmoment-Torsionswinkel-Diagramm. Der Schweißpunktdurchmesser und die Bruchart der Punktschweißverbindungen sind an den gebrochenen Proben nach DIN EN ISO 14329 [11] zu bestimmen.

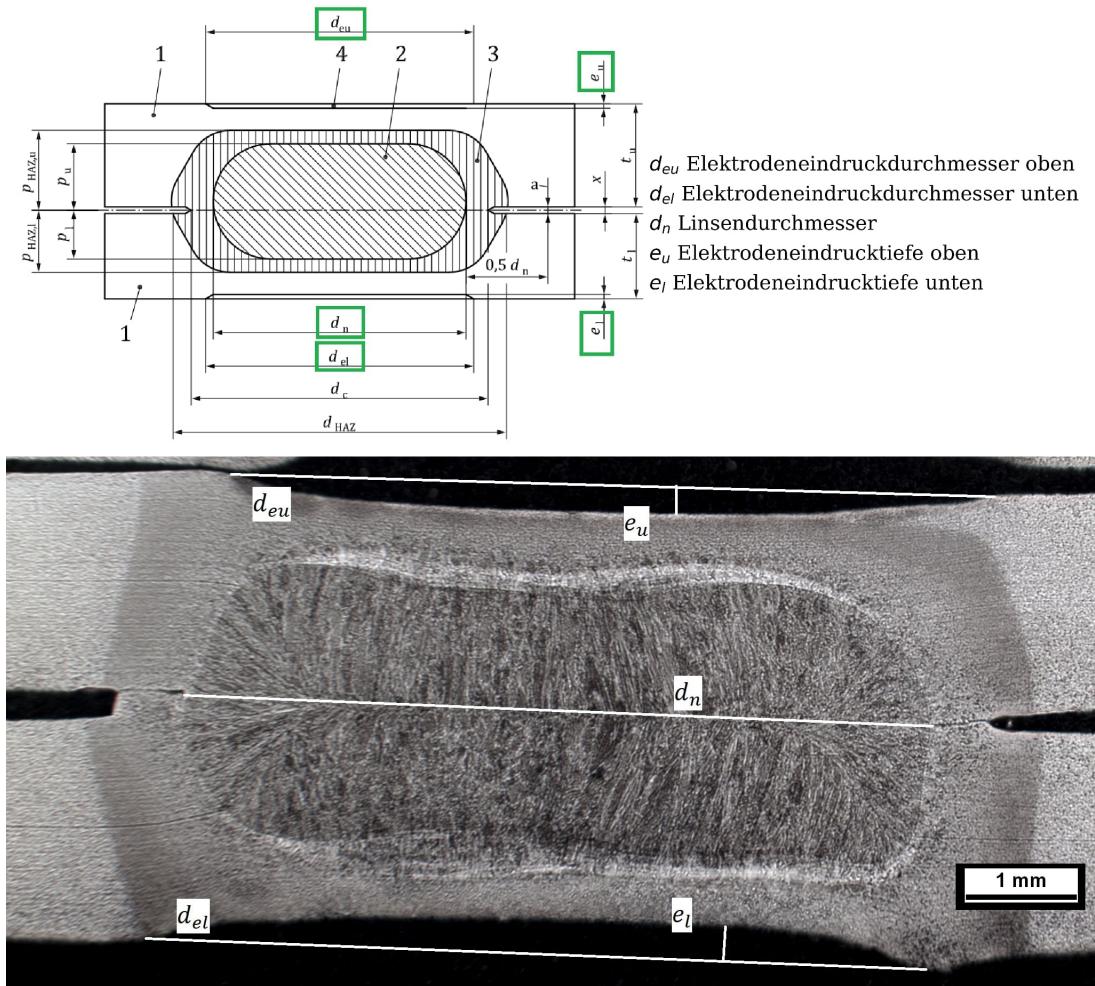
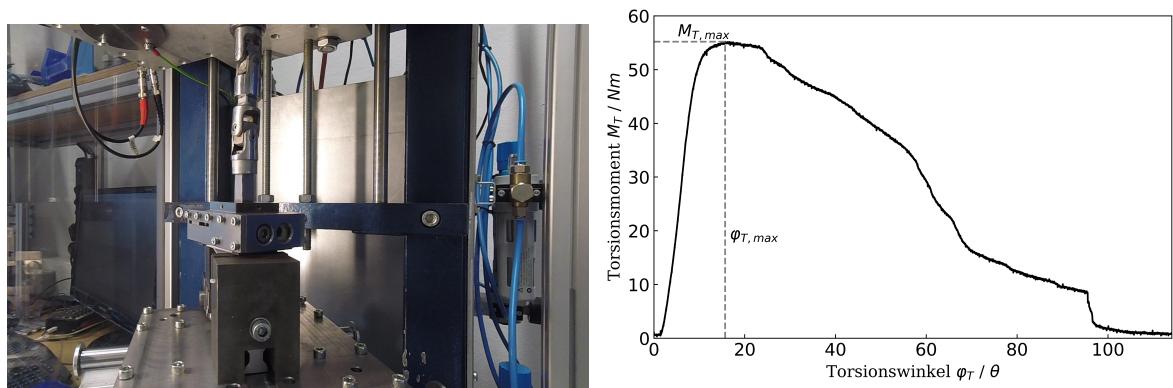


Abbildung 3.7: Messgrößen am Querschliff [14]



(a) Messeinrichtung für die Torsionsprüfung

(b) Torsionsmoment-Torsionswinkel-Diagramm

Abbildung 3.8: Torsionsprüfung

## 3.3 Durchgeführte Messungen

### 3.3.1 Elektrodenverschleißuntersuchung

Ziel des ersten Teil der Versuchsreihen war es, die Einflüsse der verschiedener Elektrodenbedingungen zu bestimmen, weshalb die Versuchsmatrix für MDK1 wie folgende Tabelle 3.8 durchgeführt wurden. Für alle Stufen wurde die Punktanzahl in Verschleiß-

**Tabelle 3.8:** Versuchsmatrix MDK1

Bezeichnung der MDK	Stufe	Punktanzahl
MDK1	1	400
	2	800
	3	1200
	4	1600
	5	4000

und Prüfbleche eingeteilt. Die Prüfbleche wurden für Ermittlung der Punktdurchmesser genutzt. Dies wurde durch nach DIN EN ISO 10447 [6] durch die Meißelprüfung erfasst. Verschleißbleche dienen dem Verschleiß der Elektroden während der Elektrodenverschleißuntersuchung. Verschleiß- und Prüfbleche wurden abwechselnd geschweißt. Die Tabelle 3.9 zeigt die Eigenschaften von Verschleiß- und Prüfbleche für die Elektrodenverschleißuntersuchung. Die schematische geometrische Darstellung von Verschleiß- und Prüfbleche kann man von der Abbildung A.1 entnehmen.

**Tabelle 3.9:** Eigenschaften der Verschleiß- und Prüfbleche für die Elektrodenverschleißuntersuchung

Blechtyp	Eigenschaft	Value
Prüfblech	Punktanzahl	8
	Punkt für Meißeltest	2, 3, 4, 5, 6
	Punkt für Querschliff	8
	Maße (Länge × Breite)	250 mm × 30 mm
	Punktabstand	30 mm
	Randabstand	15 mm
Verschleißblech	Punktanzahl	192
	Maße (Länge × Breite) (min.)	470 mm × 350 mm
	Punktabstand	30 mm
	Randabstand (min.)	10 mm

Der Versuchsplan wurden basierend auf DIN EN ISO 8166 [7] geplant. Das Abbildung 3.11 Links zeigt den Versuchsablauf des Stufenversuchs.

- Zuerst wurden Elektroden gefräst;
- Die Durchführung von 8 Schweißungen für Prüfblech;
- Messung der Oberflächentopographie für Elektroden und Blech;
- Die Durchführung von 192 Punktschweißungen für Verschleißblech;
- Messung der Oberflächentopographie für Elektrode und Blech;
- Wiederholung der in den Punkten 2 bis 4 beschriebenen Schritte bis zum Stufenende;
- Metallographische Untersuchungen für Schweißverbindungen.

Die Abstimmung des Schweißbereiches wurden in [31] durchgeführt. Das abgestimmte Schweißstrom von  $9,2 \text{ kA}$  erfolgte durch den Soll-Punktdurchmesser  $d_{w,soll}$  von  $5,2\sqrt{t}$ . Während der Durchführung wurden alle Schweißbedingungen (Tabelle 3.10) konstant geblieben außerhalb der Elektrodenzustände und der Geometrie der Bleche. Die Abbildung 3.9 Links zeigt das Schweißprozess von Schweißstrom und Elektrodenkraft. Basierend auf dem Konstantstrom- und Konstantkraftregler variieren die Reglern der Schweißmaschine die Ausgangsstrom und Ausgangskraft, um konstante Strom und Kraft aufrechtzuerhalten.

**Tabelle 3.10:** Schweißbedingungen für MDK1

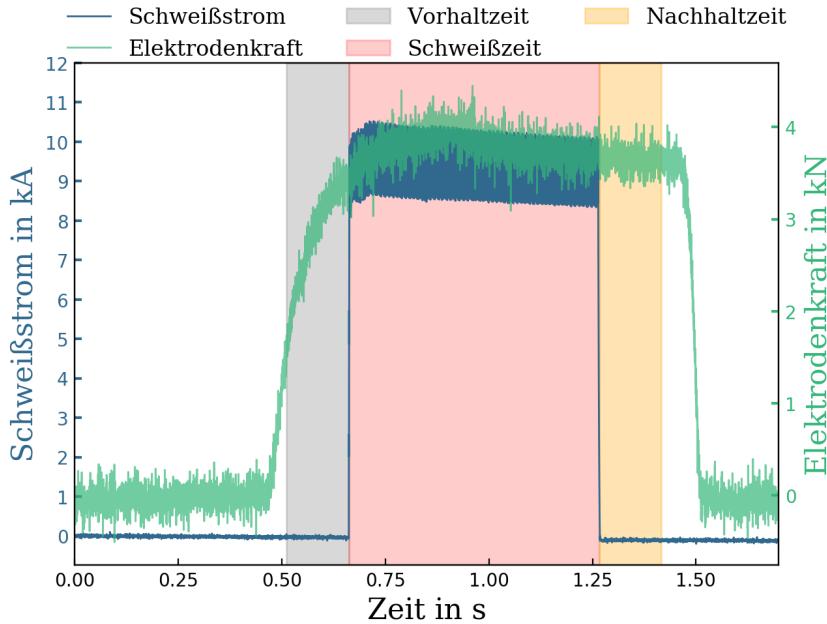
Schweißbedingungen	Formelzeichen	Einheit	Größe
Elektrodenkraft	$F_E$	kN	3,5
Schweißstrom	$I_S$	kA	9,2
Vorhaltzeit	$t_V$	ms	150,0
Schweißzeit	$t_S$	ms	600,0
Nachhaltzeit	$t_N$	ms	150,0

### 3.3.2 Verschiedene Stromstärken

#### 3.3.2.1 Stufenuntersuchung

Der zweite Teil der Messungen diente der Untersuchung des Einflusses der Stromstärke auf die Schweißpunktqualität beim selben Versuchsstand. Deswegen war das Schweißstrom die einzige Variable für diese Untersuchung. Die Versuchsmatrix für MDK2 ist in folgender Tabelle 3.11 zu bekommen.

Insgesamt wurden 72 Schweißungen durchgeführt. Der erste Schweißpunkt von jedem



**Abbildung 3.9:** Tatsächliche Signale von Schweißstrom und Elektrodenkraft bei MDK1

**Tabelle 3.11:** Versuchsmatrix für MDK 2

Bezeichnung der MDK	min. Schweißstrom [kA]	max. Schweißstrom [kA]	Stromschritt [kA]	Punktzahl je Stromstufe
MDK2	2,0	10,4	0,4	3

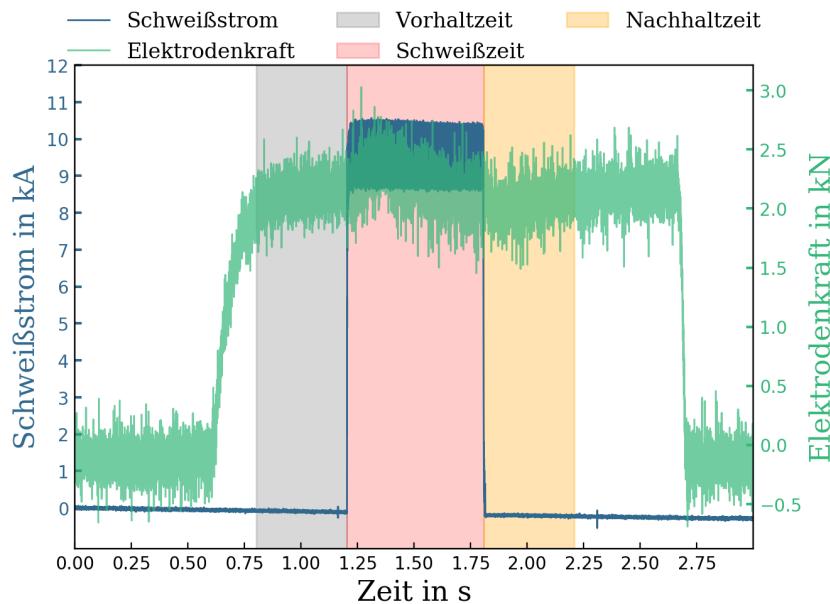
Blech wurden nicht in die Prüfung aufgenommen, weil er ohne vergleichbare Nebenschlusseffekt geschweißt wurden. Die Abbildung 3.11 Rechts zeigt den Versuchsablauf der Stufenversuche.

- Zuerst wurden Elektroden gefräst;
- Die Durchführung von 3 Schweißungen mit einer Stromstufe;
- Erhöhung des Stroms nach dem Stromschritt  $\Delta I$ ;
- Wiederholung der in den Punkten 2 bis 3 beschriebenen Schritte bis zum endlichen Schweißstromstufe;
- Metallographische Untersuchungen der Schweißverbindungen.

Die Tabelle 3.12 zeigt die Schweißbedingungen für MDK2. In der Zeit wurden die Schweißbedingungen konstant geblieben außerhalb des Schweißstroms. Von der Abbildung 3.10 kann man beispielsweise die tatsächlichen Signale von Schweißstrom 9,2 kA und Elektrodenkraft 2,0 kN erfahren.

**Tabelle 3.12:** Schweißbedingungen für MDK2

Schweißbedingungen	Formelzeichen	Einheit	Größe
Elektrodenkraft	$F_E$	kN	2,0
Schweißstrom	$I_S$	kA	variabel
Vorhaltzeit	$t_V$	ms	400,0
Schweißzeit	$t_S$	ms	600,0
Nachhaltzeit	$t_N$	ms	400,0

**Abbildung 3.10:** Tatsächliche Signale von Schweißstrom und Elektrodenkraft bei MDK2

### 3.3.2.2 Spritzeruntersuchung

Der Unterschied zur Stufenuntersuchung der Stromstärke war, dass bei der Spritzeruntersuchung wurden die einzelnen Bleche mit MDK1 (50 Proben) und MDK2 (47 Proben) durchgeführt. Zu diesem Zweck wurde ein Schweißen mit hoher Spritzerwahrscheinlichkeit durchgeführt, dadurch sind die Kriterien zur Klassifikation der Spritzerstärke herauszufinden, d. h. in dieser Untersuchung soll neben der Diagnose, ob ein Spritzer vorliegt, auch deren Stärke beurteilt werden. Die Tabelle 3.13 zeigt die Schweißbedingungen für die Spritzeruntersuchung.

Tabelle 3.13: Schweißbedingungen für Spritzeruntersuchung

Schweißbedingungen	Formelzeichen	Einheit	MDK1	MDK 2
Elektrodenkraft	$F_E$	kN	3,5	2,0
Schweißstrom	$I_S$	kA	7,0...10,0	9,0...10,0
Vorhaltzeit	$t_V$	ms	400	400
Schweißzeit	$t_S$	ms	600	600
Nachhaltzeit	$t_N$	ms	400	400
Probenanzahl	-	-	50	47

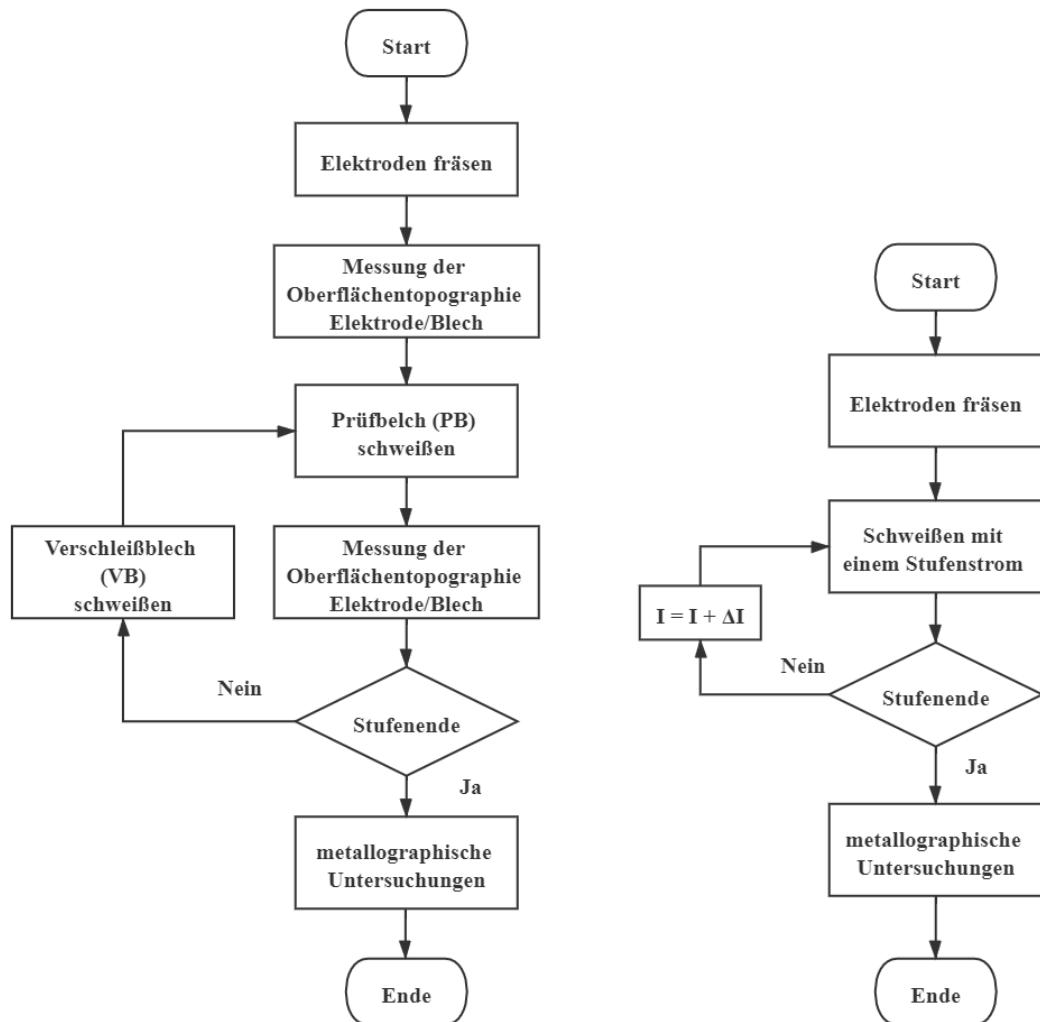


Abbildung 3.11: Links: Versuchsablauf des Stufenversuchs von MDK1; Rechts: Versuchsablauf des Stufenversuchs von MDK2

# 4 Versuchsergebnisse

## 4.1 Elektrodenverschleißuntersuchung

### 4.1.1 Punktdurchmesser

Wie in dem Abschnitt 3.3 erwähnt hat, dass die Punktdurchmesser durch die Meiβelprüfung für Prüfblech ermittelt wurden. Die Schweißpunkt Durchmesser von der Elektrodenverschleißuntersuchung bis Stufe 5 sind in Abbildung 4.1 mit Schweißpunktnummer dargestellt. Der Mindestlinsendurchmesser  $d_{w,min}$  von  $3,5\sqrt{t}$  [12] ist die Untergrenze für

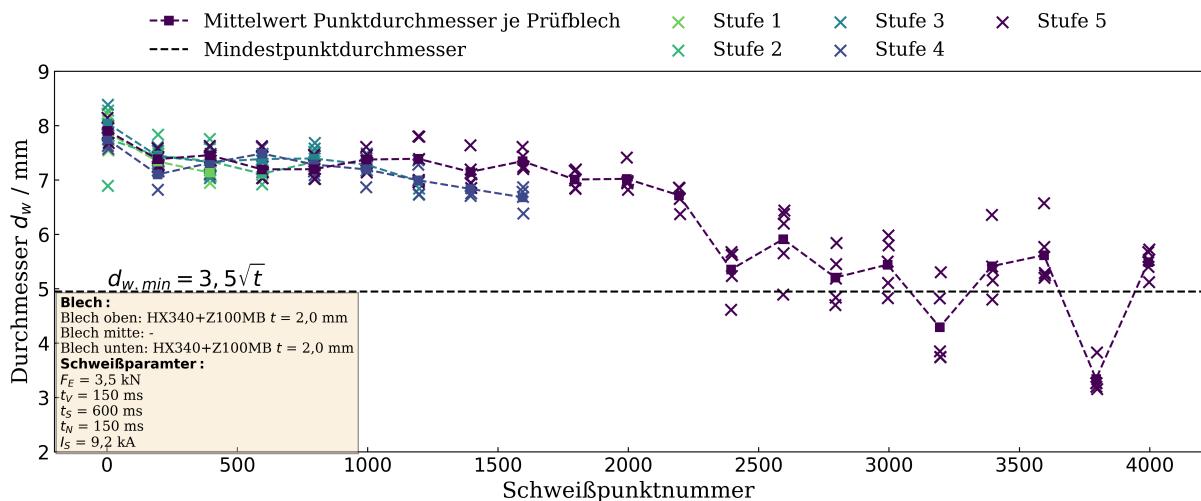


Abbildung 4.1: Schweißpunkt Durchmesser der Elektrodenverschleißuntersuchung

die Evaluierung vom Punktdurchmesser. Die statische Analyse der Ergebnisse für alle Stufen, die aus der Abbildung 4.1 gezogen werden könnten, waren wie folgt:

- bei Messungen des Schweißpunktdurchmessers nach folgender Gleichung:

$$d_w = (d_1 + d_2)/2 \quad (4.1)$$

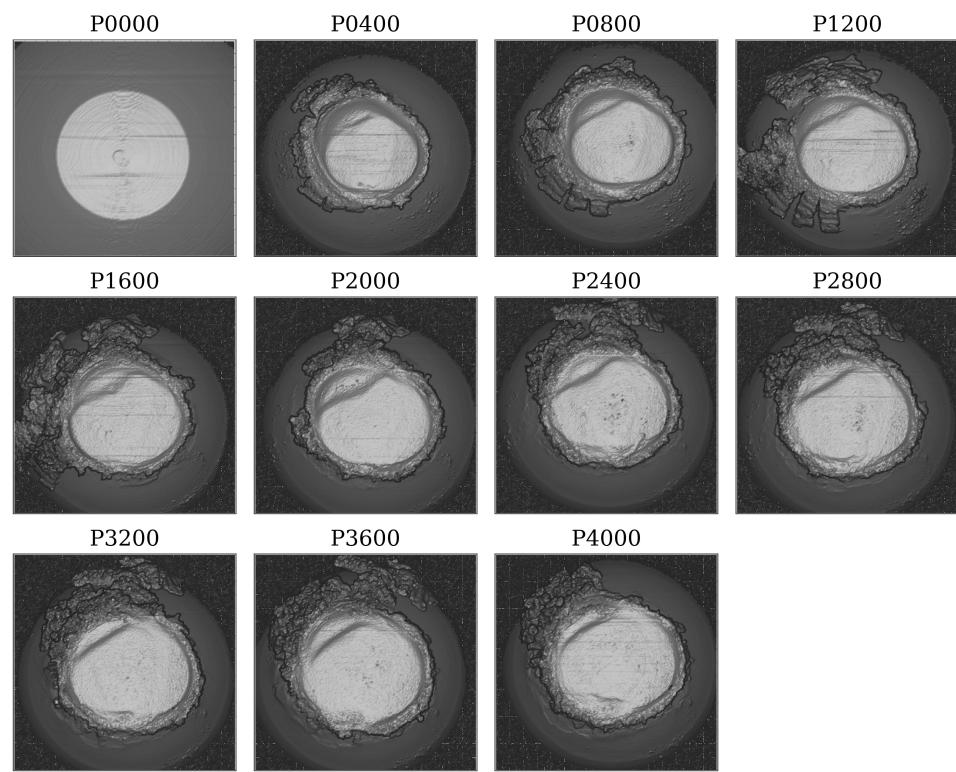
- mit zunehmender Schweißpunktnummer zeigt das  $d_w$  eine reduzierte Tendenz;
- seit ca. 1200 Schweißpunkte haben die Mittelwert von  $d_w$  je Prüfblech stattgefunden, kleiner als  $5\sqrt{t}$  zu sein;
- seit ca. 2400 Schweißpunkte haben die  $d_w$ , die kleiner als  $d_{w,min}$  waren, aufgetreten;
- seit ca. 2200 ist  $d_w$  bei der visuellen Beobachtung offensichtlich verringert und wurden die Varianz von  $d_w$  je Prüfblech zugenommen.

### 4.1.2 Elektroden topographie

Wie in dem Abschnitt 3.3 erwähnt hat, dass die Messungen der Oberflächentopographien der Elektroden in jeder Schleife der Stufe durchgeführt wurden. Die Tabelle 4.1 und 4.2 zeigen die Messergebnisse der Stufe 5 alle 400 Schweißpunkte. Von Ausgangszustand P0000 der Elektroden bis Endzustände P4000 der Elektroden haben die Arbeitsdurchmesser der Elektroden eine deutliche Vergrößerung aufgrund des Verschleißes in der radialen Richtung. Außerdem wurde bei den Versuchen an verzinkten Stahlblechen festgestellt, dass sich bei bestimmten Schweißparametern an den Elektroden der Zink durch lokales Aufschmelzen oder Herausbrechen der spröden verzinkten Schicht ansammelt wurde, was die Schweißpunktqualität abnehmen kann. In der Kontaktzone der zwischen Elektroden und Bleche konzentrieren sich die mechanische Kontaktspannung und der Stromflussdichte auf die Randbereiche [46, 47], was das Elektrodenverschleiß verschärfen und weiteres die Arbeitsfläche der Elektroden vergrößern lassen kann.

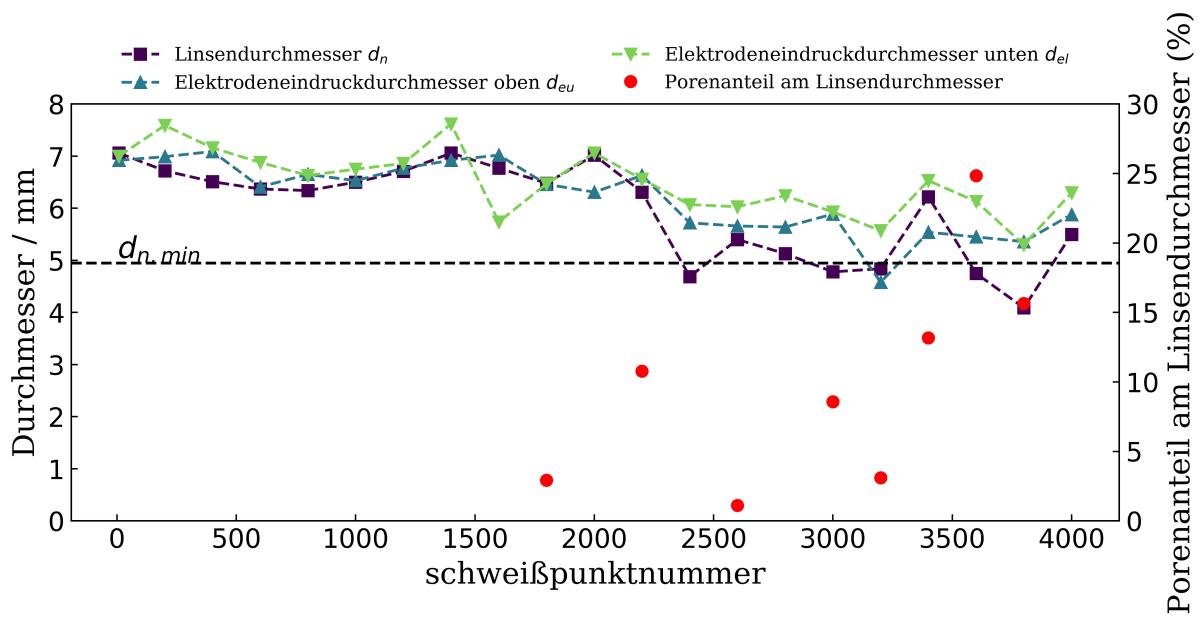
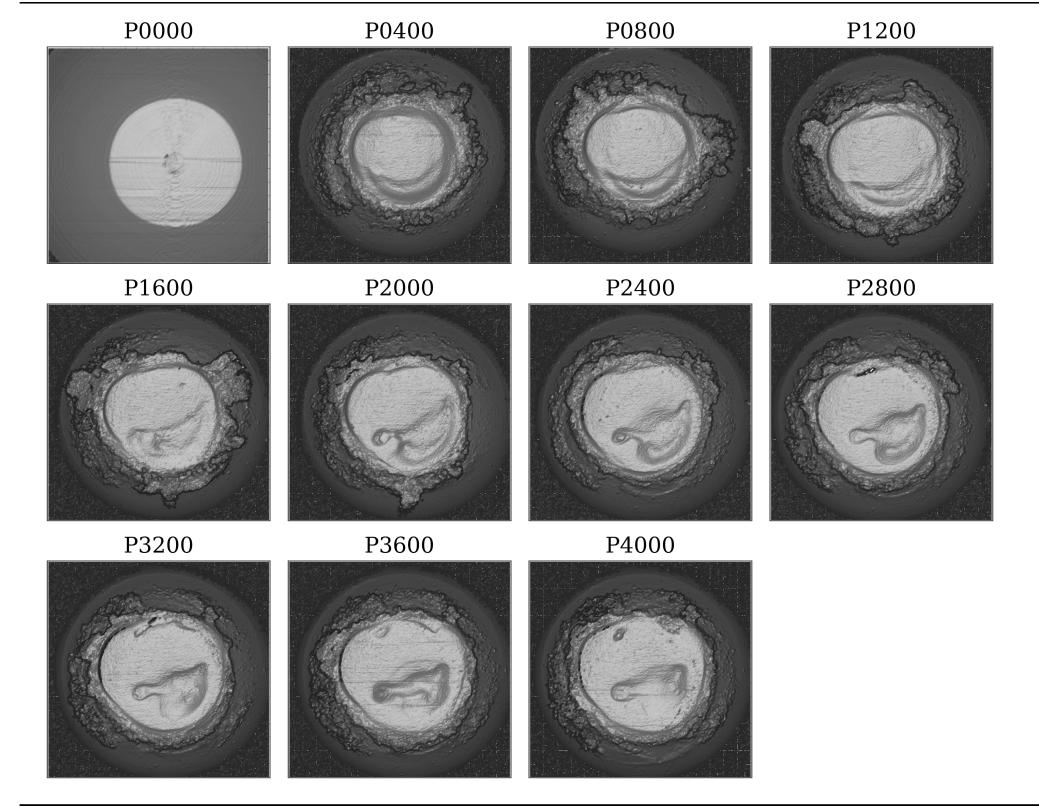
### 4.1.3 Metallographische Darstellung vom Querschliff der Punkte

Wie in der Tabelle 3.9 dargestellt hat, dass die Querschliffe für Schweißpunkte von Prüfblech (Tabelle B.1) durchgeführt wurden, damit man mittels der metallographischen Untersuchungen die genauen Linsendurchmesser und Elektrodeneindrucktiefen ermitteln konnte. Die Abbildung 4.2 zeigt die gemessenen Linsendurchmesser  $d_n$  und Elektroden-eindrucksdurchmesser  $d_{eu}$ ,  $d_{el}$ . Mit der Schweißpunktnummer haben die  $d_n$ ,  $d_{eu}$  und  $d_{el}$  einen allgemeinen verringerten Trend betragen. Seit ca. 1800 Punkte hat die Poren an metallographischer Darstellung der Querschnitte der Punkte begonnen, die im Schweißlinse

**Tabelle 4.1:** Elektrodenoberflächen der Anode**Stufe 5: Konfokal-chromatische Oberflächenmessung, Anode**

einen größeren Einfluss auf die Festigkeit der Verbindung haben, und der Porenanteil hat gegen das Linsendurchmesser einen wellenähnlichen Anstieg angezeigt.

Die Elektrodeneindrucktiefen von oben und unten  $e_u$ ,  $e_l$  sind in der Abbildung 4.3 dargestellt. Es ist deutlich zu beobachten, dass die Elektrodeneindrucktiefen mit Schweißpunkt-nummer vor ca. 1400 deutlich abgenommen wurden, während nach ca. 1400 die abfallende Tendenz nicht offensichtlich war und besonders bei  $e_u$  die Tiefen fast konstant geblieben haben.

**Tabelle 4.2:** Elektrodenoberflächen der Kathode**Stufe 5: Konfokal-chromatische Oberflächenmessung, Kathode****Abbildung 4.2:** Die gemessenen Linsendurchmesser und Elektrodeneindrucksdurchmesser

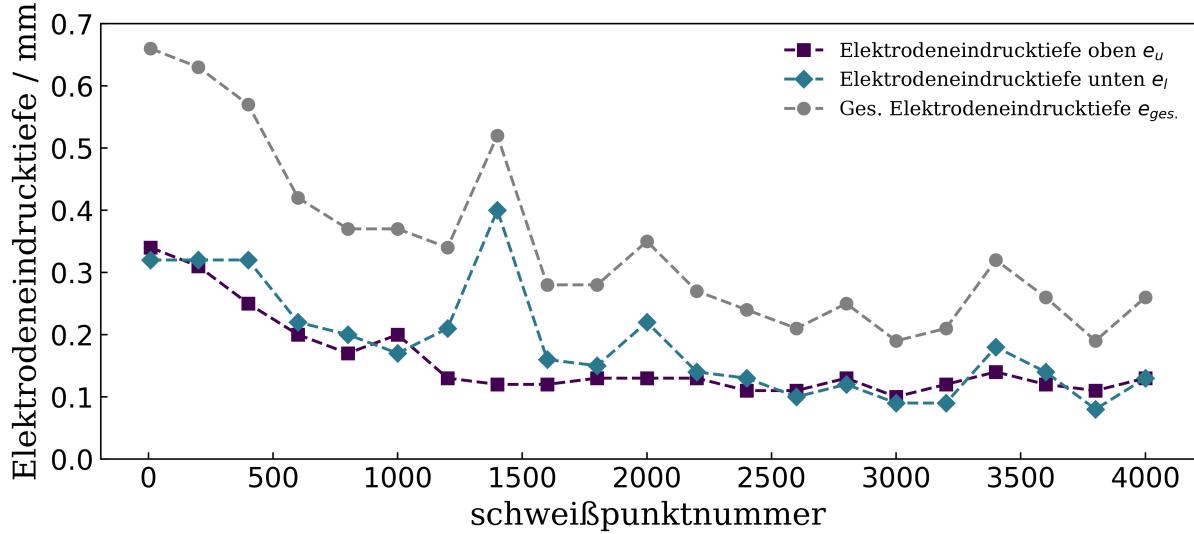


Abbildung 4.3: Die gemessenen Elektrodeneindrucktiefen

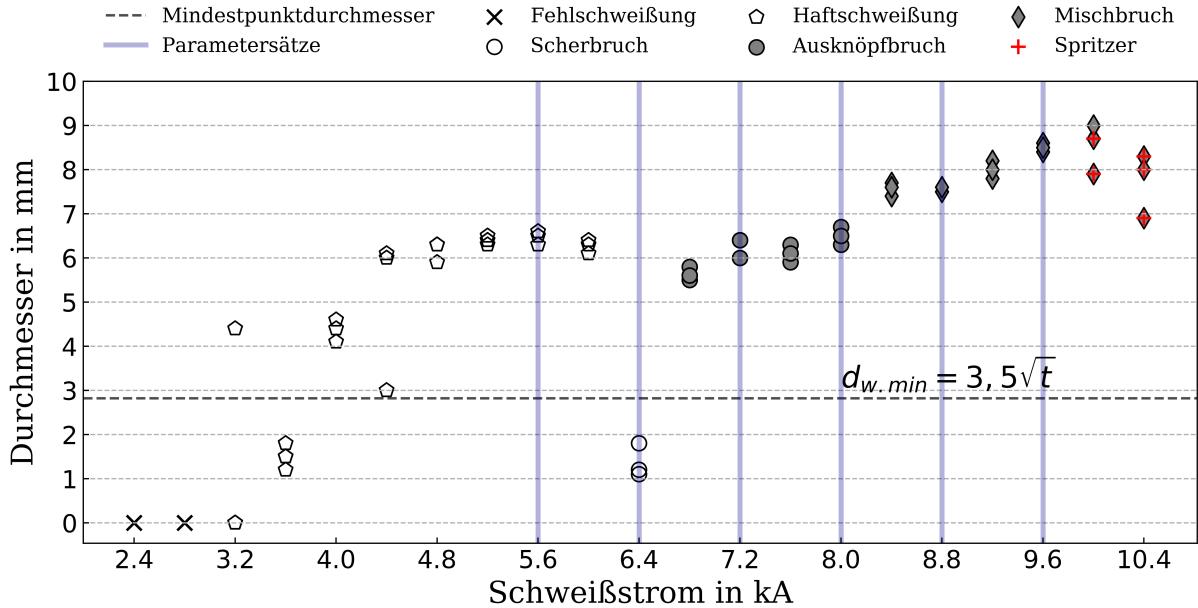
## 4.2 Verschiedene Stromstärken

### 4.2.1 Stufenuntersuchung

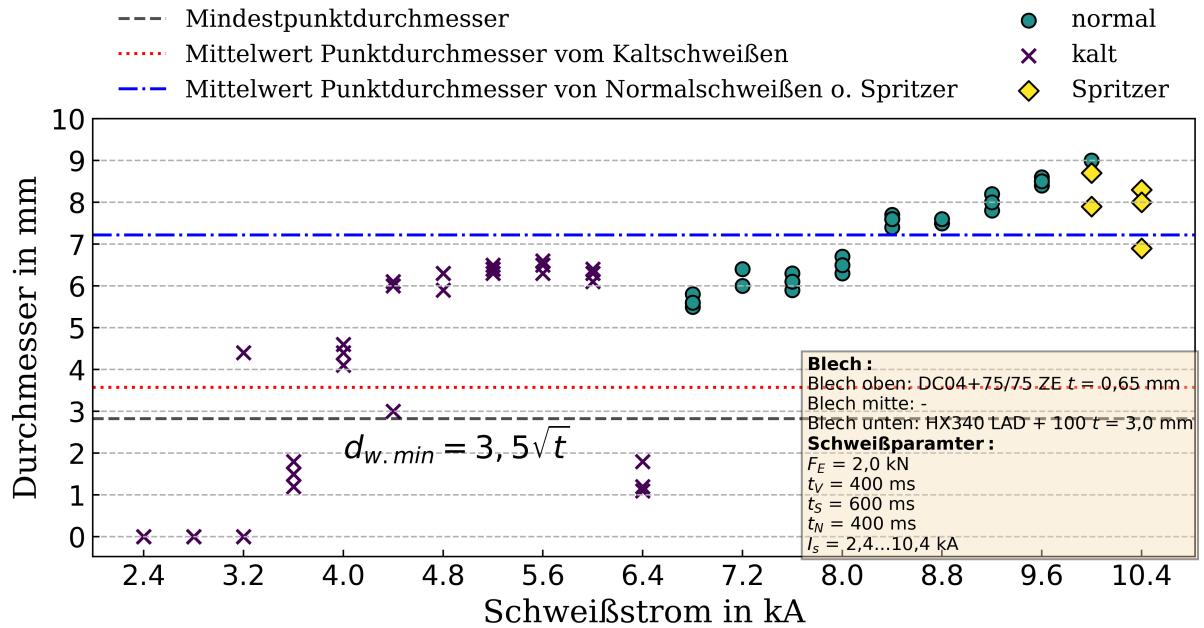
#### 4.2.1.1 Punktdurchmesser und Brucharten

Wie in dem Unterabschnitt 3.3 erwähnt hat, dass die Untersuchung mit unterschiedlichen Stromstufen bei MDK2 durchgeführt hat. Zur Sicherstellung der Schweißpunktqualität war die Meißelprüfung durchzuführen. Aufgrund einer manuelle Meißelprüfung ist es nicht möglich, die digitalisierte Festigkeit zu messen, aber die Brucharten und Punktdurchmesser, die nach der Meißelprüfung erfassbar sind, wie in der Abbildung 4.4 dargestellt, können sich etwa die Festigkeit der Schweißverbindung wiederum spiegeln. Basierend auf den Brucharten, den Punktdurchmesser sowie dem Spritzer wurde die Schweißpunktqualität in 3 Klassen verteilt: das Kalte, das Normale, der Spritzer, wie in Abbildung 4.5 dargestellt. Normalerweise ist die Bruchart beim kalten Schweißen aufgrund weniger Wärme der Scherbruch in der Schweißzone, womöglich gibt es Haftschweißung und Fehlschweißung, was bedeutet, dass die Festigkeit von solchen Schweißpunkten nicht ausreichend ist. Die Schweißpunkte mit Mischbruch und Ausknöpfbruch bei Meißelprüfung bedeuten, dass in der Schweißzone eine ausreichende Schweißlinse aufgebaut werden und die Punktdurchmesser von solchen Schweißpunkten über das Mindestpunktdurchmesser  $d_{w,min}$  waren.

Beim Schweißen von Blechen mit zwei unterschiedlichen Dicken sollten die  $d_{w,min}$  entsprechend der kleineren Blechdicke festgelegt werden [12].



**Abbildung 4.4:** Die Brucharten und Punktdurchmesser nach verschiedenen Stromstärken



**Abbildung 4.5:** Die klassifizierte Schweißqualität nach verschiedenen Stromstärken

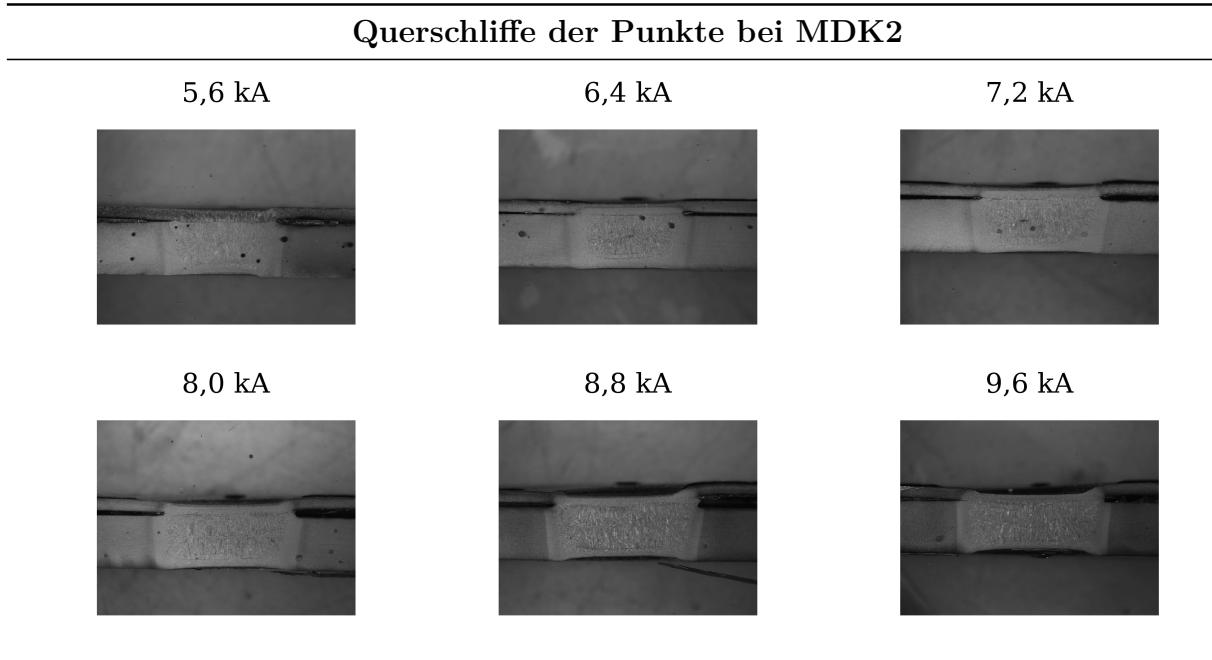
Seit  $6,4 \text{ kA}$  haben die Mischbrueh und Ausknöpfbruch statt des Scherbruch begonnen und

seit  $10 \text{ kA}$  hat der Spritzer wegen zu viel Wärme in der Schweißzone aufgrund z. B. hohem Strom verhaltet wurde. Mit zunehmende Schweißstrom haben die Punktdurchmesser eine zunehmende Tendenz dargestellt . Der Mittelwert  $d_w$  vom Kaltschweißen kleiner als der Mittelwert  $d_w$  von dem Normalschweißen und dem Schweißen mit Spritzer.

#### 4.2.1.2 Metallographische Darstellung vom Querschliff der Punkte

Das einzelne Schweißen wurde nach den in der Abbildung 4.4 markierten Parametersätzen durchgeführt, damit die metallographische Untersuchung ausgeführt werden konnte. Von der metallographischen Darstellung der Querschliffe ist es deutlich zu beobachten, dass die in der Abbildung 3.7 markierten Messgrößen  $e_u$ ,  $e_l$ ,  $d_n$ ,  $d_{eu}$ ,  $d_{el}$  mit zunehmenden Stromstärken sich erhöht haben (Tabelle 4.3).

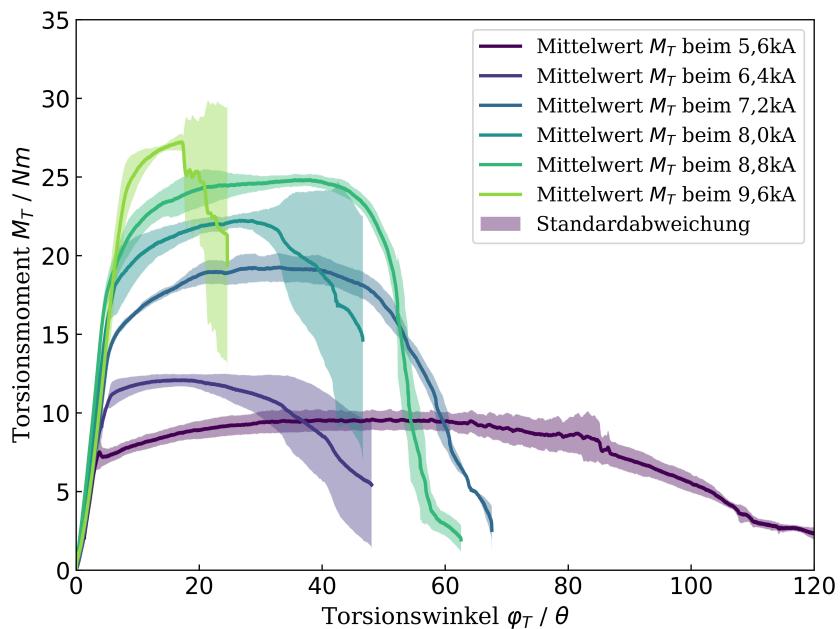
**Tabelle 4.3:** Querschliffe der Punkte bei MDK2



#### 4.2.1.3 Torsionsprüfung

Maximales Torsionsmoment, Torsionswinkel bei  $M_{max}$  und Bruchwinkel können auch eine Beurteilung zur Beschreibung des Verhaltens der Punktschweißverbindung. Die Abbildung 4.6 zeigt den Torsionsversuch in den Stromstufen von  $5,6 \text{ kA}$  bis  $9,6 \text{ kA}$ . Mit der zunehmenden Stromstufe hat die maximale Torsionsmoment  $M_T$  vergrößert, während die

Torsionswinkel bis zum Bruch der Schweißverbindung verringert hat, was bedeutet, dass durch zunehmende Wärme in der Wärmeeinflusszone mit dem immer höheren Schweißstrom die aufgebauten Linsendurchmesser vergrößert wurden, dies verbessert die Festigkeit der Schweißverbindung. Deswegen hat die gute Punktschweißverbindung normalerweise relativ hohe  $M_{max}$ , relativ kleine  $\varphi_{max}$  und Bruchwinkel, d. h. diese Verbindung besitzt gute Festigkeit und Dehnbarkeit. Zu hohe  $M_{max}$  und zu kleine  $\varphi_{max}$  bedeuten einen Sprödbruch bei einer Torsionsprüfung, was häufig bei Schweißen mit Spritzer passiert. Dagegen hat die nicht ausreichende Punktschweißverbindung kleine  $M_{max}$ , große  $\varphi_{max}$  und Bruchwinkel.



**Abbildung 4.6:** Torsionsmoment-Torsionswinkel-Diagramm für verschiedene Stromstärken

Aus der Sicht von den Brucharten kam die geringe Festigkeit beim Torsionsversuch zum Scherbruch und kleinen Punktdurchmesser im Vergleich dazu, dass der Ausknöpfbruch und der große Punktdurchmesser beim Torsionsversuch die ausreichende Festigkeit aufweisen konnten. [17].

### 4.2.2 Spritzeruntersuchung

Wie in dem Unterabschnitt 3.3 erwähnt hat, dass das Schweißen mit hoher Spritzerwahrscheinlichkeit durchgeführt. Während des Schweißens ist es in der Lage, mittels der Beobachtung und Einschätzung für die Spritzerstärke für jedes Schweißen unscharfe La-

bel zu liefern. In folgender Abbildung 4.7 sind die auf der Blechoberfläche markierten Label nach der Torsionsprüfung dargestellt. Der obere Teil und untere Teil ist jeweils die Spritzeruntersuchung für MDK1 und MDK2. Die folgenden Informationen können von den Labels auf den Blechoberflächen entnommen werden:

- Schweißpunktnummer;
- Schweißstrom;
- Spritzer oder kein Spritzer;
- Anzahl des Spritzers während des Prozesses;
- Stärke des Spritzers.

Die Bedeutungen der Label sind von der Tabelle 4.4 erfassbar.

**Tabelle 4.4:** Bedeutungen der Label auf den Blechoberflächen

Zeichnung	Bedeutung	Zeichnung	Bedeutung
45	Punktnummer	↖	kleiner Spritzer
9,7	Schweißstrom	↗	starker Spritzer
<i>S</i>	Spritzer	↗↗	sehr starker Spritzer
<i>S, S</i>	Doppelspritzer	-	-



**Abbildung 4.7:** Die nach Beobachtung und Einschätzung gelabelten Bleche bei der Spritzeruntersuchung

# **5 Definitionen und Eigenschaften eines Algorithmus**

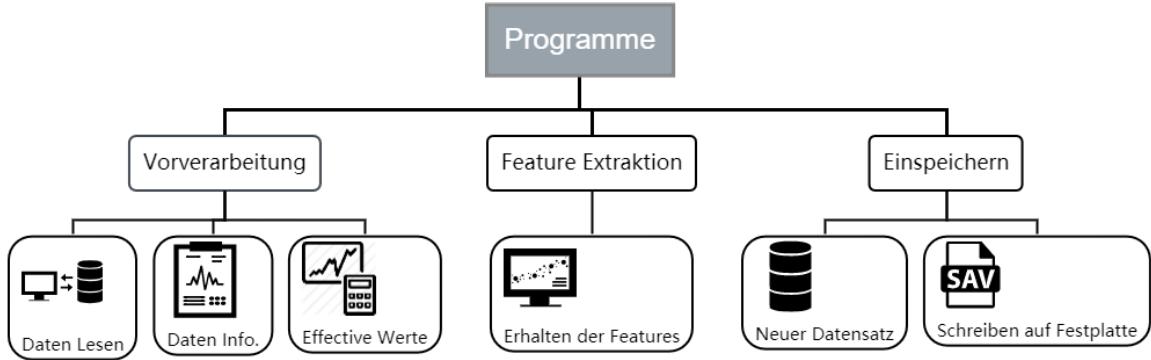
Bei der Entwicklung des Programms müssen alle Details des gestellten Problems beherrscht werden. Da es möglich ist, dass aus den Stellen der Probleme Anforderungen auf unterschiedlichen Weisen und auf unterschiedlichen Computern herauszukommen, stellt jedes entwickelte Programm nur eine von vielen möglichen Lösungen dar. Aufgrund der engen Wechselbeziehungen zwischen den Algorithmen und den Daten erfolgte ihre Ausarbeitung gleichzeitig und in gegenseitiger Abhängigkeit. Um den sich jederzeit änderbaren Datensatz an die Algorithmen gut anzupassen, wurde das geplante Programm relativ komplexe Algorithmen erhalten gegenüber einfache Daten.

Aufgrund der Komplexität des Programms wurde es in mehrere kleinere Module unterteilt. Dies ermöglichte eine einfachere Programmierung. Darüber hinaus hat eine solche Programmstruktur den weiteren Vorteil, dass auch einzelne Programmmodulen verwendet werden können gebraucht. Wenn ein Programm in einzelnen, gut dokumentierten Modulen programmiert und auf dem Datensatz basiert ist, kann eine bestimmte Routine über einen längeren Zeitraum verwendet werden. Der Einfachheit halber wurden manche Module aus vorhandenen Bibliotheken verwendet.

## **5.1 Algorithmen Design**

Der erste Teil der Algorithmen wurden nach Top-down-Design Konzept entwickelt. Diese Algorithmen wurden in drei Teilen unterteilt: die Vorverarbeitung der Daten aus dem geschützten Datenbasis, die Extraktion der Features und das Einspeichern der bearbeiteten Daten. Die Abbildung 5.1 zeigt die Baum-Diagramm zur Verarbeitung der Daten für

die Analyse der Prozessparameter und die Datensatz für ML. Die UML-Diagramme der Programme können von der Abbildung A.13 A.14 A.15 entnommen werden.



**Abbildung 5.1:** Die Struktur Top-down-Design zur Verarbeitung der Daten aus dem Datensatz

Dieser Teil konzentrierte sich hauptsächlich auf die folgenden Anforderungen:

- Das von Benutzer definierte Datenbasis zum Speichern der Daten auf Festplatte aufzubauen;
- Die in TDMS Format gespeicherten Messdaten aus einem geschützten Datenbasis zu lesen und speichern;
- Die Details der Daten (Daten Eigenschaften) zu lesen und speichern;
- Die rohen Messsignals zu filtern und entrauschen, nämlich die effektiven Werte der Time-Domain-Signale auszureichen;
- Die Features nach der statischen Analyse zu extrahieren und speichern.

Beim zweiten Teil kam es zu den ML-Algorithmen. Dabei wurden die ML-Algorithmen mit dem basierend auf den ausgewählten Features Eingabe, die schon eine statistische Analyse durchgeführt habe, zur Qualitätsbewertung der Schweißpunkte im Gebrauch gemacht. Die Abbildung 5.2 zeigt das Vorgehen bei ML-Verfahren. In der Abbildung 5.3 ist der schematische Überblick der Algorithmen dargestellt.

Nach der Top-down-Design-Struktur und dem ML-Verfahren werden die schematische Darstellung in drei Blöcken mit unterschiedlichen Farben aufgeteilt.

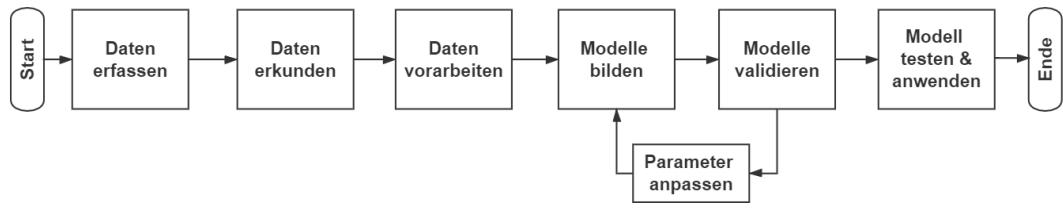


Abbildung 5.2: Vorgehen bei ML-Verfahren

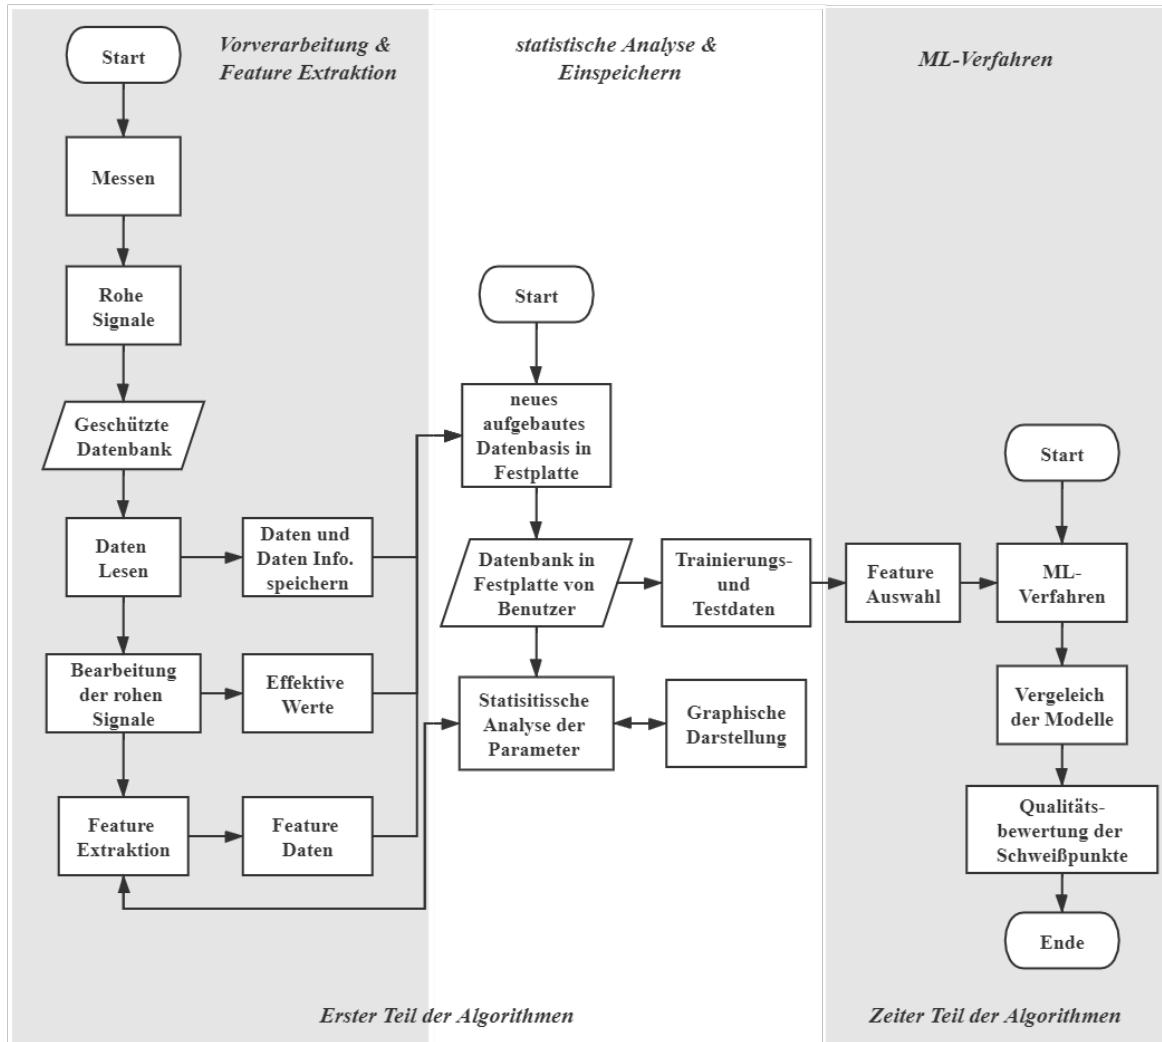


Abbildung 5.3: Schematische Darstellung des Überblicks auf die Algorithmen

## 5.2 Vorverarbeitung

Die Vorverarbeitung ist verantwortlich dafür, die Daten aus dem geschützten Datenbasis zu erfassen und die aus Sensoren gemessenen rohen Signale zu bearbeiten. Die Messdaten wurden in TDMS Format gespeichert und die Struktur von einzelner TDMS-Datei ist beispielsweise wie folgende Abbildung 5.4 bezeichnet.

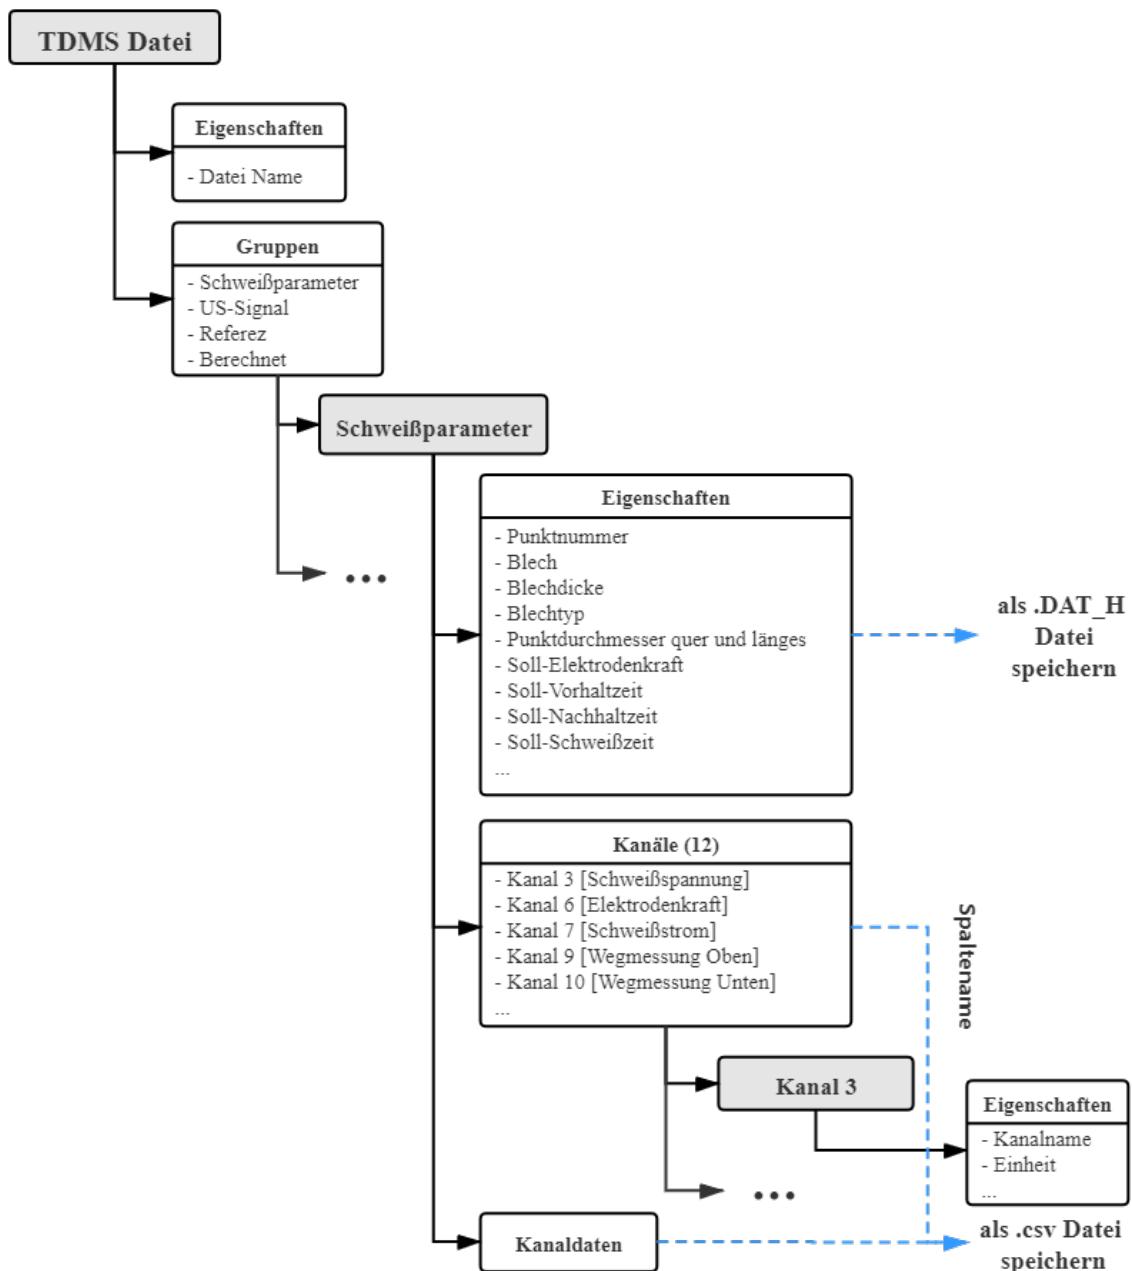


Abbildung 5.4: Einzelne TDMS-Datei Struktur eines Schweißpunkts

Die Eigenschaften von Schweißparameter wurden als DAT\_H-Datei speichert, davon wurden die eingestellten Schweißparameter und anderen notwendigen Informationen jedes Schweißpunkts aufgezeichnet. Darüber hinaus waren die Eigenschaften in der Lage, als Attribute einer Klasse zu sein, was für die Extraktion der Features und Dokumentation der Daten hilfreich war. Vom Schweißparameter wurden die Kanalnamen und die entsprechenden Kanaldaten als CSV-Datei in einem durch Benutzer definierten Datenbasis auf einer Festplatte gespeichert.

### 5.2.1 Vorverarbeitung für Strom- und Spannungssignal

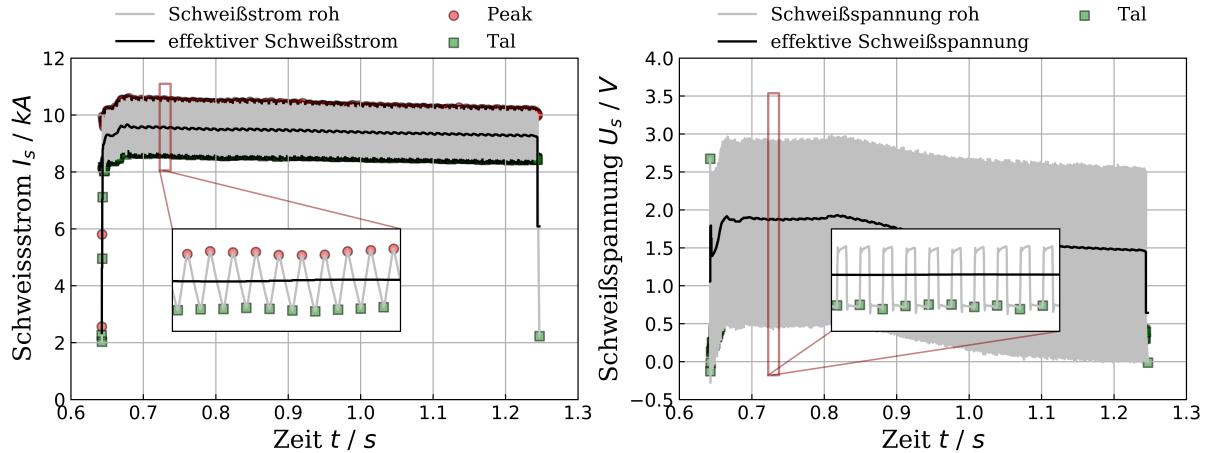
Den Effektivwert auszurechnen ist sehr notwendig, damit die Features von den Signalen deutlich erkennt werden. Das Stromsignal ist ein dreieckiges periodisches Signal, das Spannungssignal ist rechteckiges periodisches Signal, wie in der Abbildung 5.5 dargestellt. Mittels der Algorithmen 5.1, 5.2 ist es in der Lage, die Peak-Position und Tal-Positionen des Signals herauszufinden, um die Periode der Signal zu ermitteln. Die Perioden des dreieckigen und rechteckigen Signals haben Eins-zu-Eins-Korrespondenz auf der Zeitachse, d. h. allein die Perioden des Stromsignals zu ermitteln ist benötigt. Der Effektivwert entspricht dem quadratischen Mittel der zeitabhängigen Größe:

$$I_{eff} = \sqrt{\frac{1}{T} \int_0^T i(t)^2 dt} \quad (5.1)$$

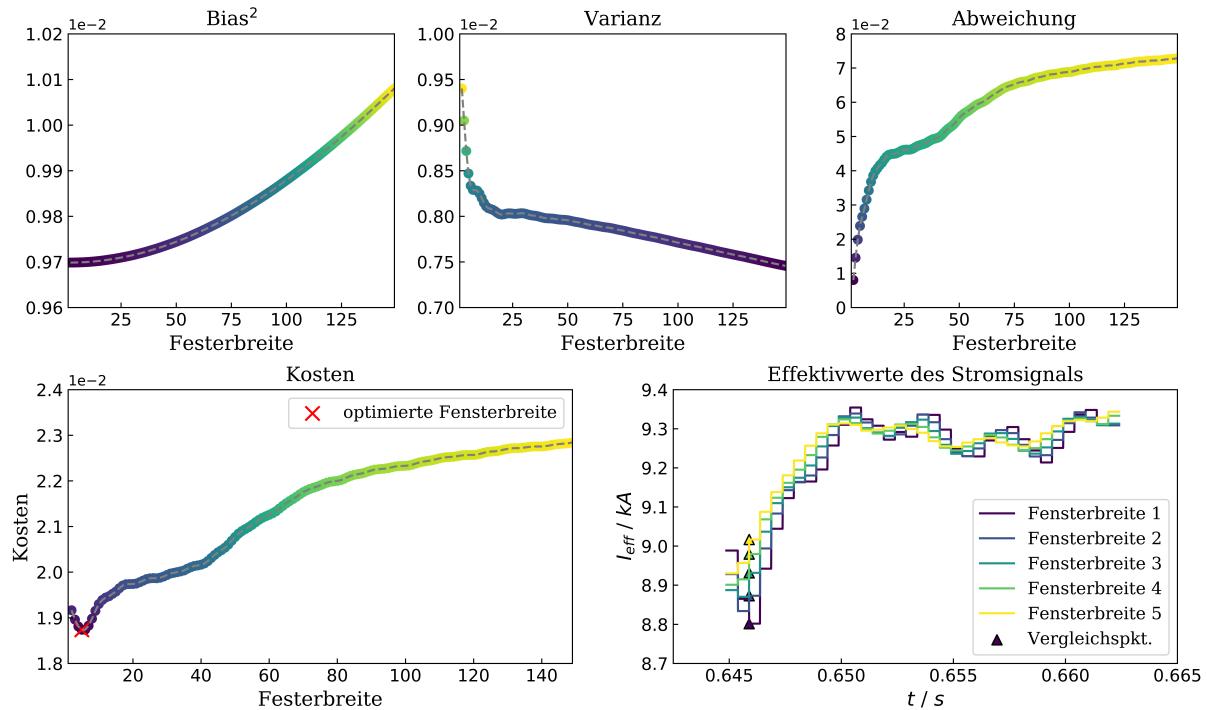
$$U_{eff} = \sqrt{\frac{1}{T} \int_0^T u(t)^2 dt} \quad (5.2)$$

Zwar gibt es eine Möglichkeit den Effektivwert für jede Periode des dreieckigen oder rechteckigen Signals nach Gl. 5.1 und Gl. 5.2 zu berechnen, was zu kleinem Bias aber großer Varianz führen kann. Einseitiger gleitender Mittelwert (EGM) ist eine oft verwendete Methode zur Glättung von Zeit- bzw. Datenreihen, die als Tiefpassfilter die höheren Frequenzanteile entfernt. Ein Ausschnitte „Fenster“ hat iterativ die Menge der gleitenden Durchschnitte berechnet. Das verwendete Fenster wird so verschoben, dass es sich überlappt. Allerdings kommt es zu systematischen Abweichungen, hier einer Phasenverschiebung, die für die Anwendung berücksichtigt wenden müssen. Deswegen ist es notwendig, die Analyse der Fensterbreite durchzuführen, um die optimierte Fensterbreite herauszufinden, was zu den niedrigsten Kosten  $k$  nach der EGM kommt.

Die Abbildung 5.6 zeigt die analysierte optimierte Fensterbreite für einzelnes Stromsignal.



**Abbildung 5.5:** Links: Das rohe und effektive Stromsignal; Rechts: Das rohe und effektive Spannungssignal



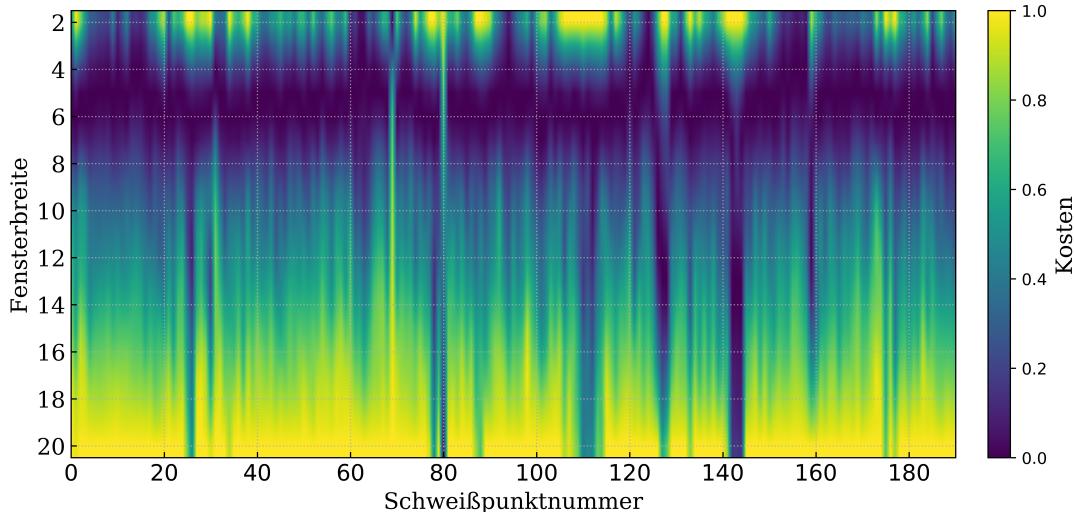
**Abbildung 5.6:** Analyse der optimierte Fensterbreite für einzelnes Stromsignal

Mit zunehmender Fensterbreite steigt das Bias und aber sinkt die Varianz. Das Diagramm von Abweichung zeigt die quantifizierte Phasenverschiebung mit zunehmender Fensterbreite, die bei den Vergleichspunkten mittels der Gl. 5.3 bestimmt wurden, wobei  $i$  die Fensterbreite ist. Die Vergleichspunkte sollen so ausgewählt, dass bei diesem Vergleichspunkt die durch Phasenverschiebung verursachten Abweichungen  $dy$  in y-Achse, hier  $I_{eff}$ , so groß wie möglich sind. Nach der Gl. 5.4 wurden das Kostendiagramm bezeichnet. Die

optimierte Fensterbreite liegt bei den niedrigsten Kosten, nämlich eine optimierte Balance zwischen Bias, Varianz und Abweichung. Um die optimierte Fensterbreite der ganzen Datenmenge zu bestimmen, wurden eine Analyse der Fensterbreite für die Stromsignale von den ersten 200 Schweißpunkten durchgeführt. Die optimierte Fensterbreite liegt häufig bei 5 oder 6, wie in der Abbildung 5.7. Die durch EGM mit Fensterbreite 6 geglätteten Strom- und Spannungssignal sind mittels des Algorithmus 5.3 in der Abbildung 5.5 ermittelt.

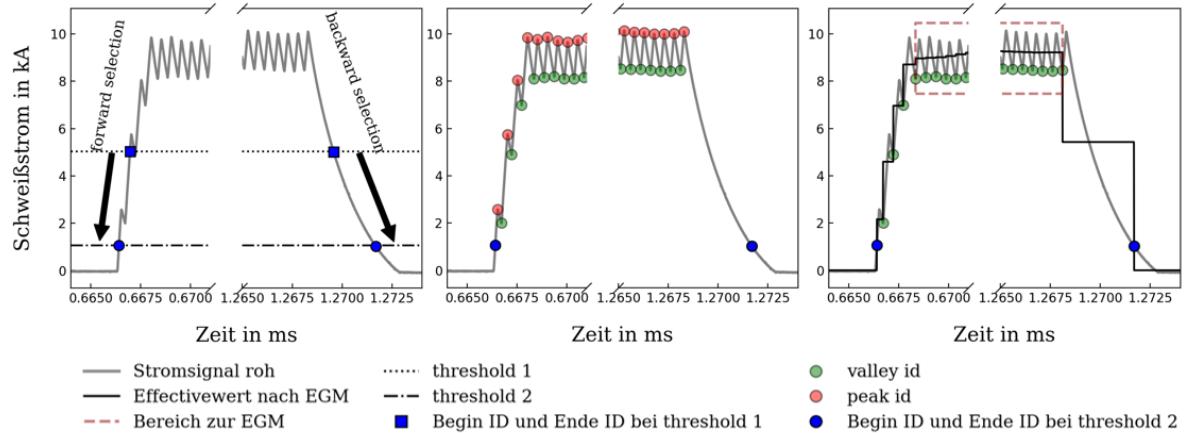
$$dy_i = 1 - \frac{I_{eff,V,1}}{I_{eff,V,i}} \quad (5.3)$$

$$k_i = Bias^2 + Varianz + dy_i^2 \quad (5.4)$$



**Abbildung 5.7:** Ein Überblick der optimierte Fensterbreite

Ein Arbeitsablauf der Algorithmen für Vorverarbeitung des Stromsignals ist in der Abbildung 5.8 dargestellt. Die Abbildung 5.8 Links zeigt die durch den Algorithmus 5.1 bestimmten Beginn-ID und Ende-ID. Zuerst wurde irgendeinen Beginn-ID und Ende-ID durch die Türschwelle 1 ausgewählt, dabei die Ströme größer als die Untergrenze sind, die durch die Türschwelle 2 bestimmt. Die Abbildung 5.8 Mitte zeigt die durch den Algorithmus 5.2 gesuchte Tal-ID und Peak-ID. Die Abbildung 5.8 Rechts zeigt die durch den Algorithmus 5.3 ermittelten Effektivwerte über den Zeitraum zwischen jeweils zwei Tälern. Der EGM ist nicht geeignet für die Bereiche, wo der hohen Gradient vorhanden ist, hier z. B. bei dem erheblichen Anstieg und dem Abstieg des Stromsignals.



**Abbildung 5.8:** Ein Arbeitsablauf der Algorithmen für Vorverarbeitung des Stromsignals

---

#### Algorithmus 5.1: ID-Suche

**Input:** Das rohe Strom- oder Spannungssignal  $y$

**Output:** Der Beginn-ID und Ende-ID von Strom- oder Spannungssignal

```

1: thr  $\leftarrow$  float                                 $\triangleright$  Untergrenze
2: begin_id, end_id  $\leftarrow$  integer, integer  $\triangleright$  Initiale ID , dabei die entsprechenden Werte
   größer als Untergrenze sein müssen
3: forward, backward  $\leftarrow$  bool, bool
4: while forward do
5:   if  $y[\text{begin\_id}] < \text{thr}$  or begin_id  $< 0$  then
6:     break
7:   end if
8:   begin_id  $\leftarrow$  begin_id - 1
9: end while
10: begin_id  $\leftarrow$  begin_id + 1
11: while backward do
12:   if  $y[\text{end\_id}] < \text{thr}$  or end_id  $\leq \text{len}(y)$  then
13:     break
14:   end if
15:   end_id  $\leftarrow$  end_id + 1
16: end while
17: end_id  $\leftarrow$  end_id - 1

```

---

### 5.2.2 Vorverarbeitung für Kraft- und Elektrodenhubsignal

Die Sensoren zur Messung des Elektrodenhubs  $H_E$  liefern den in der Abbildung 5.9 abgebildeten Verlauf, aus dem der Beginn und das Ende des Schweißprozesses ersichtlich ist. Aufgrund hoher Frequenz und Gebräuche ist es schwer, vom rohen Signal die Features

---

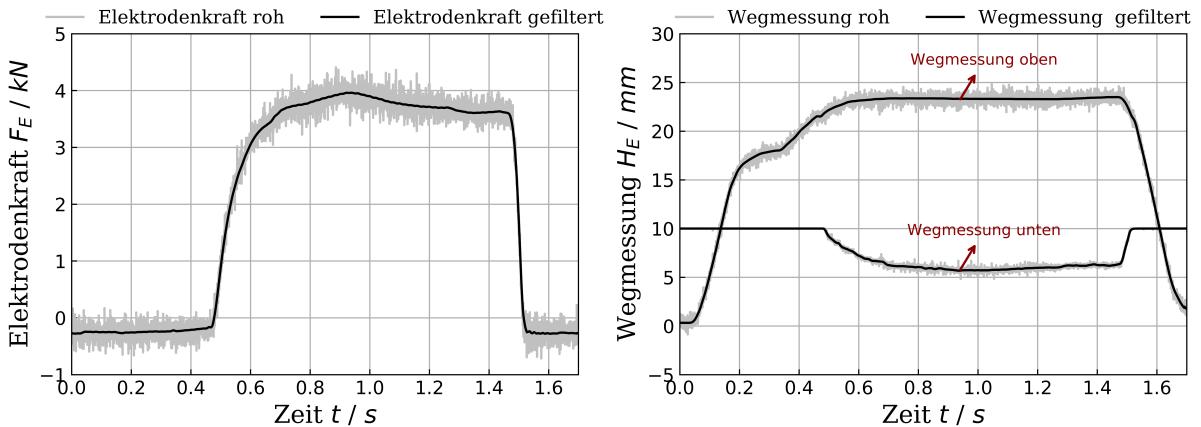
**Algorithmus 5.2:** Suche der Tal-ID und Peak-ID

**Input:** Das rohe Stromsignal  $y$

**Output:** Die Tal-IDs und Peak-IDs von Stromsignal

- 1:  $comparator\_valley \leftarrow \text{numpy.less\_equal}$   $\triangleright$  Rückgabe des Bool-Werts von  $(x1 \leq x2)$  elementweise
  - 2:  $comparator\_peak \leftarrow \text{numpy.greater\_equal}$   $\triangleright$  Rückgabe des Bool-Werts von  $(x1 \geq x2)$  elementweise
  - 3:  $order \leftarrow \text{integer}$   $\triangleright$  Anzahl der Punkte auf jeder Seite für den Vergleich
  - 4:  $y = y[\begin{begin\_id} : \end{begin\_id}]$
  - 5:  $valleyid = \text{scipy.signal.argrelextrema}(y, comparator\_valley, order) + begin\_id$
  - 6:  $peakid = \text{scipy.signal.argrelextrema}(y, comparator\_peak, order) + begin\_id$
- 

zu extrahieren. Der Kalman-Filter ist ein Satz mathematischer Gleichungen, die ein effiziente Methode zur Schätzung des Zustands eines Prozesses auf einer Weise bieten, die den Mittelwert des quadratischen Fehlers (MSE) minimiert. Der Filter ist in mehrfacher Hinsicht sehr leistungsfähig: Er unterstützt Schätzungen vergangener, gegenwärtiger und sogar zukünftiger Zustände und dies kann auch dann tun, wenn die genaue Charakter des modellierten Systems unbekannt ist [48].



**Abbildung 5.9:** Links: Das rohe und gefilterte Kraftsignal; Rechts: Das rohe und gefilterte Wegmessung

Die Abbildung 5.10 hat die Funktionsweise des Kalman-Filters dargestellt. Abschließend ist es festzustellen, dass sich unter Bedingungen, bei denen die Prozessrauschkovarianz  $Q$  und die Messrauschkovarianz  $R$  tatsächlich konstant sind, sowohl die Fehlerkovarianz  $P_k$  als auch die Kalman-Gain  $K_k$  schnell stabilisieren und dann konstant bleiben. Die Quelle der  $R$  ist ein Sensorfehler, d. h. eine Ungenauigkeit des Sensors, die Messung in der Regel vor dem Betrieb des Filters gemessen werden. Die  $Q$  könnte z. B. durch äußere Störungen

---

**Algorithmus 5.3:** Effektivwert mit EGM

**Input:** Das rohe Strom- oder Spannungssignal  $y$

**Output:** Der Effektivwert von Strom- oder Spannungssignal  $\bar{y}$

```

1:  $ww \leftarrow \text{integer}$                                 ▷ Die Fensterbreite für EGM
2:  $idsearch \leftarrow \text{bool}$ 
3:  $valleyid \leftarrow \text{array}$ 
4:  $begin\_id, end\_id \leftarrow \text{integer, integer}$ 
5:  $e, repeat\_num, \bar{y} \leftarrow [ ], [ ], [ ]$ 
6: if  $idsearch$  then ▷ Ist keine Beginn-ID, Ende-ID und Tal-ID zuzugeben, können die
   Algorithmen ID_search() und find_valley_id() die herausfinden
7:    $begin\_id, end\_id \leftarrow \text{def.ID\_search()}$ 
8:    $valleyid \leftarrow \text{def.find\_valley\_id()}$                 ▷ Tal-ID des Stromsignals
9: end if
10:  $y \leftarrow y[begin\_id : end\_id]$                          ▷ Abschnitt des Signals im Zeitbereich
11: for  $i = 0 \rightarrow \text{len}(valleyid) - 1$  do           ▷ wie viele Zahlen zwischen je zwei Täler
12:    $d \leftarrow valleyid[i + 1] - valleyid[i]$ 
13:    $repeat\_num.append(d)$ 
14: end for
15: for  $k \in valleyid[: -1]$  do                           ▷ Effektiver Wert je Fensterbreite
16:    $i \leftarrow np.where(valleyid == k)[0][0]$ 
17:    $a \leftarrow repeat\_num[i]$ 
18:   for  $_ \in \text{range}(ww - 1)$  do
19:      $i \leftarrow i + 1$ 
20:      $a \leftarrow a + repeat\_num[i]$ 
21:   end for
22:    $y_{k,eff} \leftarrow \sqrt{\frac{y[k+np.arange(a)]^2}{\text{len}(a)}}$ 
23:    $e.append(y_{k,eff})$ 
24: end for
25: for  $n, y_{k,eff} \in \text{zip}(repeat\_num, e)$  do      ▷ Effektiver Wert in jedem Moment
26:   for  $_ \in \text{range}(n)$  do
27:      $\bar{y}.append(y_{k,eff})$ 
28:   end for
29: end for

```

---

verursacht, deren Bestimmung in der Regel schwierig ist, da es normalerweise nicht in der Lage ist, den geschätzten Prozess direkt zu beobachten. Aufgrund der unbekannten  $R$  von Weg- und Kraftsensor hat ein kleiner Wert für die Sensoren angenommen. Der auf Funktionsweise des Kalman-Filters basierende Algorithmus 5.4 kann eine gute Wirkung auf dem Filtern des Kraft- oder Elektrodenhussignal ausüben. Angenommen  $R = 1e^{-2}$ , ist es in der Lage, durch Änderung der  $Q$  das Ziel zur Optimierung des Filters zu erreichen.

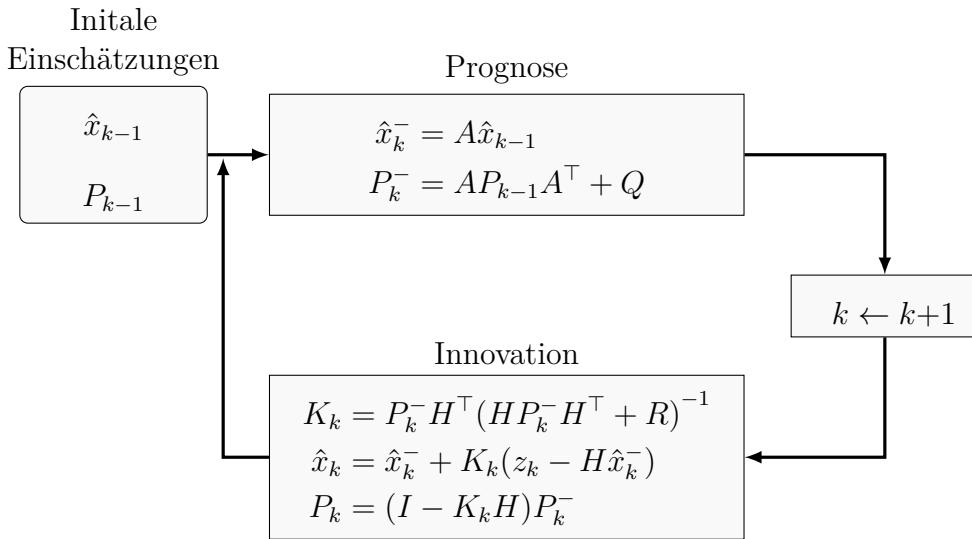


Abbildung 5.10: Funktionsweise des Kalman-Filters

Hier wurden drei Kriterien zur Bestimmung der  $Q$  eingesetzt, jeweils die Varianz, MSE, und Signal-Rausch-Verhältnis (SNR). Während mit abnehmendem  $Q$  die SNR und MSE angestiegen sind, ist die Varianz abgenommen. Die optimiert  $Q$  sollte vor plötzlicher Änderung der Kriterien stehen, damit das gefilterte Signal einen relativ kleinen MSE halten und gleichzeitig bessere SNR und kleinere Varianz besitzen kann, wie z. B. bei  $Q = 5e^{-8}$ . Das gefilterte Signal mit abnehmendem  $Q$  hat in x-Achse eine immer größere Phasenverschiebung besteht. Bei  $Q = 0$  ist der Filtereffekt sehr glatt, jedoch führt dies zur Divergenz des Filters und mehr MSE, wenn  $Q$  groß ist, ist der Filtereffekt schlechter. Allerdings kann diese Phasenverschiebung aufgrund Divergenz des Filters durch Verwendung der EGM Methode kompensiert wird. Weil die Reichungen der Phasenverschiebung von EGM und Kalman-Filter gegenseitig in diesem Fall sind, ist es eine Möglichkeit, eine Kombination der zwei Methoden zu benutzen, was das gefilterte Signal nicht nur niedrigeren MSE haben sonder auch glatter mit geeigneter Fensterbreite sein lässt. Die Abbildung 5.9 zeigt die durch die kombinierte Methode gefilterten Signals.

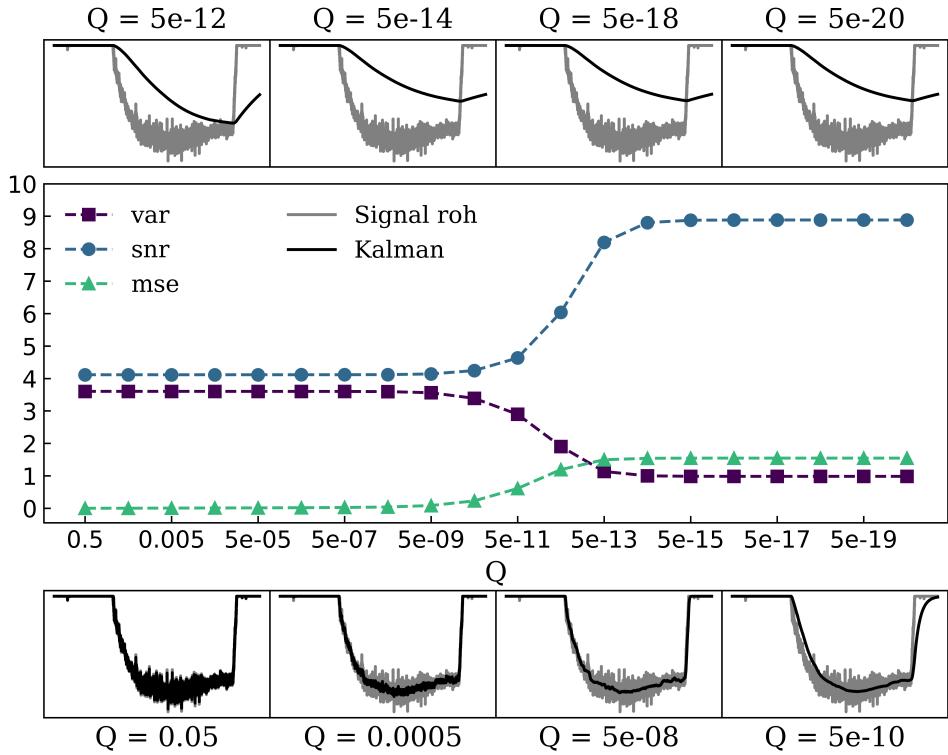


Abbildung 5.11: Suche des optimierten Q Parameters

**Algorithmus 5.4:** Kalman-Filter**Input:** Das rohe Kraft- oder Elektrodenhussignal  $z$ **Output:** Das gefiltert Kraft- oder Elektrodenhussignal  $\hat{x}$ 

- ```

1:  $x \in R^1$                                      ▷ Zustandsschätzung
2:  $P \in R^1$                                      ▷ Geschätzte Fehlerkovarianz
3:  $z \in R^1$                                      ▷ Messung
4:  $A \leftarrow 1$ 
5:  $H \leftarrow 1$ 
6:  $n \leftarrow \text{len}(z)$                          ▷ Iteration
7:  $R \leftarrow 1e^{-2}$                            ▷ Messrauschkovarianz, angenommen, dass sie konstant sind
8:  $Q \leftarrow Q$                                ▷ Prozessrauschkovarianz, angenommen, dass sie konstant sind
9:  $\hat{x}_0 = z_0$ 
10:  $P_0 = 1$ 
11: for  $k = 1 \rightarrow n$  do
12:    $\hat{x}_k^- \leftarrow \hat{x}_{k-1}$ 
13:    $P_k^- \leftarrow P_{k-1} + Q$ 
14:
15:    $K_k \leftarrow P_k^- (P_k^- + R)^{-1}$ 
16:    $\hat{x}_k \leftarrow \hat{x}_k^- + K_k (z_k - \hat{x}_k^-)$ 
17:    $P_k \leftarrow (1 - K_k) P_k^-$ 
18: end for

```

## 5.3 Einspeichern

Das Einspeichern ist verantwortlich dafür, neuen Datensatz auf der Festplatte aufzubauen und die benötigen Daten und Bilder in entsprechender Kategorie zu speichern. Die Strukturen vom neuen gebauten Datensatz ist in der Abbildung 5.12 dargestellt. Im Ordner *XXX\_ALL* wurden die alle Features als .dat-Datei gespeichert und die Ordner *XXX\_TEST*, *XXX\_TRAIN* speicherte die Features zum Test und Training. Die von TDMS-Datei gelesene Messdaten und Eigenschaften der Schweißparameter als .csv- und .dat\_h-Datei wurden im Ordner *XXX\_CSV* gespeichert. Die vorverarbeiteten Signale wurden als .csv-Datei im Ordner *XXX\_EFF* gespeichert. Die Ordner *XXX\_PIC* speicherte die Bilder.

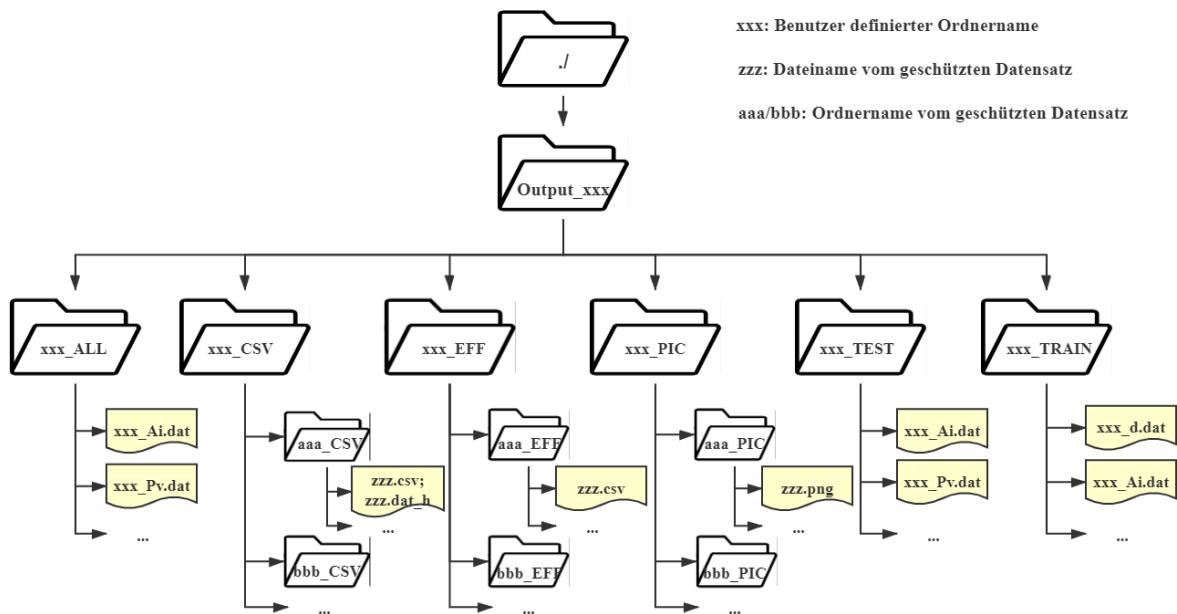


Abbildung 5.12: Struktur vom neuen aufgebauten Datenbasis

# **6 Bestimmung der Qualitätspараметер**

Die durch Sensoren gemessenen Prozessparameter sind wichtig für Qualitätsbewertung. Die rohen Signale haben schon nach im Abschnitt 5.2 erwähnten Algorithmen zum Filtern gefiltert, was vorteilhaft für Extraktion der Features. Die aus den gefeilten Signale extrahieren Features müssen das Prozessverhalten unter den verschiedenen Bedingungen widerspiegeln, und die gemessenen Variablen müssen den Unterschied zwischen bestimmten Prozesszuständen ermöglichen. Die Durchmesser oder Brucharten wurden durch die Meißelprüfung oder die Torsionsprüfung ermitteltet. Jedoch waren die Spannungssignale bei der Elektrodenverschleißuntersuchung aufgrund irgendeinem Fehler nicht nutzbar außerhalb der Stufe 5, deswegen wurden die Analysen der Qualitätsparameter um Stufe 5 durchgeführt.

## **6.1 Qualitätspараметер bei Elektrodenverschleißuntersuchung**

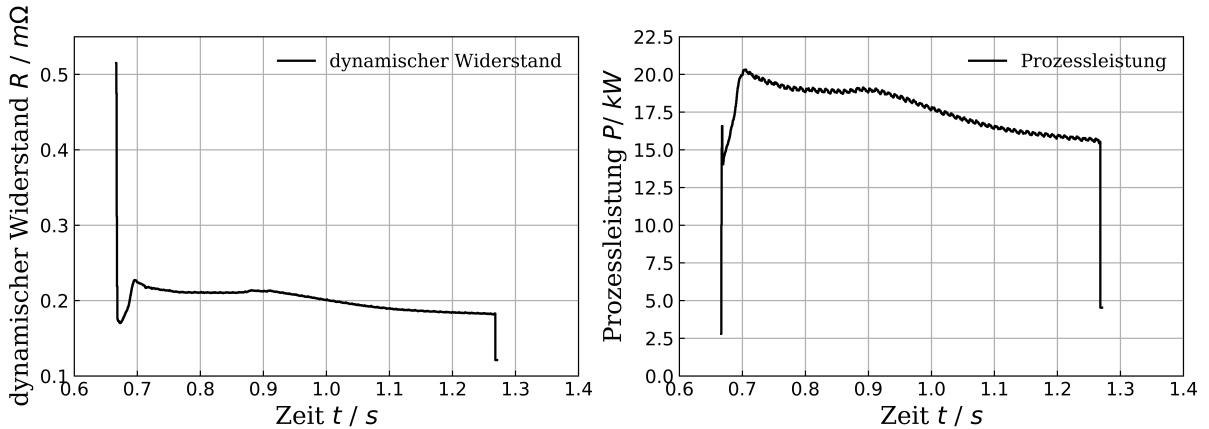
Die Oberflächenmessungen der Elektroden von Elektrodenverschleißuntersuchung zeigen eine kontinuierlich Wachsen der Elektrodenarbeitsfläche. Infolgedessen hat die Schweißstromdichte abgenommen, was zu verringerten Energiemenge, die in der Schweißzone zugeführt wurde, kleineren Schweißpunktdurchmessern führte, wie in Abbildung 4.1 dargestellt. Das Schweißstrom  $I_s$  hat bei  $9,2\text{ kA}$  geblieben. Aufgrund dessen waren die Signale von Kraft, Spannung und Wegmessung in der Lage, die verschiedenen Prozessverhalten wegen des Elektrodenverschleißes zu erkennen.

### 6.1.1 Aus der Schweißspannung und dem Schweißstrom gewonnene Parameter

Mit Schweißspannung und Schweißstrom lässt es sich zuerst ermöglichen, den dynamischen Widerstand (DW) und die Prozessleistung nach der Gl. 6.1 und Gl. 6.2 zu ermitteln, wobei  $t$  die ganze Prozesszeit ist .

$$R(t) = \frac{U(t)}{I(t)} \quad (6.1)$$

$$P(t) = I(t)^2 \cdot R(t) \quad (6.2)$$

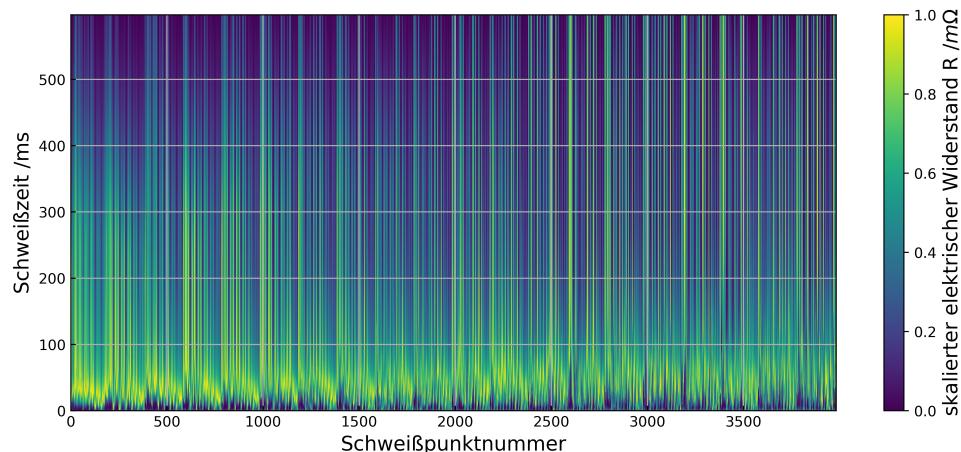


**Abbildung 6.1:** Links: ermittelter dynamischer Widerstand; Rechts: ermittelte Prozessleistung

$R(t)$  ist der dynamische Widerstand im Schweißprozess, wie in der Abbildung 6.1 Links gezeigt. Da beim Schweißen der Konstantschweißstrom verwendet wurde, ist es leicht abzuleiten, dass das Leistungskurve eine ähnliche Tendenz wie der DW aufweisen sollte. Die Abbildung 6.1 Rechts zeigt das typische Leistungskurve bei MDK1. Die Leistungskurve steigt zuerst auf einen Spitzpunkt an und zeigt dann einen absteigenden Trend, bis sie den Endpunkt erreicht. Diese Leistungsentwicklung entspricht einem bestimmten physikalischen Phänomen unter dem Schweißprozess. Die erste Anstiegesphase umfasst zwei physikalische Phänomene. Unter der Auswirkung der Elektrodenkraft und der Wärme in der Kontaktzone brechen die Unebenheiten der Oberfläche und die Kontaktfläche nimmt zu, dadurch nimmt der Widerstand ab. Da der Schweißstrom gleichzeitig erhebliche ansteigt, steigt dann die Leistung. Mit steigender Temperatur in der Schweißzone schmilzt das Metall und es bildet sich ein Linsen. Der Effekt des spezifischen Widerstand spielt eine führende Rolle, während der Strom in dieser Phase konstant ist, was zu einer Erhöhung der Leistungskurve führt. In der abnehmenden Phase überwältigen die Auswirkung

des vergrößerten Linsendurchmessers und des abnehmenden Schweißstroms die anderen Effekte. Deswegen nimmt die Kurve bis zum Erreichen des Endpunkts ab.

Von der Abbildung 6.2 ist es deutlich zu beobachten, dass DW beim ersten 10% (ca. 60 ms) größere Änderung hat, aber mit der Zeit die Änderung je 60 ms zu niedrig kommt. Nach Korrelationsanalyse[45] hat der Endwiderstand des Prozesses große Abhängigkeit von Linsendurchmesser bewiesen. Deswegen könnte der gemittelte DW vom letzten 10% des Schweißprozesses eine signifikante Feature sein. Die vom ersten 10% und letzten 10% von DW gemittelten Werte  $R_{10}$ ,  $R_{-10}$  mit dem Durchmesser und der Schweißpunktzahl ist in der Abbildung A.6 dargestellt.



**Abbildung 6.2:** Skalierte dynamische Widerstände der ganzen Schweißpunkte

Die Leistungskurve zeigt nicht nur einen ähnlichen Ablauf wie der DW, sondern hat in Vergleich zum DW einen größeren Einfluss auf die Wärme, die der Schweißzone zugeführt wird. Dies ist der wesentliche Faktor für Linsenbildung. In der Abbildung 6.3 sind drei Klassen der Schweißqualität und ihre entsprechenden Leistungskurven dargestellt. Der Peakwert vom Kaltschweißen scheint offensichtlich weniger zu sein, was auf eine leichte lokale Schmelze und eine unzureichende Linsenbildung hinweist. Das Leistungskurve für eines Normalenschweißen zeigt genau das typische Leistungskurve. Es ist zu beobachten, dass zwischen den Kurven bemerkenswerte Unterschiede bestehen, besonders bei Peakwert  $P_{max}$ , Zeitdifferenz  $\Delta t$ , Leistungsdifferenz  $\Delta P$  und Gradient  $P_v$  zwischen Peak- und Wendepunkt. Es ist anzumerken, dass der Zeitpunkt beim Peakpunkt für das Normalenschweißen im Vergleich zum Kaltschweißen deutlich früher aufgetreten ist. Das Leistungskurve vom Spritzer fällt nach Erreichen des Peakwert erheblich ab, da das geschmolzene Metall beim Ausstoß aus der Schweißzone spritzt. Ein Überblick für die Leistungskurven der ganzen Schweißpunkte und die extrahierten Features aus Leistungskurve mit den Durchmesser

können von der Abbildung A.4 entnommen werden.

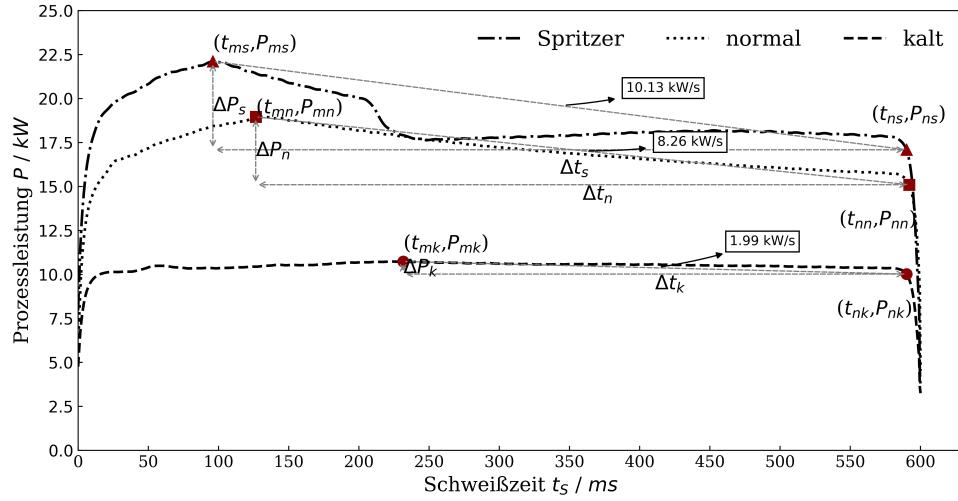


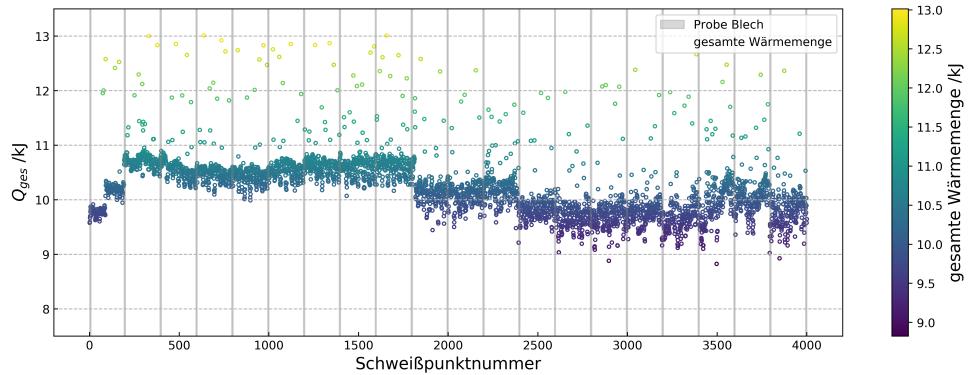
Abbildung 6.3: ermittelte Leistungskurven für verschiedene Schweißqualitäten

Die gesamte Wärmemenge  $Q_{ges}$  ist mittels der Gl. 6.3 durch die ermittelte Leistungskurve ermittelbar. Die  $Q_{ges}$  kann eine signifikante Beziehung zu den Qualitätsindikator sein, weil die  $Q_{ges}$  direkt Einfluss auf die Linsenbildung hat, die wiederum die Festigkeit, Punktdurchmesser usw. stark beeinflussen kann. Von der  $Q_{ges}$  ist es auch möglich, die partiellen Wärmemenge pro Schweißpunkt abzuleiten, z. B., wie viel Wärmemenge in einem Zeitbereich erzeugt werden, und die Summe der partiellen Wärmemenge sollte genau so wie die  $Q_{ges}$ . Im Vergleich dazu kann die  $Q_{ges}$  insgesamt eine differenzierte Aussage liefern, die für die Beurteilung des Verschleißzustands der Elektrodenkappen nicht ausreicht (Abbildung 6.4). Mit Hilfe von dem Intensitätsdiagramm der partiellen Wärmemenge können Aussagen zum Verlauf der erzeugten Wärme mit der Zeit getroffen werden (Abbildung 6.5 a).

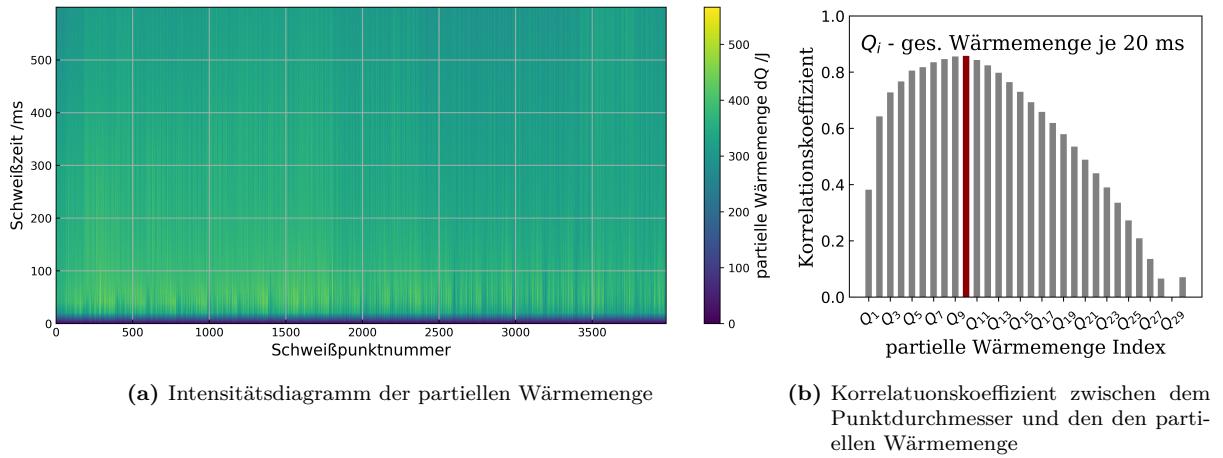
$$Q_{ges} = \int P(t) dt \quad (6.3)$$

Die  $Q_{ges}$  werden in 30 partiellen Wärmemenge  $Q_i$  mit einem Zeitschritt  $20\text{ ms}$  aufteilt. Nach der Korrelationsanalyse zwischen dem Punktdurchmesser und den partiellen Wärmemenge (Abbildung 6.5 b) werden die signifikanten partiellen Wärmemenge  $Q_{sig}$  bestimmen, die in der Zeitbereich  $180\text{...}200\text{ ms}$  unter Schweißzeit  $600\text{ ms}$  entstanden sind, und in der Zeit finden möglicherweise ein starkes Wachstum der Schweißlinse statt.

Da die partiellen Wärmemenge eine Weise zur Erklärung des Verlaufs der Wärmeerzeugung von einer Zeit-Achse ist. Infolgedessen ist ein Vergleich zwischen der theoretisch



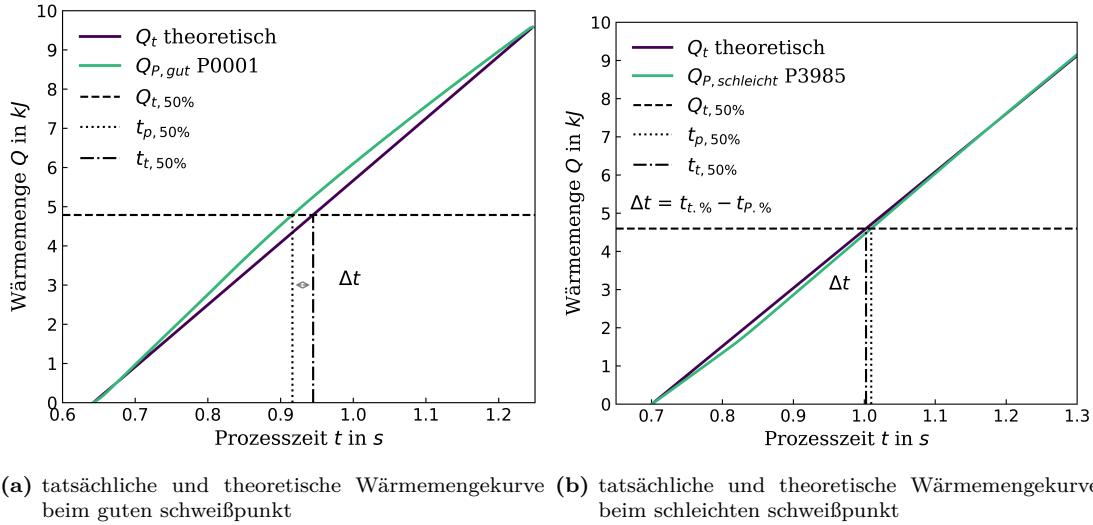
**Abbildung 6.4:** Gesamte Wärmemenge für alle Schweißpunkte bei MDK1 und Stufe 5



**Abbildung 6.5:** Intensitätsdiagramm der partiellen Wärmemenge und Korrelationskoeffizient zwischen dem Punktdurchmesser und den partiellen Wärmemengen

notwendigen- und der tatsächlich erzeugten Wärmemenge verfügbar. Es wird angenommen, dass die theoretische Wärmemenge linear während des Schweißprozesses zunimmt. Während bei einem relativ guten Schweißpunkt genügend Wärmemenge zugeführt sind, d. h. die tatsächliche Wärmemengekurve sollte meistens deutlich über die linear ansteigende theoretische Wärmemengekurve sein, ist die Wärmemenge bei einem relativ schlechten Schweißpunkt nicht ausreichend verfügbar, d. h. die tatsächliche Wärmemengekurve liegt die meiste Zeit sehr nahe an der theoretischen Wärmemengekurve oder sogar niedriger als die theoretische Wärmemengekurve. Für Extraktion einer Feature davon wird eine bestimmte Wärmemenge  $Q_{t.\%}$  zu einem bestimmten Zeitpunkt  $t_{t.\%}$  angegeben. In der Abbildung 6.6 zeigt die Situation bei  $Q_{t.50\%}$  zu  $t_{t.50\%}$ . Für einen relativ guten Schweißpunkt ist die  $t_{P.50\%}$  deutlich kleiner als  $t_{t.50\%}$ , d. h. die theoretische benötigten Wärmemenge in diesem Schweißen haben schon früher erfüllt, die Widerspiegelung auf zeit-Achse ist

$\Delta t > 0$ , dagegen ist  $\Delta t$  nahe an null oder kleiner als null. Die Tendenz von  $\Delta t$  mit der Schweißpunktnummer und dem Durchmesser ist von der Abbildung A.3 erfassbar.



**Abbildung 6.6:** Vergleich der tatsächliche und theoretische Wärmemengenkurve

Die Erwärmungsgeschwindigkeit  $\dot{Q}$  kann bei verschiedenen Prozessverhalten anders sein, wie in der Abbildung 6.6 gezeigt, dass der Gradient der zunehmenden Wärmemenge von 0 auf  $Q_{P,50\%}$  unterschiedlich ist. Wenn die Erwärmungsgeschwindigkeit zu hoch ist, überhitzt sich die Fügezone, was häufig zu einem Spritzer führt. Wenn die Erwärmungsgeschwindigkeit zu niedrig ist, beginnt die Wärmeableitung in den Elektroden und Bleche, was bedeutet, dass zu wenig Wärme verfügbar ist, um die Metalle der Fügezone zu schmelzen. Dies kann zu einem zum kleinen Punktdurchmesser führen. Die Abbildung 6.7 zeigt den Erwärmungsgeschwindigkeit. Der erwartete Wert ergibt sich aus Gl. 6.4, wobei  $n$  die aktuelle Schweißpunktnummer ist. Die Bewertung des aktuellen Schweißpunktes erfolgt durch Grenzbereiche. Die Grenzbereiche sind nach dem Kriterium  $P_{M12} : \notin [\mu(\dot{Q}) - 0.1\mu(\dot{Q}) : \mu(\dot{Q}) + 0.2\mu(\dot{Q})]$  [31] bestimmt. Mit Schweißpunktnummer zeigt die  $\dot{Q}$  eine absteigende Tendenz. Die  $\dot{Q}$  mit dem Punktdurchmesser ist in der Abbildung A.3 dargestellt.

$$\mu_n(\dot{Q}) = \frac{1}{n} \sum_{i=1}^n \dot{Q}_i(P_i) \quad (6.4)$$

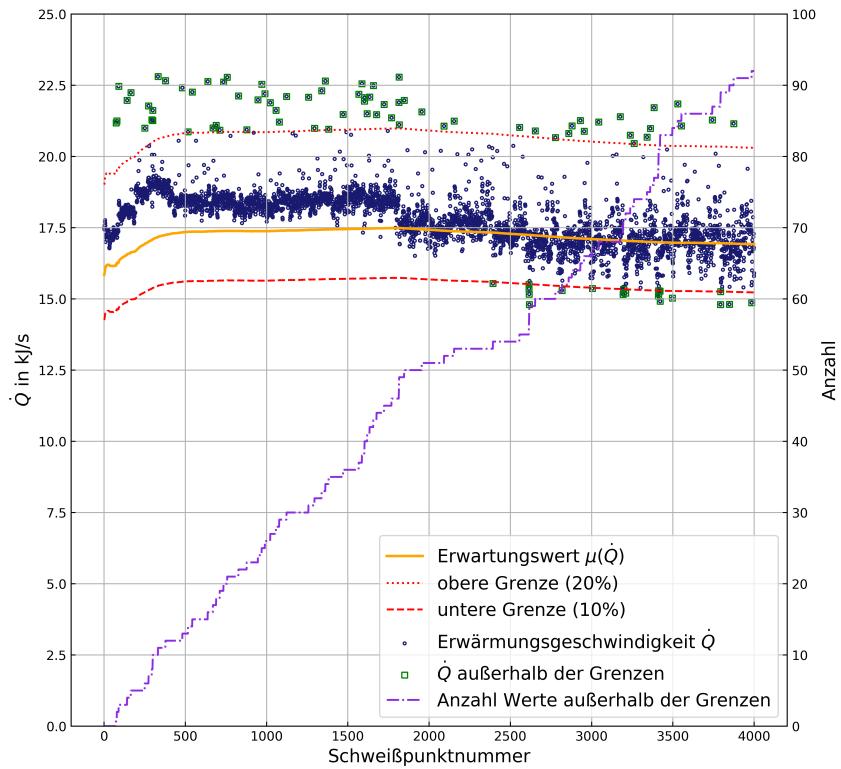


Abbildung 6.7: Erwärmungsgeschwindigkeiten mit der Schweißpunktnummer

### 6.1.2 Aus der Kraft und dem Elektrodenhub gewonnene Parameter

Die durch den Verschleiß verursachte Materialverlust aus der Elektrodenoberfläche und die Zinkablagerung Zusammenwirken führt zu einer Längeänderung der Elektroden. Von der Wegmessung der Elektroden ist es in der Lage, die geschätzte Längenänderung der Elektroden zu ermitteln. Die Abbildung 6.8 a zeigt die Wegmessungen von Anode beim ersten und letzten Schweißpunkt. In gewisser Weise könnte die Wegdifferenz  $\Delta S$  die Längenänderung aufgrund der Materialverlust oder Zinkablagerung der beiden Elektroden widerspiegeln, d. h.  $\Delta S$  kann die Summe der Längenänderung von oben und von unten sein, es ist angenommen, dass die Längenänderung von oben und von unten gleich sind. Die Abbildung 6.8 b bezeichnet eine fallende Tendenz der Längenänderung mit der Schweißpunktnummer. Die Schwankungen der Daten können durch Anhaftungen von Schweißspritzen oder anderen Verunreinigungen auf den Elektrodenarbeitsflächen verursacht werden.

Aufgrund der gegebenen Ausgangszustand der Elektroden ist es mittels der Geometrie von Kugelsegment möglich, die theoretische Elektrodenarbeitsfläche  $A_{ab}$  zu berechnen. Weiteres ist es mit gemittelter Elektrodenkraft aus dem Kraftsignal in der Schweißzeit in der Lage, den theoretischen Elektrodendruck  $p_{ab}$  zu ermitteln.

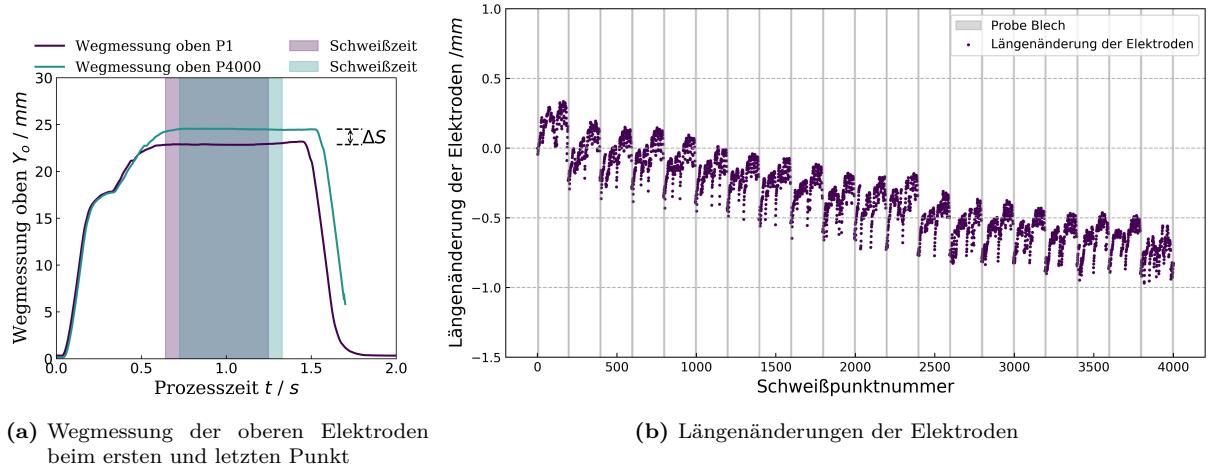
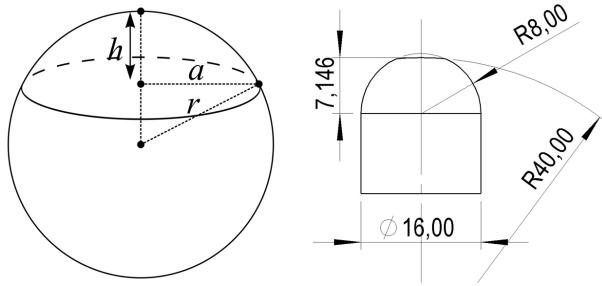


Abbildung 6.8: obere Wegmessungen und Längenänderungen der Elektroden



$$a_i = \sqrt{2rh_i - h_i^2}$$

$$A_{ab,i} = \pi \cdot a_i^2$$

$$p_{ab,i} = \bar{F}_i / A_{ab,i}$$

$$h_0 = r - 7,416$$

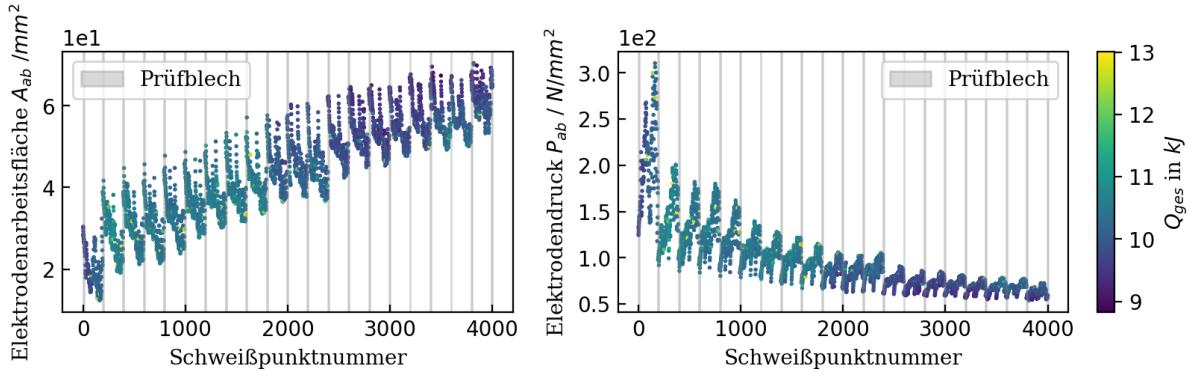
$$h_i = h_0 + \Delta S / 2$$

$$p_{ab,i} = \bar{F}_{E,i} / A_{ab,i}$$

wobei  $i : 1 \dots 4000$ ;  $r = 8 \text{ mm}$

In Abbildung 6.9 Links sind die Änderungen der Elektrodenarbeitsfläche dargestellt. Hier ist es zu erkennen, dass die Längenänderung der Elektroden zu einer Vergrößerung der Arbeitsfläche führt. Die zunehmenden  $A_{ab}$  kommt zu einen abnehmenden  $Q_{ges}$  hauptsächlich aufgrund der mit  $A_{ab}$  verringerten Stromdichte. Der spezifische elektrische Widerstand  $\rho$  jedes Schweißpunkts kann als eine synthetische Feature betrachtet, die von der Gl. 6.5 abgeleitet wird, wobei  $L$  die Restgesamtblechdicke und  $R_{10}$  der gemittelte dynamische Widerstand von erstem 10% des Schweißprozesses ist. Da am Anfangen der Schweißzeit die Metallen in der Fügezone noch nicht stark geschmolzen haben, kann die Blechdicke kaum große Änderung in vertikaler Richtung im Vergleich zu der Ausgangszustand beibehalten, aus diesem Grunde dürfen die  $L$  als die Gesamtblechdicke beim Blechausgangszustand betrachtet werden. Die  $\rho$  mit der Schweißpunktzahl und Punktdurchmesser ist in der Abbildung A.6 dargestellt.

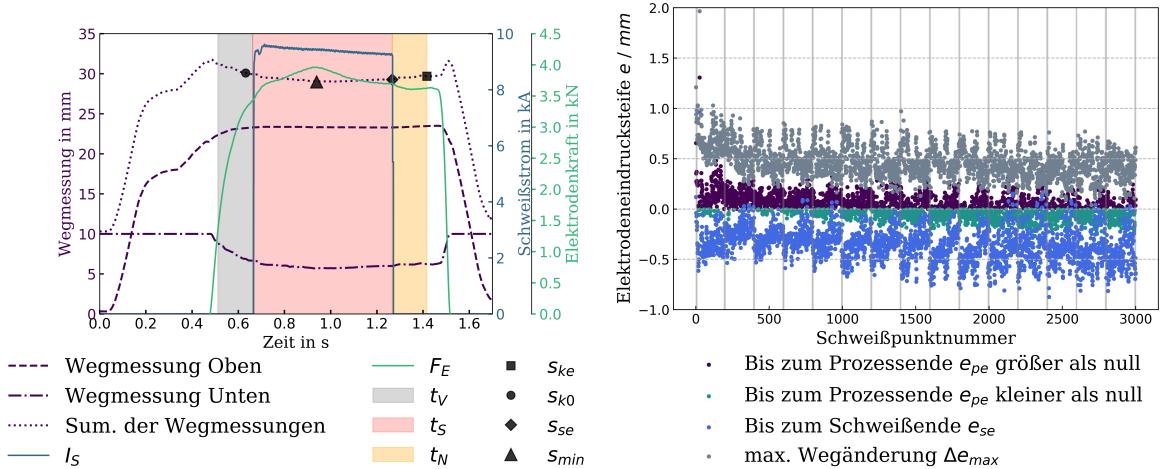
$$\rho_i = \frac{R_{10,i} \cdot A_{ab,i}}{L} \quad (6.5)$$



**Abbildung 6.9:** Veränderung der Elektrodenarbeitsfläche (Links) und Elektrodendruck (Rechts)

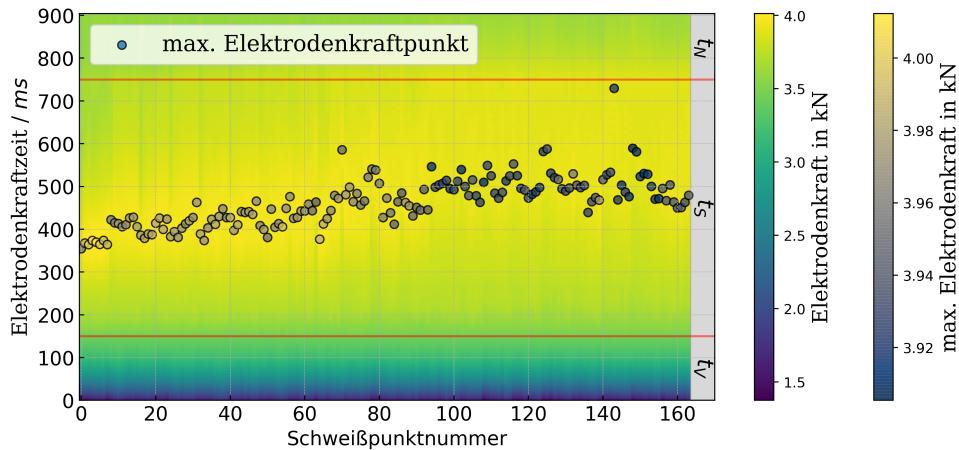
In Abbildung 6.9 Rechts sind die Änderungen der Elektrodendruck dargestellt. Die zunehmenden  $A_{ab}$  führen übrigens zum verringerten Elektrodendruck  $p_{ab}$ . Vom Anfang bis ca. 2000 ist die Abstiegsgradient relativ steiler als die nachfolgenden Abstiegsgradient, d. h. der Verschleiß der Elektroden am Anfang wegen kleiner  $A_{ab}$  stärker, aber mit der zunehmenden  $A_{ab}$  und abnehmenden Stromdichte kommt der Einfluss des Verschleißes auf die Arbeitsfläche in radialer Richtung zu klein. Die Verringerung des Elektrodendrucks ist aus der Sicht der Elektrodeneindrucktiefe (Abbildung 6.10 b) auch deutlich zu erkennen. Hier werden 4 Punkte (Abbildung 6.10 a) beim bestimmten Zeitpunkt von der Kurve der Summe von Wegmessungen extrahiert, jeweils die Summe der Wegmessungen bei Vorhaltzeit  $S_{k0}$ , Prozessende  $S_{ke}$ , Schweißende  $S_{se}$  und der minimale Summe der Wegmessung  $S_{min}$ . Prinzipiell ist die Differenz zwischen  $S_{ke}$  und  $S_{k0}$  die Elektrodeneindrucktiefe von beiden Elektroden über den ganzen Prozess, nämlich  $e_{pe}$ , und die Differenz zwischen  $S_{se}$  und  $S_{k0}$  ist die Elektrodeneindrucktiefe von beiden Elektroden über Schweißzeit, nämlich  $e_{se}$ , und von der Differenz zwischen  $S_{ke}$  und  $S_{min}$  ist die maximale Wegänderung während des Prozesses zu erkennen, nämlich  $\Delta e_{max}$ , die näher an der Summe der tatsächlichen Eindrucktiefe von beiden Elektroden ist. Die extrahierten Features aus Wegmessung mit Schweißpunktzahl und Punkt durchmesser ist in der Abbildung A.2 dargestellt.

Während des Schweißprozesses wurde die Bleche sich ausdehnen aufgrund von Hitze, besonders wenn die Innenmaterialien geschmolzen wurden. Aufgrund von Elektrodenverschleiß mit der zunehmenden Schweißanzahl werden die elektrischen Stromdichte mit zunehmender Kontaktfläche abnehmen, was zu einer Abnahme des Wärmeeintrags in der Fügezone führt. Die Kraftsensor könnte eine Reaktion auf die Ausdehnung durch die maximale Elektrodenkraft und das entsprechend auftretende Zeitpunkt haben, wie die Abbildung 6.11 gezeigt ist. Mit der Schweißpunktzahl nimmt die maximale Elektro-



**Abbildung 6.10:** Veränderung der Elektrodeneindrucktiefen und die Extraktion der Features

denkraft ab, während der entsprechende auftretende Zeitpunkt später kommt. Deswegen könnte der Anstiegsgradient  $S_1$  vom Beginn der Schweißzeit bis zum Zeitpunkt bei maximaler Elektrodenkraft eine signifikante Feature sein. Der  $S_1$  mit Schweißpunktnummer und Punktdurchmesser ist in der Abbildung A.5 dargestellt.



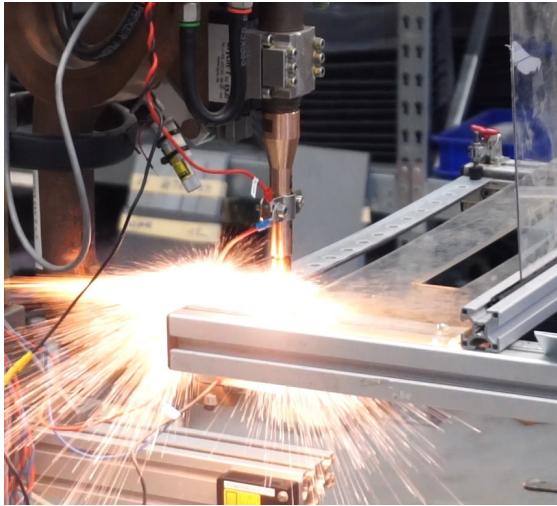
## 6.2 Qualitätsparameter bei verschiedenen Stromstärken

Wie der Abschnitt 3.3 erwähnt hat, dass das Experiment die Einfluss der Stromstärke auf der Schweißpunktqualität untersuchte. Die meisten zur Qualität relevanten Parameter und die Methoden zur Extraktion der Features sind genau so wie in der Eletrodenverschleißuntersuchung allerdings mit solchen Ausnahmen, dass die Features, die um Elektrodenarbeitsfläche gehen, nicht berücksichtigt sind, weil der Einfluss des Verschleißes der Elektrode bei weniger Schweißanzahl im Vergleich zum Einfluss der Stromstärke auf die Schweißpunktqaulität wenige Rolle gespielt hat. Allerdings gibt es aufgrund extremer Strömstärke, z. B. extrem groß oder extrem klein, etwas besonderes Prozessverhalten, die kaum oder selten in in der Eletrodenverschleißuntersuchung passiert sein könnten. Die genauen Qualitätsparameter bei verschiedenen Stromstärken ist in dem graphischen Anhang A.2.2 entnehmbar.

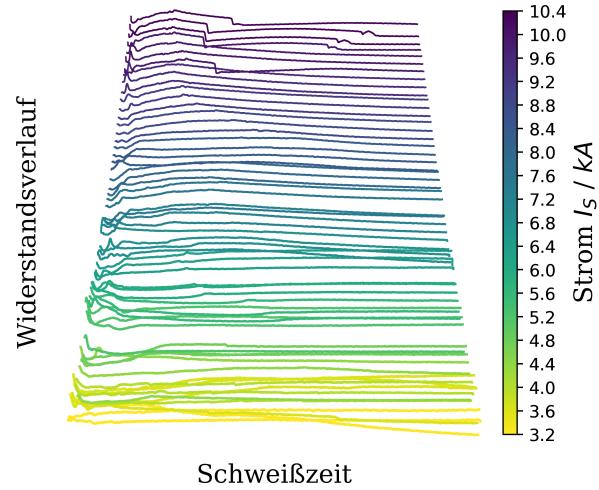
### 6.2.1 Spritzer Diagnose

Aufgrund hohes Schweißstroms in diesem Versuch ist das Spritzer-Phänomen aufgetreten, wie in Abbildung 6.12 gezeigt. Während des ohne Spritzer Prozesses tendiert der DW nach dem Ende des Kontaktwiderstands allmählich zu flach mit einer kleinen Amplitudenschwankung zwischen benachbarten Punkten. Wenn ein Spritzer auftritt, gibt es einen oder mehreren sofortigen Abfall (Abbildung 6.13). Aufgrund des sofortigen Abfalls von DM sind die Stromsignal, Spannungssignal sowie Leistungskurve ebenfalls beeinflusst. Nach dem ohmschen Gesetz steigt mit dem abnehmenden elektrischen Widerstand der Strom aber sinkt die elektrische Spannung wegen der Materialverlust beim Spritzer, wie in der Abbildung 6.14 dargestellt. Bei der Anwendung einer Konstantstromregelung werden das Stromsignal nach der plötzlichen Änderung auf den vorher eingestellten Wert zurückkehren. Deswegen könnte die Größe der Stromänderung  $\Delta I$ , die normalerweise nach dem Erreichen auf dem eingestellten Strom und vor dem Verschwinden des Stroms geschehen ist, ein Feature zur Diagnose des Spritzers sein. Je größer  $\Delta I$  wäre, desto stärker könnte der Spritzer während des Schweißens sein.

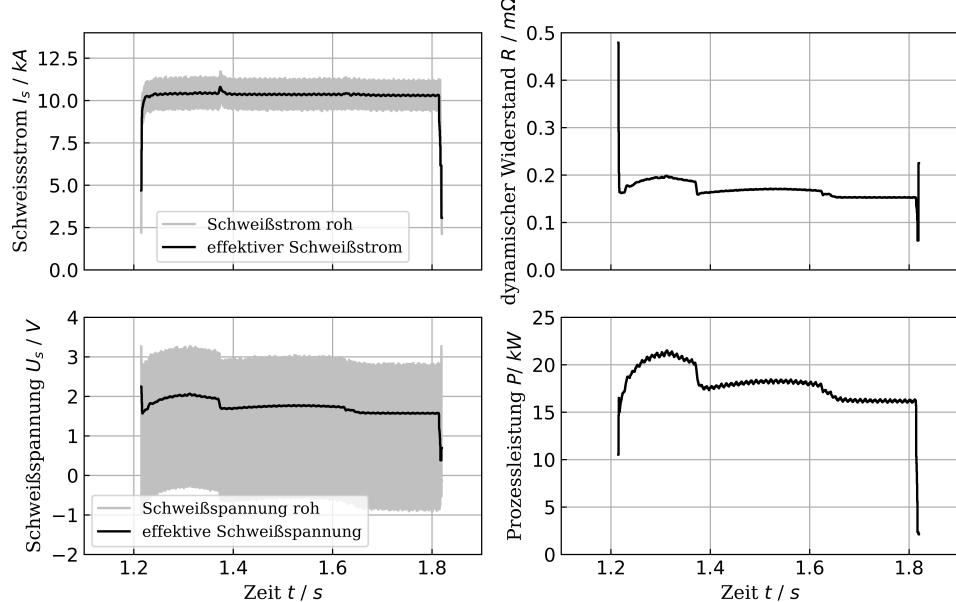
Ist das Strom groß genug, steigt auch der lokale Wärmemenge an den Kontaktflächen dünner Stähle. Daher fallen die Elektrodenkräfte aufgrund des Austreibens von geschmolzenen Innenmaterialien durch die große in der Fügezone der Bleche zugeführt Wärmemenge. Deswegen besteht es die Möglichkeit, die Features, die aus dem Kraftsignal extrahiert werden,



**Abbildung 6.12:** starker Spritzer während des Schweißprozesses



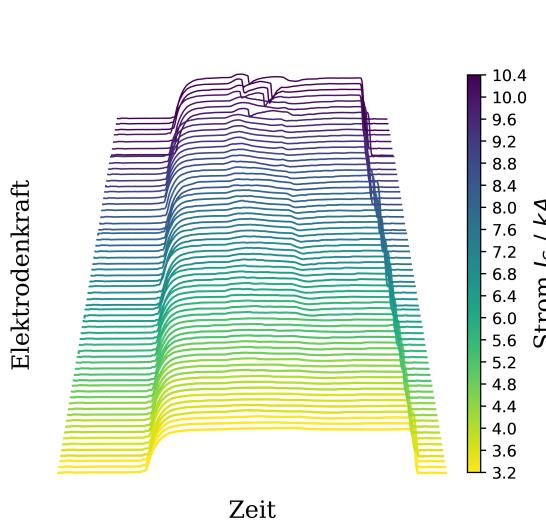
**Abbildung 6.13:** dynamische Widerstände der Schweißpunkte in dem Stromstufenversuch



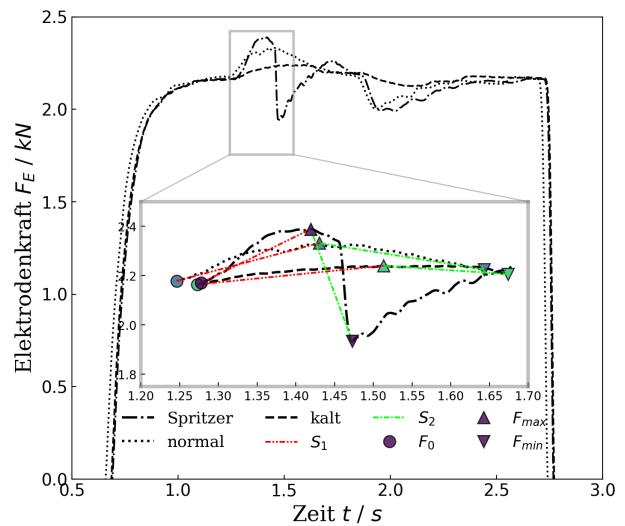
**Abbildung 6.14:** Signalverhalten beim Spritzer

zur Klassifizierung der Qualität zu verwenden [37]. Wie in der Abbildung 6.15 gezeigt, haben die Kraftsignale mit dem zunehmenden Schweißstrom mehr Schwankung aufgrund der Ausdehnung der Bleche unter den Wärmeeinträgen in der Fügezone, besonders beim Spritzer. Die Abbildung 6.16 zeigt die Kraftsignale für drei typische Schweißpunktqualitäten und die davon ausgewählten Teile der Signale, die ein paar signifikante Features beinhalten. Die  $F_0$  ist die Elektrodenkraft beim Beginn der Schweißzeit. Während beim

Kaltschweißen die  $F_{max}$  mit niedrigstem Wert aufgrund der nicht ausreichenden Wärmemenge am spätesten aufgetreten hat, hat die  $F_{max}$  mit höchstem Wert beim Spritzer am frühesten erscheint, sodass die Anstiegsgradienten  $S_1$  bei drei Prozessverhalten Von  $F_0$  bis maximale Elektrodenkraft  $F_{max}$  anders sein könnten. Aufgrund des sofortigen Abfall von Kraftsignal beim Spritzer könnte der Abstiegsgradient  $S_2$  von  $F_{max}$  bis  $F_{min}$ , die seit dem Zeitpunkt bei  $F_{max}$  herausgesucht hat, sehr groß sein, aber wegen kleiner Schwankung könnte  $S_2$  beim Kaltschweißen im Vergleich zum Normalschweißen und Spritzer sehr klein sein. Die von Kraftsignal extrahierten Features mit der Schweißpunktnummer und dem Punktdurchmesser ist in der Abbildung A.11 dargestellt.



**Abbildung 6.15:** Elektrodenkräfte der Schweißpunkte in dem Stromstufenversuch



**Abbildung 6.16:** Elektrodenkräfte für verschiedene Schweißqualität

## 6.3 Zusammenfassung der Qualitätsparameter

In diesem Kapitel werden viele Parameter zur Qualitätsbewertung nach der statischen Analyse bestimmt. Da WPS ein sehr komplexes Prozess mit der Multiphysik ist, ist es schwierig, alle relevanten Features von verfügbaren Signalen zu extrahieren. Die von oben erwähnten Features waren von Stromsignal, Spannungssignal, Kraftsignal, Wegmessung sowie die von solchen Signalen abgeleiteten anderen Kurven oder physikalischen Größen entnommen (Tabelle 6.1). Allerdings haben nicht alle Features wichtige Bedeutung für Qualitätsbewertung, und die Beziehungen zwischen Features und Punktdurchmesser oder Klasse der Qualität könnten nichtlinear sein, deswegen waren die Verwendung von linearen

Regressions- oder Klassifikationsmodelle nicht eine geeignete Entscheidung zu treffen.

**Tabelle 6.1:** zusammengefasste extrahierte Features

| Strom- und Spannungssignal |                                                        | Kraftsignal und Wegmessung |                                                      |
|----------------------------|--------------------------------------------------------|----------------------------|------------------------------------------------------|
| Formel-<br>zeichnung       | Bedeutung                                              | Formel-<br>zeichnung       | Bedeutung                                            |
| $R_{10}$                   | Mittelwert der ersten 10 % des dynamischen Widerstands | $A_{ab}$                   | Elektrodenarbeitsfläche                              |
| $R_{-10}$                  | Mittelwert der letzten 10% des dynamischen Widerstands | $p_{ab}$                   | Elektrodendruck                                      |
| $P_{max}$                  | Peakwert der Leistung                                  | $\rho$                     | spezifischer elektrischer Widerstand                 |
| $\Delta P$                 | Leistungsdifferenz zwischen dem Peak- und Wendepunkt   | $e_{pe}$                   | Eindruckstiefe beim Prozessende                      |
| $P_v$                      | Abstiegsgradient zwischen dem Peak- und Wendepunkt     | $e_{se}$                   | Eindruckstiefe beim Schweißende                      |
| $Q_{ges}$                  | gesamte Wärmemenge                                     | $\Delta e_{max}$           | maximale Wegänderung                                 |
| $Q_{sig}$                  | signifikante partielle Wärmemenge                      | $S_1$                      | Elektrodenkraftanstiegsgradient                      |
| $\Delta t$                 | Zeitdifferenz von Wärmemengenkurve                     | $S_2$                      | Elektrodenkraftabstiegsgradient                      |
| $\dot{Q}$                  | Erwärmungsgeschwindigkeit                              | $\Delta F$                 | Elektrodenkraftdifferenz im ausgewählten Zeitbereich |
| $\Delta I$                 | Größe der Stromänderung beim Spritzer                  |                            |                                                      |
| $I_{soll}$                 | Soll-Schweißstrom                                      |                            |                                                      |

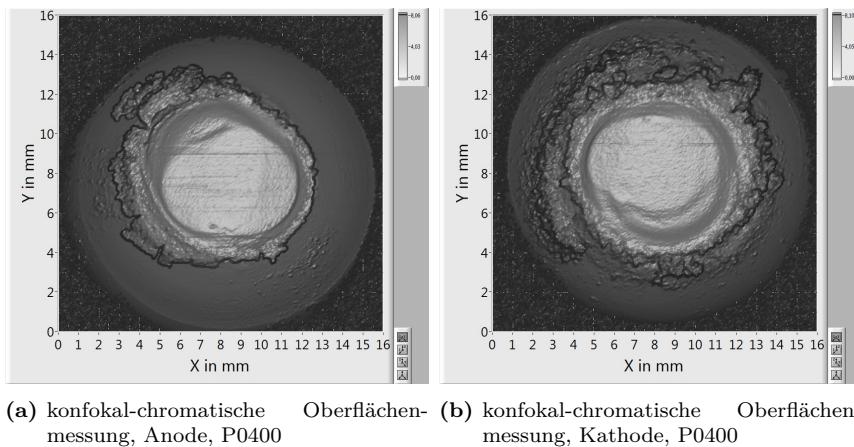
## 7 Experimentelle Testdaten

Wie in der Abbildung 5.2 dargestellt, erfordert das Modell des maschinellen Lernens Trainings-, Validierungs- und Testdaten. Die beste Lösung zur Vorbereitung der Daten ist vom gesamten Datensatz nach dem bestimmten Anteil in drei Teilen zur Training, Validierung und Test zu verteilen. Trainings- und Validierungsdaten sind verantwortlich für Trainierung der Modelle, Bewertung der Modelle, Anpassung der Parameter, Auswahl der Vorzugsmodelle. Testdaten sind zuständig für Test der Modelle und Anwendung der Modelle. Obwohl in Experiment der Elektrodenverschleißuntersuchung 5 Stufen getestet wurden, fehlten den Daten in den Stufen 1 bis 4 Spannungsdaten, so dass die in dem Unterabschnitt 6.1.1 extrahierten Features von Stufe 1 bis 4 nicht verwendet werden konnten, was bedeutet, dass nur Messdaten von Stufe 5 verfügbar zur Extraktion der Features waren. Da nur einige Punkte (fünf von acht) in Prüfblech zerstört wurden, um die Label ( $d_w$ ) zu erhalten, waren die meisten der 4000 Punkte in stufe 5 nicht gelabelt. Aufgrund der Verlust von Verschleißblech und Prüfblech machte es unmöglich, zerstörende Prüfung durchzuführen, um mehr Label zu erhalten. Daher war es notwendig, neue Experimente durchzuführen, um gelabelte Daten zum Test der Modelle zu erhalten. Zwar war die allen Schweißpunkte bei der Stufenuntersuchung der verschiedenen Stromstärken ein Label zur Verfügung gestellt, wie in den Abbildungen 4.4, 4.5 dargestellt, aber die Menge der Daten war nicht genug, sodass die Testdaten zu wenig war, wenn der Datensatz in drei Teilen verteilt wurde. Daher war es notwendig, Experimente zur Vermehrung der Testdaten durchzuführen.

## 7.1 Experimentelle Testdaten für Elektrodenverschleißuntersuchung

### 7.1.1 Versuchsvorbereitung und Berechnung

Aufgrund des hohen zeitlichen und ökologischen Aufwand bei der Stufenuntersuchung des Elektrodenverschleißs wurde eine alternative Lösung zur Simulation der Elektrodenzustand während der Elektrodenverschleißuntersuchung mittels manueller Bearbeitung der Elektrodenarbeitsfläche stattgefunden. Zuerst wurde die Elektrodenarbeitfläche von konfokal-chromatische Oberflächenmessung für Anode und Kathode, wie in der Abbildung 7.1 dargestellt, mittels der Gl. 7.1 ermittelt.



**Abbildung 7.1:** konfokal-chromatische Oberflächenmessung bei P0400

$$A_{ab,i} = \frac{\pi \cdot d_{m,i}^2}{4}; \quad d_m \approx \frac{d_x + dy}{2} \quad (7.1)$$

Infolge der Geometrie von Kugelsegment der Elektroden ist es mittels der Gl. 7.2 in der Lage, die Elektrodenlängenänderungen  $\Delta L_E$  festzustellen. Die Abbildung 7.2 zeigt die von konfokal-chromatischer Oberflächenmessung für Anode und Kathode berechneten  $A_{ab}$  und  $\Delta L_E$ . Der theoretische Trend (Abbildung 6.9 a) und tatsächliche Trend wird gegenseitig bestätigt. Aus der Perspektive der Kugelsegmentgeometrie ist der Trend so erklärt, dass die Änderung der  $A_{ab}$  immer weniger ist, auch wenn es angenommen, dass die durch Verschleiß verursachte  $\Delta L_E$  linear ansteigt wäre, weil die aufgrund der zunehmenden

$\Delta L_E$  verursachte Vergrößerung der  $A_{ab}$  in radialer Richtung basierend auf der Geometrie von Kugelsegment immer weniger ist (Abbildung 7.3). Darüber hinaus hat nahm die tatsächliche  $\Delta L_E$  auch nicht linear zu, weil der Verschließ der Elektroden aufgrund der zunehmenden  $A_{ab}$  und abnehmenden Wärmemenge in der Fügezone verringern wurde. Die konkreten Daten sind von der Tabelle B.2 erfassbar.

$$\Delta L_{E,i} = r - \sqrt{r^2 - \frac{A_{ab,i}}{\pi}} - h_0 \quad (7.2)$$

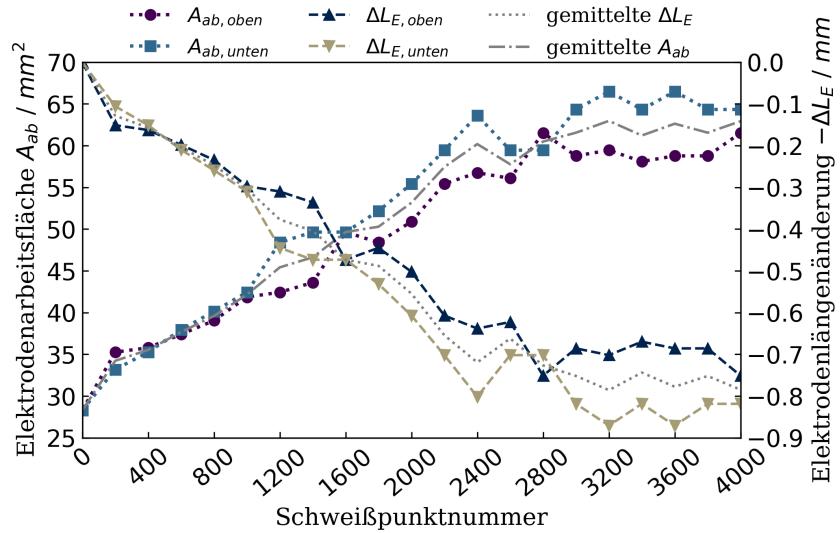


Abbildung 7.2: Elektrodenarbeitsfläche und Längenänderung

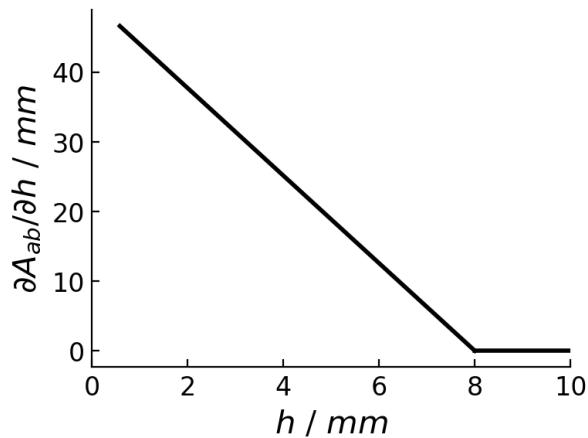


Abbildung 7.3: Theoretische Flächenwachstumsrate

In der manuellen Bearbeitung der Elektroden mittels Werkzeugmaschine muss die Genauigkeitsauswirkung diskutieren werden. Unterschiedliche Präzision hat unterschiedliche Auswirkungen auf die Ergebnisse, also können die Genauigkeiten der Schnittlänge

für Elektroden unmittelbar Einfluss auf die Elektrodenarbeitsfläche haben. Die Kugelabschnittsfläche, hier etwa Elektrodenarbeitsfläche wurde nach der Gl. 7.3 ermittelt. Um die Genaugkeitsauswirkung herauszufinden, werden die  $\Delta h$  und  $\Delta A_{ab}$  in der Gl. 7.3 eingesetzt.

$$A_{ab,i} = \pi(2rh_i - h_i^2) \quad (7.3)$$

$$\begin{aligned} A_{ab,i} + \Delta A_{ab,i} &= \pi[2r(h_i + \Delta h_i) - (h_i + \Delta h_i)^2] \\ A_{ab,i} + \Delta A_{ab,i} &= \pi(2rh_i - h_i^2) + \pi(2r\Delta h_i - 2rh_i\Delta h_i - \Delta h_i^2) \\ \frac{\Delta A_{ab,i}}{\pi} &= 2r\Delta h_i - 2h_i\Delta h_i - \Delta h_i^2 \\ (\Delta h_i^2) &\approx 0, \text{ wenn } \Delta h_i^2 \text{ zu klein ist} \end{aligned}$$

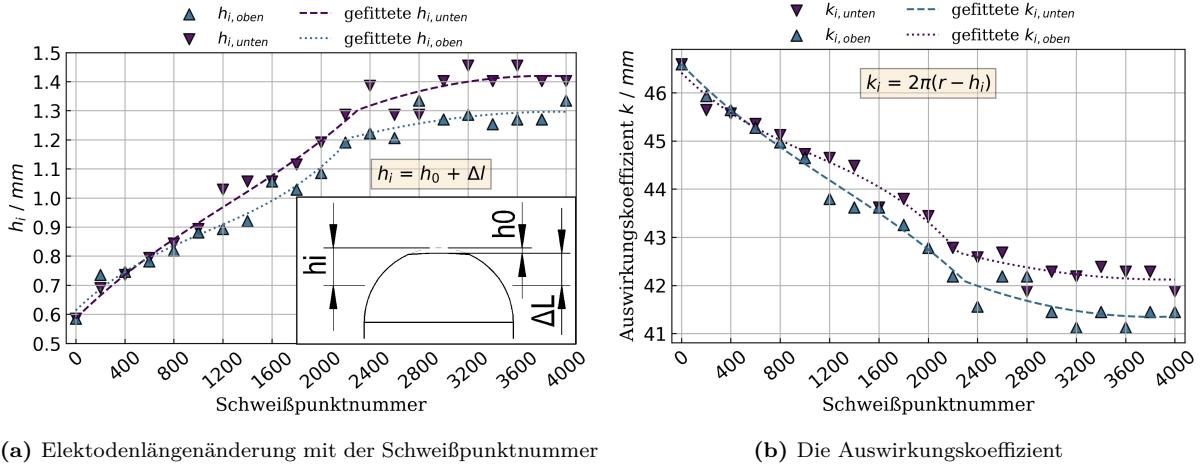
$$\Delta A_{ab,i} = 2\pi(r - h_i)\Delta h_i \quad (7.4)$$

Der Auswirkungskoeffizient  $k$  ist von der Gl. 7.4 abgeleitet:  $2\pi(r - h_i)$ . Die abgeleitete  $k$  ist abhängig von der  $h_i$ . Von der Abbildung 7.4 a ist es deutlich zu erkennen, dass der Trend der  $\Delta L_E$  mit der Schweißpunktnummer durch stückweise Funktionen 7.5 und 7.6 gefittet werden kann. Während am Anfang die Elektroden stark verschließen wurden, kam nach ca. 2200 Schweißpunkten der Gradient der  $\Delta L_E$  deutlich zu klein, besonders zum Ende fast zu null, was bedeutet, dass die  $k$  der Schnittgenauigkeit von Werkzeugmaschine dieselbe stückweise Funktionen besitzt, wie in der Abbildung 7.4 b dargestellt.

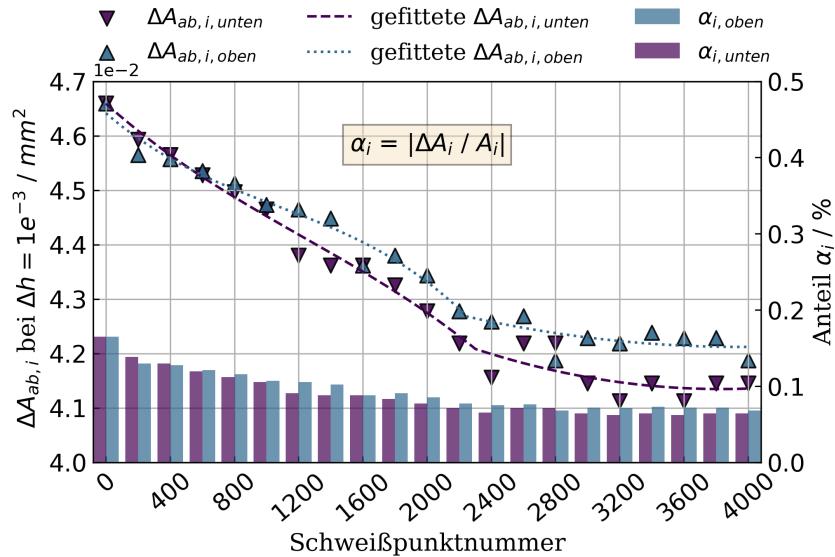
$$h_{i,unten} = \begin{cases} 3,33e^{-11}x^3 - 1,23e^{-7}x^2 + 0,42e^{-3}x + 0,59 & x \leq 2300 \\ -4,99e^{-8}x^2 + 0,38e^{-3}x + 0,68 & x > 2300 \end{cases} \quad (7.5)$$

$$h_{i,oben} = \begin{cases} 6,69e^{-11}x^3 - 2,14e^{-7}x^2 + 0,41e^{-3}x + 0,61 & x \leq 2250 \\ -3,08e^{-8}x^2 + 0,24e^{-3}x + 0,82 & x > 2250 \end{cases} \quad (7.6)$$

Die Bearbeitungsgenauigkeit von Werkzeugmaschine kann auf Tausendstel genau sein, d. h., ist  $\Delta h_i = 1e^{-3} mm$ , können z. B. die  $\Delta A_{ab,i,oben}$  nach Gl. 7.4 in  $0,0421...0,0464 mm^2$  sein und beträgt der Anteil  $\alpha_{i,oben}$  von  $\Delta A_{ab,i,oben}$  gegenüber  $A_{ab,i,oben}$  in  $0,068...0,16\%$  (Abbildung 7.5). Die positive Änderung  $\Delta h_i$  um  $1e^{-3} mm$ , d. h.  $1e^{-3} mm$  mehr Schnitt, hat mit zunehmender Schweißpunktnummer immer weniger Einfluss auf der Elektrodenarbeitsfläche.



**Abbildung 7.4:** Elektodenlängenänderung und Auswirkungskoeffizient der Schnittgenauigkeit mit der Schweißpunktzahl



**Abbildung 7.5:** Tausendstel Auswirkung der Bearbeitung für Elektrodenarbeitsflächen

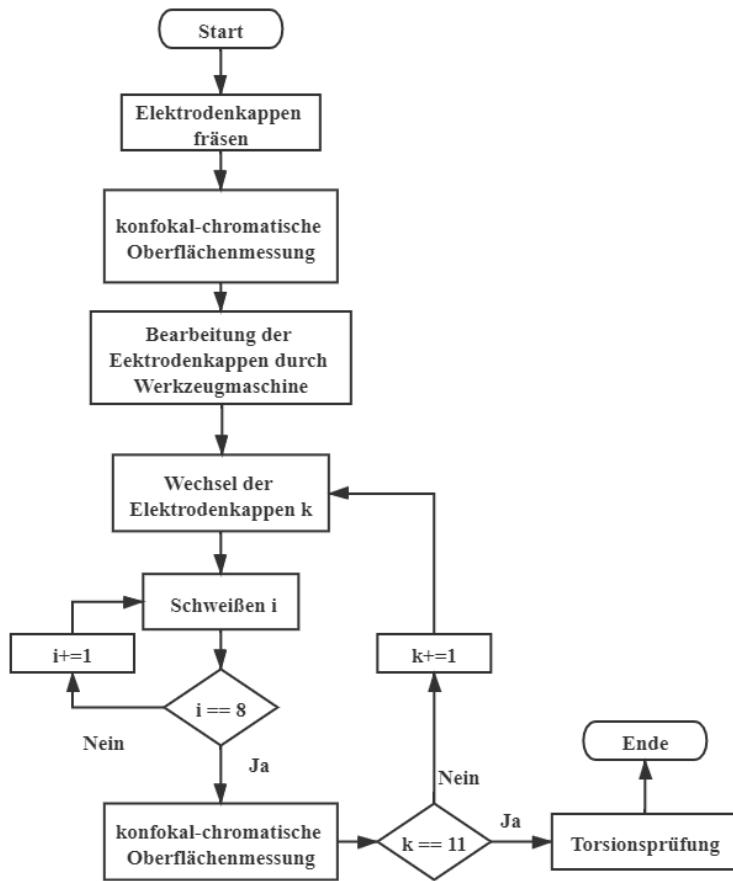
### 7.1.2 Versuchsplanung

Der Versuch wurde so geplant:

- Insgesamt 88 Schweißpunkte auf einzelnen Bleche;
- Insgesamt 22 Elektrodenkappen, 11 sind für obere Elektrode, die andere 11 sind für untere Elektrode;

- Obere Elektrodenkappen werden nach der folgenden Tabelle 7.1 bestimmte Länge weggeschnitten;
- Ausgangszustand der Elektrodenkappen werden durch konfokal-chromatischer Oberflächenmessung bestimmen;
- Untere Elektrodenkappen werden nach der folgenden Tabelle 7.1 bestimmte Länge weggeschnitten;
- Jedes Paar Elektrodenkappen werden 8 Schweißen durchgeführt;
- Endzustand von jedem Paar Elektrodenkappen nach 8 Schweißen werden durch konfokal-chromatischer Oberflächenmessung bestimmen.

Das Flussdiagramm ist in der Abbildung 7.6 dargestellt. Die Schweißbedingungen sind genau sowie Tabelle 3.10.



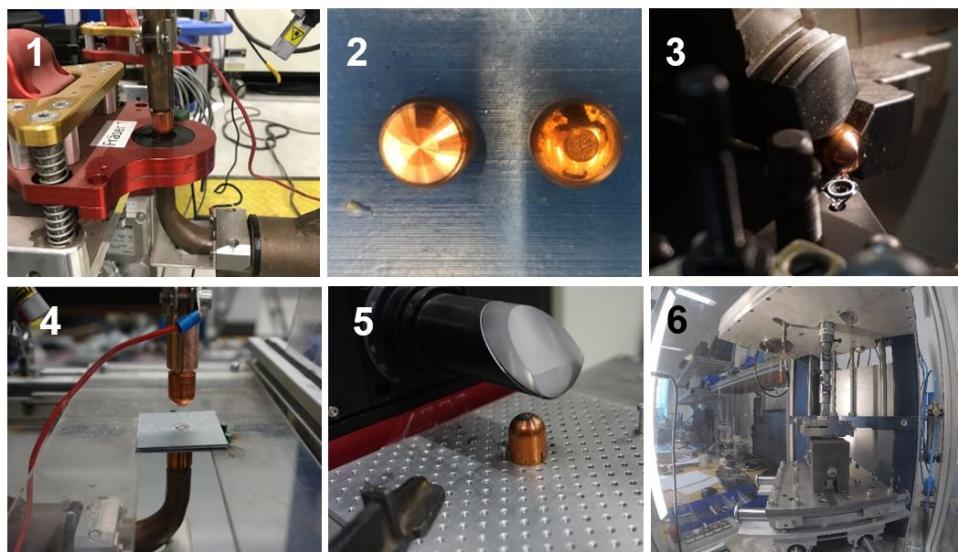
**Abbildung 7.6:** Flussdiagramm zu experimentellen Testdaten für Elektrodenverschleißuntersuchung

**Tabelle 7.1:** Die zu schneidende Länge für Elektrodenkappen nach den gefitteten Kurven

| Punktnummer | $\Delta L_{E,oben}$ [mm] | $\Delta L_{E,unten}$ [mm] |
|-------------|--------------------------|---------------------------|
| 0           | 0,00                     | 0,00                      |
| 400         | 0,16                     | 0,15                      |
| 800         | 0,25                     | 0,28                      |
| 1200        | 0,33                     | 0,39                      |
| 1600        | 0,41                     | 0,49                      |
| 2000        | 0,52                     | 0,61                      |
| 2400        | 0,64                     | 0,73                      |
| 2800        | 0,67                     | 0,78                      |
| 3200        | 0,70                     | 0,82                      |
| 3600        | 0,71                     | 0,83                      |
| 4000        | 0,71                     | 0,84                      |

### 7.1.3 Experimentdurchführung und Ergebnisanalyse

Das Elektrodenfräsen ließ zuerst die Elektrodenarbeitsfläche bei Ausgangszustand (ideales Durchmesser der Arbeitsfläche: 6 mm) stehen (Abbildung 7.7 1, 2). Die von der gefitteten  $h_i$ -Schweißpunktnummer-Kurve ermittelten  $\Delta L_{E,i}$  (Tabelle 7.1) wurden von der Elektrodenkappen mittels Werkzeugmaschine unter der Hilfe von technischem Mitarbeiter weggeschnitten (Abbildung 7.7 3).



**Abbildung 7.7:** 1: Elektrodenfräsen; 2: gefräste und nicht gefräste Elektrodenkappe; 3: Schneiden durch Werkzeugmaschine; 4: Schweißen des einzelnen Blechs; 5: konfokal-chromatische Oberflächenmessung; 6: Torsionsprüfung

Wie in der Versuchsplanung 7.1.2 erwähnt, sollten die Ausgangszustände der Elektrodenkappen nach dem Elektrodenfräsen die konfokal-chromatische Oberflächenmessung (Abbildung 7.75) durchgeführt werden, die Software GUI und Parameter sind in Abbildung 7.8 dargestellt. Der Abstand der Oberflächen beim Ausgangszustand war der extrahierte Median aus dem ersten 1% der höchsten Werte, die von konfokale-chromatischen gemessenen Abstand rausgelesen wurde, (Abbildung 7.9), was es in der Lage sein ließ, die Zustände der Elektrodenkappen in axialer Richtung zu erklären. Die initialen Abstände von oberen und unten Elektrodenkappen haben meistens innerhalb  $\bar{a} \pm \sigma$  gelegen, d. h. die Ausgangszustände von meisten Elektrodenkappen waren relativ stabil nach dem Fräsen.

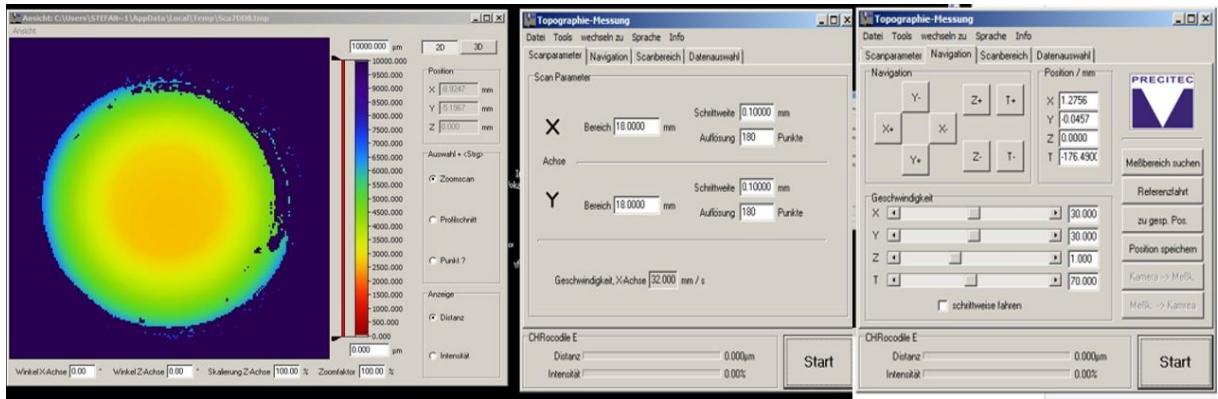


Abbildung 7.8: konfokale GUI und Parameter

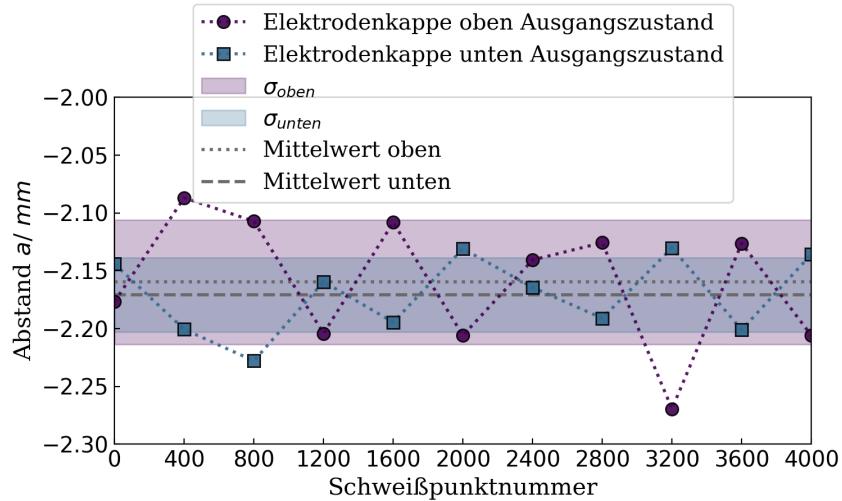
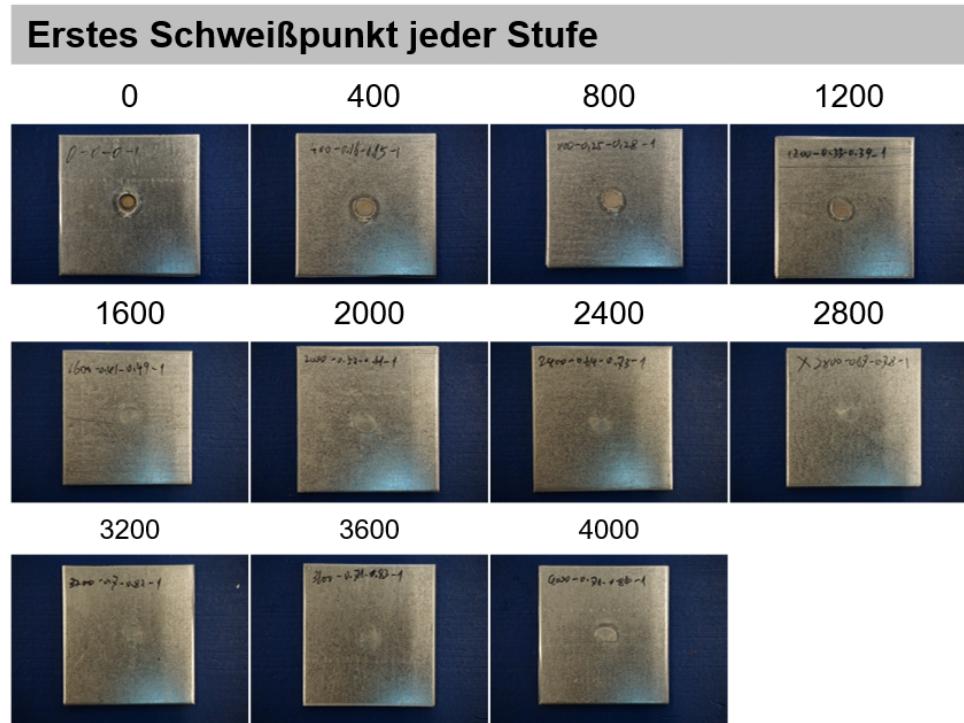


Abbildung 7.9: Ausgangszustände der Elektrodenkappen

Nach dem Schnitt der Elektrodenkappen wurden die Schweißen nach der Versuchsfloss durchgeführt (Abbildung 7.74). Die ersten Schweißpunkte jeder Stufe ist in der Abbildung 7.10 dargestellt. Mit der durch zunehmende  $\Delta L_E$  vergrößerte Elektrodenarbeits-

fläche kamen Eindrucksspuren der Elektroden auf Blech zu undeutlich. Es geht um den verringerten Elektrodendruck und die in der Fügezone zugeführten Schweißwärmemenge. Die Endzustände der Elektrodenkappen nach jede Schweißstufe wurden ebenfalls mittels konfokal-chromatischen Messungen gemessen, damit die Elektrodenlängenänderungen in axialer Richtung ermittelt wurden (Abbildung 7.11). Die dargestellten Oberflächenmessungen von Anode und Kathode nach dem Schweißen zeigt verringerte Intensität von Elektrodenkappen in axialer Richtung sowie infolgedessen eine vergrößerte Tendenz von Elektrodenkappen in radialer Richtung.



**Abbildung 7.10:** Der erste Schweißpunkt jeder Schweißstufe

Der Abstand der Oberflächen beim Ausgangszustand war ebenfalls der aus dem ersten 1% der höchsten Werte extrahierte Median. Von der Abstanddifferenz könnte die  $h_i$  zu ermitteln sein, wenn es angenommen ist, dass nach dem Fräsen die Elektrodenzustand genauso wie die idealen Ausgangszustand (Durchmesser: 6 mm) wäre. Die ermittelten  $h_i$  und  $\alpha_i$  sind in der Abbildung 7.12 gezeigt. Unter dem idealen Ausgangszustand der Elektrodenkappen sind die ermittelten  $h_i$  meistens weniger als die theoretischen gefitteten  $h_i$ , trotzdem war der maximale Anteil  $\alpha$  knapp 15%, was zur groben Simulation der Elektrodenverschleiß akzeptabel war.

Die geschweißten einzelnen Bleche wurde durch der Torsionsprüfung (Abbildung 7.76)

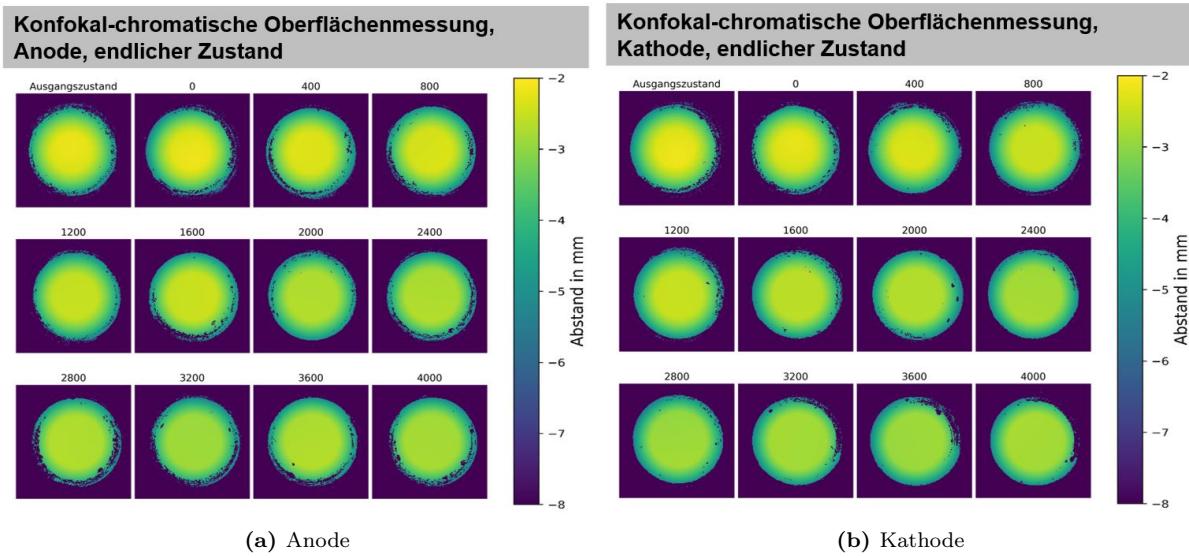


Abbildung 7.11: konfokal-chromatischen Oberflächemessungen der Elektrodenkappen

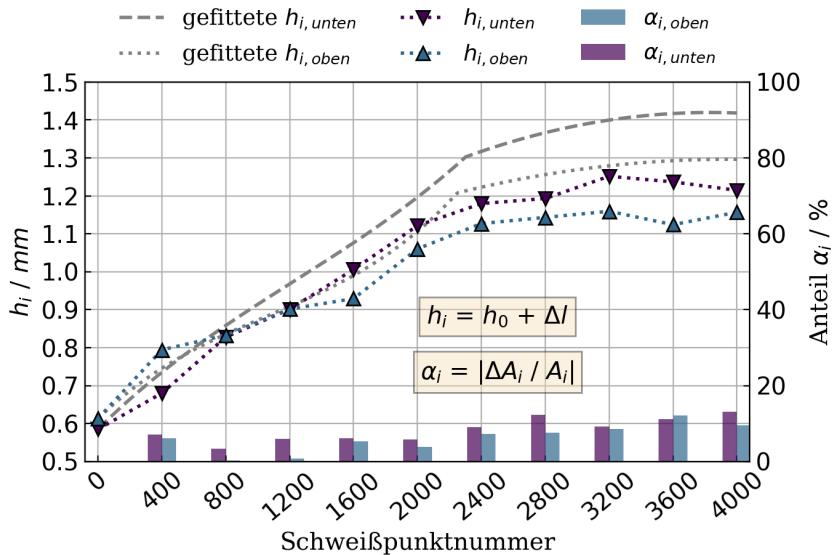


Abbildung 7.12: Nach konfokalen Messungen ermittelte Längenänderungen und entsprechende absolute Anteile der Arbeitsflächenänderungen von Elektrodenkappen

zerstört, damit die  $d_1$ ,  $d_2$  und  $d_w$  messbar waren (Abbildung 7.13). Die Tendenz der Durchmesser von Testblech ist sehr ähnlich wie die in der Abbildung 4.1 dargestellte Tendenz bei Stufe 5. Allerdings waren die Elektroden durch Einschätzung, Berechnung und Bearbeitung der Werkzeugmaschine zu bekommen, deswegen waren die auf Elektrodenarbeitsfläche Zinkablagerung und die unebenen Arbeitsfläche wegen des Verschleißes und der Ansammlung von Material kaum simulierbar, was reduzierte gewissermaßen die Elek-

trodenarbeitsfläche in der Tatsache, daher hätten die Durchmesser von Testblech nach ca. 2000 meistens kleiner als die Durchmesser von Prüfblech. Darüber hinaus aufgrund der Verwendung der einzelnen Bleche bei Testdaten gab es keine Nebenschlussverlust während eines Schweißens, die an der Schweißstelle infolge der Ableitung des Stromes zu nicht genügend Strom zur Verfügung führt. Auf diesem Grund wären die Durchmesser von Prüfblech am Anfang kleiner als die Durchmesser von Testblech.

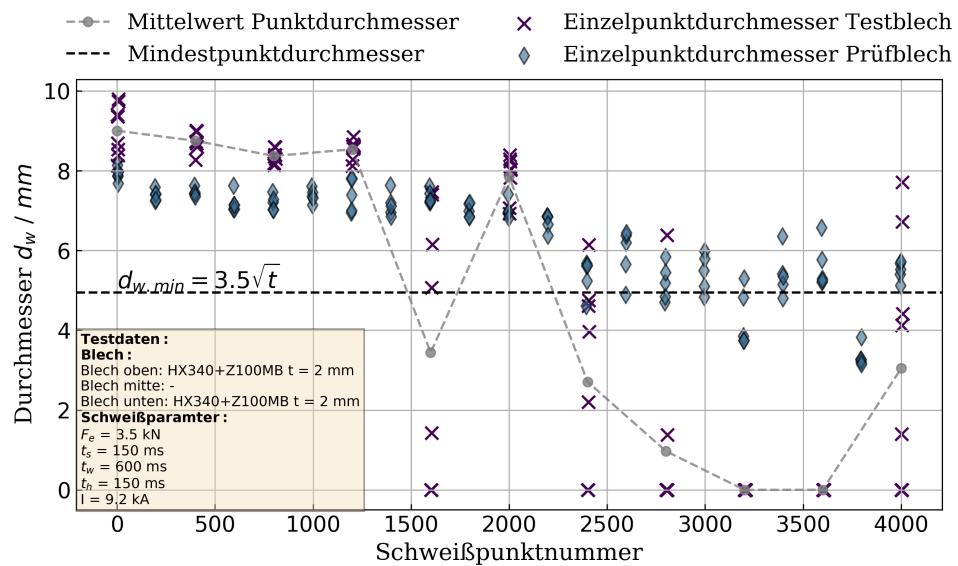
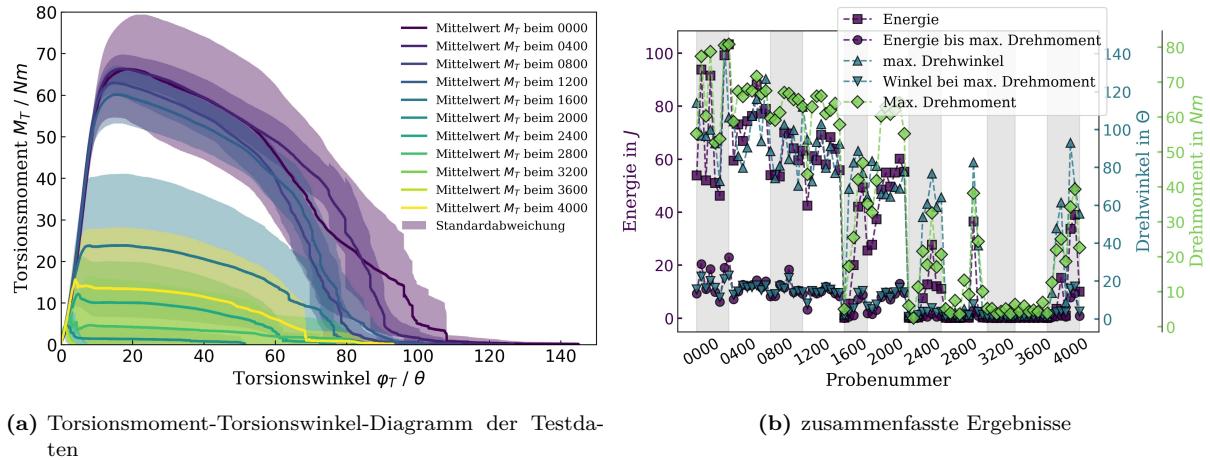


Abbildung 7.13: Schweißpunkt durchmesser der Testbleche

Die Abbildung 7.14 a zeigt das Torsionsmoment-Torsionswinkel-Diagramm. Es ist offensichtlich zu erkennen, dass die maximalen  $M_T$  mit der zunehmenden Schweißpunktnummer verringerte werden, d. h. die Festigkeit der Schweißpunkte mit der zunehmenden Elektrodenarbeitsfläche verringerte. Geringe Verbindungsfestigkeit ist normalerweise auch mit kleinere  $\varphi_T$  und Energie, die zu Zerstörung der Schweißverbindung bei der Torsionsprüfung gebraucht wird, wie in der Abbildung 7.14 b dargestellt.

## 7.2 Experimentelle Testdaten für Stufenuntersuchung der verschiedenen Stromstärken

Der Ziel dieses Experimentes ist, die Testdaten für ML-Modelle zu vorbereiten, die einer Klassifikation der Schweißpunktqualität unter verschiedenen Stromstärken dienen.



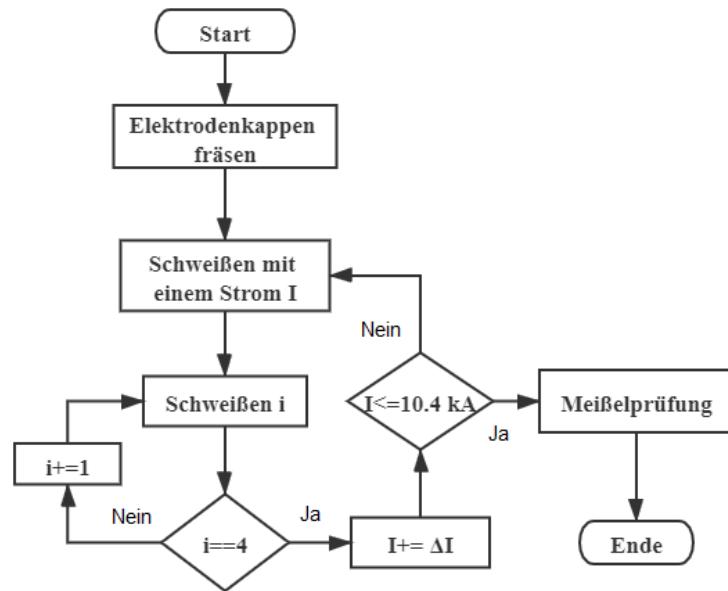
**Abbildung 7.14:** Ergebnisse der Torsionsprüfung für die Testdaten der Elektrodenverschleißuntersuchung

### 7.2.1 Versuchsplanung

Der Versuch wurde so geplant:

- Insgesamt 28 Schweißpunkte wurden auf den Bleche ( $30 \times 500 \text{ mm}$ ) alle  $30 \text{ mm}$  geschweißt;
- Insgesamt 7 Stromstufen ( $5, 6 \dots 10, 4 \text{ kA}, \Delta I = 0,8 \text{ kA}$ ) wurden versucht, in jeder Stufe wurden 4 Schweißen durchgeführt;
- alle ersten Schweißpunkt von einem Blech wurde aufgrund ohne Nebenschlusswirkung nicht berücksichtigt.

Der Flussdiagramm ist in folgender Abbildung 7.15 dargestellt. Die Schweißbedingungen sind genau sowie Tabelle 3.12 ausschließlich der Stromstufen.



**Abbildung 7.15:** Flussdiagramm zu experimentellen Testdaten für verschiedene Stromstufen

## 7.2.2 Experimentdurchführung und Analyse der Ergebnisse

Statt der einzelnen Bleche wurde das Schweißen auf den  $30 \times 500 \text{ mm}$  Bleche durchgeführt, wie in der Abbildung 7.17 dargestellt. Nach dem Schweißen war eine Meißelprüfung für alle Bleche durchgeführt, wie in der Abbildung 7.16 dargestellt. Die Brucharten ist deutlich zu beobachten, dass seit  $6,4 \text{ kA}$  die Misch- und Ausknöpfbruch begonnen wurden, während bei  $5,6 \text{ kA}$  es ein Scherbruch war. Seit  $9,6 \text{ kA}$  sind die aufgrund Spritzer erzeugten Spuren deutlich zu erkennen. Die durch E-Nonius gemessenen Punktdurchmesser sind in der Abbildung 7.18 bezeichnet. Die Tendenz des Punktdurchmessers und evaluierten Brucharten entsprechen den in den Abbildungen 4.4, 4.5 dargestellten Trainingsdaten.



Abbildung 7.16: Meißelprüfung für Testdaten mit verschiedenen Stromstärken

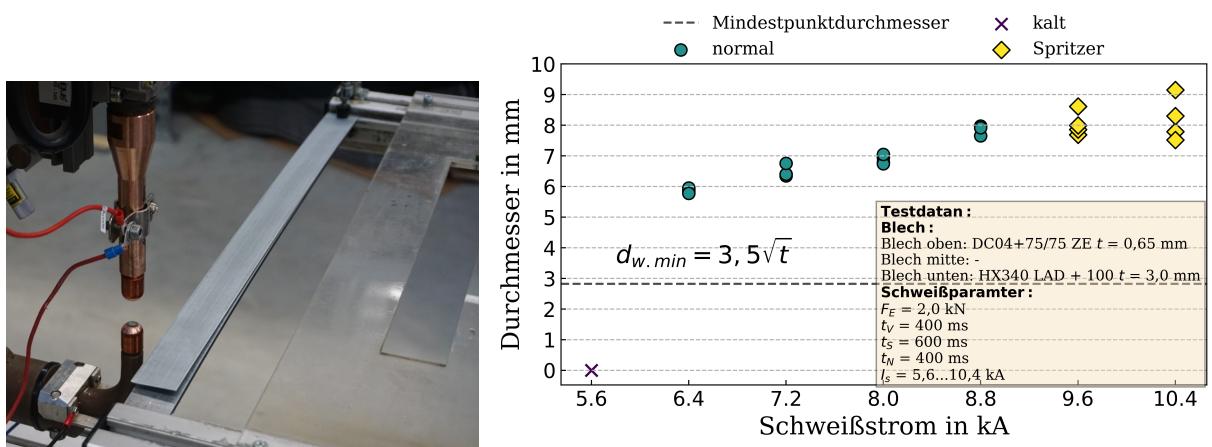


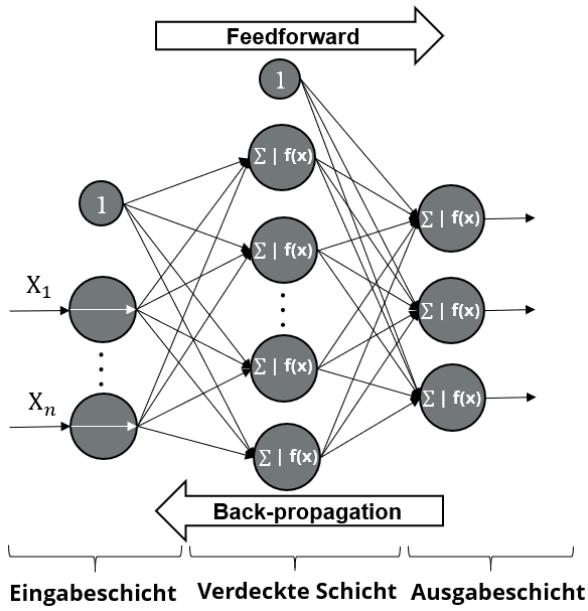
Abbildung 7.17: Schweißen

Abbildung 7.18: Schweißpunkt durchmesser und Schweißpunktqualität für Testdaten mit verschiedenen Stromstärken

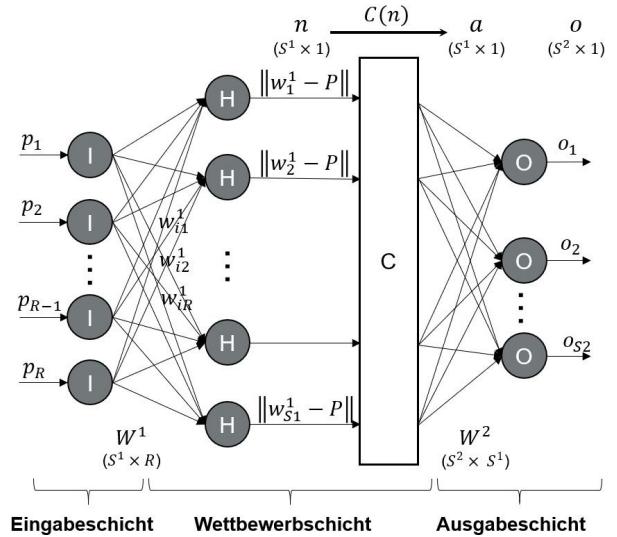
# 8 Modell des maschinellen Lernens

## 8.1 Frühere Forschungen

In diesem Abschnitt werden einige vielversprechende AI-Ansätze vorgestellt, um das Problem der Schweißpunktqualität zu lösen. Ein paar typische Methoden ist in Tabelle 8.1 zusammengefasst. Ein Algorithmus, der auf künstliche neuronale Netzwerke (KNN) basiert, wird in [3, 10, 19, 27, 45, 49] beschrieben. KNN gelten als sehr effizient für die Anwendung auf komplizierte und aufeinander einwirkende Probleme, da sie freie Linearität oder nichtlineare Funktionsabbildung realisieren können. Das neuronale Netzwerk mit der Back-Propagation (BP) ist ein mehrschichtiges Feedforward-Netzwerk, das gemäß dem Fehler-Back-Propagation-Algorithmus trainiert wurde und eines der am weitesten verbreiteten neuronalen Netzwerkmodelle ist. Kurz gesagt, es handelt sich um einen Gradientenabstieg, bei dem eine effiziente Technik zur automatischen Berechnung der Gradienten verwendet wird. Mit anderen Worten, es kann herausfinden, wie jedes Verbindungsgewicht und jedes Bias angepasst werden sollte, um den Fehler zu reduzieren. Sobald diese Gradienten vorhanden sind, wird lediglich ein regulärer Gradientenabstiegsschritt ausgeführt, und der gesamte Vorgang (eins Feedforward und ein Back-Propagation) wird wiederholt, bis das Netzwerk zur Lösung konvergiert. Die topologischen Strukturen des neuronalen BP-Netzwerks (Abbildung 8.1) umfassen die Eingabe-, verdeckte und Ausgabeschicht. Die erste Schicht ist die Eingabeschicht. Jedes Neuron in der Eingabeschicht repräsentiert eine eindeutige Eigenschaft in dem Datensatz, z. B.  $I_S$ ,  $F_E$  usw. Verdeckte Schichten setzen sich zwischen die Eingabe- und Ausgabeschicht und wenden die Aktivierungsfunktion an, bevor das Ergebnis in nächster Schicht übergeben wird. Die Ausgabeschicht ist die letzte Schicht in einem Netzwerk. Die empfängt Eingaben von der vorherigen verdeckte Schicht, wendet optional eine Aktivierungsfunktion an und gibt eine Ausgabe zurück, die die Vorhersage des Modells darstellt, z. B. Punktdurchmesser, Schweißpunktqualität usw.



**Abbildung 8.1:** Die topologischen Strukturen des neuronalen BP-Netzwerks



**Abbildung 8.2:** Architektur des neuronalen Netzwerks der lernenden Vektorquantisierung (LVQ)

LVQ, die ein Verfahren aus dem Bereich der KNN ist und der Klassifikation von nichtlinearen Problemen dient, ist auch häufig verwendet zur Qualitätsbewertung, was in [4, 22, 37, 38] vorgestellt wird. LVQ ist ein prototypbasierter, überwachter Klassifizierungsalgorithmus, der von T. Kohonen vorgeschlagen wurde. Die Vorteile von LVQ bestehen darin, dass Prototypen erstellt werden, die für Experten auf dem Gebiet der Anwendung leicht zu interpretieren sind und LVQ besonders gut mit kleinen Trainingssätzen funktioniert, diese Eigenschaft für industrielle Anwendungen von großer Bedeutung ist, bei denen die Trainingsdaten sehr begrenzt sind. Ein großer Nachteil ist, dass bei Datensätzen mit einer großen Anzahl von Kategorien das Training des Netzwerks sehr lange dauern kann. Wie in der Abbildung 8.2 dargestellt, besteht es aus drei Schichten, jeweils Eingabeschicht, Konkurrenzschicht und Ausgabeschicht. LVQ-Netzwerk klassifiziert seinen Eingabevektor durch einen zweistufigen Prozess in eine von mehreren Klassen. In der ersten Stufe wird eine Konkurrenzschicht verwendet, um die Unterklassen von Eingabevektoren zu identifizieren. In der zweiten Stufe wird eine lineare Ausgabeschicht verwendet, um diese Unterklassen zu den entsprechenden Zielklassen zu kombinieren [24].

Außerdem sind baumbasierte Methoden [39] auch häufig zur Klassifizierung verwendet, z. B., Decision Tree, Random Forest, Extra Tree, Gradient Boosting usw. Ziel ist es, ein Modell zu erstellen, das den Wert einer Zielvariablen vorhersagt, indem einfache Entschei-

dungsregeln gelernt werden, die aus den Features der Daten abgeleitet werden. Eine der großen Vorteile der Entscheidungsbaum ist, dass der das White-Box-Modell verwendet. Wenn eine bestimmte Situation im Modell beobachtet werden kann, können die Bedingungen leicht durch die Boolesche Logik erklärt werden. Im Gegensatz dazu sind die Ergebnisse in Black-Box-Modellen (z. B. in KNN) möglicherweise schwieriger zu interpretieren. Jedoch kann Entscheidungsbaum überkomplex erstellen werden, die die Daten nicht gut verallgemeinern, d. h. „Overfitting“. Daher werden Random Forest und Extra Tree verwendet, durch Anpassung einer Reihe von Entscheidungsbaum an verschiedene Subproben des Datensatzes und Verwendung der Mittelwertbildung, um die Vorhersagegenauigkeit zu verbessern und das „Overfitting“ zu vermeiden. Gradient Boosting fügt einem Ensemble nacheinander Prädiktoren hinzu, von denen jeder seinen Vorgänger korrigiert. Diese Methode versucht, den neuen Prädiktor an die residualen Fehler des vorherigen Prädiktors anzupassen. Es hat Hyperparameter zur Steuerung des Wachstums von Entscheidungsbäumen sowie Hyperparameter zur Steuerung des Ensemble-Trainings [21].

**Tabelle 8.1:** Zusammenfassung von einigen früheren Forschungen auf der Grundlage künstlicher Intelligenz

| Forschung                             | Verwendete Technik                          | Zweck                                                                                                                   | Type       |
|---------------------------------------|---------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|------------|
| T. Arunchai; [3]<br>K. Sonthipermpoon | KNN(BP)                                     | Regression<br>I: $I_s$ ; $F_E$ ; $t$ ; $R$<br>O: Scherzugfestigkeit                                                     | Supervised |
| S. Chen; [10]<br>N. Wu                | KNN(BP)<br>Wavelet Analyse                  | 2 Klassen<br>I: Amplitude; Kurtosis Index<br>O: mit/ohne Spritzer                                                       | Supervised |
| A. El Ouafi; [19]<br>R. Bélanger      | KNN<br>ANOVA                                | Regeression<br>I: $I_s$ ; $F_E$ ; $t$ ; $R$<br>O: Linsendurchmesser;<br>Linseneindringtiefe;<br>Elektrodeneindrucktiefe | Supervised |
| M. El-Banna; [4]<br>D. Filev          | LVQ                                         | 3 Klassen<br>I: extrahierte Featuers aus $R$<br>O: kalt; normal;<br>mit Spritzer                                        | Supervised |
| E. Haapalainen; [22]<br>P. Laurinen   | KNN<br>LVQ<br>...                           | Vergleich Klassifikator<br>I: extrahierte Features aus<br>$I_s$ und $U_S$<br>O: Genauigkeit                             | Supervised |
| M. Óscar; [30]<br>P. María            | baumbasierte Methoden<br>Ultraschallprüfung | 4 Klassen<br>I: extrahierte Features aus<br>Ultraschalloszillogramme<br>O: Good; NoWeld;<br>Stick; Undersize            | Supervised |
| X. Wan; [45]<br>Y. Wang               | KNN(BP)                                     | Regression<br>I: extrahierte Features aus<br>Leistungskurve<br>O: Punktdurchmesser                                      | Supervised |
| H.-L.Lin; [28]<br>T.Chou              | KNN(BP)<br>Taguchi-Methode                  | Regression<br>I: $d_w$ ; $I_s$ ; $F_E$ ; $t_S$<br>Sauberkheit der Probe<br>O: Zugscherfestigkeit                        | Supervised |

## 8.2 Modellierung neuronaler Netze für Elektrodenverschleißuntersuchung

Bei dieser Untersuchung gab es nicht viel gelabelte Trainingsdaten (insgesamt ca. 4000, davon 105 gelabelt in der Stufe 5), wie in der Kapitel 7 erwähnt, und leider kein Modell wurde gefunden, das für eine ähnliche Aufgabe trainiert wurde. Außerdem ist mehr Trainingsdaten zu sammeln sehr aufwendig, besonders für Verschleißuntersuchung, die große Menge Schweißpunkte erfordert, und es ist auch aufwendig ein Label zur Trainingsdaten zuzuweisen aufgrund der Oberflächenmessung und Querschliffe des Schweißpunkts. Wenn eine komplexe überwachte Aufgabe anzugehen, aber nicht viel gelabelte Trainingsdaten verfügbar sind, besteht eine Lösung für neuronales Netzwerk darin, dass das eine ähnliche Aufgabe ausführt, und seine niedrige Schichten wiederzuverwenden. Auf dieser Weise könnte ein Modell trainieren werden, aber nur wenige Trainingsdaten werden verwendet, da neuronales Netzwerk nicht alle „low-level-features“ lernen muss, d. h. unüberwachtes Pre-Training. 2006 haben Geoffrey Hinton et al. [23] ein Modell mittels gestapelten restriktierten Boltzmann-Maschinen (RBMs) angewendet, die als „greedy layer-wise pretraining“ bezeichnet wurde. Aber 2007 haben Yoshua Bengio et al. [5] gezeigt, dass gestapelte Autoencodern für unüberwachtes Pre-Training genauso gut funktionierten, was das viel einfacher werden lässt. Die alle basieren auf einem ähnlichen Ansatz: „greedy layer-wise“ unüberwachtes Pre-Training, gefolgt von überwachtem Fine-Tuning. Jede Schicht ist mit einem unüberwachten Lernalgorithmus vorab trainiert, der eine nichtlineare Transformation ihrer Eingabe (der Ausgabe der vorherigen Schicht) lernt, die die Hauptvariationen ihrer Eingabe erfasst. Das unüberwachte Pre-Training bildet nur die Grundlage für ein abschließendes Training, in der tiefe neuronale Netzwerke (DNN) in Bezug auf ein überwachtes Training mit dem Optimierer genau angepasst wird [2, 15].

Vor Modellierung eines unüberwachten ML-Modell ist es notwendig zu bestimmen, welche ungelabelte Schweißpunkte ausgewählt werden sollte, die zum Training des Modells verwendet werden. Die Schweißpunktposition könnte eine Rolle während des Schweißens spielen, weil das Randzone des Verschleißblechs gespannt auf Prophalter war, während die Mittelzone entspannt und aufgrund der Auswirkung der Gravitation niedriger als Randzone in der vertikalen Richtung war. Beim Schweißen des einzelnen Blechs für Testdaten war das Blech entspannt, was dem Schweißen in der Mittelzone von Verschleißblech entspricht. Hierbei wurden das Verschleißblech in drei Zonen (Zone 1: Randzone, Zone 2: Übergangszone, Zone 3: Mittelzone) verteilt (Abbildung 8.3a). Die Abbildung 8.3 b und c stellen den möglichen Einfluss der Schweißpunktposition auf Punktdurchmesser beim Prüfblech dar.

Deshalb könnte die Position der Schweißpunkte den Einfluss auf einem Schweißpunkt erzeugen. Um den möglichen Positionseinfluss zu beseitigen, wurden nur die Schweißpunkte in der Mittelzone des Verschleißblechs als Trainingsdaten benutzt.

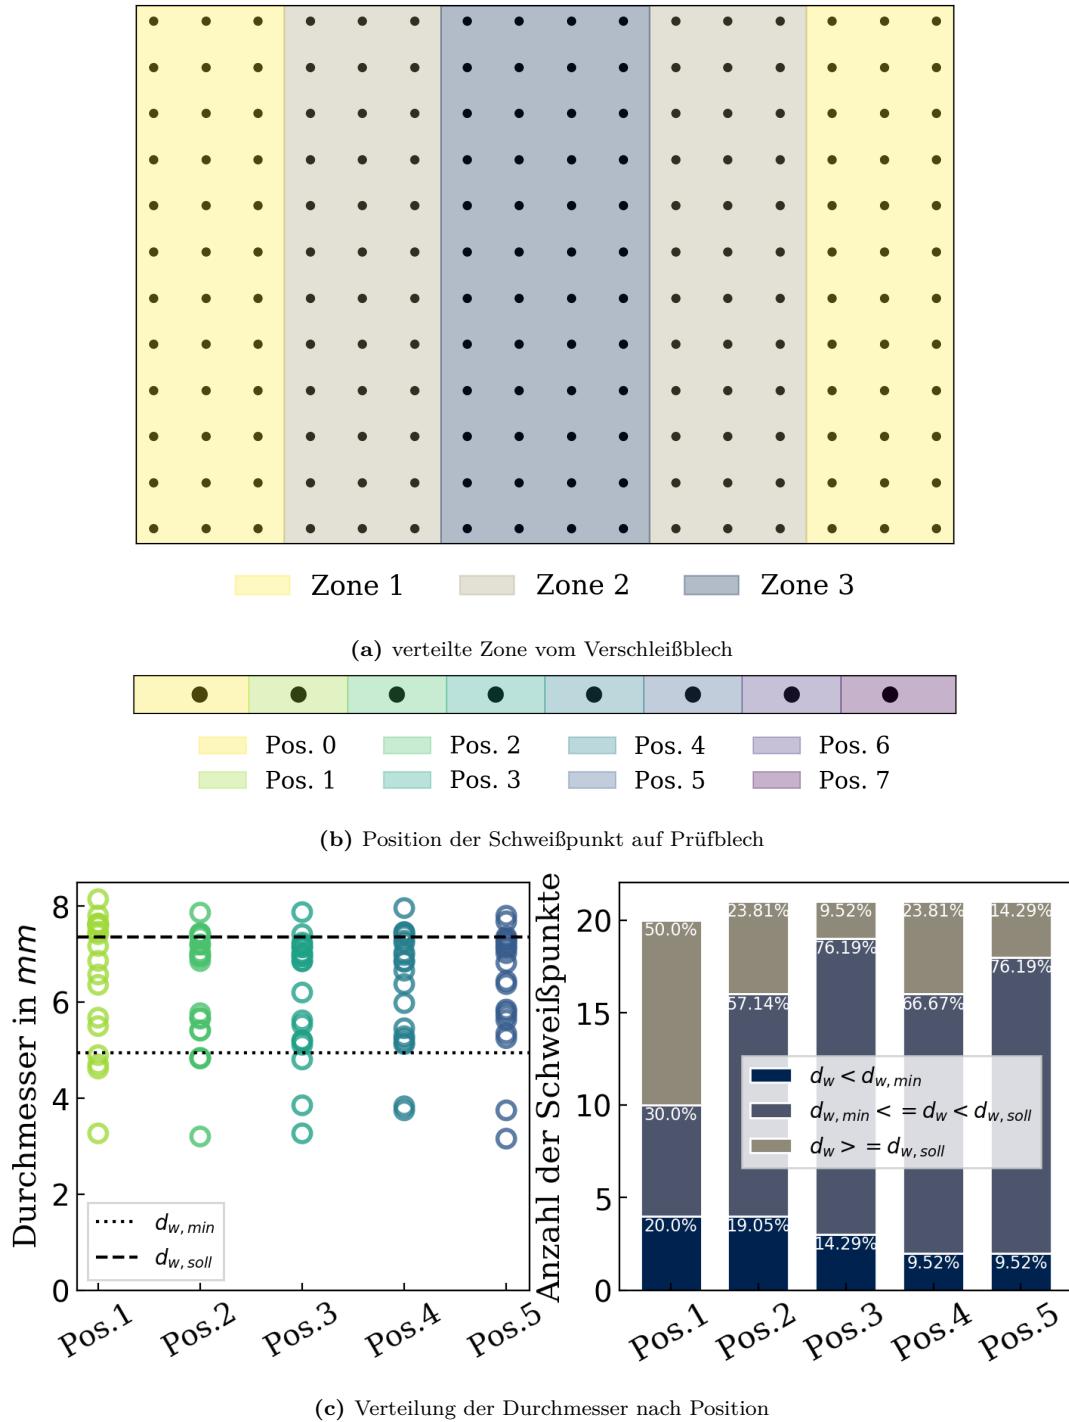


Abbildung 8.3: Positionseinfluss auf die Punktdurchmesser

Um mehr gelabelte Schweißpunkte zu bekommen jedoch kein weiteres Schweißen aufgrund hohem Aufwand durchzuführen, wurde ein „semi-supervised learning“ verwendet, das ein halb-überwachtes Modell ist, das bedeutet, dass ein Datensatz nicht nur gelabelte Daten sondern auch nicht gelabelte Daten besitzen muss. Bei Prüfblech waren 164 Schweißpunkte verfügbar und 105 Schweißpunkte gelabelt. Es ist in der Lage mit einem Algorithmus „Label-Spread“ [50] basierend auf dem normalisierten Graphen Laplace [8] zur Verbreitung des Labels zu benutzen. Während der Verbreitung des Labels war die Wahrscheinlichkeit des Ereignisses ermittelt, um die Entropie  $H$  einer Verteilung für gegebene Wahrscheinlichkeitswerte zu ermitteln, weil zwar dieser Algorithmus Klemmfaktor hat, um für alle ungelabelte Daten Label zuzuweisen, allerdings ist ein verbreitetes Label mit hoher  $H$  (hier größer als 0,6) nicht akzeptable. Außerdem ist es schwer zu bestimmen mit welcher Größe des Klassifizierungskriteriums (hier  $d_{w,soll}$ ) eine optimale Verbreitung erhalten wird. Es ist angenommen, dass der Punktdurchmesser in 1 ( $d_w \geq d_{w,soll}$ ), 0 ( $d_w < d_{w,soll}$ ) enkodiert wurde, danach wurde die durch Algorithmus 8.1 erhaltenen Ergebnisse der Verbreitung des Labels mit verschiedenen  $d_{w,soll}$  Kriterien in der Abbildung 8.4 dargestellt. Es ist deutlich zu beobachten, dass die allen verbreiteten Labels mit über 70% Glaubwürdigkeit oder unter 30% Unzuverlässigkeit nach Iteration haben (Summe der Glaubwürdigkeit und Unzuverlässigkeit für ein Label ist immer 1), wenn die alle  $H$  der durch Labelverbreitung gelabelten Punkte kleiner als 0,6 sind. Nach der Labelverbreitung hat die Anzahl des gelabelten Punkts von 105 zumindest auf 142 zugenommen. Durch das halb-überwachte Lernen wurde Datensatz zum Fine-Tuning vermehrt. Die verwendeten Features zur Eingabe sind in der Tabelle B.3 entnehmbar.

Danach kommt es zu Testen und Evaluation der Modelle. Die Wirksamkeit der Modelle wurde validiert und ihre Performance durch das Testdatensatz aus Experiment bewertet. Das Modellvalidierungsverfahren ist in Abbildung 8.5 dargestellt. Das tief trainierte Modell wurde an ungelabelten Daten getestet.

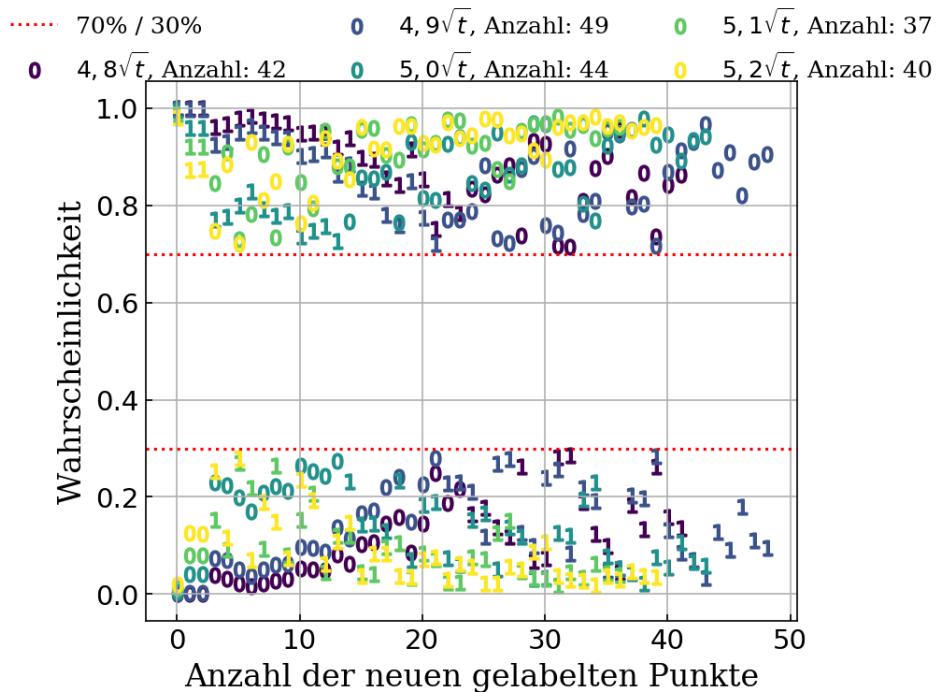


Abbildung 8.4: Labelverbreitung mit verschiedenen Klassifizierungskriterien

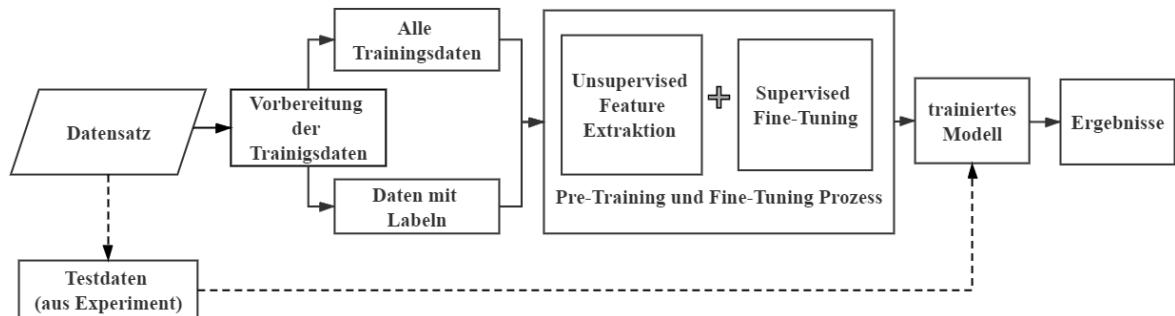


Abbildung 8.5: Flussdiagramm mit der Vorgehensweise zur Validierung des Modells

### 8.2.1 Unüberwachtes Pre-Training und Fine-Tuning

Keras ist eine High-Level-API für Deep Learning, mit der Sie auf einfache Weise alle Arten von neuronalen Netzen erstellen, trainieren, bewerten und ausführen können. Außerdem wird TensorFlow selbst jetzt mit seiner eigenen Keras-Implementierung, tf.keras, ausgeliefert. Im dieser Arbeit wurden Keras und TensorFlow 2.4.1 zur Modellierung der neuronalen Netzen verwendet.

---

**Algorithmus 8.1:** Verbreitung des Labels

**Input:** gelabelter und ungelabelter Datensatz  $X$ (Feature),  $y$ (Klasse)

**Output:** neuer Datensatz besteht aus vorher gelabelten und durch Labelverbreitung gelabelten Daten

```

1:  $H \leftarrow 0,6$                                      ▷ Maximale Entropie
2:  $Status \leftarrow True$ 
3:  $i \leftarrow 0$  ▷ Anzahl der Iteration
4: while  $Status$  do                                ▷ Iteration
5:   if Anzahl der ungelabelten Daten ist null then
6:      $Status \leftarrow False$ 
7:   end if
8:   Labelverbreitung (LabelSpreading())[41]
9:   Training des Modells
10:  Vorhersage des Labels mittels des trainierten Modells
11:  Berechnung der Entropie (stats.distributions.entropy())      ▷ Entropien der
    transduzierten Labelverteilungen
12:  if maximale Entropie  $\leq H$  then
13:     $Status \leftarrow False$ 
14:  end if
15:  Auswahl eines Beispiels, über das der Klassifikator am unsichersten ist
16:  Entfernung vom gelabelten Datensatz
17:  Neuer  $X$  und  $y$  Satz zur Training des Modells
18:  Anzahl der ungelabelten Daten minus 1
19:   $i \leftarrow i + 1$ 
20: end while
21: return  $X, y$ 

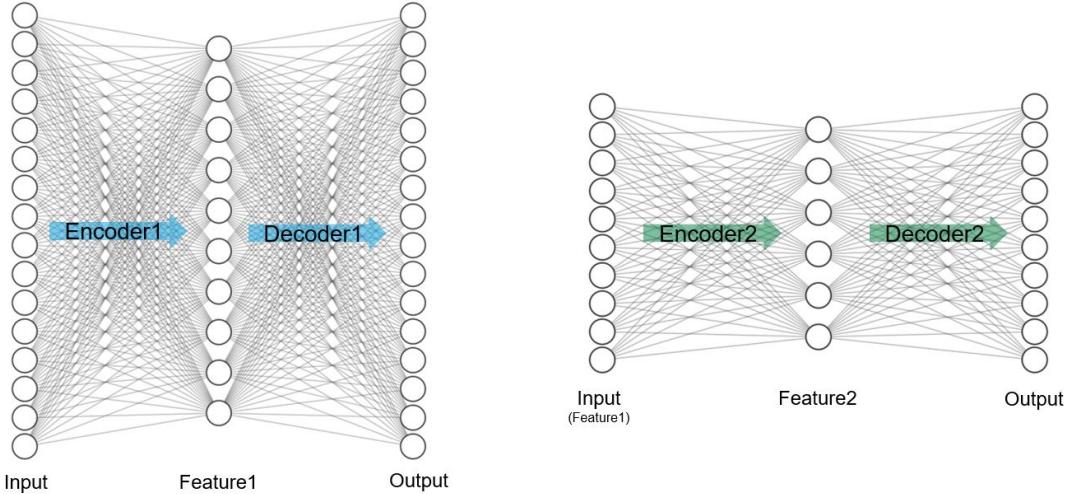
```

---

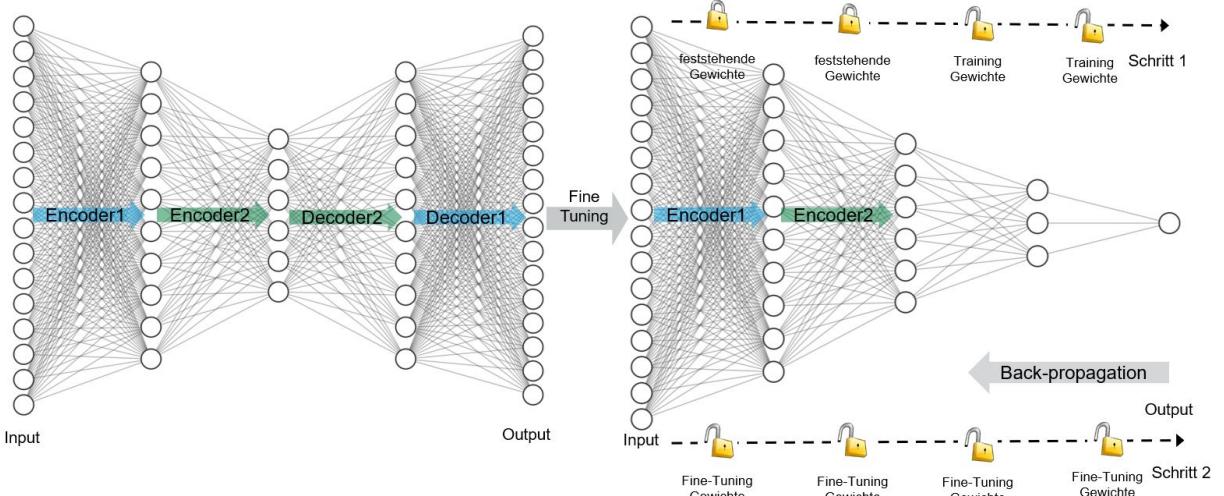
### 8.2.1.1 Greedy Layerwise

In dieser Arbeit wurde eine „greedy layer-wise“ unüberwachte Pre-Training-Methode verwendet, um Features Schicht für Schicht in einem unüberwachten KNN zu extrahieren. Die Hauptvorteile dieses Ansatzes bestehen darin, dass er nicht nur bessere lokale Minima liefert, indem die Gewichte im KNN ordnungsgemäß initialisiert und jeder Autoencoder nacheinander trainiert wird, sondern auch die Performance der Generalisierung verbessert wird. Die topologischen Strukturen von Greedy-Layerwise-Prozess ist in der Abbildung 8.6 dargestellt. Nach dem Training des ersten Autoencoders (Abbildung 8.6a Links) wurde der zweite Autoencoder trainiert, indem die primären Feature 1 aus erstem Autoencoder als rohe Eingabe für den nächsten Autoencoder verwendet haben, um die sekundären Feature 2 der aus dem Datensatz zu extrahieren, wie in Abbildung 8.6a Rechts gezeigt, d. h. die Features, die von dem ersten Autoencoder erzeugt wurden, als

Trainingsdatensatz für den zweiten verwendet. Der gierig-schichtweise Prozess wird als Pre-Training bezeichnet.



(a) Links: Autoencoder 1; Rechts: Autoencoder 2



(b) Links: gestapelte Autoencodern; Rechts: überwachtes Fine-Tuning

**Abbildung 8.6:** Layerwises unüberwachtes Pre-Training und überwachtes Fine-Tuning:  
(a) Training des 1-ten Autoencoders und des 2-ten Autoencoders; (b) überwachtes Fine-Tuning

Anschließend wurden die vom zweiten Autoencoder extrahierten Features als rohe Eingabe für die letzte verdeckte Schicht verwendet (Abbildung 8.6 b Rechts). In der ersten Schritt wurden die aus Autoencoder 1 und 2 vererbten Encoderschichten festgestanden, um die Sigmoid-Ausgabeschicht und letzte verdeckte Schicht zu trainieren. In der zweiten Schritt wurde das Fine-Tuning für unüberwachtes Pre-Training eingeführt, um die Performance weiter zu verbessern. Das Netzwerk wurde auf überwachter Weise mit der

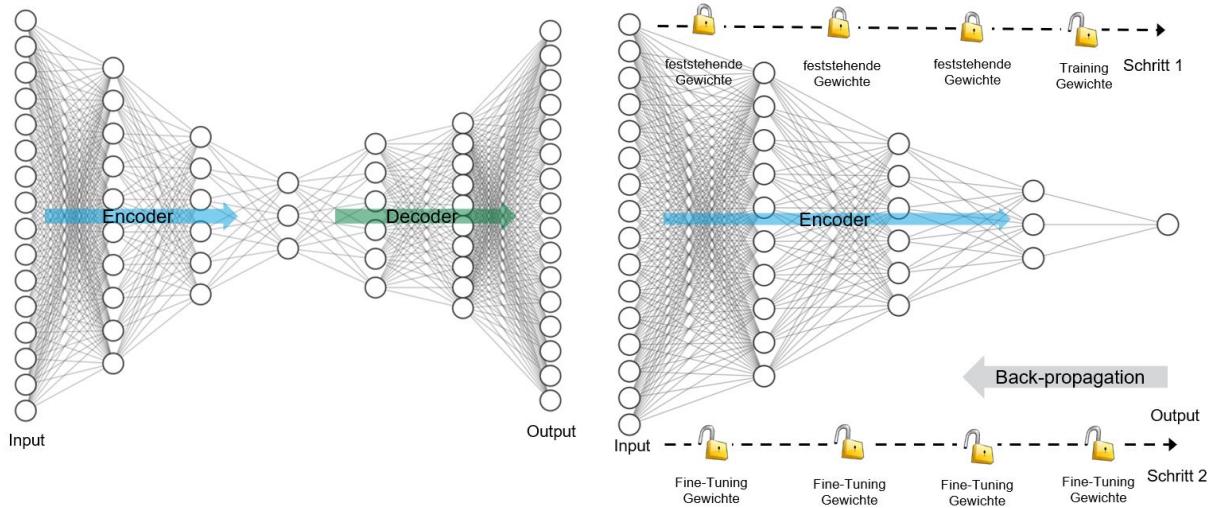
Hilfe eines Backpropagation-Algorithmus wieder trainiert. Dieser Sigmoid-Klassifikator kann die verschiedenen Klasse (0, 1) klassifizieren. Die Parameter von Autoencodern und Fine-Tuning sind wie folgt (Tabelle 8.2):

**Tabelle 8.2:** Parameter von gestapelten Autoencodern und Fine-Tuning

|                              | 1. Autoencoder                                             | 2. Autoencoder                                          | Fine-Tuning                                                |
|------------------------------|------------------------------------------------------------|---------------------------------------------------------|------------------------------------------------------------|
| <b>Struktur</b>              | $16 \times 10 \times 16$                                   | $10 \times 6 \times 10$                                 | $16 \times 10 \times 6 \times 3 \times 1$                  |
| <b>Aktivierungs-funktion</b> | selu<br>(verdeckte Schicht)<br>sigmoid<br>(Ausgabeschicht) | selu<br>(verdeckte Schicht)<br>selu<br>(Ausgabeschicht) | selu<br>(verdeckte Schicht)<br>sigmoid<br>(Ausgabeschicht) |
| <b>Optimierer</b>            | Adam                                                       | Adam                                                    | Adam                                                       |
| <b>Verlust-funktion</b>      | binary_crossentropy                                        | mse                                                     | binary_crossentropy                                        |
| <b>Callbacks</b>             | EarlyStopping<br>TensorBoard                               | EarlyStopping<br>TensorBoard                            | ModellCheckpoint<br>EarlyStopping<br>TensorBoard           |
| <b>Performance Metrik</b>    | rounded_accuracy                                           | -                                                       | accuracy                                                   |

### 8.2.1.2 Tying Weights

Wenn ein Autoencoder genau symmetrisch ist, besteht eine übliche Technik darin, die Gewichte der Decoderschichten mit den Gewichten der Encoderschichten zu verknüpfen. Dies halbiert die Anzahl der Gewichte im Modell, beschleunigt das Training und begrenzt die Risiko einer Überanpassung. Besonders wenn der Autoencoder insgesamt  $N$  Schichten hat (ohne die Eingabeschicht) und  $W_L$  die Verbindungsgewichte der  $L$ -ten Schicht darstellt (z. B. Schicht 1 ist die erste verdeckte Schicht, Schicht  $N/2$  ist die Kodierschicht und Schicht  $N$  ist die Ausgabeschicht), dann können die Gewichte von Decoderschicht einfach definiert werden als:  $W_{N-L+1} = W^T L$  mit  $L = 1, 2, \dots, N/2$  [21, 26], wie in der Abbildung 8.7 Links dargestellt. Dann wurden die Encoderschichten von der trainierten Tying-Weights-Autoencoder mit einer Ausgabeschicht zum überwachten Fine-Tuning zusammen modelliert (Abbildung 8.7 Rechts). Die Parameter von Autoencoder und Fine-Tuning sind wie folgt (Tabelle 8.3):



**Abbildung 8.7:** Tying-Weights unüberwachtes Pre-Training und überwachtes Fine-Tuning: (a) Training des Tying-Weights-Autoencoders; (b) überwachtes Fine-Tuning

**Tabelle 8.3:** Parameter von Tying-Weights-Autoencoder und Fine-Tuning

|                             | Autoencoder                                                   | Fine-Tuning                                          |
|-----------------------------|---------------------------------------------------------------|------------------------------------------------------|
| <b>Struktur</b>             | $16 \times 10 \times 6 \times 3 \times 6 \times 10 \times 16$ | $16 \times 10 \times 6 \times 3 \times 1$            |
| <b>Aktivierungsfunktion</b> | selu (verdeckte Schicht)<br>sigmoid (Ausgabeschicht)          | selu (verdeckte Schicht)<br>sigmoid (Ausgabeschicht) |
| <b>Optimierer</b>           | Adam                                                          | Adam                                                 |
| <b>Verlustfunktion</b>      | binary_crossentropy                                           | binary_crossentropy                                  |
| <b>Callbacks</b>            | EarlyStopping<br>TensorBoard                                  | ModellCheckpoint<br>EarlyStopping<br>TensorBoard     |
| <b>Performance Metrik</b>   | rounded_accuracy                                              | accuracy                                             |

### 8.2.1.3 Ergebnisse

Eine Möglichkeit, um sicherzustellen, dass ein Autoencoder richtig trainiert ist, besteht darin, die Ein- und Ausgabe (Eingabe: 16 Features, Ausgabe: dekodierte 16 Features)

zu vergleichen: Die Unterschiede sollten nicht zu große sein. Daher wurden die Validierungsdaten mit den durch den Autoencoder erhaltenen Vorhersagedaten mit den Validierungsdaten als Eingabe verglichen. In der Abbildung 8.8 a und b ist die MSE von zwei Autoencoder dargestellt. Zwar gab es Verlust nach der Decodierung, aber die MSE war klein. Die Verluste und Genauigkeiten mit Epoche der beiden Methoden sind in der Abbildung 8.8 c und d dargestellt. Die Autoencodern von beiden Methode haben gute Performance gezeigt.

Die durch Fine-Tuning wieder trainierte KNN wurde für unterschiedliche  $d_{w,soll}$  benutzt, es ist zu bestimmen, dass bei welchem Kriterium KNN die beste Performance entfalten kann. Die Genauigkeiten sind in der Tabelle 8.4 und Tabelle 8.5 bezeichnet. Ohne Fine-Tuning und lediglich mittels eines Trainings der Letzten verdeckten Schicht und Ausgabeschicht (Schritt 1) haben die Genauigkeiten von Validierungsdaten bei verschiedenen  $d_{w,soll}$  nicht ideal zu sein geschienen, während die Genauigkeiten nach einem Fine-Tuning (Schritt 2) sehr beeindruckend waren. Bei  $d_{w,soll} = 5,1\sqrt{t}$  und  $5,2\sqrt{t}$  hatten die trainierte Modelle deutlich über angepasst, weil die Genauigkeit von Validierungsdaten deutlich größer als von Trainingsdaten bei dem Epoche-Genauigkeit-Diagramm oder die Verlust von Validierungsdaten deutlich kleiner als von Trainingsdaten bei dem Epoche-Verlust-Diagramm war. Deswegen wurde die bei  $d_{w,soll} = 4,9\sqrt{t}$  trainierte Modell von beiden Methode ausgewählt. Die von Experiment gewonnenen Testdaten, wurden zur Evaluation der Genauigkeit der trainierten Modelle verwendet. Tying-Weights-Methode hatte die höhere Genauigkeit (86,36%) bei Testdaten im Vergleich zur Greedy-Layerwise-Methode (81,82%). Die Gewichte von Enocderschichten wurden bei Fine-Tuning nach dem Backpropagation-Algorithmus angepasst (Anhang A.5). Die Epoche-Genauigkeit/Verlust-Diagramme von beiden Methoden sind in der Abbildung 8.9 dargestellt.

**Tabelle 8.4:** Fine-Tuning Ergebnisse der Greedy-Layerwise-Methode

| $d_{w,soll}$  | Genauigkeit von Validdaten (Schritt 1) | Genauigkeit von Validdaten (Schritt 2) | Genauigkeit von Testdaten |
|---------------|----------------------------------------|----------------------------------------|---------------------------|
| $4,8\sqrt{t}$ | 43,23%                                 | 94,59%                                 | 85,23%                    |
| $4,9\sqrt{t}$ | 56,44%                                 | 100%                                   | 86,36%                    |
| $5,0\sqrt{t}$ | 68,42%                                 | 94,74%                                 | 77,27%                    |
| $5,1\sqrt{t}$ | 81,08%                                 | 100%                                   | 70,45%                    |
| $5,2\sqrt{t}$ | 69,44%                                 | 94,44%                                 | 62,50%                    |

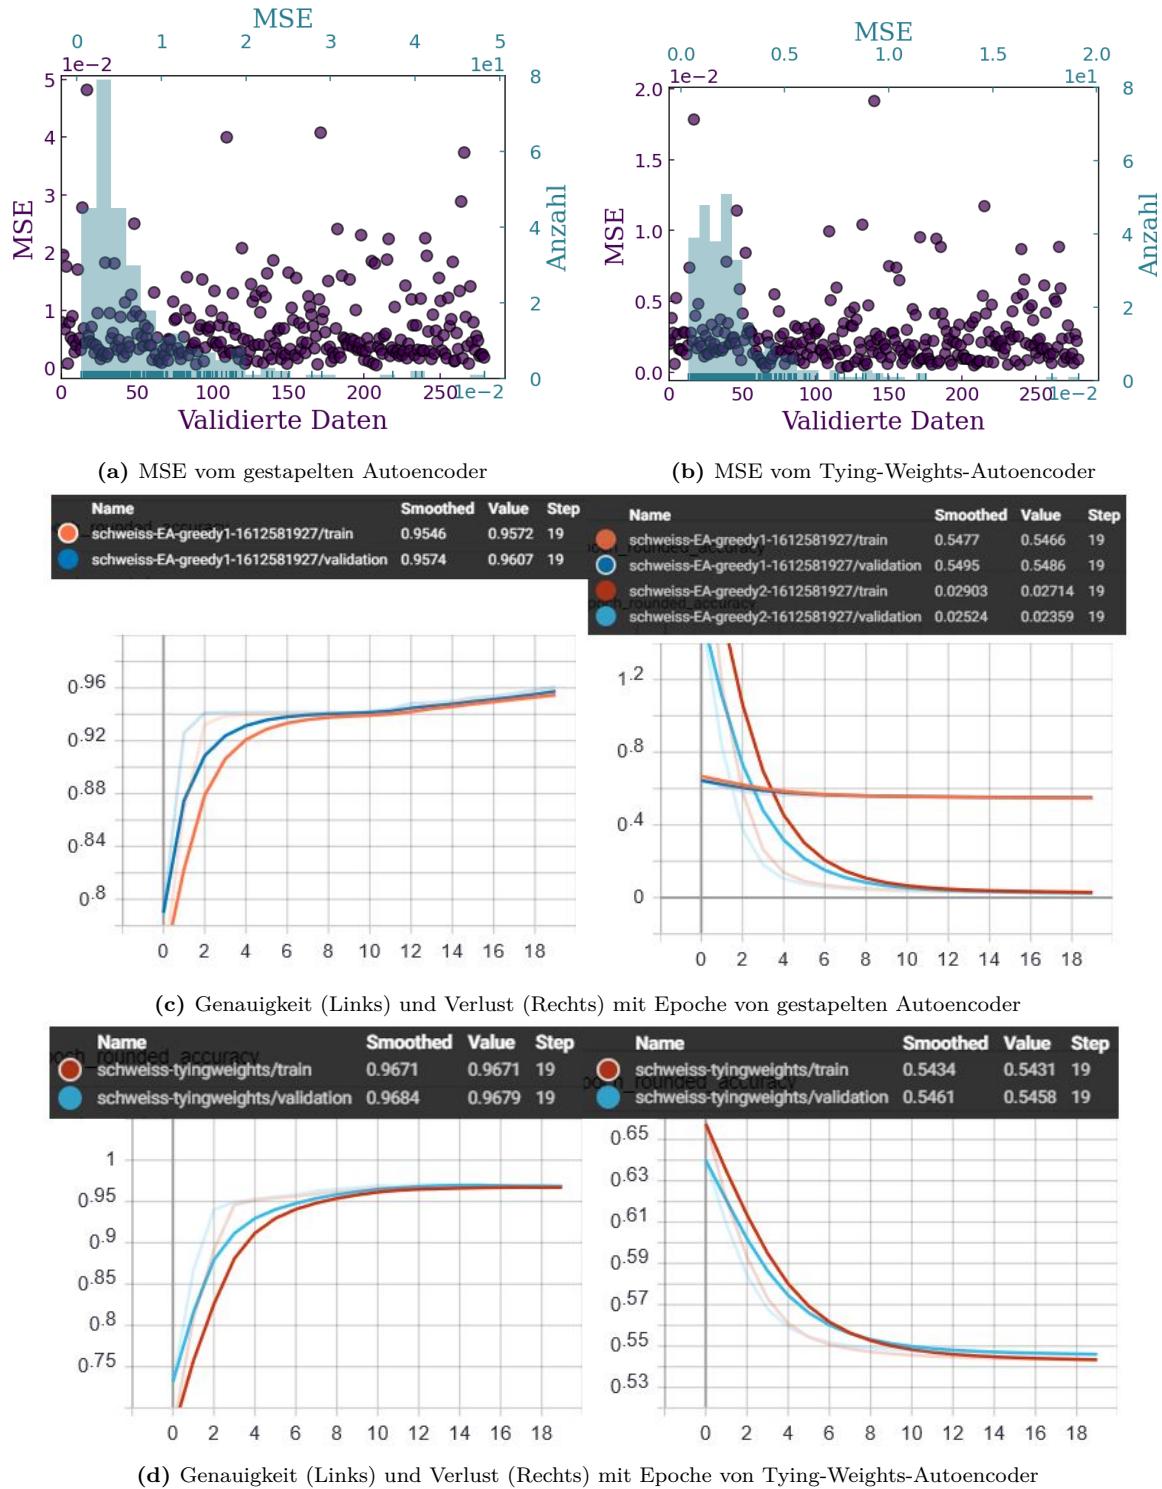
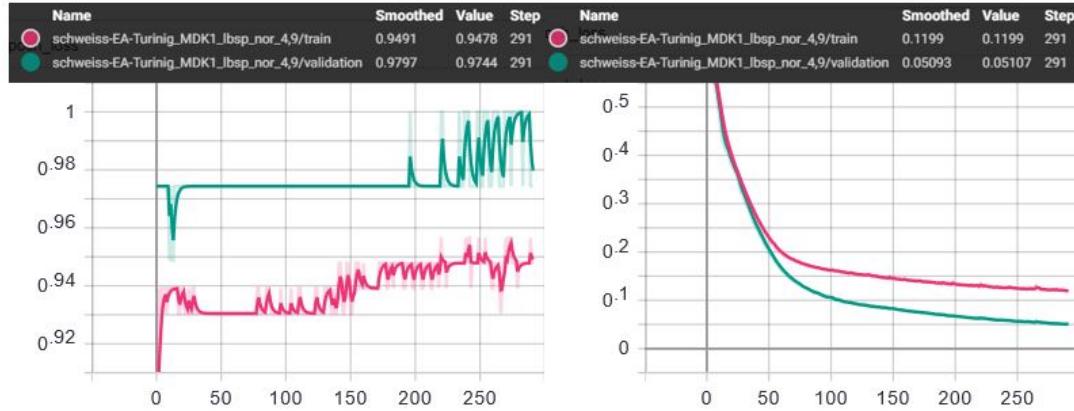


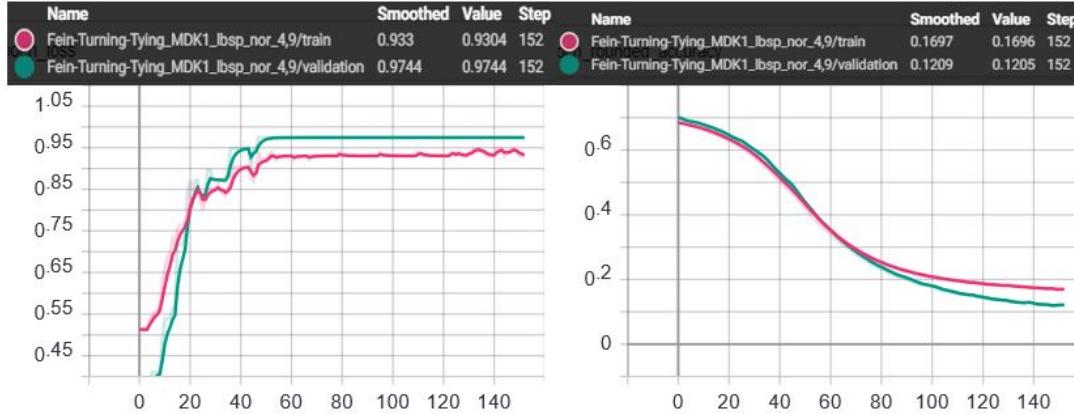
Abbildung 8.8: Performance von Autoencoder

**Tabelle 8.5:** Fine-Tuning Ergebnisse der Tying-Weights-Methode

| $d_{w,soll}$  | Genauigkeit von Validdaten (Schritt 1) | Genauigkeit von Validdaten (Schritt 2) | Genauigkeit von Testdaten |
|---------------|----------------------------------------|----------------------------------------|---------------------------|
| $4,8\sqrt{t}$ | 40,54%                                 | 86,49%                                 | 76,14%                    |
| $4,9\sqrt{t}$ | 38,09%                                 | 97,44%                                 | 81,82%                    |
| $5,0\sqrt{t}$ | 68,42%                                 | 94,74%                                 | 78,41%                    |
| $5,1\sqrt{t}$ | 69,44%                                 | 94,44%                                 | 71,59%                    |
| $5,2\sqrt{t}$ | 81,08%                                 | 100%                                   | 63,64%                    |



(a) Fine Tuning Verlust (Rechts) und Genauigkeit (Links) mit Epoche von Greedy-Layerwise-Methode



(b) Fine Tuning Verlust (Rechts) und Genauigkeit (Links) mit Epoche von Tying-Weights-Methode

**Abbildung 8.9:** Performance des Fine-Tunings

## 8.3 ML-Modells für verschiedenen Stromstärken

### 8.3.1 Klassifizierung der Schweißqualität bei Stufenuntersuchung

In dieser Arbeit wurden 3 Typen der überwachten ML-Modells versucht, LQV, Baumbasiertes und SVM. Der Ziel der ML-Modelle ist, durch Eingabe der von den Messsignals

extrahierten Features (Tabelle B.4) die 3 Qualitätsklassen (kalt, normal, Spritzer) auszugeben.

Die ausgewählten Features für ML sollten informativ, unabhängig und einfach sein. Da die Menge Features aus einem Signal extrahiert wurden, haben die Features untereinander Multikollinearität. Um die Dimensionen zu reduzieren und die Multikollinearität zu vermeiden, ist die Hauptkomponentenanalyse (PCA) bei weitem der beliebteste Algorithmus zur Reduzierung der Dimensionalität [9]. In PCA gibt es eine nützliche Information: das Prozentsatz der erklärten Varianz jeder Hauptkomponente. Das Prozentsatz gibt den Anteil der erklärten Varianz des Datensatzes an, der entlang jeder Hauptkomponente liegt. Anstatt willkürlich die Anzahl der Dimensionen zu wählen, auf die reduziert werden soll, ist es einfacher, die Anzahl der Dimensionen zu wählen, die einen ausreichend großen Teil der erklärten Varianz ergeben, z. B. 90%. Eine PCA führt für die Features durch, ohne die Dimensionen zu verringern, und berechnet dann die Mindestanzahl von Dimensionen, die erforderlich sind, um 90% der Varianz der Trainingsdaten beizubehalten (Abbildung 8.10). Vor Verwendung einer PCA wurde zuerst eine Normalisierung der Daten in Gebrauch gemacht, hier ein Skalieren jedes Features anhand seines maximalen Absolutwerts, es verschiebt oder zentriert die Daten nicht und zerstört somit keine Spärlichkeit.

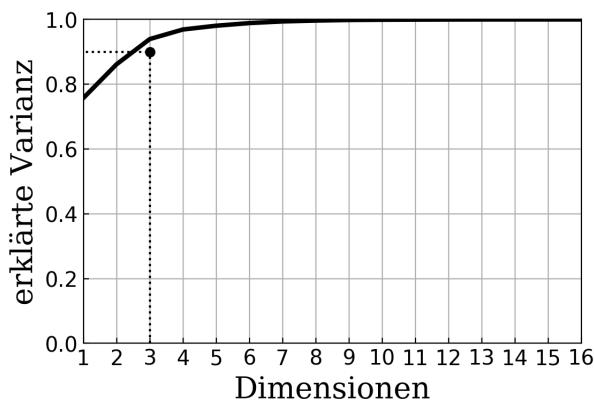


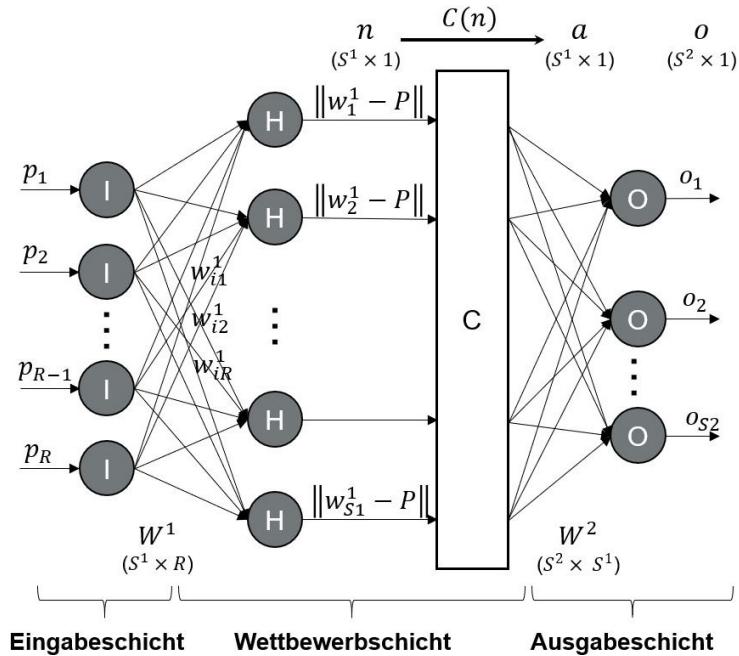
Abbildung 8.10: Erklärte Varianz als Funktion der Anzahl der Dimensionen

### 8.3.1.1 Klassifizierung durch LVQ-Algorithmus

LVQ ist auch eine sogenannte prototypbasierte Lernmethode (Abbildung 8.11). Ein oder mehrere Prototypen werden verwendet, um jede Klasse im Datensatz darzustellen. Jeder Prototyp wird als Punkt im Feature-Space beschrieben. Neues Datenpunkt wird dann die Klasse des Prototyps zugewiesen, das ihnen am nächsten liegt. Damit „am nächsten“

sinnvoll ist, muss ein Abstand definiert werden. In der Regel ist die euklidische Entfernung das Abstandsmaß auszuwählen. Es gibt keine Einschränkung, wie viele Prototypen pro Klasse verwendet werden können. Die einzige Voraussetzung ist, dass für jede Klasse mindestens 1 vorhanden ist. Die Parameter des Netzwerks sind wie folgt:

- $R$ : Die Anzahl der Neuronen von Eingabeschicht;
- $P$ : Der Eingabevektor von Trainingsdaten  $P = [p_1 \ p_2 \ \dots \ p_R]^T$
- $S^i$ : Die Anzahl der Neuronen in der  $i$ -ten Schicht;
- $W^1$ : Die Gewichtsmatrix zwischen der Eingabeschicht und der verdeckten Schicht,  $W^1 = [w_1^1 \ w_2^1 \ \dots \ w_{S^1}^1]^T$ , wobei  $w_i^1 = [w_{i1}^1 \ w_{i2}^1 \ \dots \ w_{iR}^1]$ ,  $i = 1, 2, \dots, S^1$ ;
- $W^2$ : Die Gewichtsmatrix zwischen der verdeckten Schicht und linearen Ausgabeschicht,  $W^2 = [w_1^2 \ w_2^2 \ \dots \ w_{S^2}^2]^T$ , wobei  $w_j^2 = [w_{j1}^2 \ w_{j2}^2 \ \dots \ w_{jS^1}^2]$ ,  $j = 1, 2, \dots, S^2$ ;



**Abbildung 8.11:** Architektur des neuronalen Netzwerks der lernenden Vektorquantisierung (LVQ)

Die verdeckte Schicht solches Netzwerks ist die sogenannte Konkurrenzschicht und wird daher mit dem Buchstaben C bezeichnet. Jedes Neuron (H) in der Konkurrenzschicht des Netzwerks berechnet den euklidischen Abstand zwischen dem gegebenen Eingabevektor  $P$  und einem prototypischen Unterklassenvektor  $w_i^1$  (die Zeile der Gewichtsmatrix  $W^1$ ) und findet den Prototypvektor  $w_i^1$ , der den geringsten Abstand von dem Eingabesvektor hat. Das Neuron, das den geringsten Abstand zwischen der Prototypvektor und dem Eingabevektor besitzt, wird ein Wert von 1 zugewiesen, und den anderen Neuronen wird ein Wert von 0 zugewiesen. Dies bedeutet, dass nur ein Ausgangsneuron als „Gewinner“

ausgewählt wird. Die Aktivierung des  $i$ -ten Neurons ist wie folgt:

$$a_i = \begin{cases} 1 & \text{wenn } i == \operatorname{argmin}([\|w_1^1 - P\| \dots \|w_{S^1}^1 - P\|]) \\ 0 & \text{sonst} \end{cases} \quad (8.1)$$

Schließlich verbindet die Ausgangsschicht (lineare Schicht) die Unterklassen aus der Konkurrenzschicht und der Gewichtsmatrix  $W^2$  durch eine lineare Übertragungsfunktion in Zielklassen (Gl. 8.2).

$$o = W^2 \cdot a \quad (8.2)$$

Die Reihe von  $W^2$  bezeichnet die Unterklasse und die Spalte bezeichnet die Klasse, darin nur ein Element 1 ist, und dies bedeutet, dass die Unterklasse zu der Klasse gehört, die in der Reihe wie folgt angegeben (Gl. 8.3) ist [42]:

$$W^2_{rk} = \begin{cases} 1 & \text{vorhanden und nur für } r \in K \text{ (Klasse)} \\ 0 & \text{wenn } r \notin K \text{ (Klasse)} \end{cases} \quad (8.3)$$

Wobei  $r = 1, 2, \dots, S^2$ ,  $k = 1, 2, \dots, S^1$ . Sobald  $W^2$  definiert ist, kann es nicht mehr geändert werden, während  $W^1$  für die Dauer des Trainingsprozesses reguliert wird. Die Gewichte (Prototypvektor)  $w_i^1$  des gewonnenen Neurons (eine Zeile der  $W^1$ ) werden unter Verwendung der Kohonen-Lernregel angepasst. Wenn  $P(i)$  (der Eingabevektor im  $i$ -ten Schritt) korrekt klassifiziert ist, wird der Prototypvektor des gewonnenen Neurons im  $i$ -ten Schritt  $w^1(i)$  gemäß der folgenden Gl. 8.4 in Richtung  $P(i)$  bewegt [38]:

$$w^1(i) = w^1(i-1) + \alpha \cdot (P(i) - w^1(i-1)). \quad (8.4)$$

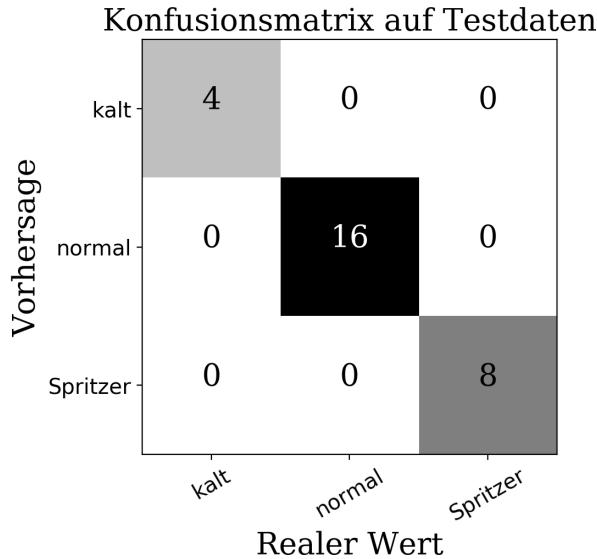
Wobei  $\alpha$  konstant Koeffizient für die dynamische Lernrate ist, die mit zunehmender Epoche abnimmt und liegt normalerweise im Bereich 0...1. Wenn  $P(i)$  jedoch falsch klassifiziert ist, wird der Prototypvektor des gewonnenen Neurons  $w^1(i)$  gemäß der folgenden Gl. 8.5 von  $P(i)$  wegbewegt:

$$w^1(i) = w^1(i-1) - \alpha \cdot (P(i) - w^1(i-1)). \quad (8.5)$$

LVQ2 ist eine verbesserte Version des Basis-LVQ. LVQ2 ermittelt einen zweiten Gewinner, der nach dem ersten Gewinner noch miternt. Es wird nur gelernt, wenn  $P(i)$  zur Klasse vom zweiten Gewinner gehört und nicht zur Klasse des ersten Gewinners. Der Gewinner wird weggedrückt, der zweite Gewinner angezogen, d. h. die Prototypvektoren von zwei

Neuronen werden aktualisiert. Die Referenz von Code ist hier [25] zur Verfügung.

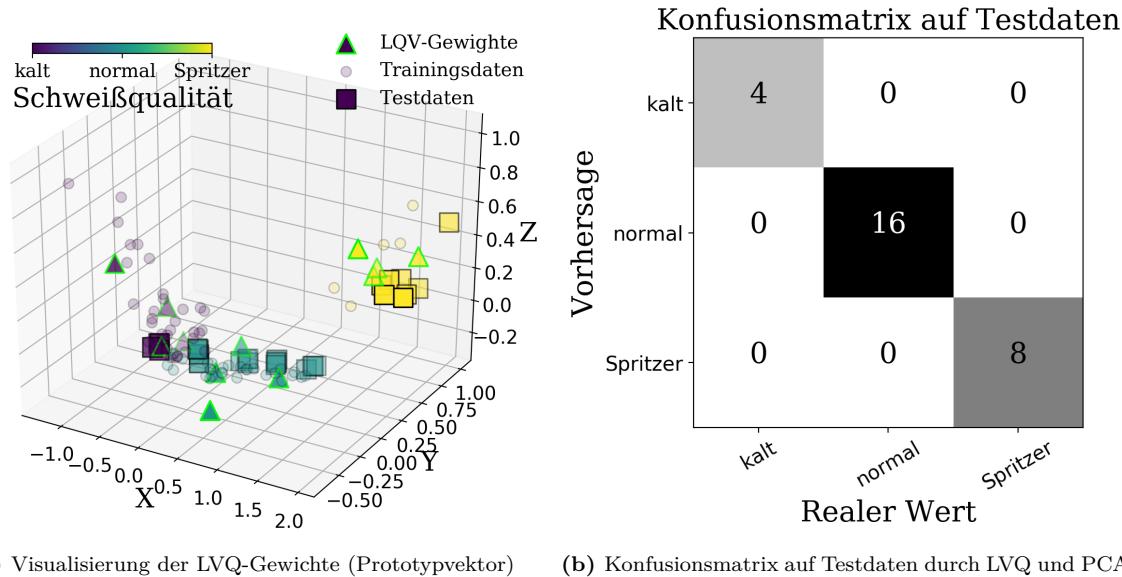
Nach der Experiment haben 68 Schweißpunkte und ihren Messdaten zu Trainings- und Validierungsdaten zur Verfügung gesteht. In dieser Arbeit ist der Eingabevektor  $P$  ein Vektor der Dimension 16, der der Anzahl der Features in der Tabelle B.4 entspricht. Um die optimalen Hyperparameter zu bestimmen, wurde ein „Estimator“ zur Optimierung der Hyperparameter, z. B. „GridSearchCV“ [40] verwendet. Der beste Estimator wurde von GridSearchCV ausgewählt wurde, d. h. dieser Estimator hat die höchste Genauigkeit, die die Performance des kreuzvalidierten Modells auf dem Testdatensatz bewertet. Die Anzahl der Neurons der Ausgabeschicht ist 3, was den drei Kategorien des Schweißqualität entspricht: kalt, normal und Spritzer. Die Anzahl der Neurons der verdeckte Schicht ist 9, was die nach dem GridSearchCV bestimmt Anzahl der Prototypvektor entspricht. Die Gewichtsmatrizes  $W^1$  und  $W^2$  hatten die Größen  $(9 \times 16)$  und  $(3 \times 9)$ . 9 verdeckte Neuronen wurden mit konstant Koeffizient  $\alpha$  von 0,01 für die dynamische Lernrate verwendet. Die Abbildung zeigt die durch LVQ vorhergesagten Klassen und die tatsächlichen Klassen der Testdaten.



**Abbildung 8.12:** Konfusionsmatrix auf Testdaten durch LVQ

Um die Datenvisualisierung zu ermöglichen, wurde die Eingabevektor  $P$  ein Vektor der Dimension 3, die nach der PCA bestimmt wurde, wie in der Abbildung 8.10 dargestellt. Hierbei war die Anzahl der Neuronen der verdeckten Schicht nach der GridSearchCV 12 und die Gewichtsmatrizen  $W^1$  und  $W^2$  hatten die Größen  $(12 \times 3)$  und  $(3 \times 12)$ . Die Abbildung 8.13 zeigt die Eingabevektoren von Testdaten und Trainingsdaten und die Prototypvektoren  $w^1$  nach der PCA. Es ist deutlich zu erkennen, dass die Prototypvektoren

von jeder Klasse nach der Regulation zuständig für eine spezifische Raumzone sind und in der Raumzone die Eingabevektoren von der entsprechenden Klasse sich gruppieren und meistens in der nah von Prototypvektoren liegen. Zwar haben die nach der PCA erhaltenen Prototypvektoren  $w_i^1 = [X_i \ Y_i \ Z_i]$  die Interpretation verloren, aber die durch Verwendung des ausgewählten besten Schätzers ermittelte Genauigkeit war noch sehr beeindruckend.



**Abbildung 8.13:** LVQ Klassifizierung nach PCA

### 8.3.1.2 Klassifizierung durch Baum-Algorithmus

Entscheidungsbaum (DT) ist ein nicht parametrisch überwachte Modell, die zur Klassifizierung und Regression verwendet wird. Ziel ist es, ein Modell zu erstellen, das den Wert einer Ziel vorhersagt, indem einfache Entscheidungsregeln gelernt werden, die aus den gegebenen Features abgeleitet werden. Ein Baum kann als stückweise konstante Annäherung angesehen werden. Nach der PCA haben die Dimensionen von 16 auf 3 ( $X, Y, Z$ ) reduziert. Die Abbildung 8.14 a erklärt das Trainigsbaum. Nach einem Kriterium  $X \leq -0,109$  von Wurzelknoten wurden die gesamten Trainigsdaten in einem Blattknoten und einem Entscheidungsknoten aufgeteilt. Bei Blattknoten waren alle kalte Schweißpunkte davon genau getrennt, während bei Entscheidungsknoten nach einem Kriterium  $Z \leq 0,142$  noch eine Entscheidung benötigt wurden, um die Blattknoten für normale Schweißpunkte und Schweißpunkt mit Spritzer zu enthalten. Das trainierte Modell für die Testdaten zu verwenden zeigt bisher eine hohe Genauigkeit (Abbildung 8.14 b).

Aufgrund der PCA ist die Interpretation des Modells jedoch beeinflusst. Ein Random-

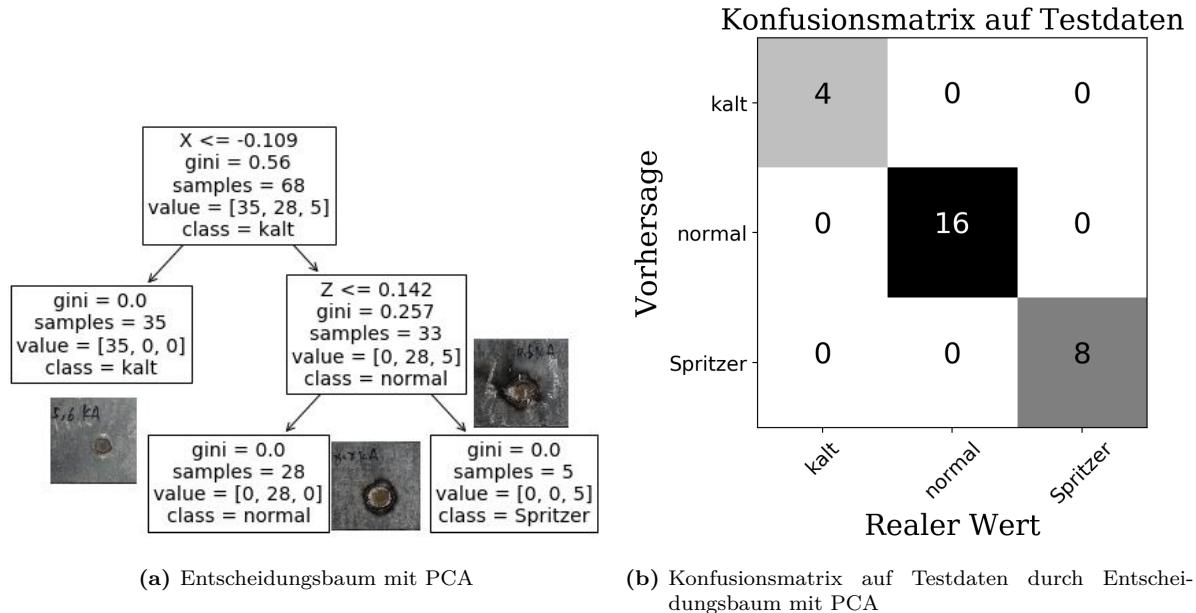


Abbildung 8.14: Entscheidungsbaum Klassifizierung nach PCA

Forst-Klassifikator (RF) ist in der Lage, die Wichtigkeit der Features zu finden. Je höher die Wichtigkeit ist, desto wichtiger ist die Feature. Sie ist auch als die Gini-Wichtigkeit bekannt. Die Anzahl des Entscheidungsbaums ist einer der wichtigen Parameter für RF, dass die nach der Gini-Wichtigkeit ausgewählten Features beeinflussen kann. Die Abbildung 8.15 a zeigt die Genauigkeit der Testdaten mit der Anzahl des Entscheidungsbaums. War die Anzahl 6, hatte der Random-Forst-Klassifikator zur Klassifikation der Testdaten die höchste Genauigkeit und waren die entsprechenden Wichtigkeiten der Features in Abbildung 8.15 b dargestellt. Endlich waren diese Featurekombination:  $\Delta e_{max}$ ,  $P_v$ ,  $Q$ ,  $R_{10}$ ,  $\Delta P$ ,  $\rho$ . Die Abbildung 8.16 zeigt die Struktur vom optimalen Random-Forest-Klassifikator mit 6 Entscheidungsbäumen. Jedes Entscheidungsbaum kann einer Eingabe eine Klasse zuweisen und nach Majoritätsabstimmung wird die finale Klasse dieser Eingabe festgelegt.

### 8.3.1.3 Klassifizierung durch SVM-Algorithmus

Eine Stützvektormaschine (SVM) ist ein mächtiges und vielseitig einsetzbares Modell für maschinelles Lernen, das lineare oder nichtlineare Klassifizierung, Regression und sogar Ausreißererkennung durchführen kann. Es ist eines der beliebtesten Modelle für maschinelles Lernen. SVMs eignen sich besonders gut zur Klassifizierung komplexer kleiner oder mittlerer Datensätze. In dieser Arbeit wurde C-Stützvektor-Klassifikation (SVC) be-

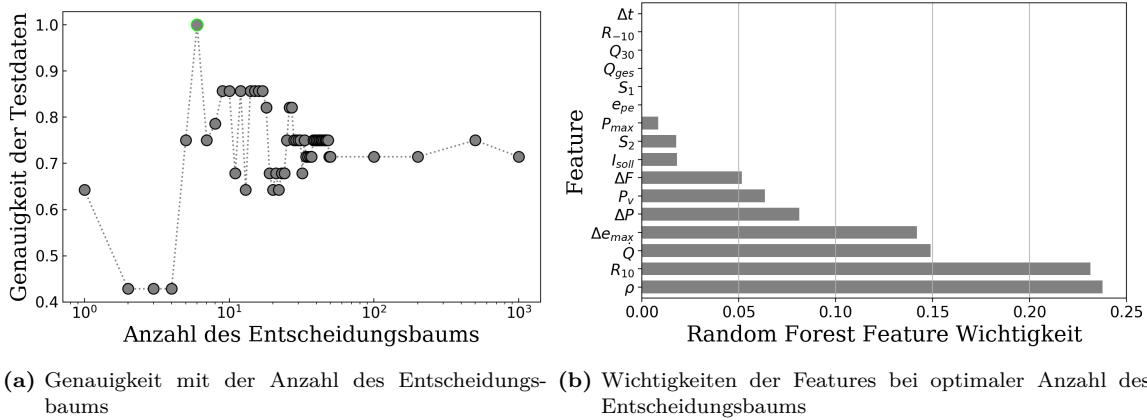


Abbildung 8.15: Random-Forest-Klassifikator

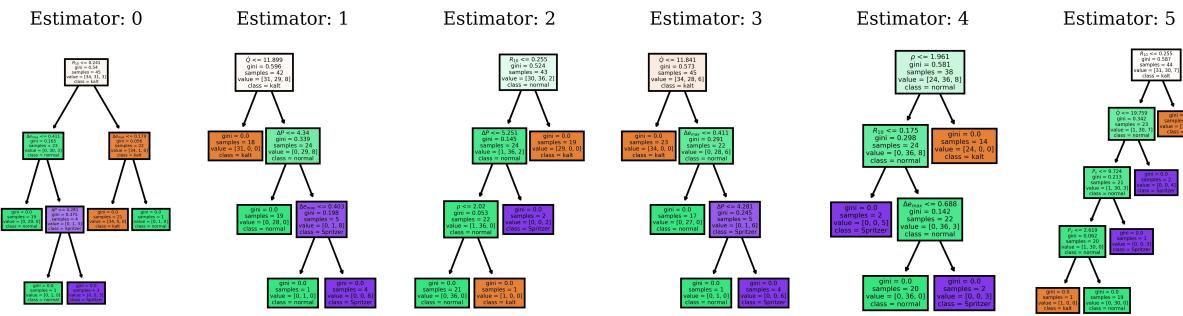


Abbildung 8.16: Entscheidungsbäume vom optimalen Random-Forest-Klassifikator

nutzt, weil SVC die Kern-Funktionen bieten kann. Nach dem GridSearchCV wurden die lineare Kernelfunktion mit Regularisationsparameter  $C=10$  zur Klassifizierung der Testdaten verwendet, die Ergebnisse ist in der Abbildung 8.17 dargestellt. Die Genauigkeit von SVM mit linearer Kern-Funktion ist 89,28% für Testdaten.

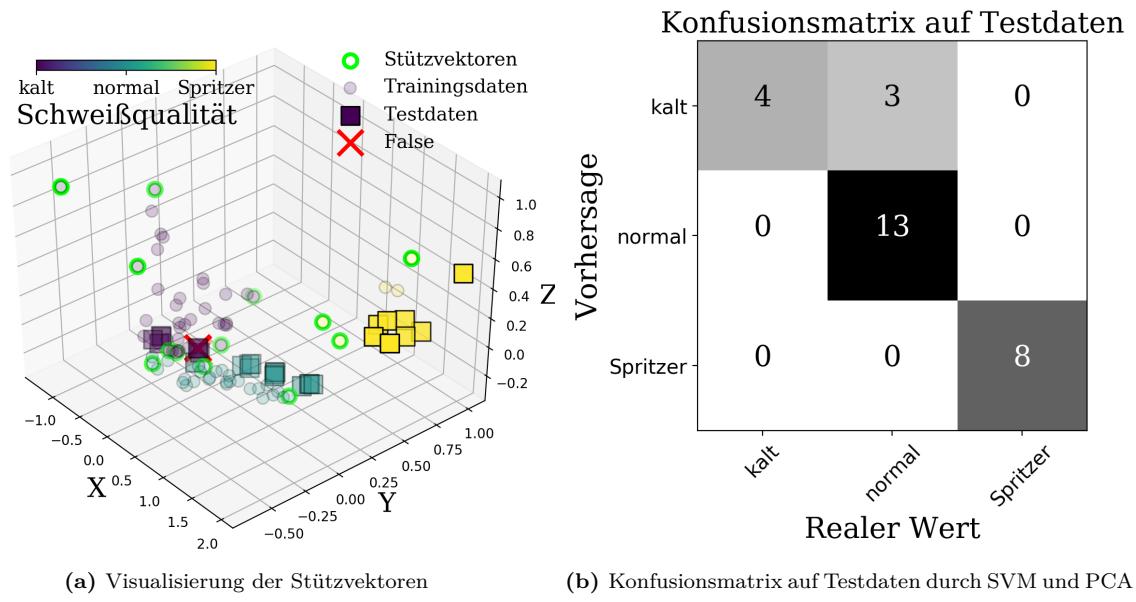


Abbildung 8.17: SVM Klassifizierung nach PCA

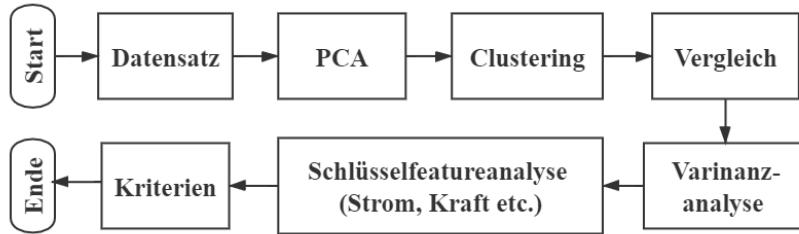
### 8.3.1.4 Zusammenfassung

Tabelle 8.6: Unterschiedliche ML-Modelle zur Klassifizierung der Schweißpunktqualität

| ML-Modell | Feature | PCA<br>(erklärte Varianz<br>über 90%) | Genauigkeit<br>[%] | Klasse   |
|-----------|---------|---------------------------------------|--------------------|----------|
| LVQ       | 16/3    | Nein/Ja                               | 100                | kalt     |
|           |         |                                       |                    | normal   |
|           |         |                                       |                    | Spritzer |
| DT        | 3       | Ja                                    | 100                | kalt     |
|           |         |                                       |                    | normal   |
|           |         |                                       |                    | Spritzer |
| RF        | 6       | Nein                                  | 100                | kalt     |
|           |         |                                       |                    | normal   |
|           |         |                                       |                    | Spritzer |
| SVC       | 3       | Ja                                    | 89,28              | kalt     |
|           |         |                                       |                    | normal   |
|           |         |                                       |                    | Spritzer |

### 8.3.2 Klassifizierung der Spritzeruntersuchung

Wie in der Unterabschnitt 4.2.2 erwähnt, haben die Label zwar während des Experiments für jedes einzelne Blech zugewiesen, aber die durch Einschätzung und Beobachtung auf den Blechoberflächen markierten Labeln könnten anders wie die von den Messsignale abgeleiteten Label sein. Damit die Kriterien zur Klassifizierung der Spritzerstärke herauszufinden sind, ist es zuerst notwendig, das unüberwachte Lernen zur Klassifizierung der Spritzerstärken durchzuführen. Danach ist es in der Lage, einen Vergleich zwischen den von Messsignale extrahierten Features mittels unüberwachtes ML-Modells abgeleiteten Labels und den durch Einschätzung und Beobachtung zugewiesenen Label zu erstellen. Durch Varianzanalyse für jede Klasse können ein paar Schlüsselfeatures eingenommen werden, die große Einflüsse auf die Klassifizierung besitzen könnten. Anschließend sind die Kriterien mittels ausgewählten Schlüsselfeatures herauszufinden (Abbildung 8.18). Die verwendeten Features sind in der Tabelle B.5 verfügbar.

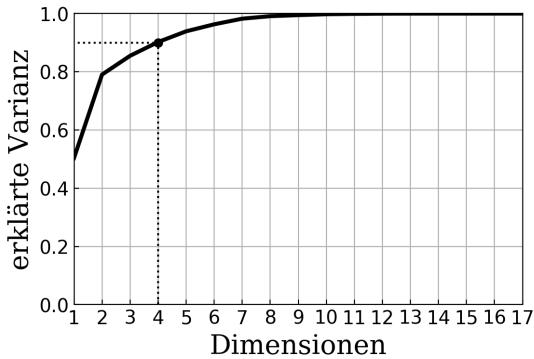


**Abbildung 8.18:** Herausfinden der Kriterien zur Klassifizierung der Spritzerstärke

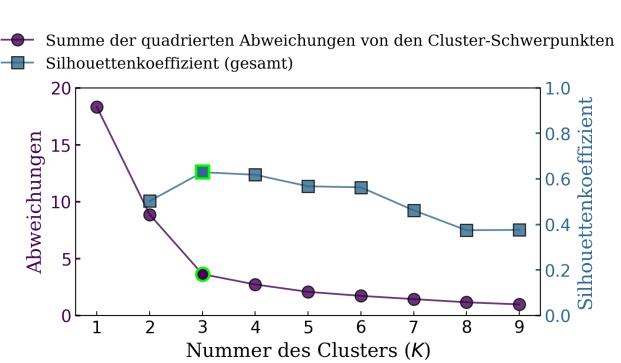
#### 8.3.2.1 Spritzeruntersuchung bei MDK1

Für Clustering wurde K-Means in diese Arbeit verwendet. Der K-Means-Algorithmus ist ein einfacher Algorithmus, mit dem die Datensatz sehr schnell und effizient geclustert werden kann, häufig in nur wenigen Iterationen. Nach der PCA (erklärte Varianz über 90%) haben die Dimensionen von 17 auf 4 reduziert (Abbildung 8.19). Die optimale Anzahl der Cluster  $K$ , die der Algorithmus finden muss, kann durch die Summe der quadrierten Abweichungen von den Cluster-Schwerpunkten und Mittelwert der Silhouettenkoeffizienten, wie in der Abbildung 8.20 festgestellt werden. Die Anzahl von Cluster kann so ausgewählt, dass das Hinzufügen eines weiteren Clusters kein wesentlich besseres Modell liefert. Diese Kurve hat ungefähr „Ellbogen“ bei  $K = 3$ . Ein genauerer Ansatz ist die Verwendung des Silhouettenkoeffizienten. Der SilhouettenKoeffizient kann zwischen  $-1$  und  $+1$  variieren.

Ein Koeffizient nahe +1 bedeutet, dass sich die Instanz innerhalb ihres eigenen Clusters und weit entfernt von anderen Clustern befindet, während ein Koeffizient nahe 0 bedeutet, dass sie nahe an einer Clustergrenze liegt, und schließlich bedeutet ein Koeffizient nahe -1, dass sich die Instanz befindet möglicherweise in einem falschen Cluster. Die Kurve hat bestätigt, dass  $K = 3$  eine gute Wahl sein konnte.



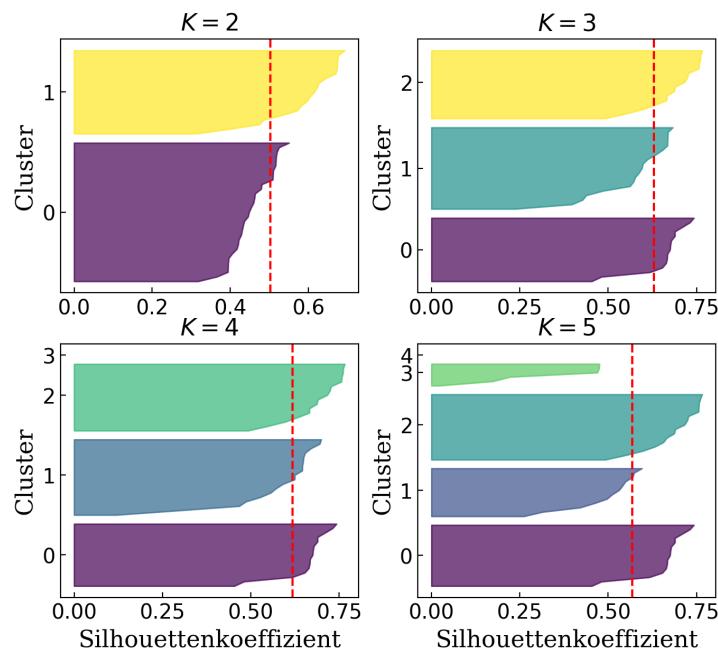
**Abbildung 8.19:** Erklärte Varianz als Funktion der Anzahl der Dimensionen für



**Abbildung 8.20:** Optimalen Anzahl der Cluster

Das Silhouette-Diagramm (Abbildung 8.21) ist noch aussagekräftigere Darstellung. Jedes Diagramm enthält ein Messer Form pro Cluster. Die Höhe der Form gibt die Anzahl der Instanzen an, die der Cluster enthält, und ihre Breite gibt die sortierten Silhouettenkoefizienten der Instanzen im Cluster an (breiter ist besser). Bei  $K = 3$  waren alle Cluster mehr oder weniger ähnlich dick und jede Breite von Cluster war höher als Mittelwert des Silhouettenkoeffizienten.

Nach dem Clustering wurden die Schweißpunkte in drei Clustern verteilt, ohne Spritzer, kleiner Spritzer und starker Spritzer. Jede Feature aus der Tabelle B.5 wurde den Mittelwert von jedem Cluster ermittelt, je größer der Varianz der Mittelwerte von einer Feature ist, desto größere Rolle könnte diese Feature zur Klassifizierung der Spritzerstärke gespielt haben, d. h. Schlüsselfeature, wie in der Abbildung 8.22 dargestellt. Es ist deutlich zu beobachten, dass die Features:  $\Delta I$ ,  $S_2$ ,  $\Delta F$ ,  $e_{pe}$  relativ große Varianz der Mittelwerte haben, d. h. die vier Features könnten als Schlüsselfeatures in weiterer Analyse benutzt werden. Außerdem kommen die vier Features aus Stromsignal, Kraftsignal und Wegmessung, die entsprechenden Signalverläufe von jedem Cluster sind in der Abbildung 8.23 dargestellt. Aus der Sicht der Signalverläufe sind die Ergebnisse von Clustering zufrieden. Von dem Stromsignal scheint es so, dass kein Impuls  $\Delta I$  über das Schweißprozess in den Signalen existiert haben, die in Klasse 0 geclusterten wurde, während in Klasse 1 und 2 jedoch niedriger oder hoher, ein oder mehrere Impulse vorhanden sind. Hohe oder mehrere Impulse



**Abbildung 8.21:** Auswählen der Anzahl der Cluster mit Silhouette-Analyse bei KMeans-Clustering

könnten bedeuten, dass bei dem Schweißen starker Spritzer passiert hat. Drüber hinaus wurde der Impuls in Klasse 2 normalerweise früher aufgetreten als in Klasse 1, d. h. die zugeführte Wärmemenge war groß genug und zu viel über die theoretische Wärmemenge, sodass der Spritzer früher und stärker aufgetreten wurde.

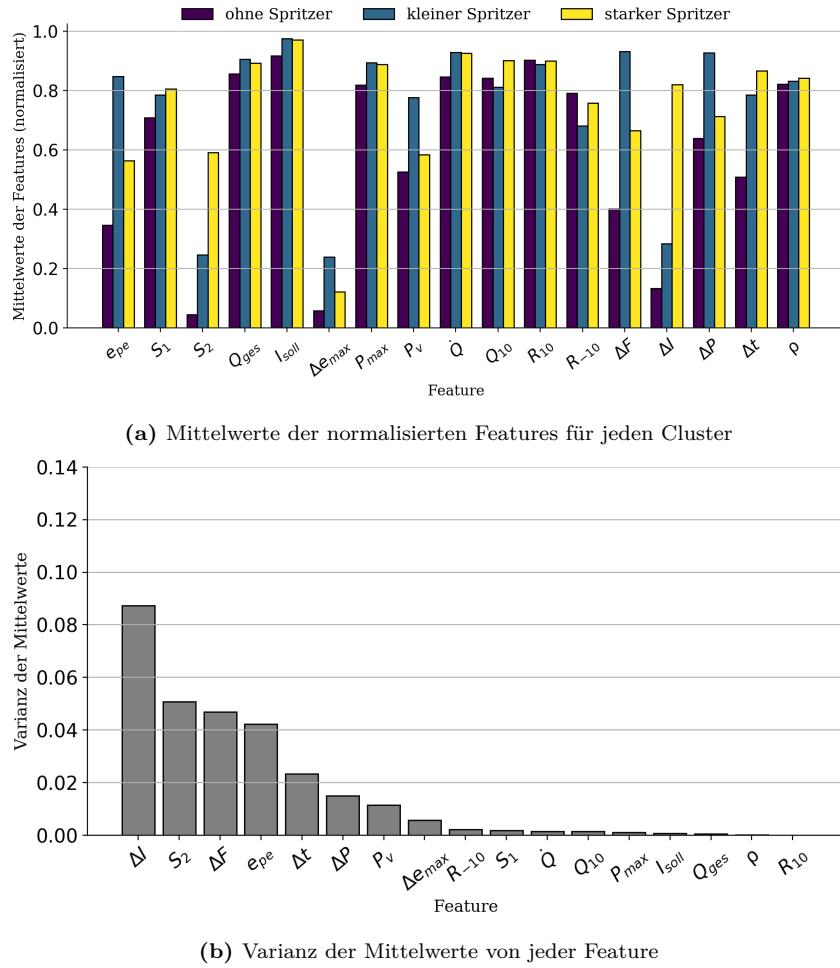


Abbildung 8.22: Schlüsselfeature zum Clustering

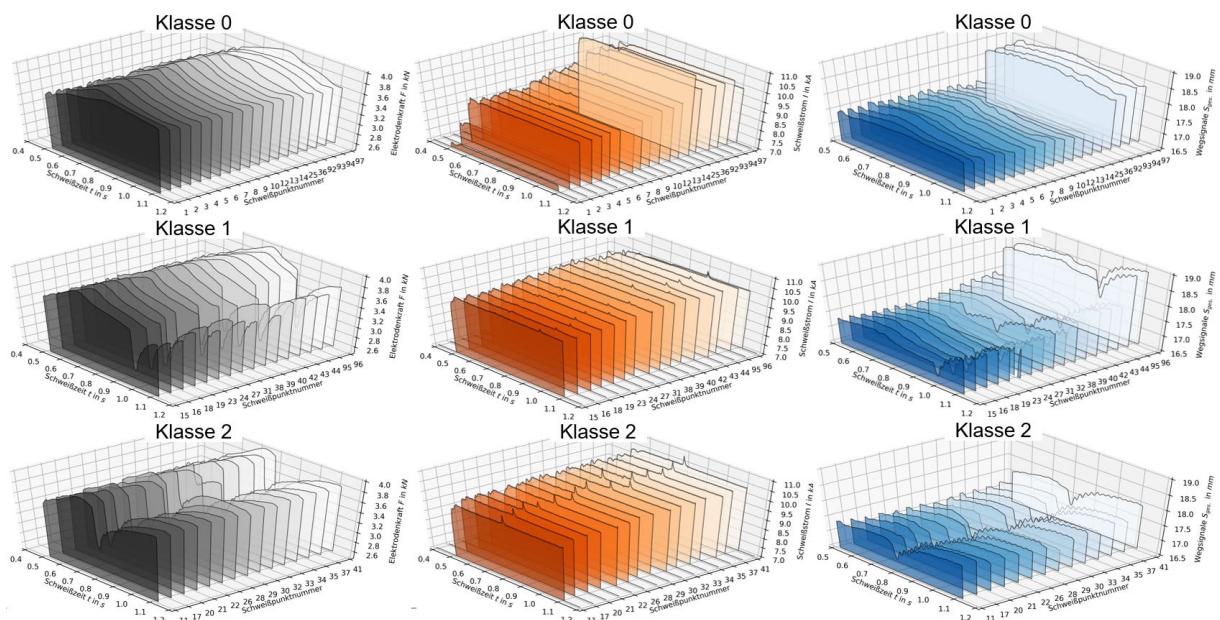


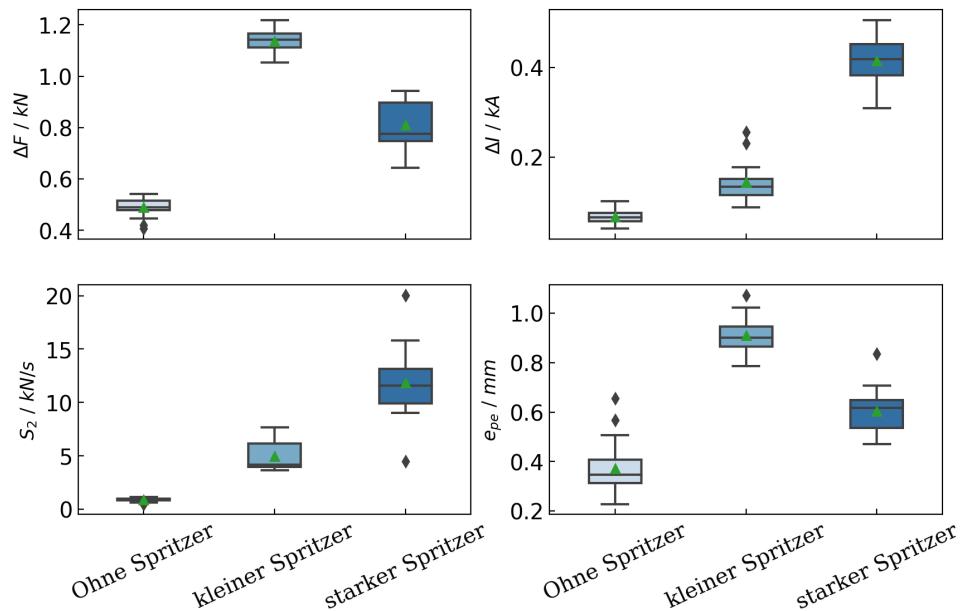
Abbildung 8.23: Signalverläufe von jedem Cluster (Links: Kraftsignal; Mitte: Stromsignal; Rechts: Summe der Wegmessung von oberen und unteren Elektroden)

Anschließend können die Kriterien zur Klassifizierung der Spritzerstärke von der Abbildung 8.24 abgeleitet werden. Der starke Spritzer wurde höheren Impuls  $\Delta I$  und Elektrodenkraftabstiegsgradient  $S_2$  verhalten. Aufgrund dem früheren Auftreten der Spritzer bei Klasse 2 wurden die Kraftdifferenz  $\Delta F$  und Eindrucktiefe  $e_{pe}$  beim Prozessende im bestimmten Zeitbereich relativ wenig sein, trotzdem wurden sie bei Klasse 2 größer als bei Klasse 0

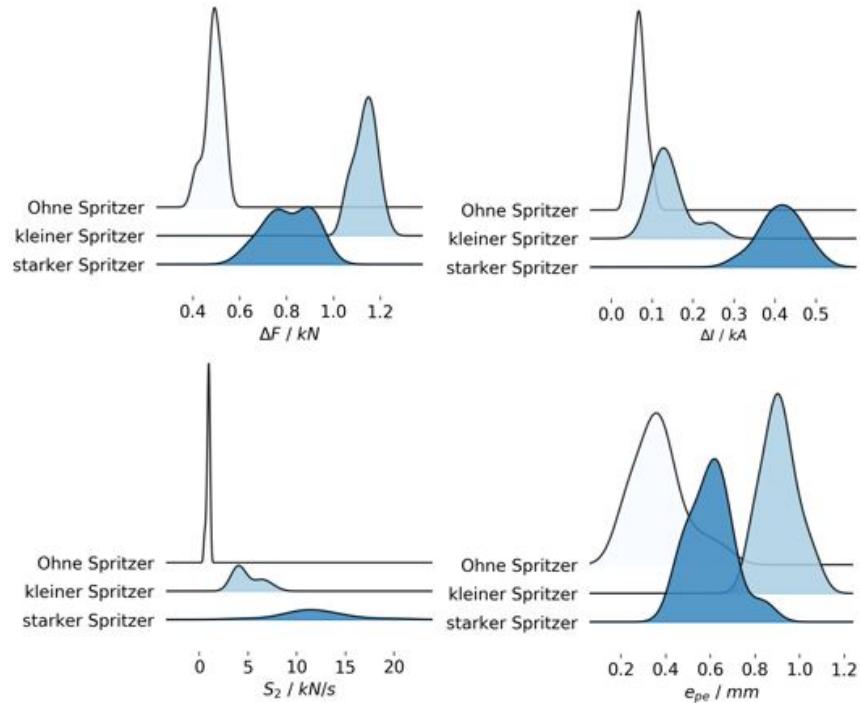
### 8.3.2.2 Spritzeruntersuchung bei MDK2

Durch die Analyse der Messsignale war es herauszufinden, dass es groß Unterschied zwischen den auf Blech markierten Labeln und durch K-Means zugewiesenen Labeln gab, besonders bei kleinem und keinem Spritzer. Einerseits wurde ein Spritzer zwar während des Schweißens beobachtet, aber ist der Spritzer zu wenig, sodass die von gefilterten Messsignals extrahierten Features allerdings die Bedeutung zur Klassifizierung verloren könnten, was negativ auf die PCA auswirken könnte, andererseits war Spritzer oder kein Spritzer während des Schweißens deutlich zu beobachten, aber es könnten unscharf sein, durch visuelle Beobachtung die Spritzerstärke zu klassifizieren. Deswegen wurden die signifikanten Features ( $\Delta I$ ,  $S_2$ ) anstatt der durch PCA extrahierten Features in K-Means verwendet (Abbildung 8.25). Die Abweichungen der von Cluster-Schwerpunkten mit den signifikanten Features ist niedriger als mit PCA und der Silhouettenkoeffizient mit den signifikanten Features auch besser (größer) als mit PCA. Das Silhouette-Diagramm (Abbildung 8.27) bei  $K = 3$  zeigt das optimale Ergebnis vom Cluster bei  $K = 3$ . Die Abbildung 8.26 stellt die Cluster-Schwerpunkte mit den normalisierten signifikanten Features ( $\Delta I_{norm.}$ ,  $S_2 norm.$ ) bei  $K = 3$  dar.

Anschließend kommt es zur Varianzanalyse, wie in der Abbildung 8.28 dargestellt. Hierbei wurden  $\Delta I$  und  $S_2$  als Schlüsselfeatures als die Kriterien der Spritzerstärke verwendet (Abbildung 8.30). Die Schlüsselfeatures ist von Strom- und Kraftsignal extrahiert. Die Signalverläufe sind in der Abbildung 8.29 dargestellt. Die Klassen von Cluster bei MDK2 bedeuten: ohne oder sehr wenigen Spritzer, Spritzer, starken Spritzer.



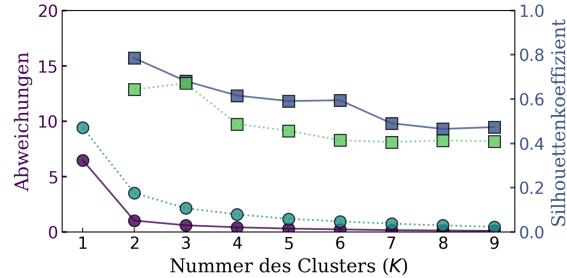
(a) Box-Plot der Schlüsselfeatures mit verschiedenen Clustern



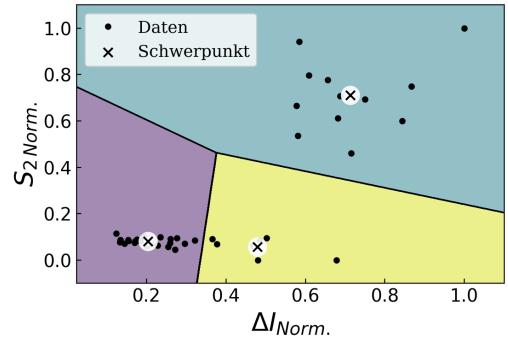
(b) Häufigkeitsverteilung der Schlüsselfeatures mit verschiedenen den Clustern

**Abbildung 8.24:** Kriterien zur Klassifizierung der Spritzerstärke

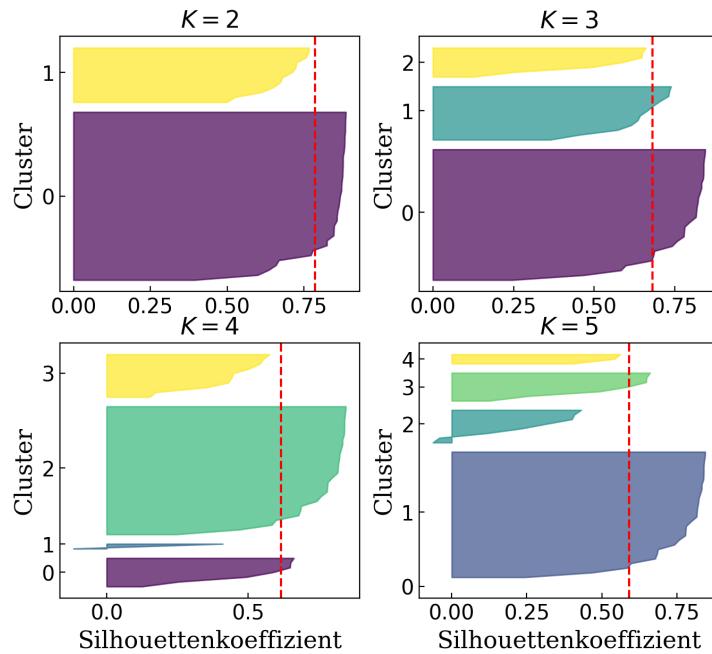
- Summe der quadrierten Abweichungen von den Cluster-Schwerpunkten ( $\Delta I, S_2$ )
- Summe der quadrierten Abweichungen von den Cluster-Schwerpunkten (PCA)
- Silhouettenkoeffizient (gesamt) ( $\Delta I, S_2$ )
- Silhouettenkoeffizient (gesamt) (PCA)



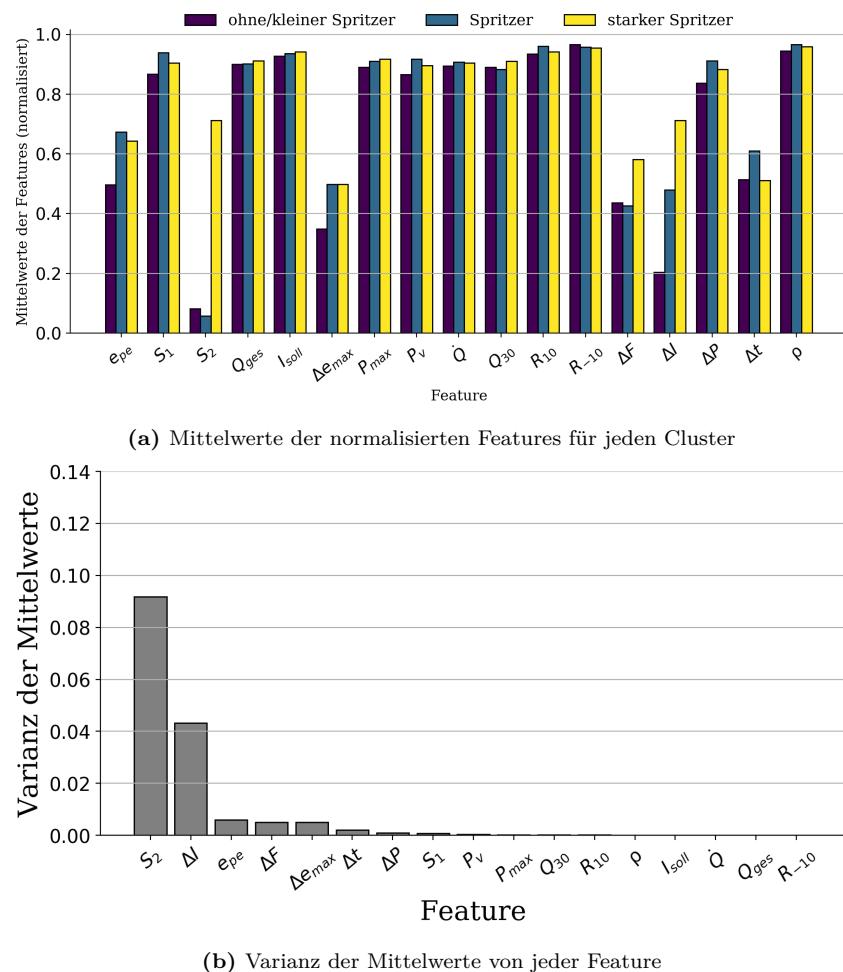
**Abbildung 8.25:** Vergleich der Abweichung und Silhouettenkoeffizienten zwischen signifikanten und Features und PCA

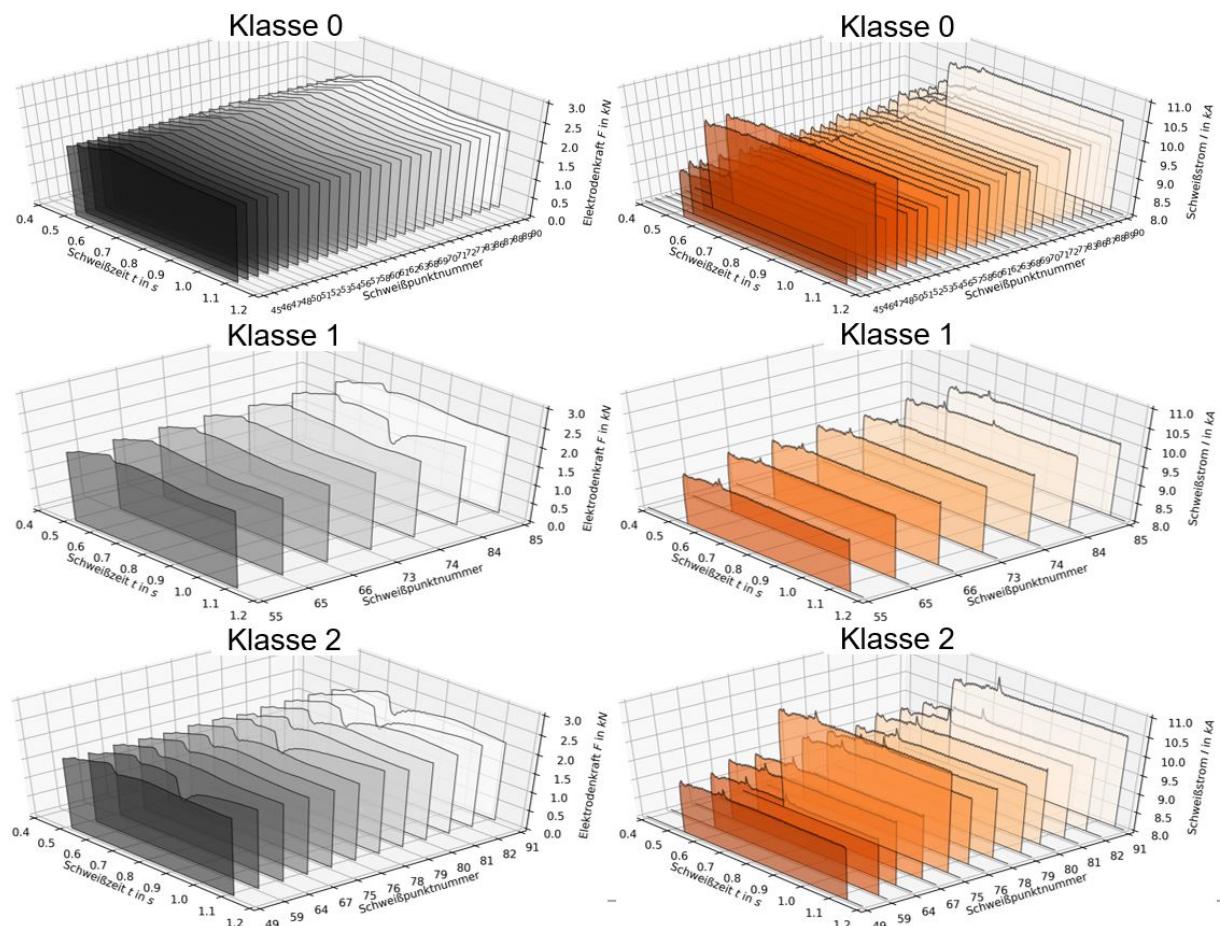


**Abbildung 8.26:** Clusterschwerpunkt

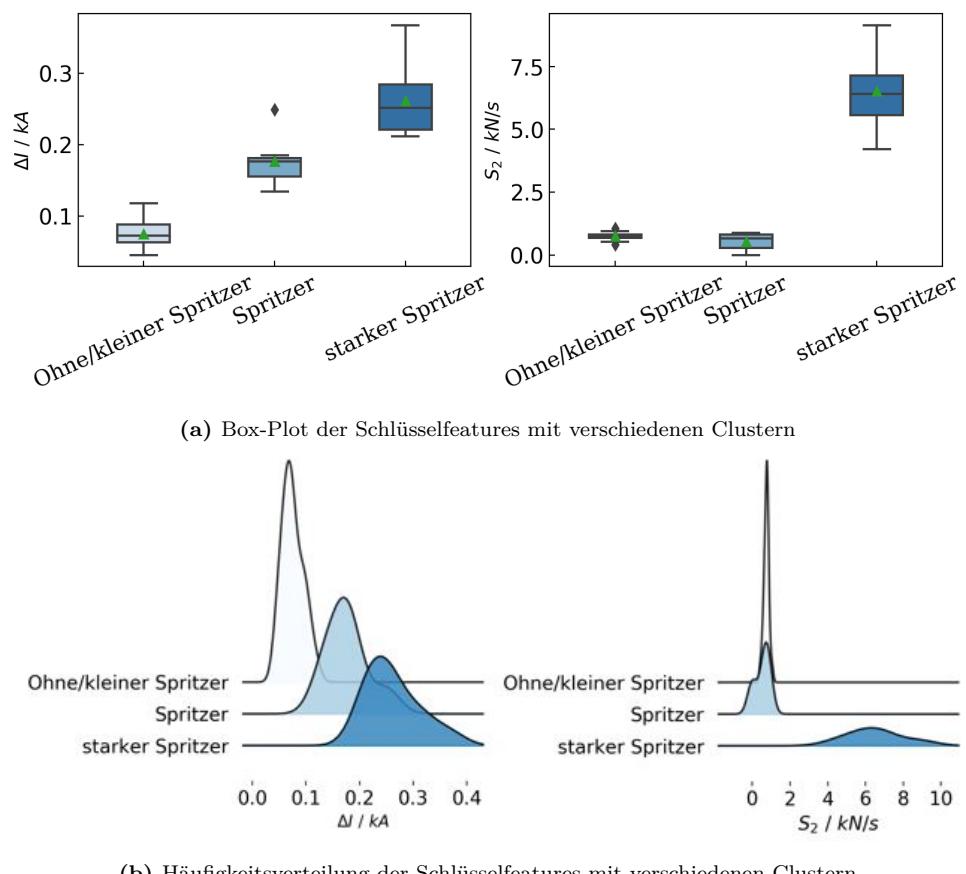


**Abbildung 8.27:** Auswählen der Anzahl der Clusters mit Silhouette-Analyse bei KMeans-Clustering

**Abbildung 8.28:** Schlüsselfeature zum Clustering



**Abbildung 8.29:** Signalverläufe von jedem Cluster (Links: Kraftsignal; Rechts: Stromsignal)



**Abbildung 8.30:** Kriterien zur Klassifizierung der Spritzerstärke

## 9 Zusammenfassung und Ausblick

In durchgeführten Versuchen von dieser Arbeit kamen zwei verschiedene Methoden zur Anwendung. Bei der ersten handelt es sich um die Analyse der Schweißpunktqualität in Abhängigkeit von nicht konstanten Elektrodenbedingungen aufgrund der Elektrodenabnutzung, während bei der zweiten die Veränderung der Schweißpunktqualität in Abhängigkeit von nicht konstanten Schweißstrom ist. In der Elektrodenverschleißuntersuchung waren ca. 4000 Schweißpunkte auf Prüfbleche und Verschleißbleche nach DIN EN ISO 8166 durchgeführten Schweißpunkte (MDK1) verfügbar, die durch kontinuierliches Schweißen eines Elektrodenpaars erfolgte. In dem Versuch verschiedener Schweißstromstärken wurde es in Stufenuntersuchung und Spritzeruntersuchung verteilt. In der Stufenuntersuchung wurde die Schweißpunkte (MDK2) mit Schweißstrom  $2,0 \dots 10,4 \text{ kA}$  durchgeführt. In der Spritzeruntersuchung wurden die Kriterien zur Klassifizierung der Spritzerstärke von den durch hohem Schweißstrom durchgeführten Schweißpunkten (MDK1 & MDK2) abgeleitet.

Während des Schweißprozesses jedes einzelnen Schweißpunkts wurden die Schweißspannung, der Schweißstrom, die Elektrodenkraft, die Elektrodenwegmessung durch Sensoren gemessen und als TDMS-Format eingespeichert. Die Messungen erfolgten bei einer Sampelerate  $1e^5 \text{ Hz}$ . Für alle in der Elektrodenverschleißuntersuchung durchgeführten Messungen wurde die Schweißpunktqualität durch Messungen des Ausknöpfbruchdurchmessers nach der DIN EN ISO 10447 bestimmt. Für alle in der Stufenuntersuchung der Schweißstromstärke durchgeführten Messungen wurde die Schweißpunktqualität durch drei Klassen klassifiziert: kalt, normal und Spritzer, die nach der Meißelprüfung basierend auf den Brucharten und der Spur von Spritzer bestimmt wurde. Für alle in der Spritzeruntersuchung durchgeführten Messungen wurde die Spritzerstärke zuerst nach Beobachtung und Einschätzung während des Schweißens vermutet.

Da das WPS unter einem Zusammenwirken von multiphysikalischen Feldern erfolgt, ist es schwierig, die Schweißpunktqualität ausschließlich nach Expertenwissen oder empiri-

scher Einschätzung ohne zerstörende oder zerstörungsfreie Prüfungen zu bewerten oder mittels einer klaren mathematischen Form darzustellen. Die Anwendung der ML-Modelle zur Bewertung der Schweißpunktqualität kann die Schwierigkeit überwinden. Allerdings sind die Trainingsdaten für Modellierung des ML-Modells notwendig. Vor der Modellierung des ML-Modells ist es notwendig, eine Vorverarbeitung für Messdaten zu schaffen. Für Schweißstrom und Schweißspannung wurde ein EGM Methode zum Filtern des Signals verwendet, die die effektiven Werte von einem gegebenen Signal durch bewegliches Fenster entlang der Zeitachse berechnet, während die Elektrodenkraft und Elektrodenwegmessungen durch Kalman-Filter und EGM entrauscht und geglättet wurden. Hierbei wurden die bedeutenden Features, die zum Training des ML-Modells verwendet wurden, wurden aus den vorverarbeiteten Messdaten extrahiert.

Aufgrund der Multikollinearität der Features und nichtlineare Beziehung zwischen Features und Zielen wurden die nichtlinearen ML-Modelle versucht. Trotz der umstrittenen Forschungen auf dem Gebiet der Analyse des WPSSs, aber das ML-Modell, das auf Trainingsdaten basiert, ist nicht möglich, eine allgemein gültige Lösung für die Prognose der Schweißpunktqualität auszuarbeiten.

Für der Elektrodenverschleißuntersuchung wurden das unüberwachte Pre-Training und überwachte Fine-Tuning Strategie verwendet, weil die Menge des ungelabelten Datensatzes viel größer als die Menge des gelabelten Datensatzes. Das Pre-Trainig wurde in zwei Methoden versucht, die einen ist Greedy-Layerwise-Methode, die durch Training der zwei einfachen Autoencodern nacheinander und dann Stapel der zwei Autoencodern in einen Autoencoder realisiert wurde, die anderen ist Tying-Weights-Methode, die durch Training einen genau symmetrischen Autoencoder erfolgte, deren Gewichte der Decoderschichten mit den Gewichten der Encoderschichten verknüpfen wurden. Bei Fine-Tuning wurde die DNN, die mittels gestapelten Ausgabeschicht und Encoderschichten modelliert wurde, mit dem gelabelten Datensatz mittels Backpropagation-Algorithmus wieder trainiert wurde, um die Gewichte und Bias fein abzustimmen. die DNN wurde für Klassifizierung verwendet, ob das Schweißpunktdurchmesser die  $d_{w,soll}$  erreicht hat. Die trainierten ML-Modelle von zwei Methode bei  $d_{w,soll} = 4,9\sqrt{t}$  verwendet, wobei die ML-Modelle die idealen Klassifizierungsgenauigkeiten von Validierungsdaten hatten.

Für den Versuch der Stufenuntersuchung verschiedener Stromstärken wurden drei Typen von ML-Modellen (LVQ, baumbasierte Methode, SVC) zur Klassifizierung der Schweißpunktqualität eingesetzt. LVQ ist ein überwachtes KNN, was besonders geeignet für kleines Datensatz ist. Baumbasiertes ML-Modell ist ebenfalls häufig zur Klassifizierung mit kollinearem Algorithmus eingesetzt. Hier wurden Entscheidungsbaum mit PCA und

Random-Forest-Klassifikator verwendet. SVC kann aufgrund der Kern-Funktionen das Problem der nichtlinearen Abbildung gut behandeln. Für der Spritzeruntersuchung haben die einzelnen Bleche zwar nach der Beobachtung und Einschätzung die Label besitzt, jedoch konnten nicht alle durch Analyse des Signalverhaltens abgeleitet Ergebnisse mit den vorhandenen Labeln übereinstimmen. Deswegen wurde K-Means zur Clusteranalyse verwendet. Danach wurden die Features durch eine Varianzanalyse für jedes Cluster bestimmt, die für Klassifizierung der Spritzerstärke wichtig Rolle gespielt haben. Damit wurden die Kriterien ermittelt.

Durch die Experiment in der Unterabschnitt 7.1 wurde die Testdaten zur Evaluation der ausgewählten ML-Modelle bekommen. Aufgrund hohem Aufwand der Elektrodenverschleißuntersuchung wurde eine manuelle Bearbeitung der Elektrodenkappen zur Simulation der Elektrodenzustände durchgeführt, anstatt eine kontinuierliche große Menge Schweißen durchzuführen. Bei Verwendung der Greedy-Layerwise-Methode konnte die Genauigkeit der Prognose für Testdaten auf 86,36% erreichen. Und wenn man bedenkt, dass der simulierte Elektrodenzustände nicht 100% nahe am realen Zustände liegt, hat die DNN relativ gute Performance bekommen. Zum Erhalten von Testdaten für Stufenuntersuchung verschiedener Stromstärken hat die Experiment nach dem vorherigen experimentellen Verfahren für Trainingsdaten nachgeahmt. Bei Verwendung der LVQ und baumbasierte ML-Modelle war die Genauigkeit der Prognose für Testdaten sehr beeindruckt (100%), während bei SVC 89,29% Genauigkeit bekommen wurde. Die K-Means-Algorithmus hat die Schweißpunkte von der Spritzeruntersuchung in drei Clustern verteilt. Aus der Sicht des Signalverhaltens haben diese drei Clustern in etwa keinem, kleinem und starkem Spritzer entsprochen. Bei MDK1 wurden  $\Delta I$ ,  $S_2$ ,  $\Delta F$  und  $e_{pe}$  nach der Varianzanalyse als Kriterien zur Bewertung der Spritzerstärke benutzt, während bei MDK2  $\Delta I$  und  $S_2$  eingesetzt wurden.

Schlussfolgernd kann gesagt werden, dass durch ML-Modelle mit ausgewählte bedeutende Features ist es möglich, die Qualitätsbewertung von Punktschweißverbindungen zu realisieren. Aber ist es schwierig, einen idealen Parameter oder eine ideale Parameterkombination zu bestimmen. Außerdem sind die schon trainierte ML-Modelle nicht in der Lage, als eine allgemeine Lösung für Qualitätsbewertung von Punktschweißverbindungen zu verwenden, die sind in Abhängigkeit von Schweißausrüstung, Material usw. Jedoch hat die entwickelte Methode einen hohen Referenzwert. Die Verwendung von „faltendes neuronales Netzwerk“ mittels graphischen Daten könnte ein größeres Potenzial in zukünftigen Forschungen haben und würde auch mit höheren experimentellen Kosten und Lernkosten für ML-Modell einhergehen [35]. Die Einrichtung von Deep-Learning-Algorithmen in

Echtzeitüberwachungssystemen ist ebenfalls eine Diskussion wert.

# Literaturverzeichnis

- [1] F. AHMED / K.-Y. KIM: Data-driven Weld Nugget Width Prediction with Decision Tree Algorithm. In: *Procedia Manufacturing*, Vol. 10 (2017), S. 1009–1019.
- [2] M. ALI / D.-H. SON / S.-H. KANG / S.-R. NAM: An Accurate CT Saturation Classification Using a Deep Learning Approach Based on Unsupervised Feature Extraction and Supervised Fine-Tuning Strategy. In: *Energies*, Vol. 10, Nr. 11 (2017), S. 1830.
- [3] T. ARUNCHAI / K. SONTHIPERMPOON / P. APICHAYAKUL / K. TAMEE: Resistance Spot Welding Optimization Based on Artificial Neural Network. In: *International Journal of Manufacturing Engineering*, Vol. 2014 (2014), S. 1–6.
- [4] M. EL-BANNA / D. FILEV / R. B. CHINNAM: Online qualitative nugget classification by using a linear vector quantization neural network for resistance spot welding. In: *The International Journal of Advanced Manufacturing Technology*, Vol. 36, Nr. 3-4 (2008), S. 237–248.
- [5] Y. BENGIO / P. LAMBLIN / D. POPOVICI / H. LAROCHELLE: Greedy Layer-Wise Training of Deep Networks. In: *Advances in Neural Information Processing Systems*. Hrsg. von B. SCHÖLKOPF / J. PLATT / T. HOFFMAN. Band 19. MIT Press, 2007, S. 153–160.
- [6] BEUTH VERLAG GMBH: DIN EN ISO 10447:2015-05, Widerstandsschweißen- Prüfung von Schweißverbindungen- Schäl- und Meißelprüfung von Widerstandspunkt- und Buckelschweißverbindungen. Berlin, Mai 2015.

- [7] BEUTH VERLAG GMBH: DIN EN ISO 8166:2003-9, Widerstandsschweißen - Verfahren für das Bewerten der Standmenge von Punktschweißelektroden bei konstanter Maschinen-Einstellung. Berlin, September 2003.
- [8] G. BONACCORSO: Mastering machine learning algorithms: Expert techniques to implement popular machine learning algorithms and fine-tune your models / Giuseppe Bonaccorso. Birmingham, UK: Packt Publishing, 2018. ISBN: 9781788625906.
- [9] S. L. BRUNTON / J. N. KUTZ: Data-driven science and engineering: Machine learning, dynamical systems, and control. Cambridge: Cambridge University Press, 2019. ISBN: 9781108422093.
- [10] S. CHEN / N. WU / J. XIAO / T. LI / Z. LU: Expulsion Identification in Resistance Spot Welding by Electrode Force Sensing Based on Wavelet Decomposition with Multi-Indexes and BP Neural Networks. In: *Applied Sciences*, Vol. 9, Nr. 19 (2019), S. 4028.
- [11] DIN EN ISO 14329:2003-12, Zerstörende Prüfung von Schweißverbindungen: Brucharten und geometrische Messgrößen für Widerstandspunkt-, Rollennaht- und Buckelschweißungen. Berlin, Dezember 2003.
- [12] DIN EN ISO 14373:2015-06, Widerstandsschweißen – Verfahren zum Punktschweißen von niedriglegierten Stählen mit oder ohne metallischem Überzug. Berlin, Juni 2015.
- [13] DIN EN ISO 17653:2012-08, Widerstandsschweißen – Zerstörende Prüfung von Schweißverbindungen an metallischen Werkstoffen: Torsionsversuch an Widerstandspunktschweißverbindungen. Berlin, August 2012.
- [14] DIN EN ISO 17677-1:2010-01, Widerstandsschweißen Begriffe. Juni 2019.
- [15] DUMITRU ERHAN / AARON COURVILLE / YOSHUA BENGIO / PASCAL VINCENT: Why Does Unsupervised Pre-training Help Deep Learning? In: *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, (2010), S. 201–208.

- [16] DVS MEDIA GMBH: Merkblatt DVS 2915-1: Gütesicherung beim Punkt-Buckel und Gütesicherung beim Punkt-, Buckel- und Rollennahtschweißen Grundlagen. März ,1979.
- [17] DVS MEDIA GMBH: Merkblatt DVS 2916-1: Prüfen von Widerstandspressschweißverbindungen: Zerstörende Prüfung. März, 2014.
- [18] DVS MEDIA GMBH: Merkblatt DVS 2916-5: Prüfen von Widerstandspressschweißverbindungen – Zerstörungsfreie Prüfung von Punktschweißverbindungen. September 2017.
- [19] A. EL OUAFI / R. BÉLANGER / J. F. MÉTHOT: Artificial neural network-based resistance spot welding quality assessment system. In: *Revue de Métallurgie*, Vol. 108, Nr. 6 (2011), S. 343–355.
- [20] A. H. FRITZ / G. SCHULZE: Fertigungstechnik. Eleventh edition. Springer-Lehrbuch. Berlin, Heidelberg: Springer Vieweg, 2015. ISBN: 9783662465554.
- [21] A. GÉRON: Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems / Aurélien Géron. Second Edition. Sebastopol, CA: O'Reilly, 2019. ISBN: 9781492032649.
- [22] E. HAAPALAINEN / P. LAURINEN / H. JUNNO / L. TUOVINEN / J. RÖNING: Methods for Classifying Spot Welding Processes: A Comparative Study of Performance. In: *Innovations in applied artificial intelligence*. Hrsg. von M. ALI / F. ESPOSITO. Band 3533. Lecture notes in computer science, 0302-9743. Berlin und London: Springer, 2005, S. 412–421. ISBN: 978-3-540-26551-1.
- [23] G. E. HINTON / S. OSINDERO / Y.-W. TEH: A fast learning algorithm for deep belief nets. In: *Neural computation*, Vol. 18, Nr. 7 (2006), S. 1527–1554.
- [24] R. LANGARI / J.-S. WON: Intelligent Energy Management Agent for a Parallel Hybrid Vehicle—Part I: System Architecture and Design of the Driving Situation Identification Process. In: *IEEE Transactions on Vehicular Technology*, Vol. 54, Nr. 3 (2005), S. 925–934.
- [25] Learning Vector Quantization. 2021-01-24T20:04:42.000Z. URL: <http://www.astrowing.eu/data-science/learning-vector-quantization>.

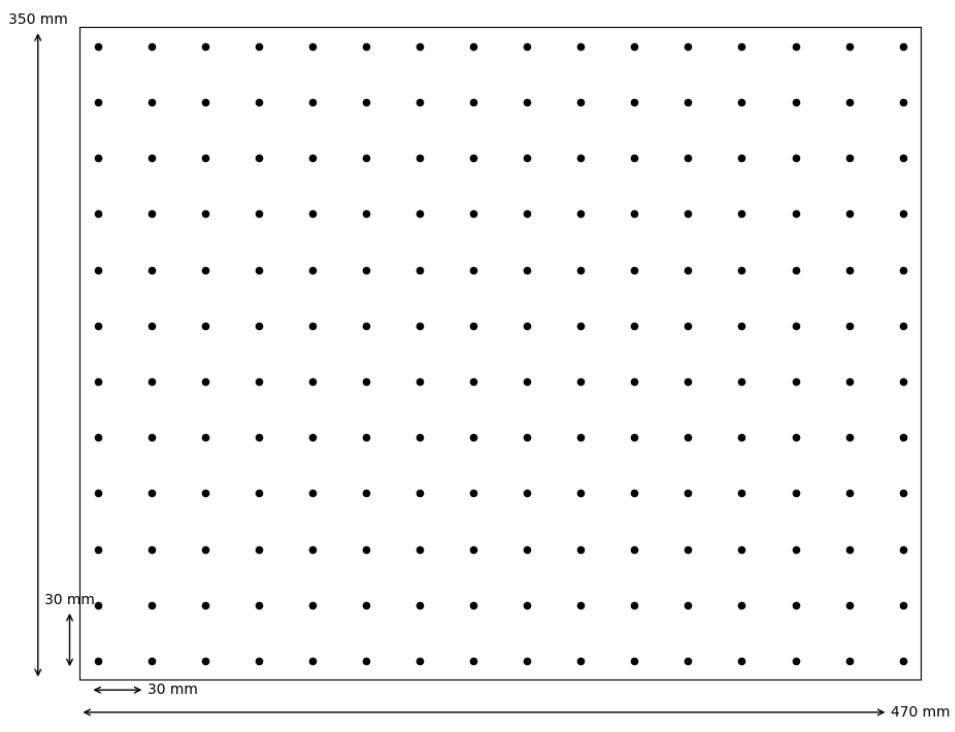
- [26] P. LI / P.-M. NGUYEN: On Random Deep Weight-Tied Autoencoders: Exact Asymptotic Analysis, Phase Transitions, and Implications to Training. In: *International Conference on Learning Representations*. 2019.
- [27] W. LI / S. J. HU / J. NI: On-line Quality Estimation in Resistance Spot Welding. In: *Journal of Manufacturing Science and Engineering*, Vol. 122, Nr. 3 (2000), S. 511–512.
- [28] H.-L. LIN / T. CHOU / C.-P. CHOU: Optimization of Resistance Spot Welding Process using Taguchi Method and A Neural Network. In: *Experimental Techniques*, Vol. 31, Nr. 5 (2007), S. 30–36.
- [29] P. LÜCKE / A. LAST / J. MOHR: Mikrooptische Sensoren nach dem chromatisch konfokalen Messprinzip. Zugl.: Karlsruhe, Univ., Diss. P. Lücke, 2006. Karlsruhe: FZ-KA, 2006.
- [30] Ó. MARTÍN / M. PEREDA / J. I. SANTOS / J. M. GALÁN: Assessment of resistance spot welding quality based on ultrasonic testing and tree-based techniques. In: *Journal of Materials Processing Technology*, Vol. 214, Nr. 11 (2014), S. 2478–2487.
- [31] C. MATHISZIK / O. SHEREPENKO / D. KÖBERLIN: Lebensdauererhöhung von Widerstandspunktschweißelektronen durch Einsatz verschleißabhängiger Fräsimintervalle und dispersionsgehärteter Kupferwerkstoffe. 2018.
- [32] C. MATHISZIK / J. ZSCHETZSCHE / U. FÜSSEL / C. GROSSMANN / M. HEIDE: Zerstörungsfreie Bewertung des Linsendurchmessers beim Widerstandspunktschweißen mit magnetischen Prüfverfahren. 2015.
- [33] K.-J. MATTHES / W. SCHNEIDER: Schweißtechnik. München: Carl Hanser Verlag GmbH & Co. KG, 2016. ISBN: 978-3-446-44561-1.
- [34] K.-J. MATTHES / W. SCHNEIDER, Hrsg.: Schweißtechnik: Schweißen von metallischen Konstruktionswerkstoffen. 6., aktualisierte Auflage. München: Fachbuchverlag Leipzig im Carl Hanser Verlag, 2016. ISBN: 3446445617.
- [35] A. MUNIATEGUI / B. HERIZ / L. ECIOLAZA / M. AYUSO / A. ITURRIOZ / I. QUINTANA / P. ALVAREZ: Spot welding monitoring system based on fuzzy classification and

- deep learning. In: *FUZZ-IEEE 2017*. [Piscataway, NJ]: IEEE, 2017, S. 1–6. ISBN: 978-1-5090-6034-4.
- [36] NI-TDMS-Dateiformat. 2020-12-26T21:33:45.000Z. URL: <https://www.ni.com/de-de/support/documentation/supplemental/06/the-ni-tdms-file-format.html#section--776004309>.
- [37] Y. J. PARK / H. CHO: Quality evaluation by classification of electrode force patterns in the resistance spot welding process using neural networks. In: *Proceedings of the Institution of Mechanical Engineers, Part B: Journal of Engineering Manufacture*, Vol. 218, Nr. 11 (2004), S. 1513–1524.
- [38] PRIMO PODR AJ / IVAN POLAJNAR / JANEZ DIACI / ZORAN KARI: Expulsion detection system for resistance spot welding based on a neural network. In: *Measurement Science and Technology*, Vol. 15, Nr. 3 (2004), S. 592–598.
- [39] Search — scikit-learn 0.24.0 documentation. 2021-01-16T19:20:42.000Z. URL: [http://scikit-learn.org/stable/search.html?q=Classifier](https://scikit-learn.org/stable/search.html?q=Classifier).
- [40] sklearn.model\_selection.GridSearchCV — scikit-learn 0.24.1 documentation. 2021-01-22T20:58:54.000Z. URL: [https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.GridSearchCV.html](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html).
- [41] sklearn.semi\_supervised.LabelSpreading — scikit-learn 0.24.1 documentation. 2021-01-31T01:41:27.000Z. URL: [https://scikit-learn.org/stable/modules/generated/sklearn.semi\\_supervised.LabelSpreading.html](https://scikit-learn.org/stable/modules/generated/sklearn.semi_supervised.LabelSpreading.html).
- [42] Q. SUI-PING / Z. HONG-JIAN / L. XIU-JUAN / Z. HONG-LIANG: Counting Steel Rods Online Using LQV Neural Network in Real-time Images. In: *2006 International Conference on Information Acquisition*. Piscataway N.J.: IEEE, 2006, S. 956–960. ISBN: 1-4244-0528-9.
- [43] C. SUMMERTON / D. ADAMS / P. COMPSTON / M. DOOLAN: Nugget Diameter in Resistance Spot Welding: A Comparison between a Dynamic Resistance Based Approach and Ultrasound C-scan. In: *Procedia Engineering*, Vol. 183 (2017), S. 257–263.

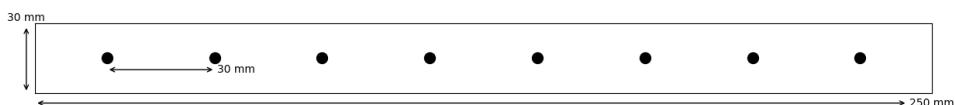
- [44] W. ROYE, HÜRTH UND S. MANTHEY, RÜSSELSHEIM: Die Ultraschallprüfung von Schweißverbindungen im Automobilbau. URL: <https://www.ndt.net/article/dgzfp01/papers/v55/v55.htm>.
- [45] X. WAN / Y. WANG / D. ZHAO / Y. HUANG / Z. YIN: Weld quality monitoring research in small scale resistance spot welding by dynamic resistance and neural network. In: *Measurement*, Vol. 99 (2017), S. 120–127.
- [46] Z. WAN / H.-P. WANG / M. WANG / B. E. CARLSON / D. R. SIGLER: Numerical simulation of resistance spot welding of Al to zinc-coated steel with improved representation of contact interactions. In: *International Journal of Heat and Mass Transfer*, Vol. 101 (2016), S. 749–763.
- [47] J. WANG / H.-P. WANG / F. LU / B. E. CARLSON / D. R. SIGLER: Analysis of Al-steel resistance spot welding process by developing a fully coupled multi-physics simulation model. In: *International Journal of Heat and Mass Transfer*, Vol. 89 (2015), S. 1061–1072.
- [48] G. WELCH / G. BISHOP: An Introduction to the Kalman Filter. USA, 1995.
- [49] D. ZHAO / Y. WANG / D. LIANG / M. IVANOV: Performances of regression model and artificial neural network in monitoring welding quality based on power signal. In: *Journal of Materials Research and Technology*, Vol. 9, Nr. 2 (2020), S. 1231–1240.
- [50] D. ZHOU / O. BOUSQUET / T. N. LAL / J. WESTON / B. SCHÖLKOPF: Learning with local and global consistency. In: *Advances in Neural Information Processing Systems 16*. MIT Press, 2004, S. 321–328.

# A Graphischer Anhang

## A.1 Verschleiß- und Prüfblech



(a) Verschleißblech mit geplanten Schweißpunkten



(b) Prüfblech mit geplanten Schweißpunkten

**Abbildung A.1:** Schematische Darstellung der Verschleiß- und Prüfbleche

## A.2 Qualitätsparameter

### A.2.1 Qualitätsparameter bei Elektrodenverschleißuntersuchung

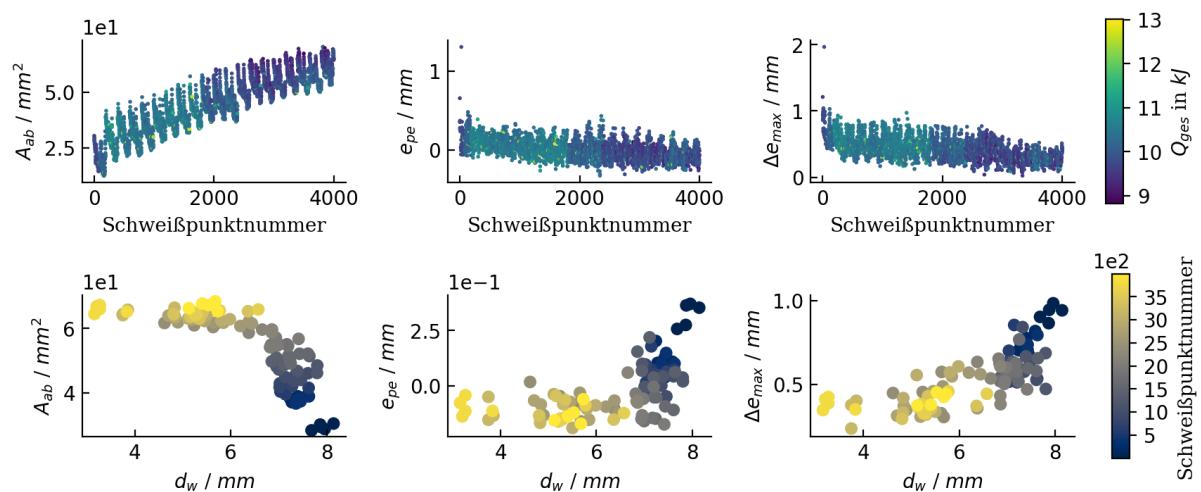


Abbildung A.2: Von Wegmessung extrahierte Features

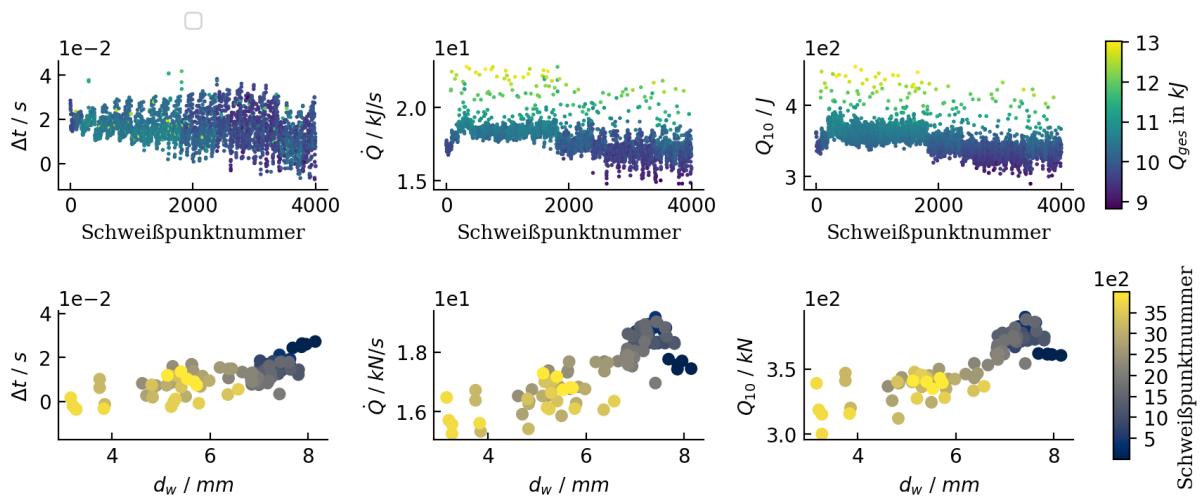


Abbildung A.3: Von Wärmemenge extrahierte Features

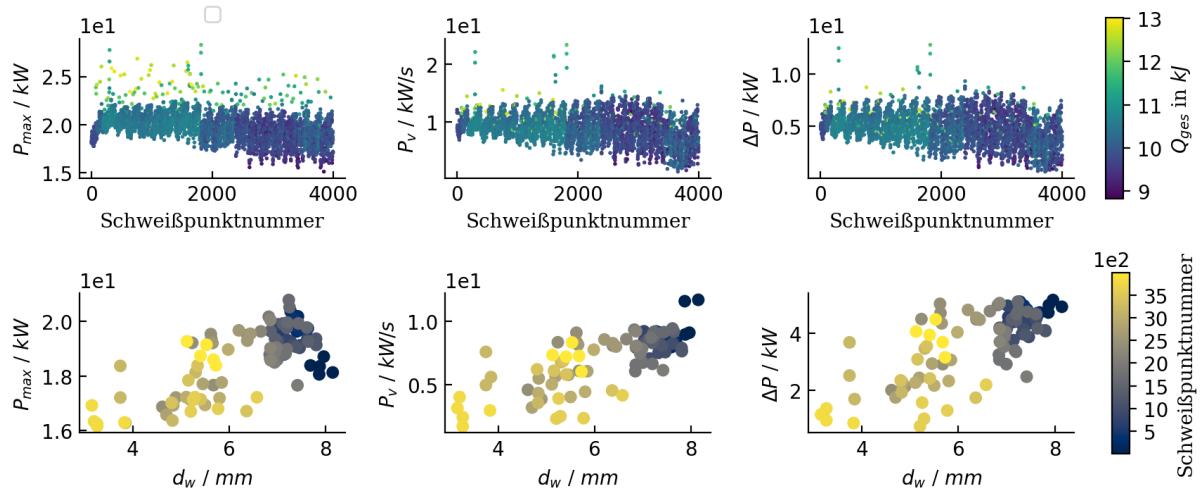


Abbildung A.4: Von Leistungskurve extrahierte Features

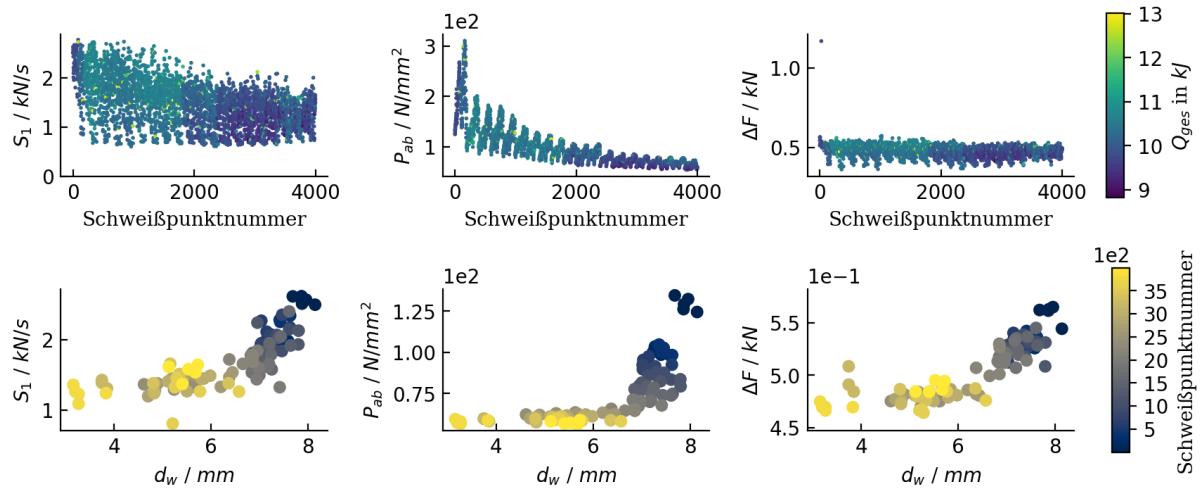
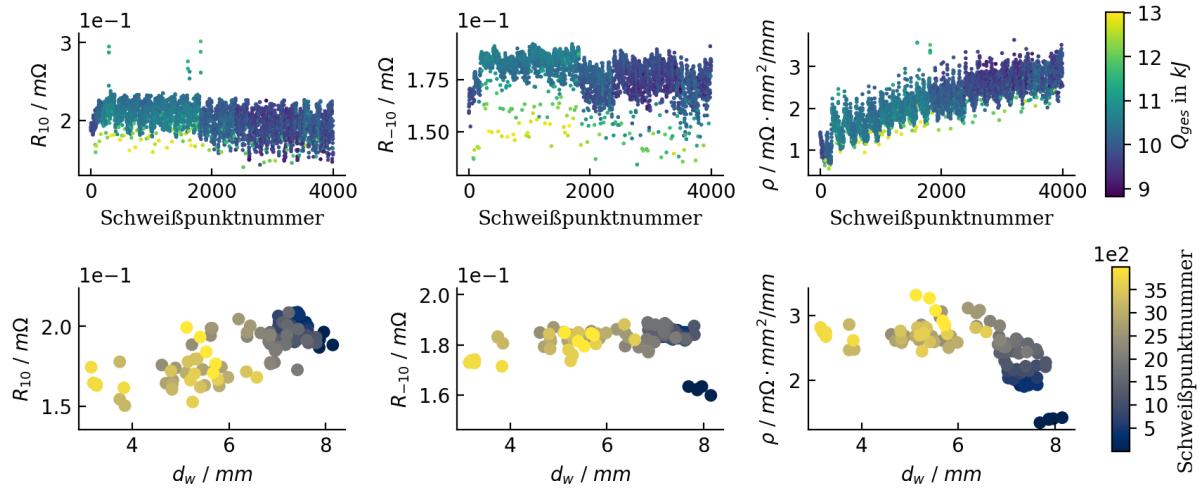


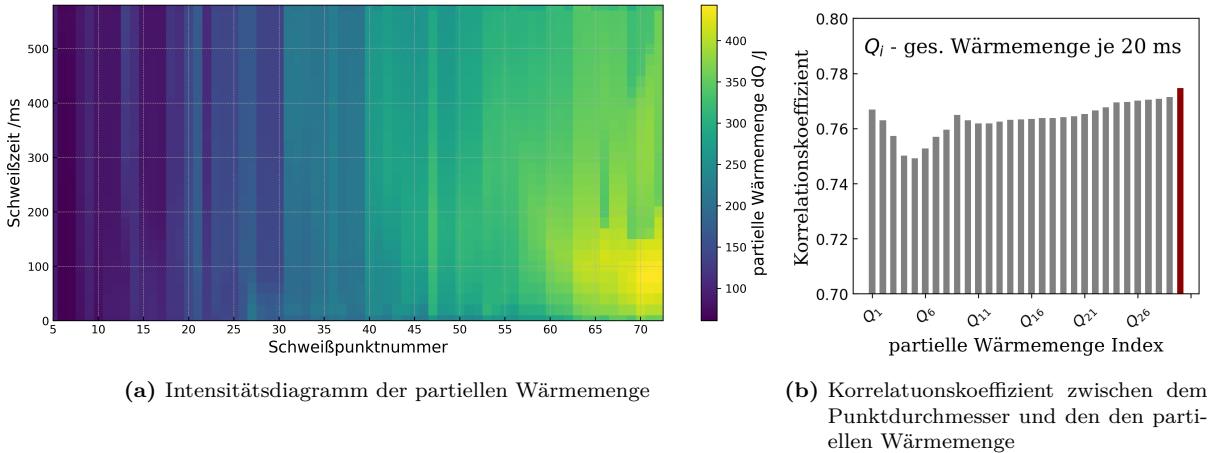
Abbildung A.5: Von Elektrodenkraft extrahierte Features



**Abbildung A.6:** Von dynamischem Widerstand extrahierte Features

## A.2.2 Qualitätsparameter bei verschiedenen Stromstärken

Nach der Korrelationsanalyse zwischen dem Punktdurchmesser und den partiellen Wärmemenge bei verschiedenen Stromstärken (Abbildung A.7) lag die signifikanten partiellen Wärmemenge  $Q_{sig}$  in dem Zeitbereich 580...600 ms, also  $Q_{30}$ .



**Abbildung A.7:** Intensitätsdiagramm der partiellen Wärmemenge und Korrelationskoeffizient zwischen dem Punktdurchmesser und den partiellen Wärmemengen

Bei Berechnung der spezifische elektrische Widerstand nach der Gl. 6.5 für verschiedene Stromstärken wurden aufgrund der Vernachlässigung des Elektrodenverschleißes, d. h. angenommen, die Elektrodenarbeitsfläche hat unverändert geblieben, die  $R_{10}$  und die

Restgesamtblechdicke  $L$  ( $3,65 - e_{pe}$  mm) und Ausgangsarbeitsfläche der Elektroden verwendet.

$$\rho_i = \frac{R_{-10,i} \cdot A_{ab,0}}{L_i}$$

Die von Wegmessung extrahierten Elektrodeneindruckstiefen beim Schweißende  $e_{se}$  sind bei niedriger Stromstufe jedoch tiefer als bei großer Stromstufe, dies ist beim tatsächlichen Schweißen unwahrscheinlich, wie in der Tabelle 4.3 gezeichnet. Deswegen ist diese Feature nicht in der Trainierung des ML-Modells verwendet.

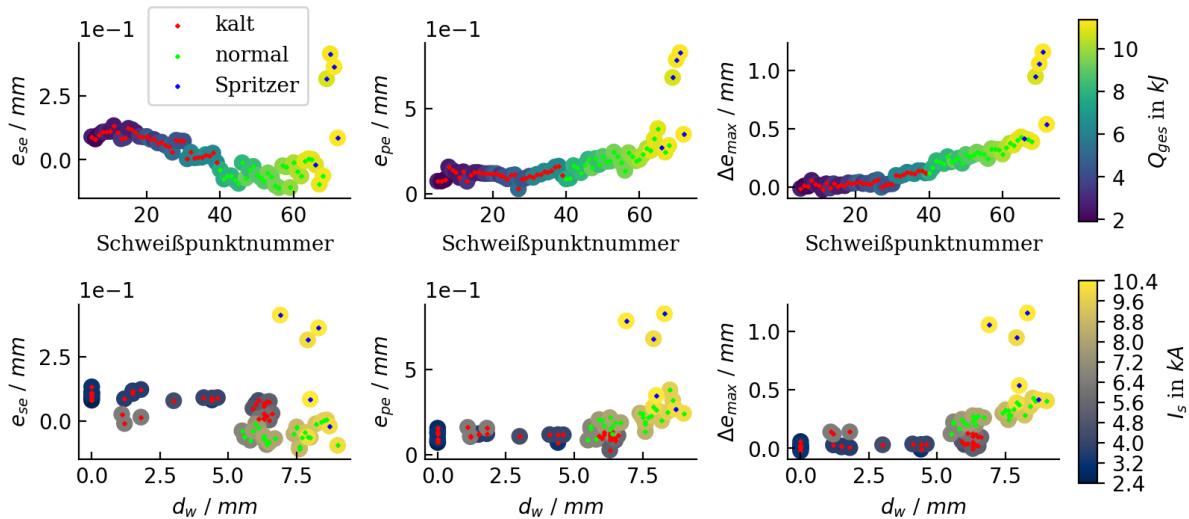


Abbildung A.8: Von Wegmessung extrahierte Features

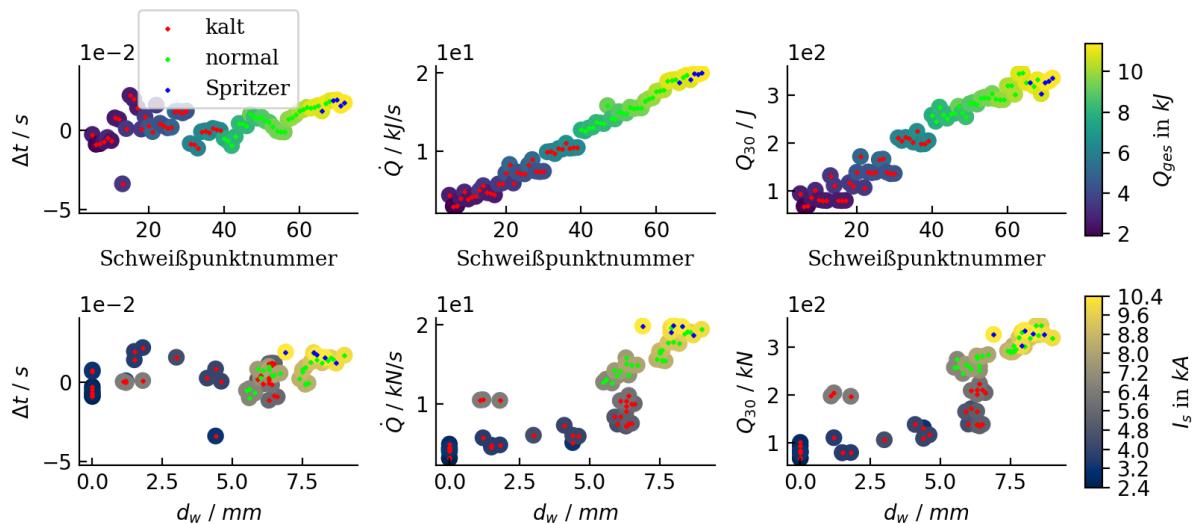


Abbildung A.9: Von Wärmemenge extrahierte Features

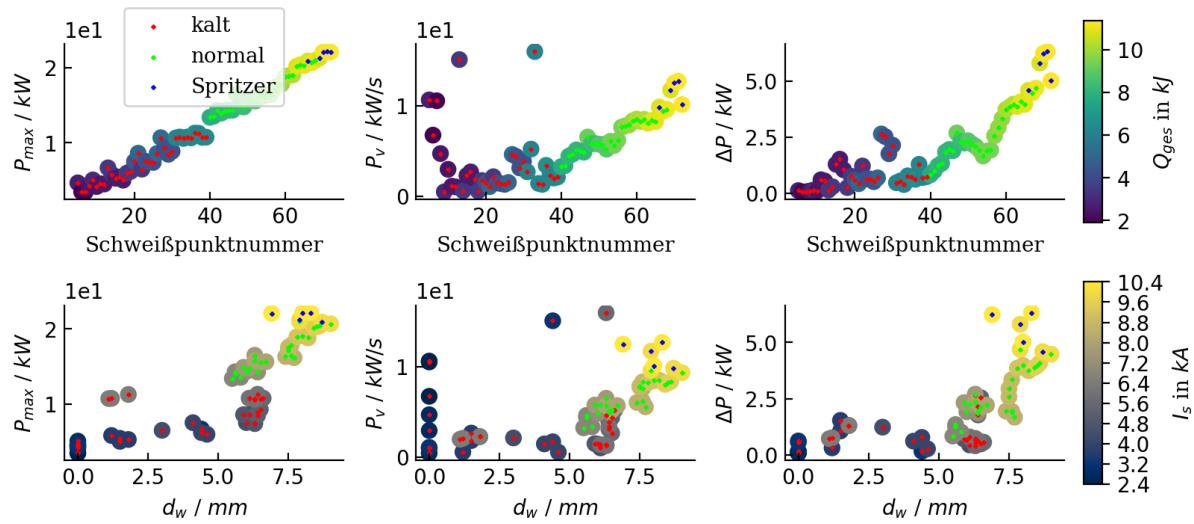


Abbildung A.10: Von Leistungskurve extrahierte Features

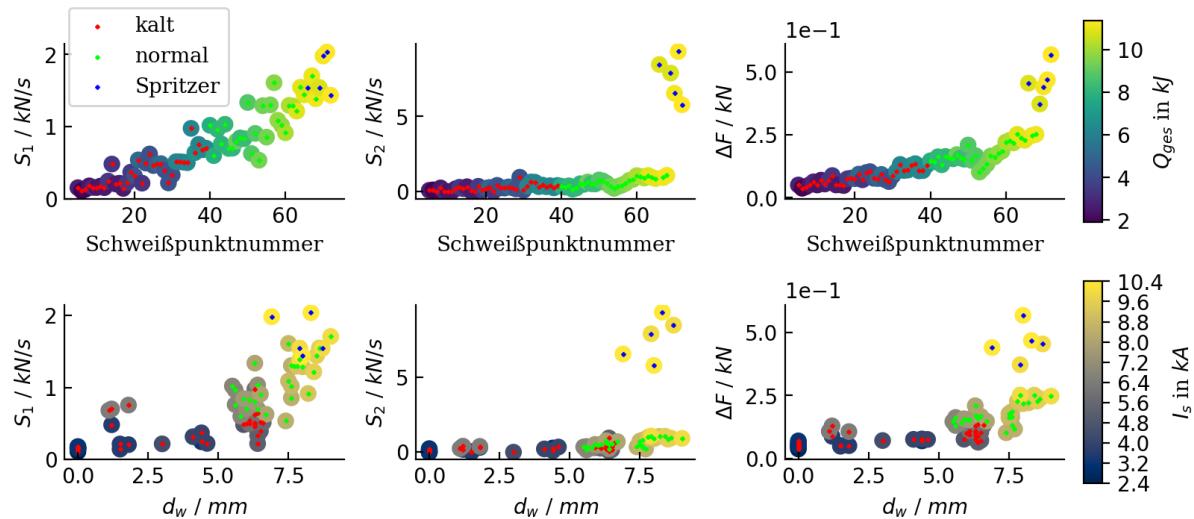


Abbildung A.11: Von Elektrodenkraft extrahierte Features

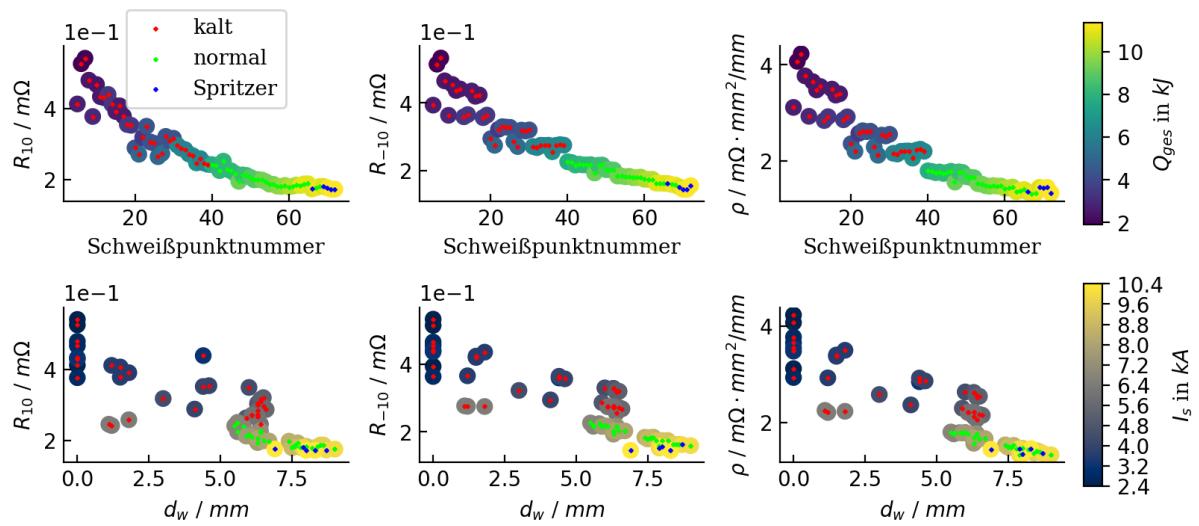
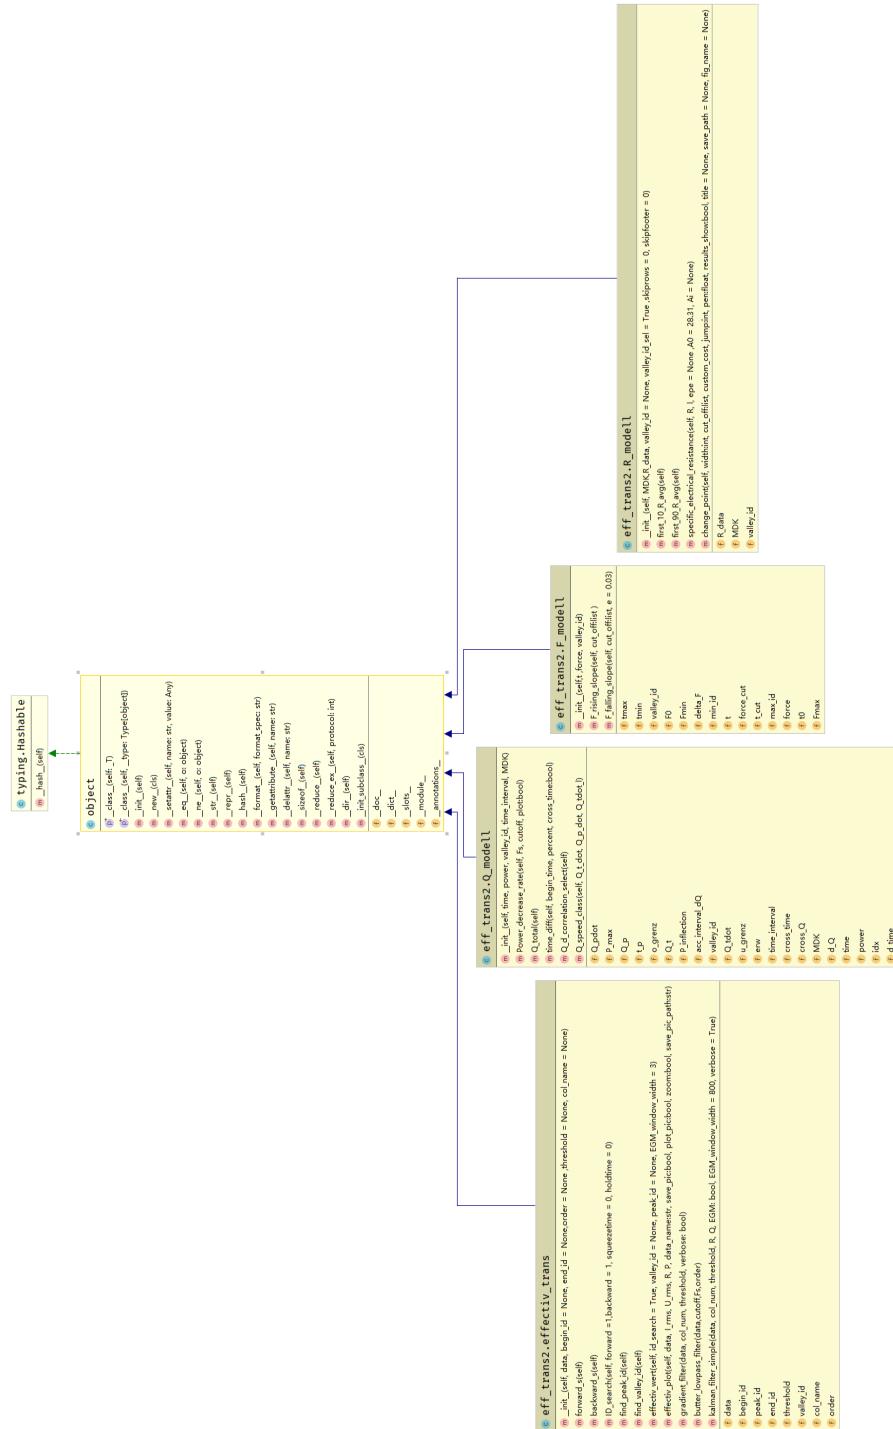


Abbildung A.12: Von dynamischem Widerstand extrahierte Features

## A.3 Klasse-Diagramm



**Abbildung A.13:** Klasse-Diagramm für effektive Werte und Extraktion der Features

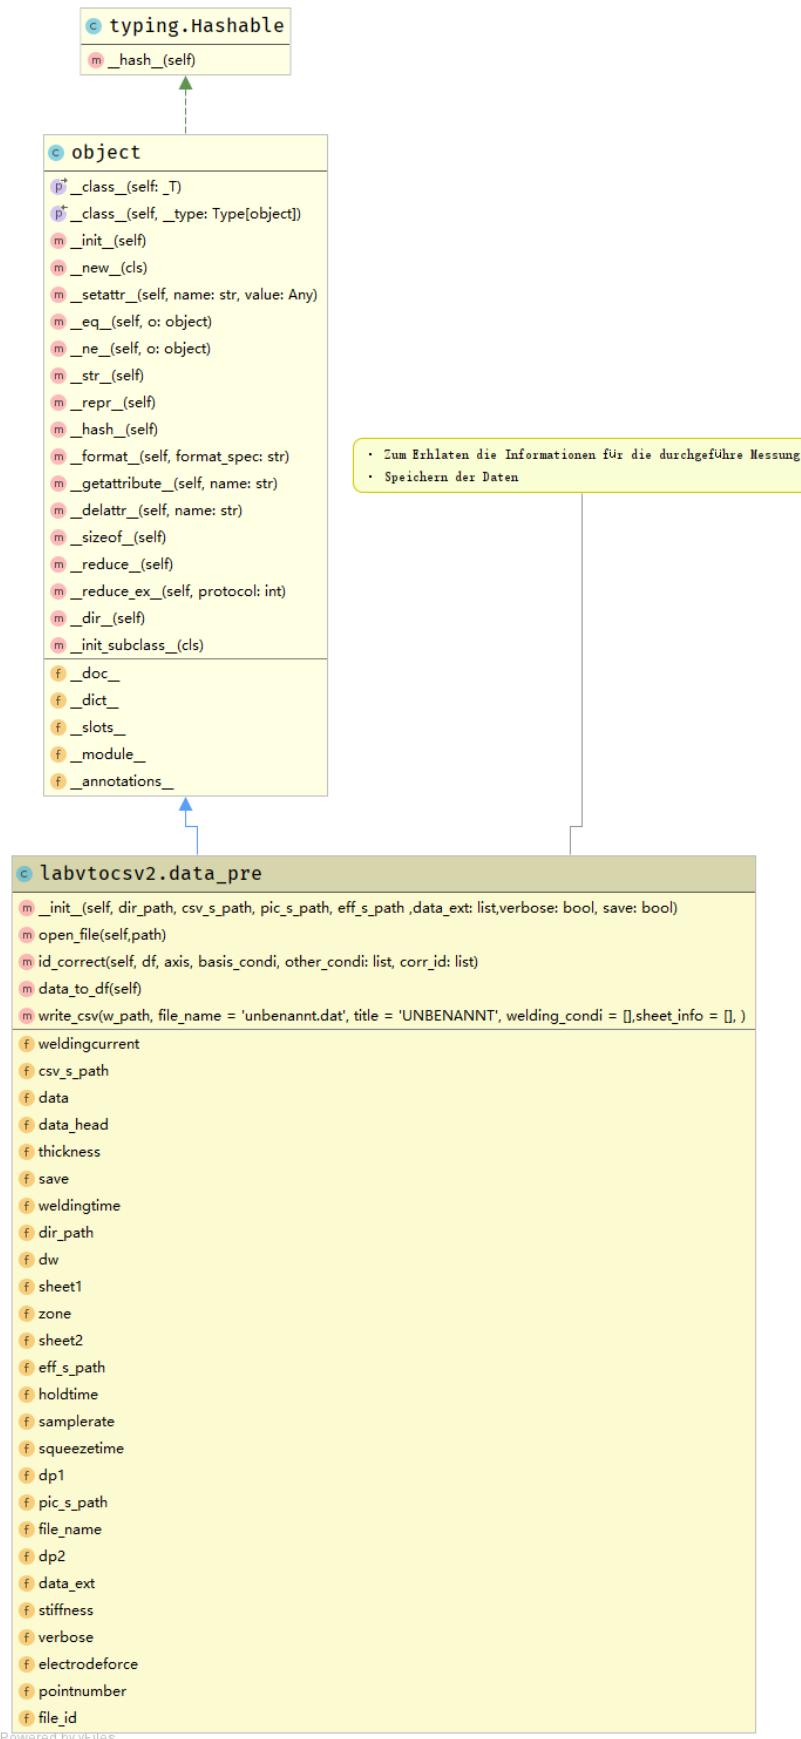


Abbildung A.14: Klasse-Diagramm für Lesen der Daten

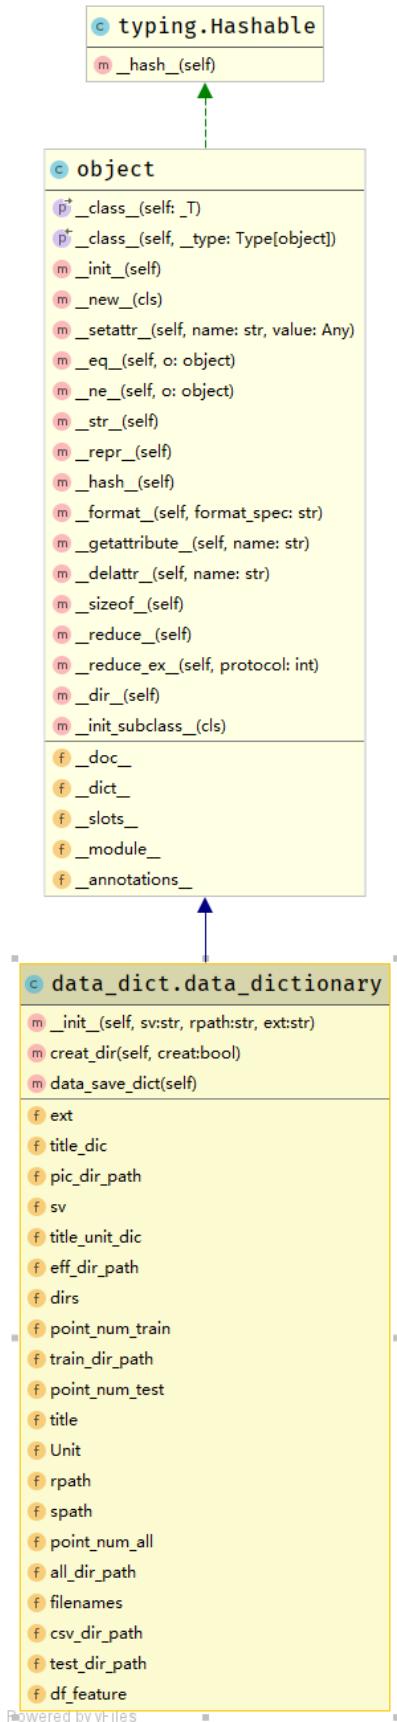


Abbildung A.15: Klasse-Diagramm für Einspeichern

## A.4 Random Forest

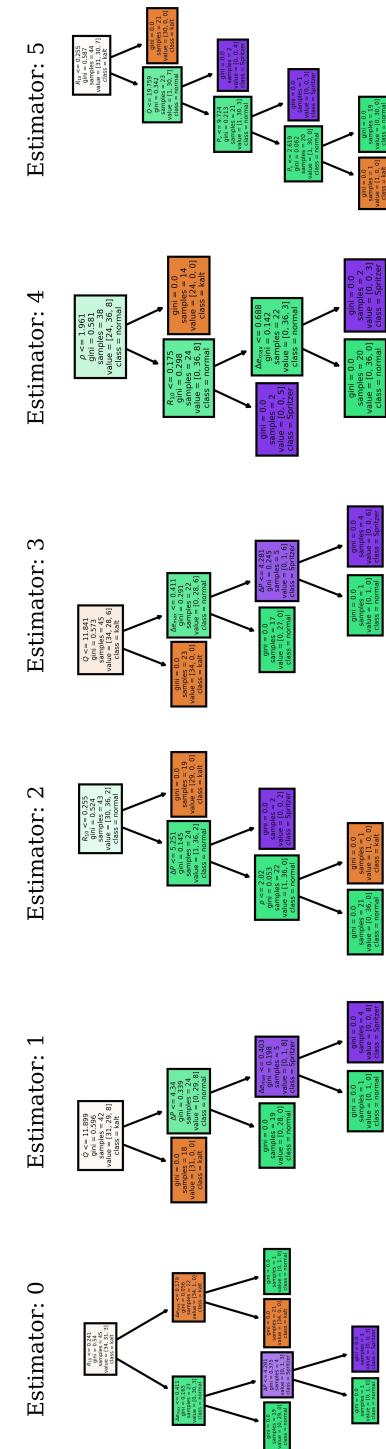
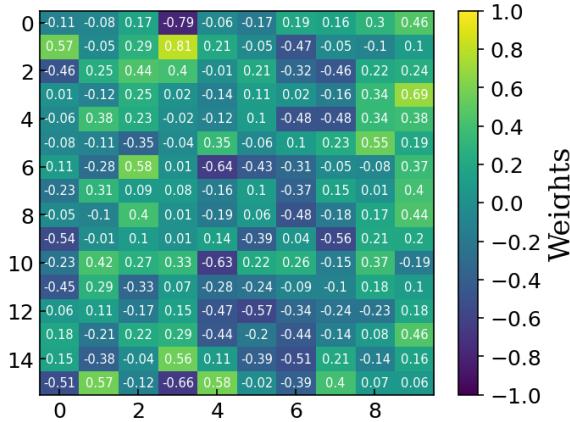


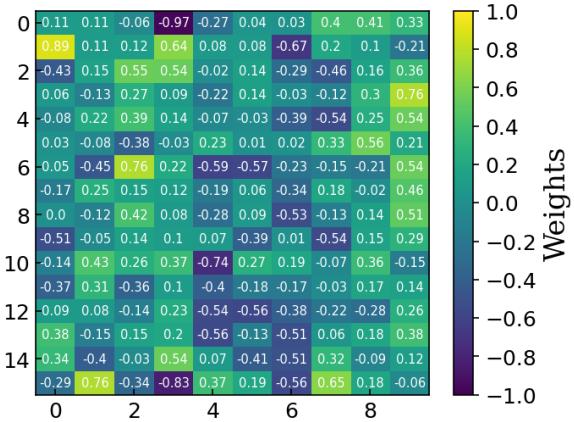
Abbildung A.16: Entscheidungsbäume vom optimalen Random-Forest-Klassifikator

## A.5 Gewichtsmatrix

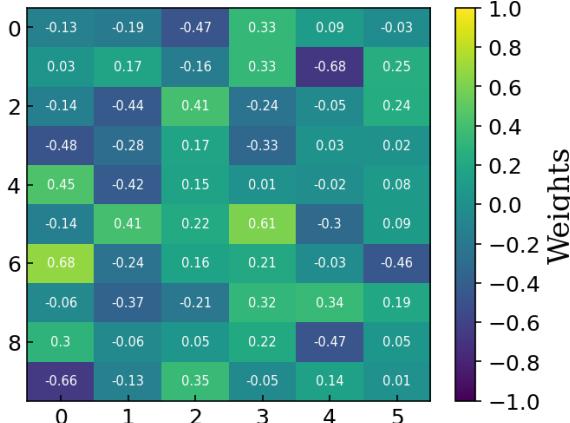
### A.5.1 Greedy Layerwise



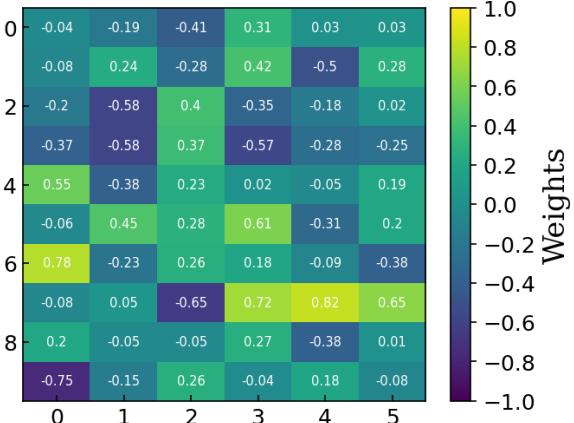
(a) Gewichte der verdeckten Schicht von 1. Encoder



(b) Gewichte der verdeckten Schicht von 1. Encoder nach Fine-Tuning



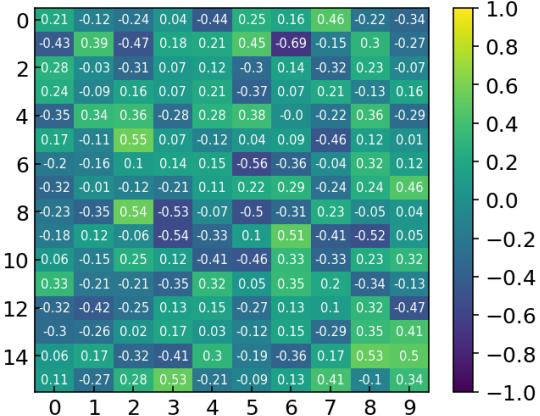
(c) Gewichte der verdeckten Schicht von 2. Encoder



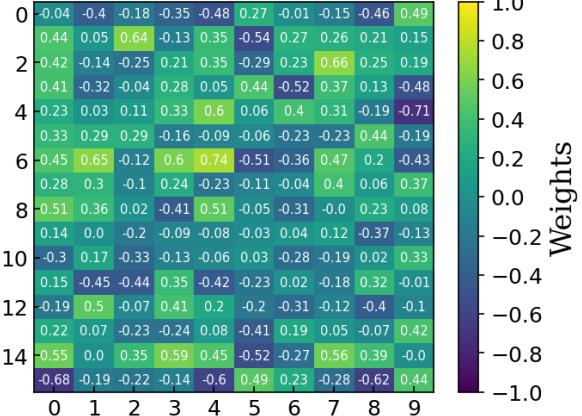
(d) Gewichte der verdeckten Schicht von 2. Encoder nach Fine-Tuning

Abbildung A.17: Anpassung der Gewichte nach Fine-Tuning

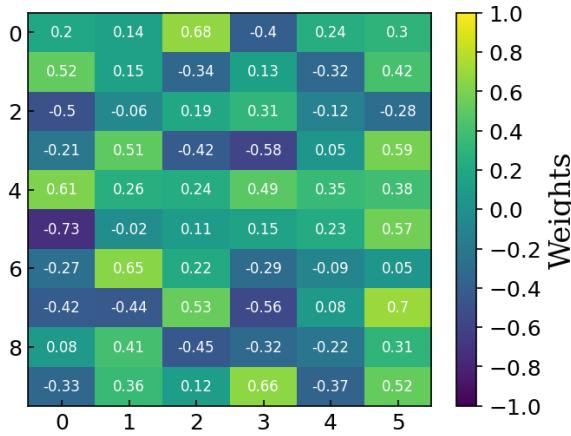
### A.5.2 Tying Weights



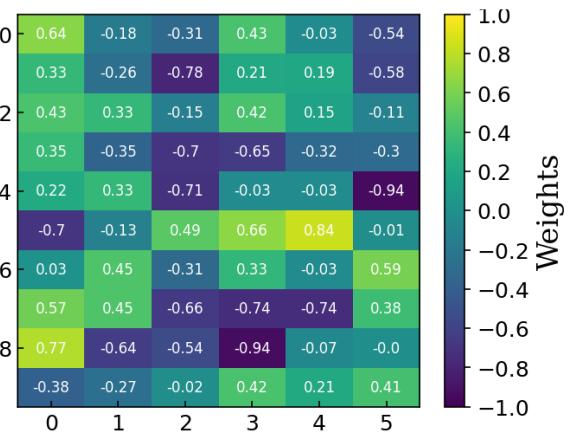
(a) Gewichte der 1. verdeckten Schicht vom Encoder



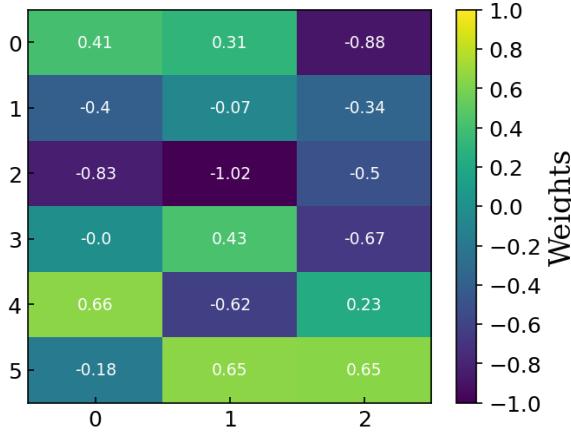
(b) Gewichte der 1. verdeckten Schicht vom Encoder nach Fine-Tuning



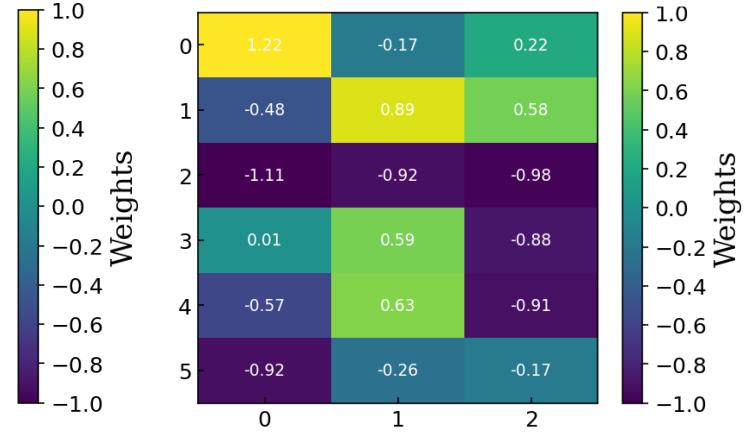
(c) Gewichte der 2. verdeckten Schicht vom Encoder



(d) Gewichte der 2. verdeckten Schicht vom Encoder nach Fine-Tuning



(e) Gewichte der 3. verdeckten Schicht vom Encoder



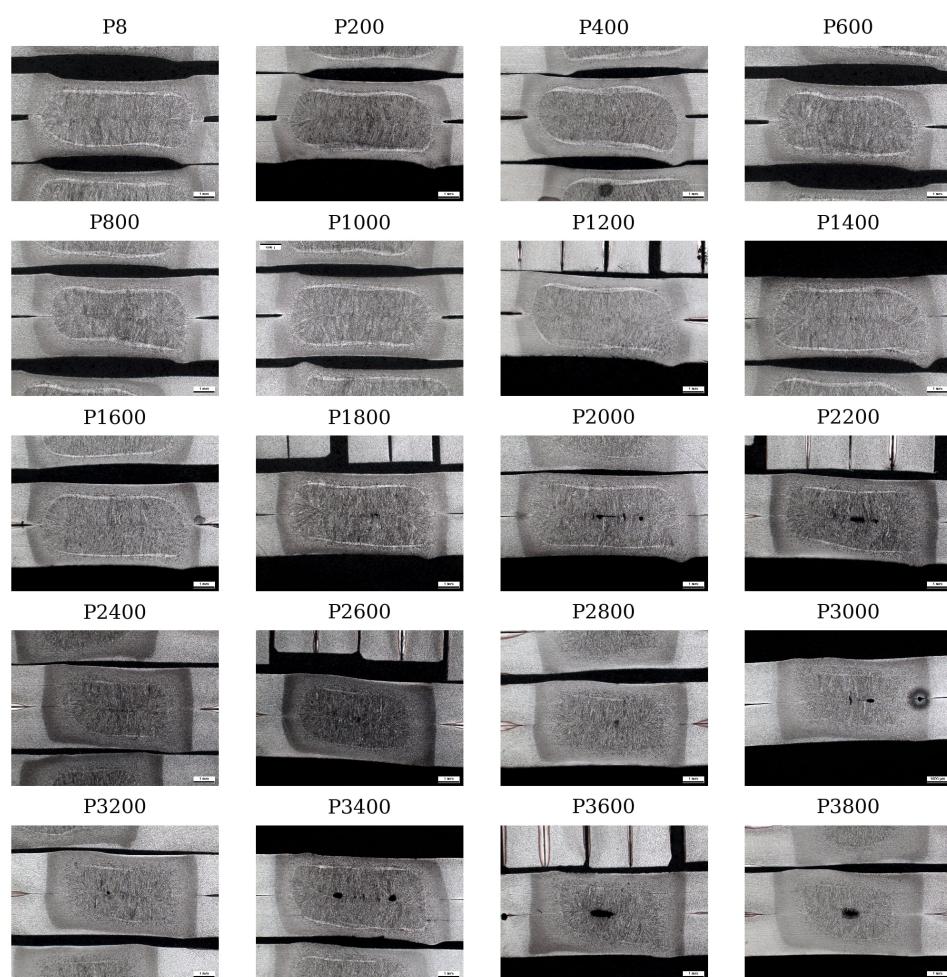
(f) Gewichte der 3. verdeckten Schicht vom Encoder nach Fine-Tuning

Abbildung A.18: Anpassung der Gewichte nach Fine-Tuning

## B Tabellarischer Anhang

Tabelle B.1: Querschliffe der Punkte bei MDK1

Stufe 5: Querschliffe der Punkte bei MDK1



**Tabelle B.2:** Ermittelte Elektrodenarbeitsflächen und Elektrodenlängenänderungen mittels konfokal-chromatischer Oberflächenmessung

| Pktnum. | $d_{m,oben}[mm]$ | $A_{ab,oben}[mm^2]$ | $\Delta L_{E,oben}[mm]$ | $d_{m,unten}[mm]$ | $A_{ab,unten}[mm^2]$ | $\Delta L_{E,unten}[mm]$ | $\bar{A}_{ab}[mm^2]$ | $\bar{\Delta L}_E[mm]$ |
|---------|------------------|---------------------|-------------------------|-------------------|----------------------|--------------------------|----------------------|------------------------|
| 0       | 6                | 28,31               | 0                       | 6                 | 28,31                | 0                        | 28,31                | 0                      |
| 8       | 6,45             | 32,67453            | 0,09484                 | 6,5               | 33,18307             | 0,10590                  | 32,92880             | 0,10037                |
| 200     | 6,7              | 35,25652            | 0,15119                 | 6,5               | 33,18307             | 0,10590                  | 34,21980             | 0,12851                |
| 400     | 6,75             | 35,78470            | 0,16277                 | 6,7               | 35,25652             | 0,15119                  | 35,52061             | 0,15698                |
| 600     | 6,9              | 37,39281            | 0,19814                 | 6,95              | 37,93669             | 0,21014                  | 37,66475             | 0,20414                |
| 800     | 7,05             | 39,03625            | 0,23447                 | 7,15              | 40,15152             | 0,25923                  | 39,59388             | 0,24684                |
| 1000    | 7,3              | 41,85387            | 0,29719                 | 7,35              | 42,42917             | 0,31006                  | 42,14152             | 0,30362                |
| 1200    | 7,35             | 42,42917            | 0,31006                 | 7,85              | 48,39820             | 0,44503                  | 45,41369             | 0,37722                |
| 1400    | 7,45             | 43,59156            | 0,33614                 | 7,95              | 49,63913             | 0,47342                  | 46,61534             | 0,40445                |
| 1600    | 7,95             | 49,63913            | 0,47342                 | 7,95              | 49,63913             | 0,47342                  | 49,63913             | 0,47342                |
| 1800    | 7,85             | 48,39820            | 0,44503                 | 8,15              | 52,16811             | 0,53164                  | 50,28315             | 0,48820                |
| 2000    | 8,05             | 50,89576            | 0,50229                 | 8,4               | 55,41769             | 0,60718                  | 53,15673             | 0,55454                |
| 2200    | 8,4              | 55,41769            | 0,60718                 | 8,7               | 59,44679             | 0,70202                  | 57,43224             | 0,65444                |
| 2400    | 8,5              | 56,74502            | 0,63828                 | 9                 | 63,61725             | 0,80162                  | 60,18113             | 0,71945                |
| 2600    | 8,45             | 56,07939            | 0,62267                 | 8,7               | 59,44679             | 0,70202                  | 57,76309             | 0,66223                |
| 2800    | 8,85             | 61,51435            | 0,75121                 | 8,7               | 59,44679             | 0,70202                  | 60,48057             | 0,72657                |
| 3000    | 8,65             | 58,76545            | 0,68589                 | 9,05              | 64,32607             | 0,81870                  | 61,54576             | 0,75196                |
| 3200    | 8,7              | 59,44679            | 0,70202                 | 9,2               | 66,47610             | 0,87077                  | 62,96144             | 0,78586                |
| 3400    | 8,6              | 58,08805            | 0,66989                 | 9,05              | 64,32607             | 0,81870                  | 61,20706             | 0,74388                |
| 3600    | 8,65             | 58,76545            | 0,68589                 | 9,2               | 66,47610             | 0,87077                  | 62,62078             | 0,77769                |
| 3800    | 8,65             | 58,76545            | 0,68589                 | 9,05              | 64,32607             | 0,81870                  | 61,54576             | 0,75196                |
| 4000    | 8,85             | 61,51435            | 0,75121                 | 9,05              | 64,32607             | 0,81870                  | 62,92021             | 0,78487                |

**Tabelle B.3:** Verwendete Features für ML-Modell bei MDK1

| Features         | Einheit                 | Bezeichnung                                      |
|------------------|-------------------------|--------------------------------------------------|
| $A_{ab}$         | $mm^2$                  | Elektrodenarbeitsfläche                          |
| $e_{pe}$         | $mm$                    | Eindruckstiefe Prozessende                       |
| $\Delta e_{max}$ | $mm$                    | max. Eindrucksteife des Prozesses                |
| $\Delta t$       | $s$                     | Zeitdifferenz der Wärmemenge                     |
| $\Delta Q$       | $kJ/s$                  | Erwärmungsgeschwindigkeit                        |
| $Q_{10}$         | $J$                     | signifikante partielle Wärmemenge                |
| $Q_{ges}$        | $kJ$                    | gesamte Wärmemenge                               |
| $P_{max}$        | $kW$                    | max. Leistungswert                               |
| $P_v$            | $kw/s$                  | Leistungsabstiegsgradient                        |
| $\Delta P$       | $kW$                    | Leistungs differenz                              |
| $S_1$            | $kN/s$                  | Elektrodenkraftanstiegsgradient                  |
| $P_{ab}$         | $MPa$                   | Elektrodendruck                                  |
| $\Delta F$       | $kN$                    | Elektrodenkraftdifferenz                         |
| $R_{10}$         | $m\Omega$               | mittlerer dynamischer Widerstand von ersten 10%  |
| $R_{-10}$        | $m\Omega$               | mittlerer dynamischer Widerstand von letzten 10% |
| $\rho$           | $m\Omega \cdot mm^2/mm$ | spezifischer elektrischer Widerstand             |

**Tabelle B.4:** Features zur Klassifikation der Schweißqualität

| Features         | Einheit                 | Bezeichnung                                      |
|------------------|-------------------------|--------------------------------------------------|
| $e_{pe}$         | $mm$                    | Eindruckstiefe Prozessende                       |
| $\Delta e_{max}$ | $mm$                    | max. Eindrucksteife des Prozesses                |
| $\Delta t$       | $s$                     | Zeitdifferenz der Wärmemenge                     |
| $\Delta Q$       | $kJ/s$                  | Erwärmungsgeschwindigkeit                        |
| $Q_{30}$         | $J$                     | signifikante partielle Wärmemenge                |
| $Q_{ges}$        | $kJ$                    | gesamte Wärmemenge                               |
| $P_{max}$        | $kW$                    | max. Leistungswert                               |
| $P_v$            | $kw/s$                  | Leistungsabstiegsgradient                        |
| $\Delta P$       | $kW$                    | Leistungs differenz                              |
| $S_1$            | $kN/s$                  | Elektrodenkraftanstiegsgradient                  |
| $S_2$            | $kN/s$                  | Elektrodenkraftabstiegsgradient                  |
| $\Delta F$       | $kN$                    | Elektrodenkraftdifferenz                         |
| $R_{10}$         | $m\Omega$               | mittlerer dynamischer Widerstand von ersten 10%  |
| $R_{-10}$        | $m\Omega$               | mittlerer dynamischer Widerstand von letzten 10% |
| $\rho$           | $m\Omega \cdot mm^2/mm$ | spezifischer elektrischer Widerstand             |
| $I_{soll}$       | $kA$                    | Größe der Stromänderung                          |

**Tabelle B.5:** Features zur Klassifikation der Spritzerstärke

| Features         | Einheit                 | Bezeichnung                                      |
|------------------|-------------------------|--------------------------------------------------|
| $e_{pe}$         | mm                      | Eindrucktiefe Prozessende                        |
| $\Delta e_{max}$ | mm                      | max. Eindrucktiefe des Prozesses                 |
| $\Delta t$       | s                       | Zeitdifferenz der Wärmemenge                     |
| $\Delta Q$       | $kJ/s$                  | Erwärmungsgeschwindigkeit                        |
| $Q_{10}$         | J                       | signifikante partielle Wärmemenge                |
| $Q_{ges}$        | $kJ$                    | gesamte Wärmemenge                               |
| $P_{max}$        | kW                      | max. Leistungswert                               |
| $P_v$            | $kw/s$                  | Leistungsabstiegsgradient                        |
| $\Delta P$       | kW                      | Leistungsdifferenz                               |
| $S_1$            | $kN/s$                  | Elektrodenkraftanstiegsgradient                  |
| $S_2$            | $kN/s$                  | Elektrodenkraftabstiegsgradient                  |
| $\Delta F$       | kN                      | Elektrodenkraftdifferenz                         |
| $R_{10}$         | $m\Omega$               | mittlerer dynamischer Widerstand von ersten 10%  |
| $R_{-10}$        | $m\Omega$               | mittlerer dynamischer Widerstand von letzten 10% |
| $\rho$           | $m\Omega \cdot mm^2/mm$ | spezifischer elektrischer Widerstand             |
| $I_{soll}$       | kA                      | Soll-Schweißstrom                                |
| $\Delta I$       | kA                      | Größe der Stromänderung                          |

# C Programmcodes

Die Programmcodes sind auf Github erreichbar

Bitte benutzen Sie geeignete IDE, um das py-Datei zu öffnen. Für ipynb-Datei verwenden Sie bitte Colab oder Jupyter Notebook. Die Erklärung wie folgt:

- data\_dict.py: neues Datenbasis aufbauen;
- dataset2.py: Labelverbreitung und Vorbereitung der Daten zum Training;
- eff\_trans2.py: Signal filtern und Features extrahieren;
- EGM\_Fensterbreite.py: optimale Fensterbreite für Verwendung der EGM-Methode;
- figsave: Bilder speichern;
- Fuzzy\_logic.py: Beispiel-Code für Fuzzy-Logic zur Diagnose des Spritzers;
- Kalmenfiltler.py: Kalman Filter für eine Dimension;
- Kalmenfiltler\_MSE.py: Optimale Parameter für Verwendung Kalman Filter;
- Korrelation\_Q\_d.py: Korrelationskoeffizient zwischen partieller Wärmemenge und Punkt-durchmesser;
- labvtocsv2.py: TDMS-Datei lesen und speichern;
- LVQClassifier.py: LVQ Methode;
- MDK1.py: Hauptprogramm für MDK1;
- MDK2.py: Hauptprogramm für MDK2;
- Schweißplan.py: Berechnung und Plotten für experimentelle Testdaten;
- Spritzer Klassification.ipynb: K-Means Spritzer Klassifikation;
- unsupervised\_greedy.ipynb: Greedy-Layerwise-Methode für Elektrodenverschleißunter-suchung;
- unsupervised\_tying.ipynb: Tying-Weights-Methode für Elektrodenverschleißuntersu-chung;
- Classification\_MDK2.ipynb: Feature-Kombination versuchen und Klassifikation der MDK2;